Puente: la generalizacion de los modelos lineales

Probabilidad, odds y log-odds

Regresion logistica

Estimacion del modelo

El GLM como marco unificador

Prediccion y evaluacion

Sintesis y cierre

Referencias

Análisis Avanzado de Datos

Sesión 5: Modelos Lineales Generalizados

Nicolás López

Primer semestre de 2026

1. Puente: la generalizacion de los modelos lineales
2. Probabilidad, odds y log-odds
3. Regresion logistica
4. Estimacion del modelo
5. El GLM como marco unificador
6. Prediccion y evaluacion
7. Sintesis y cierre
8. Referencias

Puente: la generalizacion de los modelos lineales

Probabilidad, odds y log-odds

Regresion logistica

Estimacion del modelo

El GLM como marco unificador

Prediccion y evaluacion

Sintesis y cierre

Referencias

Puente: la generalizacion de los modelos lineales

Lo que hemos construido (Sesiones 1–4)

Sesiones 1–3: RLS/RLM $\rightarrow$ regularizacion (Ridge, Lasso) $\rightarrow$ no-linealidad (splines, GAMs). Todos asumen Y **continua** con errores normales.

Sesion 4: metodos kernel para estimar densidades $f(x)$ y regresiones $E(Y|X = x)$ de forma no parametrica.

La limitacion que persiste

Todos los modelos vistos suponen implicitamente que $Y \in \mathbb{R}$. Pero muchas respuestas de interes no son continuas:

- $Y \in \{0, 1\}$: aprobar o reprobar, tiene o no hipertension.
- $Y \in \{0, 1, 2, \ldots\}$: numero de consultas medicas, conteos.
- $Y \in (0, 1)$: proporciones, tasas de exito.

La generalizacion: GLM

Los **Modelos Lineales Generalizados (GLM)** extienden RLM:

1. Distribucion de Y: se permite cualquier distribucion de la **familia exponencial**: Normal, Bernoulli, Poisson, Gamma.

2. Funcion de enlace g: en lugar de modelar $E(Y|X) = X\beta$, se modela $g(E(Y|X)) = X\beta$.

Respuesta Y	Distribucion	Enlace $g(\mu)$
Continua	Normal	μ (identidad)
Binaria	Bernoulli	$\log(\mu/(1-\mu))$ (logit)
Conteos	Poisson	$\log(\mu)$
Positiva	Gamma	$1/\mu$ (inversa)

RLM como caso particular

$Y \sim N(\mu, \sigma^2)$ y $g(\mu) = \mu$. El GLM lo recupera exactamente.

Por que no usar RLM con respuesta binaria?

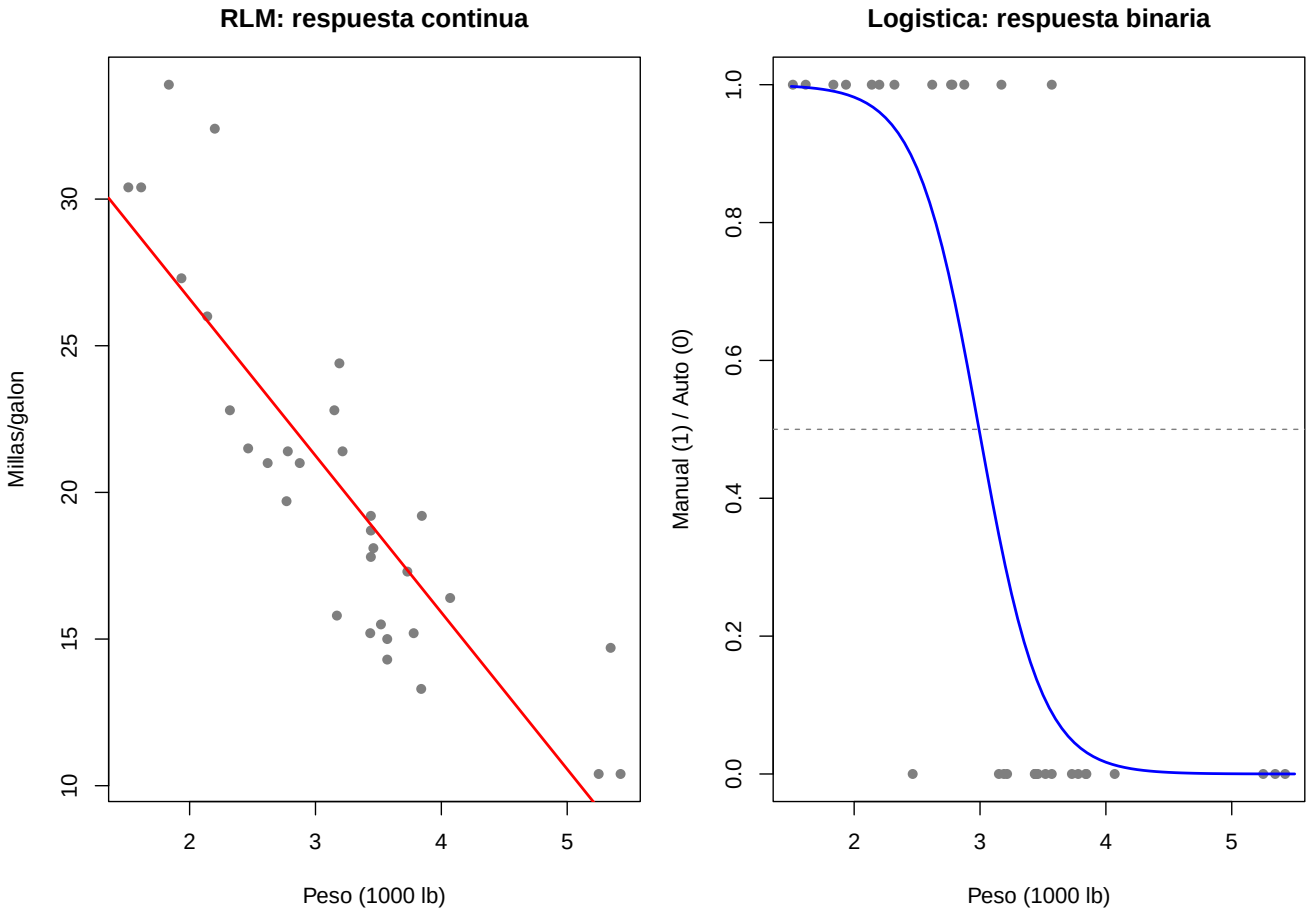

RLM puede predecir probabilidades negativas o mayores que 1. La funcion logistica garantiza $\hat{\pi}(x) \in (0, 1)$.

Puente: la generalizacion de los modelos lineales

Probabilidad, odds y log-odds

Regresion logistica

Estimacion del modelo

El GLM como marco unificador

Prediccion y evaluacion

Sintesis y cierre

Referencias

Probabilidad, odds y log-odds

El ejemplo motivador

Situacion: 500 estudiantes, de los cuales 300 aprueban y 200 reprueban.

```
table(data_course$Resultado)
```

```
##
##  Aprobar Reprobar
##      300      200
```

La pregunta es: como medir la **probabilidad de aprobar** de forma que sirva como respuesta de un modelo lineal?

Hay tres candidatas: la probabilidad, el odds y el log-odds. El camino de una a otra tiene motivaciones que van mas alla de la estetica matematica.

Probabilidad: intuitiva pero acotada

$$\pi = P(\text{Aprobar}) = \frac{300}{500} = 0.60$$

La probabilidad es la medida mas natural: hay un 60% de probabilidad de aprobar.

El problema: $\pi \in [0, 1]$ pero el predictor lineal $\beta_0 + \beta_1 x$ recorre toda la recta real $\mathbb{R}$. Si modelamos $\pi = \beta_0 + \beta_1 x$, nada impide que el lado derecho salga de $[0, 1]$.

El modelo lineal **no respeta los limites naturales** de una probabilidad.

Probabilidad: el problema de la asimetria

La probabilidad es **asimetrica en los extremos**: el mismo cambio absoluto en π tiene impacto muy distinto segun el punto de partida.

Ejemplo: suponga que asistir a clase aumenta la probabilidad de aprobar en 0.10 unidades.

Punto de partida	Con asistencia	Razon de mejora
$\pi = 0.10$	$\pi = 0.20$	$0.20/0.10 = 2.00$
$\pi = 0.90$	$\pi = 1.00$	$1.00/0.90 = 1.11$

Un incremento de 0.10 duplica las posibilidades cuando π es baja, pero casi no cambia nada cuando π es alta.

Un modelo lineal en π **trata ambos cambios como equivalentes**: incorrecto desde el punto de vista de la interpretacion.

Odds: la razon natural

$$\text{odds} = \frac{\pi}{1-\pi} = \frac{300/500}{200/500} = \frac{300}{200} = \frac{3}{2} = 1.5$$

El odds es una **razon**: "hay 3 chances de aprobar por cada 2 de reprobar."

Ejemplos cotidianos:

- En futbol: odds de ganar igual a 3 significa "3 chances de ganar por cada 1 de no ganar." Probabilidad de ganar: $3/(3+1) = 0.75$.
- En apuestas: "pago 3 a 1" significa odds de 3.
- Dado de 6 caras: odds de sacar un 6 es $1/5$ (1 a favor, 5 en contra).

El odds vive en $(0, \infty)$: elimina el limite superior 1, pero sigue teniendo el limite de 0.

Odds: todavia asimetrico

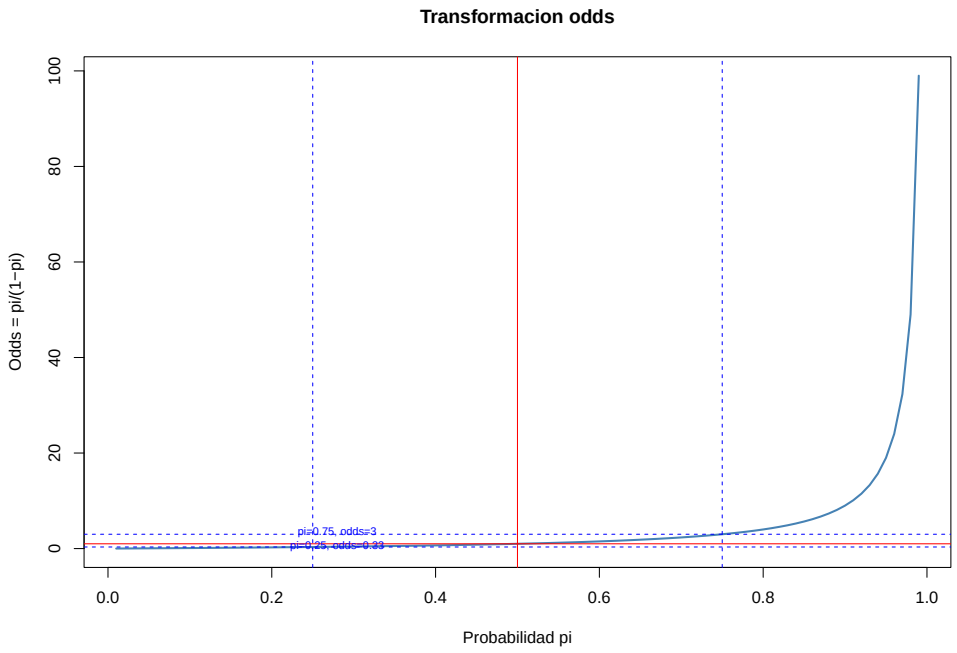

$\pi = 0.25$ y $\pi = 0.75$ son simetricos respecto a 0.5, pero sus odds son 0.33 y 3.00: no lo son.

Log-odds: cuatro razones para usarlo

El logaritmo del odds, $\text{logit}(\pi) = \log(\pi/(1-\pi))$, resuelve todos los problemas:

1. Dominio correcto: $\text{logit}(\pi) \in \mathbb{R}$, igual que el predictor lineal $\beta_0 + \beta_1 x$. Ya no hay que preocuparse por salirse de los limites.

2. Simetria: si $\pi = 0.25$, logit $= -1.09$; si $\pi = 0.75$, logit $= +1.09$. Simetrico alrededor de 0.

3. Efectos aditivos: si una variable suma β_1 al log-odds, eso corresponde a **multiplicar** el odds por e^{β_1}. Esta interpretacion multiplicativa del odds es natural en muchos contextos (razones de riesgo, factores de proteccion).

4. Referencia conocida: el log-odds ratio entre dos grupos se calcula igual que la diferencia de log-odds entre ellos. Esto conecta directamente con el analisis de tablas de contingencia.

Log-odds: simetrico y en la recta real

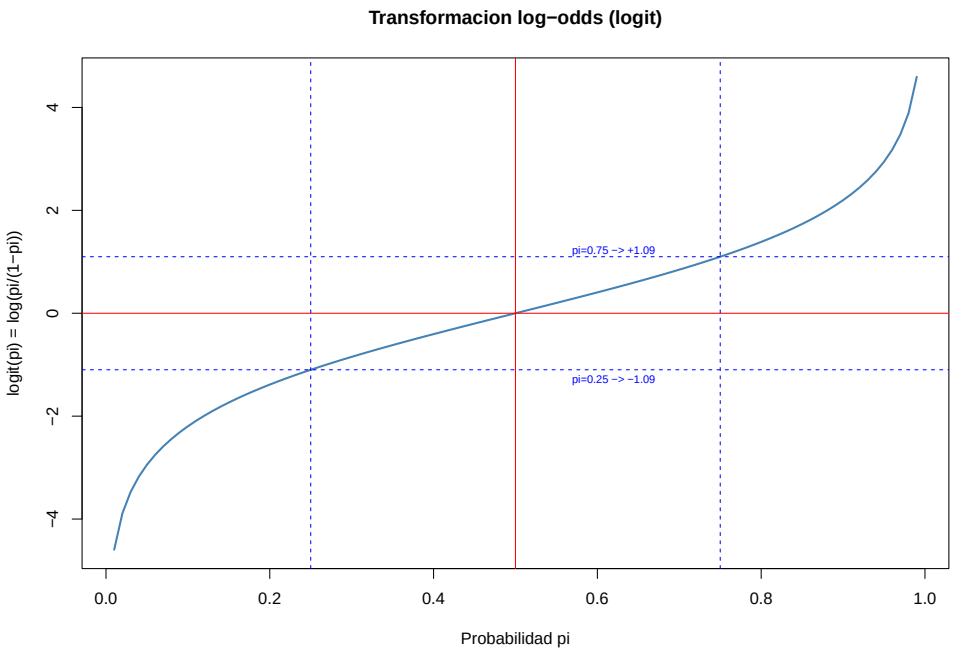

Perfecto: $\pi = 0.25$ y $\pi = 0.75$ dan log-odds iguales en magnitud y opuestos en signo. La escala es simetrica.

Interpretando el log-odds en terminos lineales

El reto: venimos de interpretar β_1 como "un aumento de 1 unidad en x produce un aumento de β_1 en y." Eso era directo.

Con el log-odds: "un aumento de 1 unidad en x produce un aumento de β_1 en el **log-odds** de π."

Eso no es tan intuitivo. La clave es pensar en tres niveles:

Nivel	Efecto de x	Ecuacion
1	$+\beta_1$ en log-odds	$\text{logit}(\pi)$ cambia en β_1
2	$\times e^{\beta_1}$ en odds	Odds se multiplica
3	Cambio no constante en π	Depende del valor base de π

El modelo **es lineal en el log-odds** aunque la relacion con π sea curva. Esto es exactamente lo que hace la funcion de enlace en el GLM.

De pi a logit y de vuelta: la sigmoide

La transformacion logit : $(0,1) \to \mathbb{R}$:

$$\text{logit}(\pi) = \log\left(\frac{\pi}{1-\pi}\right)$$

Su inversa, la **funcion sigmoide** $S : \mathbb{R} \to (0,1)$:

$$\pi = S(\eta) = \frac{1}{1+e^{-\eta}}$$

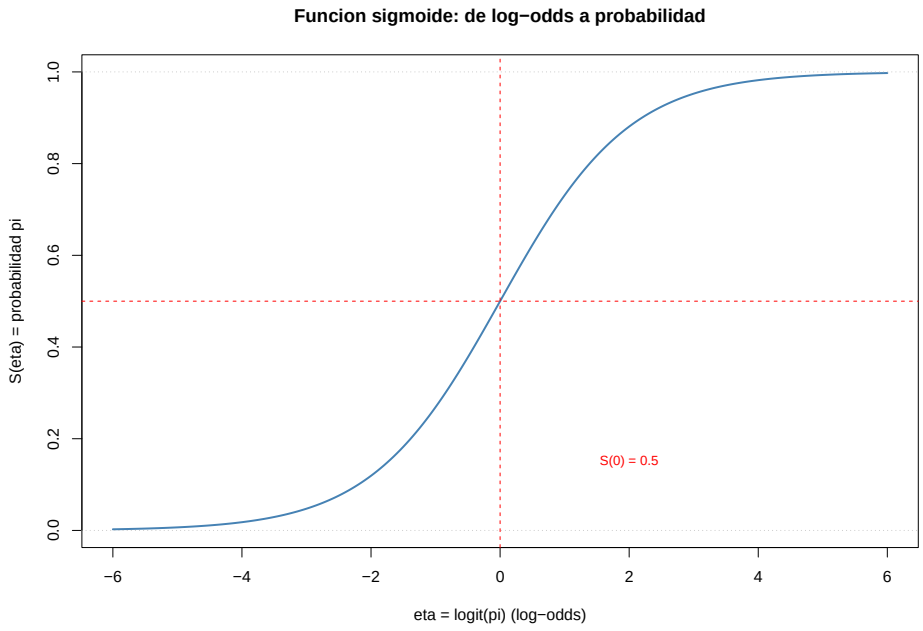

Odds ratio: comparar dos grupos

```
table(data_course$Asistencia, data_course$Resultado)
```

```
##
##           Aprobar Reprobar
##   Asiste      280       10
##   NAsiste      20      190
```

- **Asiste:** odds de aprobar $= 280/10 = 28$ (log-odds $= +3.33$).
- **No asiste:** odds de aprobar $= 20/190 = 0.105$ (log-odds $= -2.25$).

$$\text{OR} = \frac{280/10}{20/190} = \frac{28}{0.105} \approx 266$$

Los odds de aprobar siendo asistente son 266 veces los de no asistir. La asistencia es un fuerte **factor de proteccion**: aumenta masivamente la probabilidad de aprobar.

Odds ratio: interpretacion

- OR $\in (0, 1)$: la covariable reduce el odds del evento – **factor protector** (el evento es mas raro en ese grupo).
- OR $= 1$: la covariable no es informativa.
- OR $\in (1, \infty)$: la covariable aumenta el odds del evento – **factor de riesgo** (el evento es mas frecuente).

En nuestro ejemplo: OR $= 266 \gg 1$ para Asistencia. Asistir a clase **aumenta enormemente** las probabilidades de aprobar.

Log(OR) y significancia

$$\log(\text{OR}) = \log(280/10) - \log(20/190) = 3.33 - (-2.25) = +5.58$$

Bajo la hipotesis nula de independencia, el log(OR) sigue una distribucion **normal** con media 0 y varianza:

$$\text{Var}(\widehat{\log \text{OR}}) = \frac{1}{n_{11}} + \frac{1}{n_{12}} + \frac{1}{n_{21}} + \frac{1}{n_{22}}$$

```r
var_lor <- 1/280 + 1/10 + 1/20 + 1/190
cat("Error estandar:", round(sqrt(var_lor), 4), "\n")
```

```
## Error estandar: 0.3985
```

```r
cat("Estadistico z: ", round(5.58 / sqrt(var_lor), 2), "\n")
```

```
## Estadistico z:  14
```

Distribucion del log(OR) bajo H0

```
set.seed(1); h0_or <- NULL; n_tot <- 500
for(i in 1:10000){
  rv <- runif(n_tot); ra <- runif(n_tot)
  res_h0 <- ifelse(rv < 300/500, "Aprobar","Reprobar")
  asi_h0 <- ifelse(ra < 300/500, "Asiste", "NAsiste")
  tc <- table(asi_h0, res_h0)
  h0_or[i] <- log((tc[1,1]/tc[1,2])/(tc[2,1]/tc[2,2]))
}
```

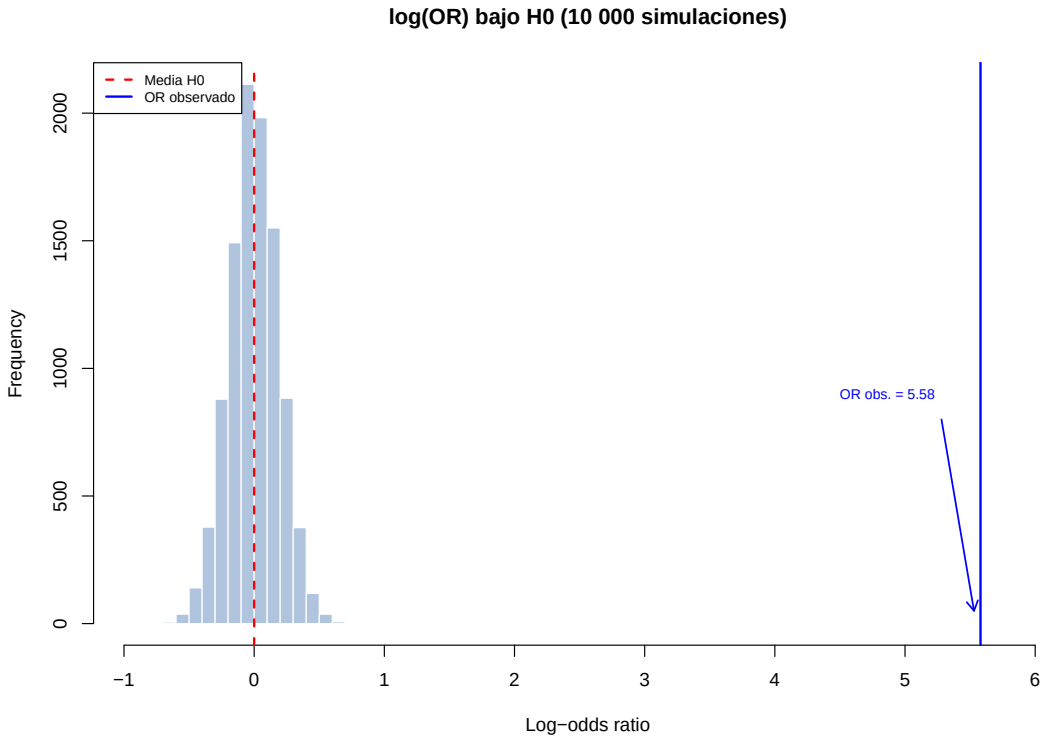

El valor observado $+5.58$ esta **muy lejos** de la distribucion bajo independencia.

Puente: la generalizacion de los modelos lineales

Probabilidad, odds y log-odds

Regresion logistica

Estimacion del modelo

El GLM como marco unificador

Prediccion y evaluacion

Sintesis y cierre

Referencias

Regresion logistica

El modelo de regresion logistica

Dado que $\text{logit}(\pi) \in \mathbb{R}$ y el predictor lineal $\beta_0 + \beta_1 x \in \mathbb{R}$, la idea es igualarlos:

$$\text{logit}(\pi(x)) = \log\left(\frac{\pi(x)}{1-\pi(x)}\right) = \beta_0 + \beta_1 x$$

Despejando $\pi(x)$:

$$\pi(x) = \frac{1}{1+e^{-(\beta_0+\beta_1 x)}} = S(\beta_0 + \beta_1 x)$$

La sigmoide S garantiza $\pi(x) \in (0,1)$ para cualquier valor del predictor lineal. Este es exactamente el enlace **logit** del GLM.

Efecto de los coeficientes sobre la curva

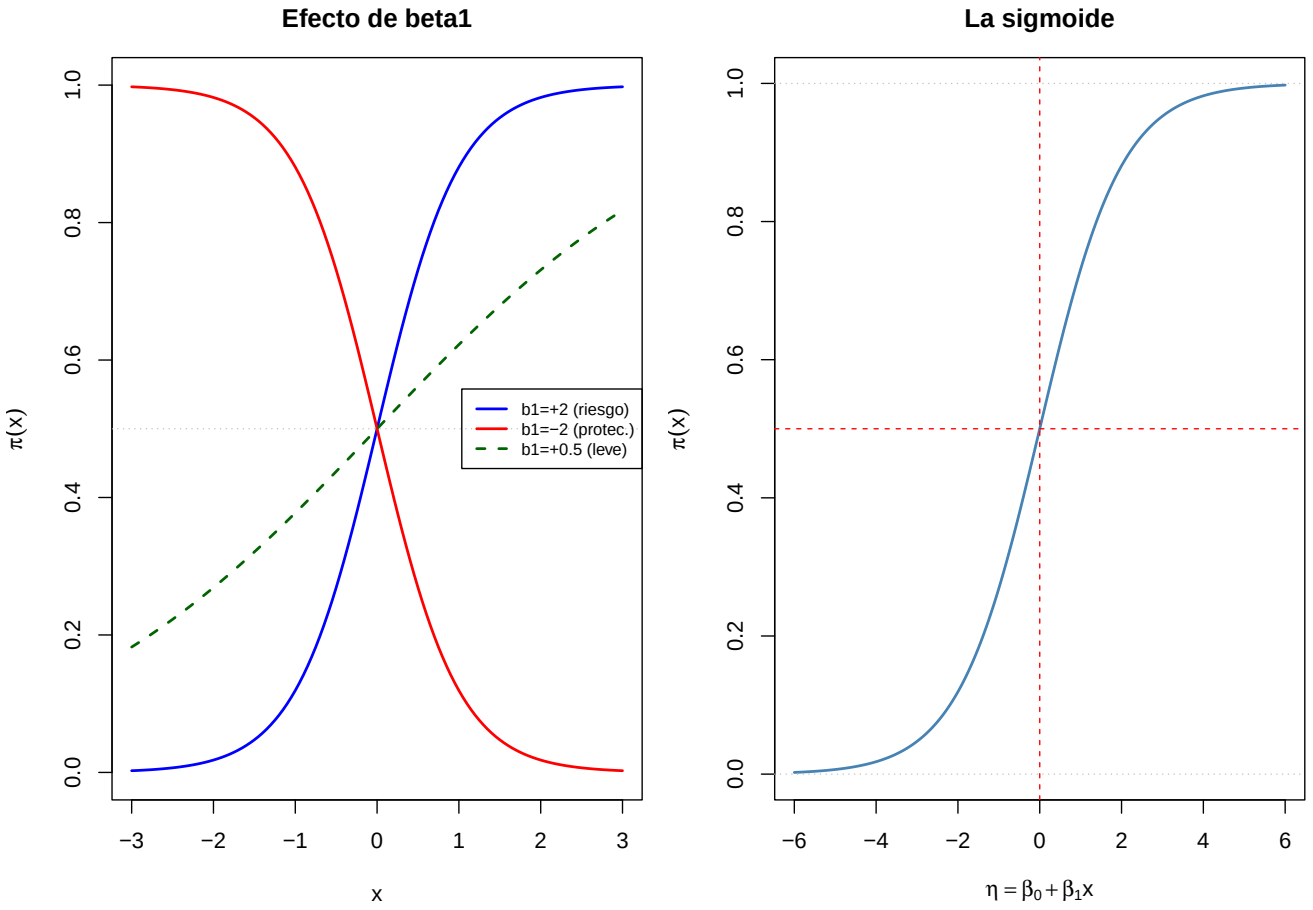

El ejemplo de carros: peso y transmisión

Contexto: 32 vehículos. Se quiere predecir si son manuales ($Y = 1$) o automáticos ($Y = 0$) en funcion de su peso (variable continua). Se contrasta con el caso de RLS, con variable respuesta las millas por galón.

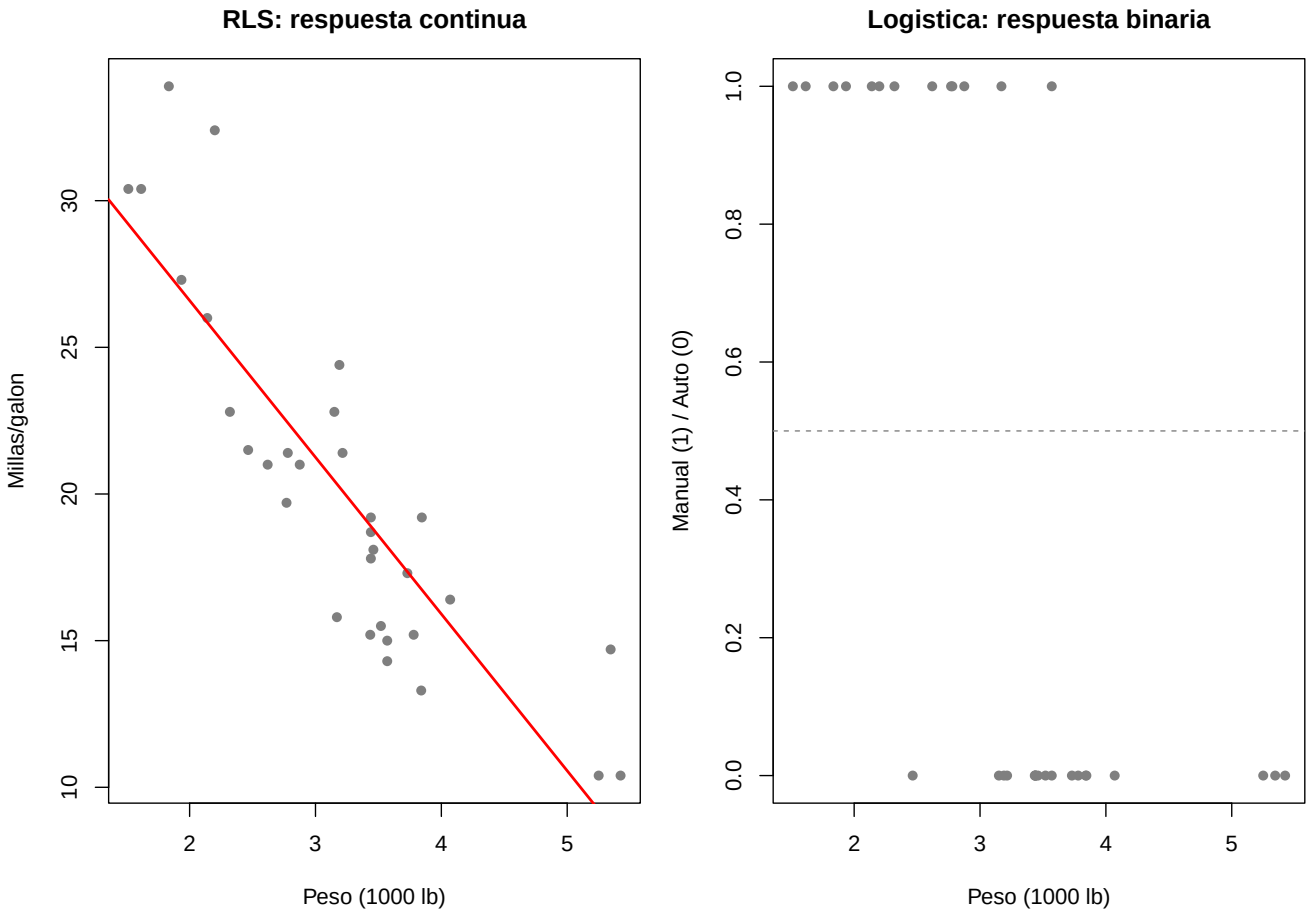
RLS: respuesta continua
Millas/galon
10
15
20
25
30
2
3
4
5
Peso (1000 lb)
Logistica: respuesta binaria
Manual (1) / Auto (0)
0.0
0.2
0.4
0.6
0.8
1.0
2
3
4
5
Peso (1000 lb)

Ajuste en R: variable continua

El ajuste se hace rápidamente desde R

```
logistic_model <- glm(am ~ wt,
                      data   = mtcars,
                      family = binomial)
round(summary(logistic_model)$coefficients, 3)
```

```
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept)   12.040      4.510   2.670    0.008
## wt            -4.024      1.436  -2.801    0.005
```

Modelo: $\text{logit}(\hat{\pi}) = 12.04 - 4.02\,x$

Ajuste en R: curva ajustada

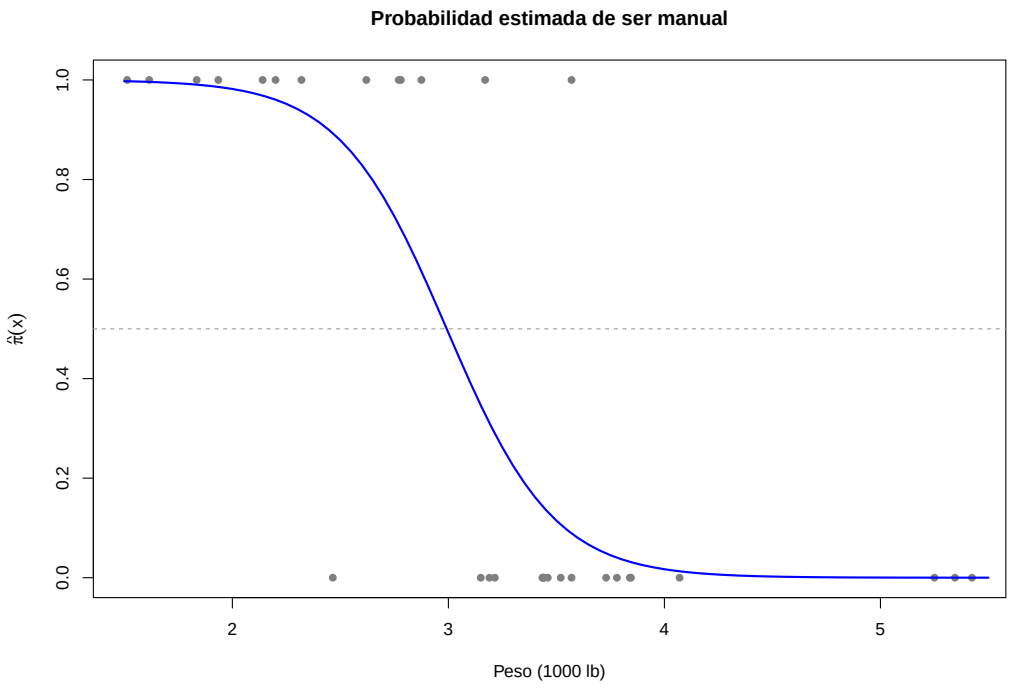

A mayor peso, menor probabilidad de ser manual.

El ejemplo de salud: hipertension y ejercicio

Contexto: 400 pacientes de un estudio clinico. Se quiere predecir si tiene hipertension ($Y = 1$) o no ($Y = 0$) en funcion de si hace ejercicio regularmente ($x = 1$) o no ($x = 0$).

El ejercicio es un **factor de proteccion**: reduce la probabilidad de hipertension. Se espera $\hat{\beta}_1 < 0$ y $e^{\hat{\beta}_1} < 1$.

```
round(prop.table(table(datos_salud$ejercicio,
                       datos_salud$hipertension), 1), 3)
```

```
##
##         0     1
##   0 0.355 0.645
##   1 0.683 0.317
```

Entre quienes no hacen ejercicio, la tasa de hipertension es notablemente mayor que entre quienes si hacen.

Ajuste en R: modelo de salud

```r
mod_salud <- glm(hipertension ~ ejercicio,
                 data   = datos_salud,
                 family = binomial)
round(summary(mod_salud)$coefficients, 3)
```

```
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept)    0.597      0.143   4.176        0
## ejercicio     -1.363      0.213  -6.410        0
```

Modelo: $\text{logit}(\hat{\pi}) = \hat{\beta}_0 + \hat{\beta}_1 \, x_{\text{ejercicio}}$

El coeficiente de ejercicio es negativo: quienes hacen ejercicio tienen menores log-odds de hipertension.

Ajuste en R: curva ajustada

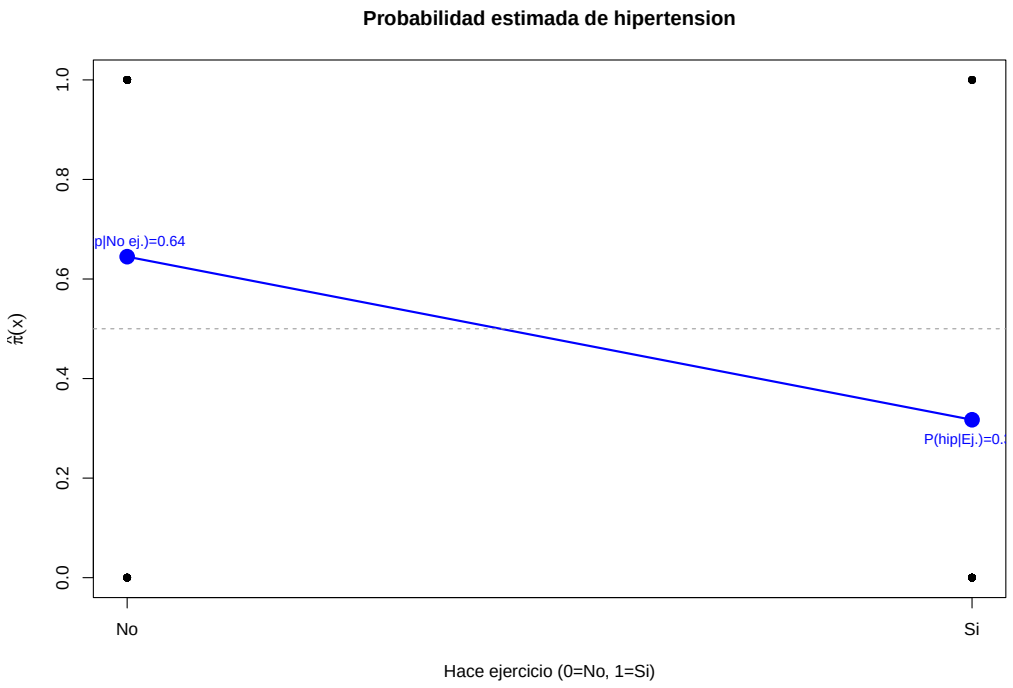

Interpretacion: Nivel 1 – log-odds (aditivo)

El modelo actua sobre la escala del **log-odds**:

$$\text{logit}(\hat{\pi}(x)) = \hat{\beta}_0 + \hat{\beta}_1 x$$

Para el ejemplo de hipertension:

$$\text{logit}(\hat{\pi}) = 0.6 + -1.36 \cdot x_{\text{ejercicio}}$$

Lectura directa en log-odds: Hacer ejercicio ($x = 1$ vs $x = 0$) **suma** $\hat{\beta}_1 = -1.36$ al log-odds de hipertension.

Esto es aditivo: el efecto de ejercicio sobre el log-odds es constante, independientemente del valor base de π -> el modelo **es lineal en el log-odds**, igual que RLM es lineal en y.

Interpretacion: Nivel 2 – odds (multiplicativo)

Al exponenciar el coeficiente, pasamos a la escala del **odds**:

$$\exp(\text{logit}(\hat{\pi})) = \frac{\hat{\pi}}{1-\hat{\pi}} = \exp(\hat{\beta}_0 + \hat{\beta}_1 x) = \exp(\hat{\beta}_0)\exp(\hat{\beta}_1 x)$$

Con

$$\frac{\hat{\pi}}{1-\hat{\pi}}$$

El odds de hipertensión. Para el ejercicio, cuando $x = 1$:

$$e^{\hat{\beta}_1} = e^{-1.36} \approx 0.256$$

Lectura en odds: Hacer ejercicio **multiplica** el odds de hipertension por ≈ 0.26, es decir, lo reduce a menos de la mitad.

Regla practica: - $e^{\beta_j} < 1$: la variable **reduce** el odds del evento (factor de proteccion). - $e^{\beta_j} = 1$: la variable no tiene efecto. - $e^{\beta_j} > 1$: la variable **aumenta** el odds del evento (factor de riesgo).

Interpretacion: Nivel 3 – probabilidad (no constante)

La probabilidad estimada se obtiene aplicando la sigmoide:

$$\hat{\pi}(x) = S(\hat{\beta}_0 + \hat{\beta}_1 x) = \frac{1}{1 + e^{-(\hat{\beta}_0 + \hat{\beta}_1 x)}}$$

Para los dos grupos del ejemplo:

```
newdata <- data.frame(ejercicio = c(0, 1))
p_pred  <- predict(mod_salud, newdata, type="response")
cat("P(hipertension | No ejercicio):",
    round(p_pred[1], 3), "\n")
```

```
## P(hipertension | No ejercicio): 0.645
```

```
cat("P(hipertension | Si ejercicio):",
    round(p_pred[2], 3), "\n")
```

```
## P(hipertension | Si ejercicio): 0.317
```

```
cat("Diferencia absoluta en pi:     ",
    round(p_pred[1]-p_pred[2], 3), "\n")
```

```
## Diferencia absoluta en pi:      0.328
```

Ajuste con variable discreta: asistencia al curso

El modelo ajustado es

$$\text{logit}(\hat{\pi}) = -2.25 + 5.58\,x$$

```
mod_curso <- glm(Aprobar ~ Asiste,
                 data   = data_course_b,
                 family = binomial)
round(summary(mod_curso)$coefficients, 3)
```

```
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -2.251      0.235  -9.577        0
## Asiste         5.583      0.399  14.010        0
```

- **No asiste** ($x = 0$):
  - log-odds $= -2.25 = \log(20/190)$
  - odds de aprobar $= 0.105$.
- **Asiste** ($x = 1$):
  - log-odds $= 3.33 = \log(280/10)$
  - odds de aprobar $= 28$.

La pendiente $+5.58$ es exactamente el log(OR) calculado antes. La regresion logistica **generaliza** el odds ratio al caso de multiples covariables.

Conexion con el odds ratio

Cantidad	Valor	Origen
$\hat{\beta}_0$	-2.25	log(odds|No asiste)
$\hat{\beta}_1$	$+5.58$	log(OR)
$e^{\hat{\beta}_1}$	266	Odds ratio (factor de proteccion enorme)

La regresion logistica con una covariable binaria **recupera exactamente** el odds ratio calculado manualmente, pero ademas:

- Extiende naturalmente a **multiples covariables**.
- Permite covariables **continuas** y **mixtas**.
- Incorpora la significancia de cada efecto.
- Permite hacer **predicciones** para nuevos individuos.

Multiples covariables

$$\text{logit}(\pi(\mathbf{x})) = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$$

```
mod_multi <- glm(hipertension ~ ejercicio + edad,
                 data = datos_salud, family = binomial)
round(summary(mod_multi)$coefficients, 4)
```

```
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -1.4624     0.4810 -3.0406   0.0024
## ejercicio    -1.4798     0.2228 -6.6432   0.0000
## edad          0.0423     0.0096  4.4233   0.0000
```

Ejercicio sigue siendo protector ($\hat{\beta} < 0$) y la edad es un factor de riesgo ($\hat{\beta} > 0$), manteniendo la otra variable constante.

Cuidado con el sobreajuste

Al agregar covariables recuerde el **problema del signo zodiacal** (Sesion 1): variables irrelevantes pueden mejorar el ajuste en entrenamiento pero perjudicar la prediccion.

Ridge y Lasso se extienden directamente:

$$\ell_{\text{pen.}} = \ell(\beta) - \lambda \sum_j \beta_j^2 \quad \text{(Ridge)} \qquad \text{o} \qquad \ell(\beta) - \lambda \sum_j |\beta_j| \quad \text{(Lasso)}$$

En R: `glmnet(X, y, family="binomial", alpha=0)` para Ridge y `alpha=1` para Lasso.

La seleccion de λ sigue siendo por validacion cruzada, exactamente como en la Sesion 2.

Puente: la generalizacion de los modelos lineales

Probabilidad, odds y log-odds

Regresion logistica

Estimacion del modelo

El GLM como marco unificador

Prediccion y evaluacion

Sintesis y cierre

Referencias

Estimacion del modelo

Por que no MCO

En RLM, el residual $e_i = y_i - \hat{y}_i$ mide el error de prediccion en escala continua.

Con $Y \in \{0, 1\}$:

- El residual no captura la probabilidad del resultado.
- Minimizar $\sum e_i^2$ puede producir probabilidades fuera de $(0, 1)$.
- La distribucion de Y es Bernoulli, no Normal.

El metodo correcto es la **maxima verosimilitud (MLE)**: encontrar los β que hacen los datos observados tan probables como sea posible bajo el modelo.

Revision de verosimilitud

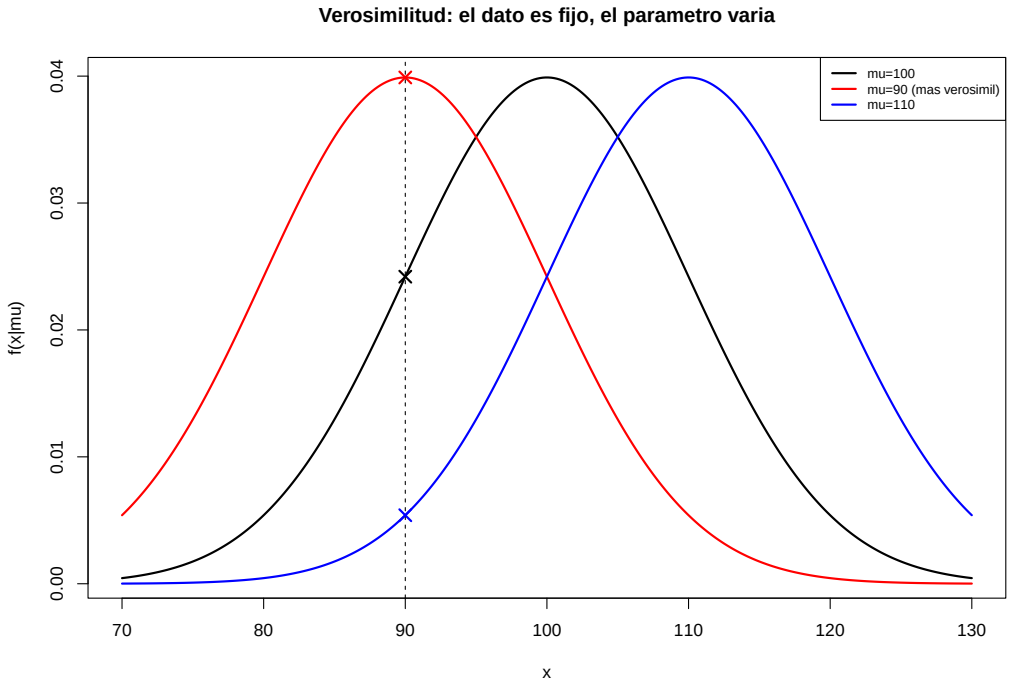

Probabilidad: fijada la distribucion, calcula la probabilidad de un evento.
Verosimilitud: fijado el dato, compara distintos parametros.

La verosimilitud logistica

El modelo asume $Y_i|X_i = x_i \sim \text{Ber}(\pi(x_i))$ con $\pi(x_i) = S(\beta_0 + \beta_1 x_i)$.

Para una observacion (x_i, y_i): $P(Y_i = y_i|x_i) = \pi(x_i)^{y_i}[1 - \pi(x_i)]^{1-y_i}$

Bajo independencia:

$$L(\beta) = \prod_{i=1}^{n} \pi(x_i)^{y_i}[1 - \pi(x_i)]^{1-y_i}$$

Y la **log-verosimilitud**:

$$\ell(\beta) = \sum_{i=1}^{n} [y_i \log \pi(x_i) + (1 - y_i) \log(1 - \pi(x_i))]$$

```r
# glm() hace IRLS automaticamente
mod_curso2 <- glm(Aprobar ~ Asiste,
                  data   = data_course_b,
                  family = binomial)
cat("Iteraciones IRLS:", mod_curso2$iter, "\n")
```

```
## Iteraciones IRLS: 6
```

```r
cat("Coeficientes finales:\n")
```

```
## Coeficientes finales:
```

```r
print(round(coef(mod_curso2), 4))
```

```
## (Intercept)      Asiste
##     -2.2513      5.5835
```

Superficie de log-verosimilitud

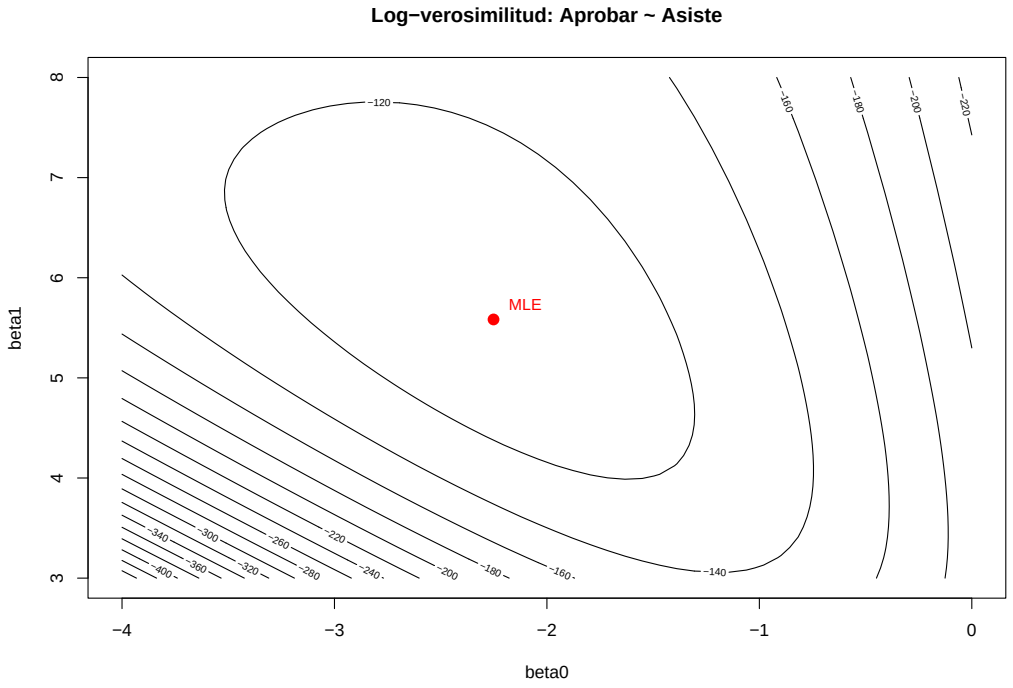

Las curvas de nivel muestran la log-verosimilitud para distintos (β_0, β_1). El punto rojo es el MLE: el par que maximiza la log-verosimilitud.

MCO vs. MLE: comparacion

Aspecto	MCO (RLM)	MLE (Logistica)
Criterio	Minimizar $\sum e_i^2$	Maximizar $\ell(\beta)$
Solucion	Analitica $(X^T X)^{-1} X^T y$	Numerica: IRLS
Distribucion de Y	Normal	Bernoulli
Bondad de ajuste	R^2, ECM	Devianza, AIC, ROC

En `glm()` de R, MLE se calcula automaticamente.

Puente: la generalizacion de los modelos lineales

Probabilidad, odds y log-odds

Regresion logistica

Estimacion del modelo

El GLM como marco unificador

Prediccion y evaluacion

Sintesis y cierre

Referencias

El GLM como marco unificador

El modelo saturado: el techo de referencia

En el **modelo saturado** hay exactamente **un parametro por observacion**: el modelo memoriza perfectamente todos los datos de entrenamiento.

En una regresion logistica con n observaciones: el modelo saturado tiene n parametros $\pi_1^*, \ldots, \pi_n^*$ donde $\pi_i^* = y_i$ exactamente.

$$\ell_{\text{sat}} = \sum_{i:y_i=1} \log(1) + \sum_{i:y_i=0} \log(1) = 0$$

Cada observacion contribuye con log-verosimilitud $= 0$ porque el modelo la predice perfectamente.

Pero este modelo **no predice nada**: si alguien nuevo llega al estudio, no hay forma de asignarle un parametro. El modelo saturado es el polo opuesto del modelo util.

Devianza: distancia al modelo saturado

La **devianza** mide cuanto pierde el modelo ajustado respecto a ese techo imposible:

$$D = -2[\ell(\hat{\beta}) - \ell_{\text{sat}}] = -2\ell(\hat{\beta}) \geq 0$$

Como $\ell_{\text{sat}} = 0$, la devianza es simplemente -2ℓ.

Una devianza pequena indica que el modelo ajustado esta cerca de la perfeccion (el modelo saturado).

La **devianza nula** usa solo el intercepto (predice siempre la proporcion global). La diferencia entre ambas mide cuanto aportan las covariables:

$$D^2_{\text{McFadden}} = 1 - \frac{D_{\text{modelo}}}{D_{\text{nula}}}$$

Devianza en R

```r
cat("Devianza nula:   ",
    round(mod_curso2$null.deviance, 2), "\n")
```

```
## Devianza nula:    673.01
```

```r
cat("Devianza modelo: ",
    round(mod_curso2$deviance, 2), "\n")
```

```
## Devianza modelo:  219.08
```

```r
cat("Pseudo-R2:       ",
    round(1 - mod_curso2$deviance /
              mod_curso2$null.deviance, 3), "\n")
```

```
## Pseudo-R2:        0.674
```

La devianza nula es el "error" de predecir siempre la proporcion global de aprobados (60%). La devianza del modelo es lo que queda despues de usar la asistencia como predictor.

Un pseudo-R^2 alto indica que la asistencia explica una fraccion importante de la variabilidad en la respuesta.

Conexion con las sesiones anteriores

El modelo logistico abre generalizaciones directas:

Con Ridge/Lasso (Sesion 1): `glmnet(X, y, family="binomial")` penaliza los coeficientes. Util con $p \gg n$.

Con splines y GAMs (Sesion 3): $\text{logit}(\pi) = \beta_0 + f_1(x_1) + f_2(x_2)$ donde cada f_j es un smooth spline. En R: `mgcv::gam(..., family=binomial)`.

Con kernels (Sesion 4): La regresion logistica con kernel reemplaza $X\beta$ por $\sum_i \alpha_i K(x, x_i)$, produciendo fronteras de decision no lineales. Conecta con las Maquinas de Vectores de Soporte (SVM).

Puente: la generalizacion de los modelos lineales

Probabilidad, odds y log-odds

Regresion logistica

Estimacion del modelo

El GLM como marco unificador

Prediccion y evaluacion

Sintesis y cierre

Referencias

Prediccion y evaluacion

De probabilidades a clasificacion

El modelo produce $\hat{\pi}(x) \in (0,1)$. Para clasificar en $\{0,1\}$ se necesita un umbral c:

$$\hat{y} = \begin{cases} 1 & \hat{\pi}(x) > c \\ 0 & \hat{\pi}(x) \leq c \end{cases}$$

La eleccion de c afecta el tipo de error. Para entender los tipos de error, pensemos en un ejemplo medico.

Verdadero positivo y verdadero negativo

Contexto: un modelo predice si una persona esta embarazada ($Y = 1$) o no ($Y = 0$).

Aplicamos el modelo a **Ana** (embarazada) y **Pedro** (hombre).

Realidad	Prediccion	Resultado	Nombre
Ana: embarazada	embarazada	Correcto	**VP** Verdadero Positivo
Pedro: no embaraz.	no embarazada	Correcto	**VN** Verdadero Negativo

Tanto VP como VN son **aciertos**. VP = detectar el evento cuando realmente ocurre. VN = descartar el evento cuando realmente no ocurre.

Falso positivo y falso negativo

Realidad	Prediccion	Resultado	Nombre
Pedro: no embaraz.	embarazada	Error	**FP** Falso Positivo
Ana: embarazada	no embarazada	Error	**FN** Falso Negativo

FP (Pedro predicho embarazado): alarma sin razon. En medicina: tratamiento innecesario, costo, ansiedad.

FN (Ana no detectada): falla en detectar el evento real. En medicina: enfermedad no tratada, consecuencias graves.

El costo relativo de FP y FN depende del contexto: en deteccion de cancer un FN puede ser fatal.

La matriz de confusion

Usando el modelo de hipertension con umbral $c = 0.5$:

```
pred_val <- ifelse(pred_salud > 0.5, "P.Hip", "P.NoHip")
obs_val  <- ifelse(datos_salud$hipertension == 1,
                   "O.Hip", "O.NoHip")
(tab <- table(obs_val, pred_val))
```

```
##          pred_val
## obs_val   P.Hip P.NoHip
##   O.Hip     138      59
##   O.NoHip    76     127
```

Filas = observado, columnas = predicho. La diagonal son los aciertos (VP y VN); fuera de la diagonal, los errores (FP y FN).

Sensibilidad y especificidad

$$\text{Sensibilidad}(c) = \frac{VP}{VP + FN} = \frac{\text{hipertensos correctamente identificados}}{\text{hipertensos totales}}$$

$$\text{Especificidad}(c) = \frac{VN}{VN + FP} = \frac{\text{sanos correctamente identificados}}{\text{sanos totales}}$$

```
VP  <- tab["O.Hip",   "P.Hip"  ]
VN  <- tab["O.NoHip", "P.NoHip"]
FP  <- tab["O.NoHip", "P.Hip"  ]
FN  <- tab["O.Hip",   "P.NoHip"]
cat("VP =", VP,  "  FN =", FN, "\n")
```

```
## VP = 138   FN = 59
```

```
cat("FP =", FP,  "  VN =", VN, "\n")
```

```
## FP = 76   VN = 127
```

```
sens  <- VP / (VP + FN)
espec <- VN / (VN + FP)
cat("Sensibilidad: ", round(sens,  3), "\n")
```

```
## Sensibilidad:  0.701
```

```
cat("Especificidad:", round(espec, 3), "\n")
```

```
## Especificidad: 0.626
```

Siempre hay un trade-off: subir c aumenta la especificidad pero reduce la sensibilidad. La curva ROC visualiza ese trade-off.

```r
umbrales   <- seq(0.01, 0.99, by=0.01)
sens_v <- espec_v <- NULL
for(i in seq_along(umbrales)){
  pv      <- ifelse(pred_salud > umbrales[i], "P.Hip","P.NoHip")
  tc      <- table(obs_val, pv)
  s_r <- if(ncol(tc)==2) tc[1,1]/(tc[1,1]+tc[1,2]) else
           if(colnames(tc)[1]=="P.Hip") 1 else 0
  e_r <- if(ncol(tc)==2) tc[2,2]/(tc[2,1]+tc[2,2]) else
           if(colnames(tc)[1]=="P.NoHip") 1 else 0
  sens_v[i]  <- s_r ; espec_v[i] <- e_r
}
pred_roc <- prediction(pred_salud, datos_salud$hipertension)
perf_roc <- performance(pred_roc, "tpr", "fpr")
plot(perf_roc, col="steelblue", lwd=2, main="Curva ROC: hipertension ~ ejercicio")
abline(a=0, b=1, lty=2, col="grey50")
```

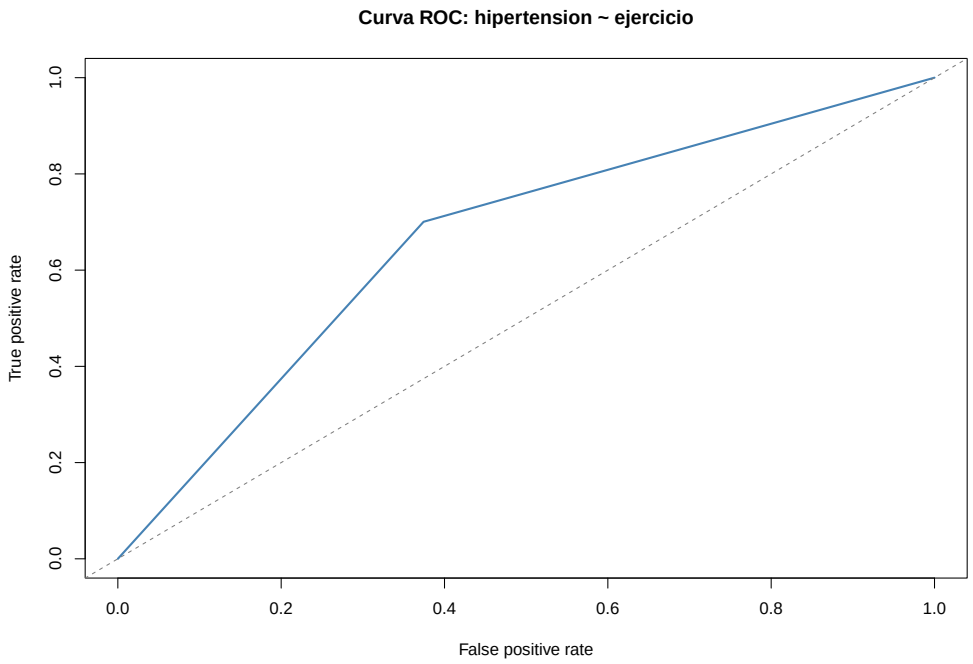

La curva ROC traza el trade-off sensibilidad/especificidad para todos los umbrales. La diagonal = clasificador aleatorio.

AUROC: el area bajo la curva

```
pred_roc2 <- prediction(pred_salud, datos_salud$hipertension)
perf_roc2 <- performance(pred_roc2, "tpr","fpr")
plot(perf_roc2, colorize=TRUE,
     main="Curva ROC coloreada por umbral")
abline(a=0, b=1, lty=2, col="grey50")
```

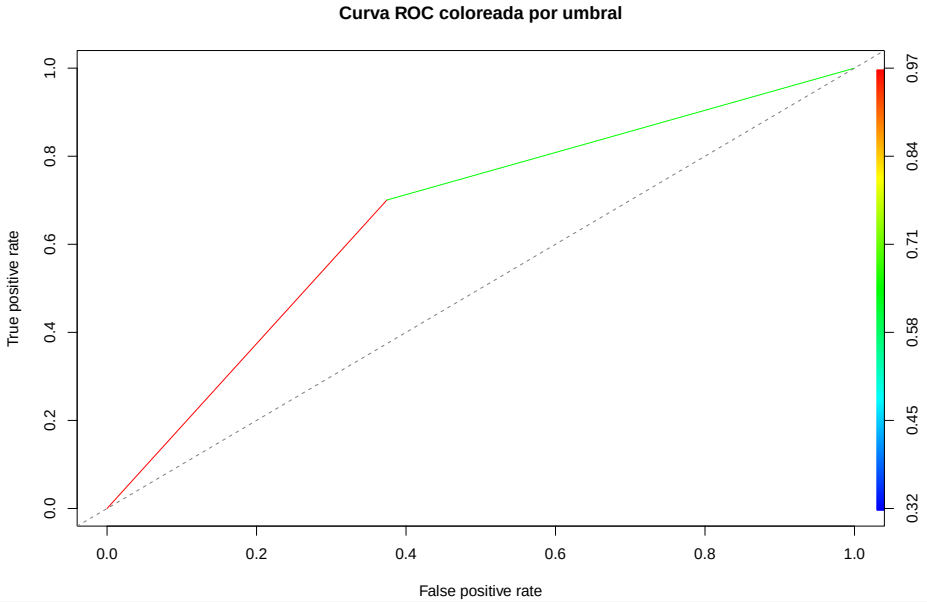


```
auc <- performance(pred_roc2, "auc")
cat("AUROC:", round(auc@y.values[[1]], 3))
```

```
## AUROC: 0.663
```

El color indica el umbral c: rojo $\approx$ c alto, violeta $\approx$ c bajo.

```r
library(ROCR)
logistic_model <- glm(am ~ wt, data = mtcars, family = binomial)
pred_resp      <- predict(logistic_model, type = "response")
pred_obj <- prediction(pred_resp, mtcars$am)
perf_obj <- performance(pred_obj,"tpr","fpr")
plot(perf_obj, colorize=TRUE,
     main="Curva ROC coloreada por umbral")
abline(a=0, b=1, lty=2, col="grey50")
```

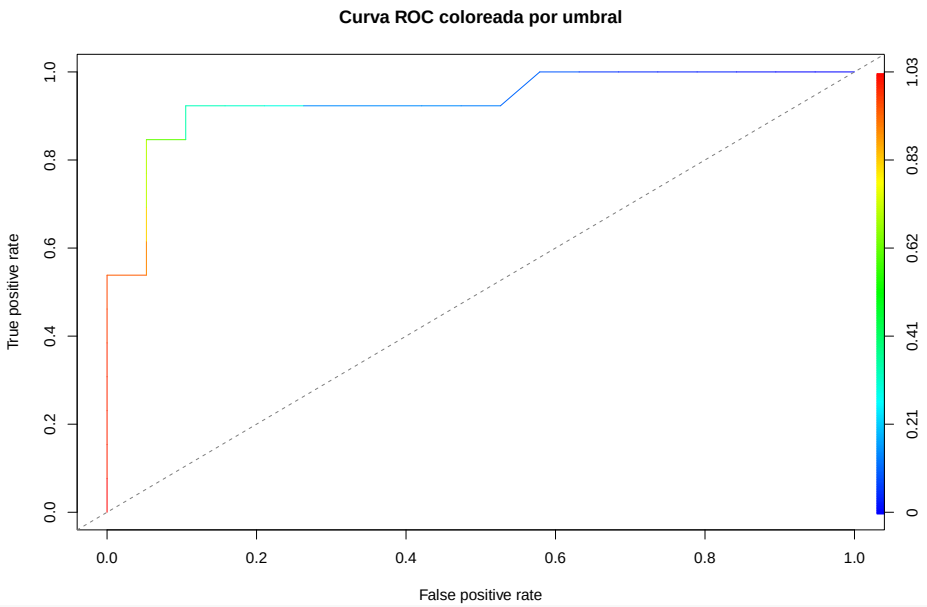


```r
auc <- performance(pred_obj,"auc")
cat("AUROC:", round(auc@y.values[[1]],3))
```

```
## AUROC: 0.933
```

AUROC: interpretacion

Que mide el AUROC:

- Con AUROC $= 0.5$: el modelo no discrimina mejor que el azar: es equivalente a asignar la prediccion al azar, como lanzar una moneda.
- Con AUROC $= 1$: discriminacion perfecta.
- Con AUROC ≥ 0.8: generalmente considerado bueno.

AUROC de prueba

```r
# 1. Preparación y Modelo
set.seed(42)
n_s     <- nrow(datos_salud)
train_i <- sample(n_s, floor(0.7 * n_s))
test_i  <- setdiff(1:n_s, train_i)

mod_tr  <- glm(hipertension ~ ejercicio + edad,
               data = datos_salud[train_i, ], family = binomial)

# 2. Predicciones y Objetos ROCR
pred_tr <- predict(mod_tr, datos_salud[train_i, ], type = "response")
pred_te <- predict(mod_tr, datos_salud[test_i, ], type = "response")

ptr <- prediction(pred_tr, datos_salud$hipertension[train_i])
pto <- prediction(pred_te, datos_salud$hipertension[test_i])

# 3. Métricas
pfr <- performance(ptr, "tpr", "fpr")
pfo <- performance(pto, "tpr", "fpr")

auc_tr <- performance(ptr, "auc")@y.values[[1]]
auc_te <- performance(pto, "auc")@y.values[[1]]
```

```r
# 4. Visualización
par(mfrow = c(1, 2))
plot(pfr, main = paste("ROC Entrenamiento | AUC:", round(auc_tr, 3)), col = "blue")
abline(a = 0, b = 1, lty = 2, col = "grey50")

plot(pfo, main = paste("ROC Prueba | AUC:", round(auc_te, 3)), col = "red")
abline(a = 0, b = 1, lty = 2, col = "grey50")
```

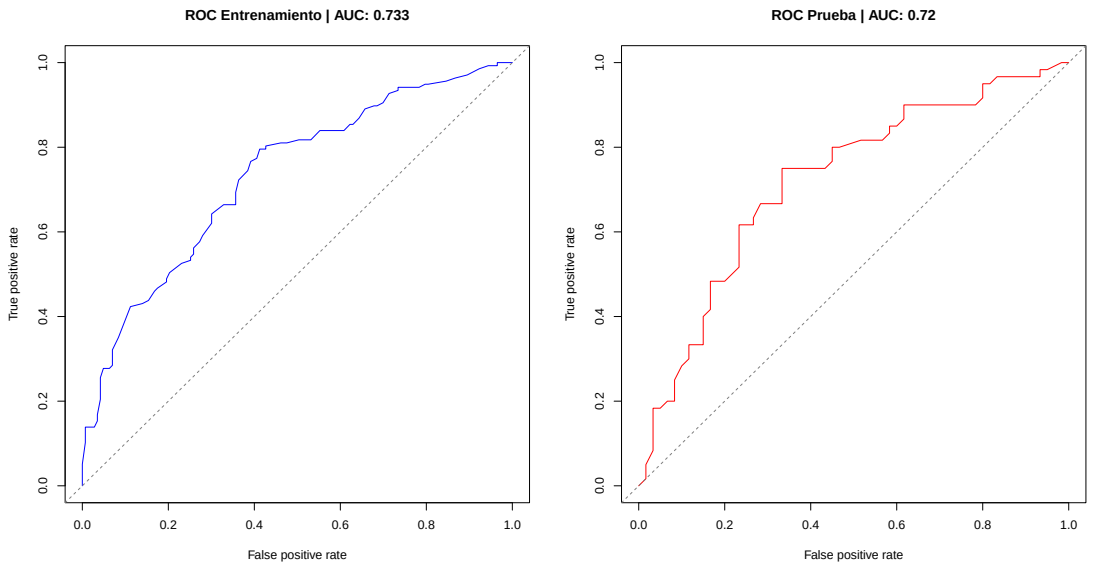

Comparar modelos: curvas ROC multiples

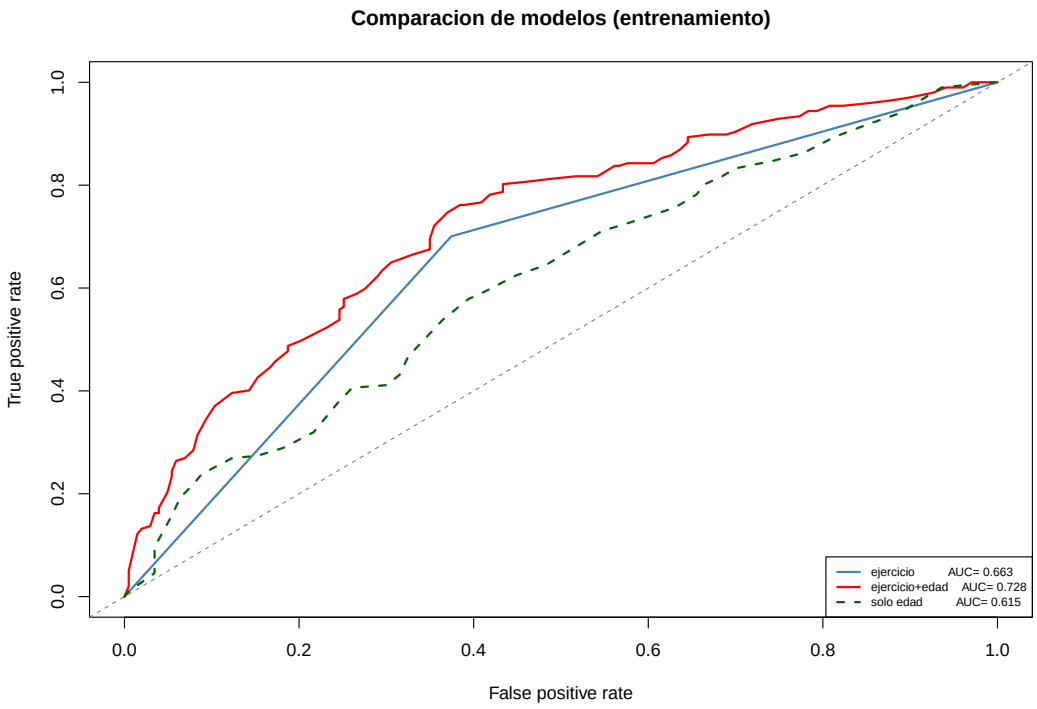

Temas avanzados para trabajo final

El GLM es el punto de partida de extensiones:

- **Regresion Poisson:** respuesta de conteos ($Y \in \{0, 1, 2, \ldots\}$), enlace log.
- **Binomial negativa:** conteos con sobredispersion.
- **Logistica multinomial:** respuesta con $K > 2$ categorias.
- **Regresion beta:** respuesta en $(0, 1)$ (proporciones).
- **Modelos de inflacion de ceros (ZIP, ZINB):** conteos con exceso de ceros.
- **Modelos de supervivencia (Cox):** tiempo hasta un evento con censura.

Todos siguen la estructura del GLM y se evaluan con las mismas herramientas de validacion de las sesiones anteriores.

Puente: la generalizacion de los modelos lineales

Probabilidad, odds y log-odds

Regresion logistica

Estimacion del modelo

El GLM como marco unificador

Prediccion y evaluacion

Sintesis y cierre

Referencias

Sintesis y cierre

Mapa conceptual de la sesion

Concepto	Descripcion
Odds	pi/(1-pi): razon, vive en (0,inf)
Log-odds (logit)	log(pi/(1-pi)): simetrico, vive en R
Odds ratio	Cociente de odds entre dos grupos
Log(OR)	Diferencia de log-odds: mide el efecto
Sigmoide	Inversa del logit: mapea R -> (0,1)
Logistica	GLM Bernoulli con enlace logit
MLE / IRLS	Estimacion de beta: maximiza verosimilitud
VP/VN/FP/FN	Los cuatro casos de clasificacion
Sens. / Especif.	Bondad del umbral de clasificacion
Curva ROC / AUROC	Poder discriminatorio en todos los umbrales
Devianza	Analogo del ECM para GLM
GLM	Marco unificador: Normal/Bernoulli/Poisson/Gamma

Hilo conductor del curso

S1: MCO – regularizacion Ridge/Lasso.

S2: Validacion – CV, LOOCV, Bootstrap.

S3: No-linealidad – Splines, GAMs.

S4: Localidad – KDE, LOESS, kernels.

S5: Respuestas no continuas – GLM, Logistica.

La estructura se mantiene en todas las sesiones: modelo estadistico, estimacion (MCO o MLE), hiperparametros de complejidad, validacion externa.

> ***Proxima sesion:*** *variables latentes y datos estructurados – reduccion de dimension, PCA, modelos de mezcla.*

Guia practica

Situacion	Recomendacion
Y binaria, predictores continuos	`glm(..., family=binomial)`
Y binaria, $p \gg n$	`glmnet(..., family="binomial")`
Y binaria, efectos no lineales	`gam(..., family=binomial)`
Y binaria, frontera no lineal	Kernel logistico / SVM
Evaluar clasificador	Curva ROC + AUROC en prueba
Seleccionar umbral	Segun costo de FP vs. FN
Comparar modelos de clasificacion	AUROC en validacion externa
Y con $K > 2$ categorias	Logistica multinomial (trab. final)
Y de conteo	Poisson / BinNeg (trab. final)

Puente: la generalizacion de los modelos lineales

Probabilidad, odds y log-odds

Regresion logistica

Estimacion del modelo

El GLM como marco unificador

Prediccion y evaluacion

Sintesis y cierre

Referencias

Referencias

Bibliografia

(1) Hastie, T., Tibshirani, R., Friedman, J. *The Elements of Statistical Learning*. Springer. (Cap. 4)

(2) James, G., Witten, D., Hastie, T., Tibshirani, R. *An Introduction to Statistical Learning with R*, 2a ed. Springer. (Cap. 4)

(3) McCullagh, P., Nelder, J.A. *Generalized Linear Models*, 2a ed. Chapman and Hall, 1989.

(4) Agresti, A. *An Introduction to Categorical Data Analysis*, 3a ed. Wiley, 2018.

Paquetes en R:

- `stats::glm()` – GLM (logistico, Poisson, Gamma).
- `glmnet` – Logistica penalizada.
- `mgcv::gam(..., family=binomial)` – GAM logistico.
- `ROCR`, `pROC` – Curva ROC y AUROC.