

Análisis Estadístico de Datos

Fundamentos Descriptivos

Profesor: Nicolás López

Universidad del Rosario

Tabla de Contenidos

1. Introducción
2. R como lenguaje de programación
3. RStudio y Posit Cloud
4. tidyverse
5. Datos y estructura
6. Conceptos fundamentales
 - 6.1. Clasificación de variables
 - 6.2. Distribución univariada
 - 6.3. Medidas de tendencia central
 - 6.4. Medidas de dispersión
 - 6.5. Forma: asimetría y curtosis
 - 6.6. Atipicidades
7. Visualización
8. Covarianza
9. Ejercicios
10. Síntesis

1. Introducción

Todos los días tomamos decisiones con información incompleta: qué ruta tomar, cuánto invertir, a quién contratar.

La estadística es, en el fondo, una caja de herramientas para tomar mejores decisiones cuando no tenemos toda la información.


- Convierte datos crudos en información útil.
- Reduce (no elimina) la incertidumbre.
- Ayuda a comparar alternativas de forma objetiva.
- Es un lenguaje común para argumentar con evidencia.

Pensemos en dos formas de tomar una decisión:

- **Con intuición:** “creo que las ventas subieron este mes”.
- **Con estadística:** “las ventas subieron 8%, y ese aumento es consistente en 9 de las 12 regiones”.

La segunda afirmación es verificable, comparable y defendible.

La estadística descriptiva —el foco de esta sesión— es el primer paso: resumir lo que los datos nos muestran, antes de intentar explicar el porqué.



2. R como lenguaje de programación


R es un lenguaje de programación creado específicamente para trabajar con datos.

No es una calculadora ni un programa de “clicks”: es un lenguaje que se escribe, se lee y se reutiliza.

Piénsenlo así: Excel les permite manipular una tabla; R les permite automatizar y repetir ese análisis cuantas veces quieran, sobre cualquier tamaño de datos.

¿Qué permite hacer R?

- Guardar los pasos del análisis, para repetirlos o compartirlos (reproducibilidad).
- Trabajar con conjuntos completos de datos, no dato por dato.
- Ampliarse con miles de paquetes gratuitos para tareas específicas.
- Crear visualizaciones con muy pocas líneas de código.



Un gráfico de R en una sola línea de código

Un primer ejemplo

En R, casi todo es un **objeto**: un número, una tabla, un gráfico. Le damos un nombre a un objeto y luego lo reutilizamos.

Guardamos cuatro números en un objeto llamado `x`, y le pedimos a R que calcule su promedio y su dispersión:

```
x <- c(2, 4, 6, 8)
```

```
mean(x)
```

```
## [1] 5
```

```
sd(x)
```

```
## [1] 2.581989
```

No calculamos “a mano”: le pedimos a R el resultado directamente. Ese es el espíritu del curso.

3. RStudio y Posit Cloud

RStudio es el programa donde escribimos y ejecutamos código en R. Es como el “escritorio de trabajo” alrededor del lenguaje.

Facilita:

- Escribir y organizar el código.
- Ver los gráficos y resultados al instante.
- Instalar y administrar paquetes.
- Organizar proyectos completos (datos, código, resultados).

Posit Cloud es una versión de RStudio que funciona desde el navegador, sin instalar nada:

- Todos trabajamos en el mismo entorno, sin importar el computador.
- Es ideal para un curso: evita problemas de instalación.
- Se accede desde cualquier lugar con internet.

4. tidyverse

El tidyverse es un conjunto de paquetes de R diseñados para que el análisis de datos sea más intuitivo y legible.

En este curso lo usaremos para tres tareas principales:

- Importar datos (traerlos a R).
- Manipular datos (filtrar, seleccionar, transformar).
- Visualizar datos (crear gráficos).

Todos estos paquetes comparten una misma filosofía, lo que facilita aprenderlos en conjunto.

Principio fundamental

- Cada **columna** es una variable.
- Cada **fila** es una observación.

Esto es exactamente como una hoja de cálculo bien construida en Excel.
Un pequeño ejemplo simulado:

```
## # A tibble: 3 x 3
##   país      año producción
##   <chr>    <dbl>      <dbl>
## 1 Colombia 2019        120
## 2 Brasil   2019        450
## 3 Perú     2019         90
```

Importando los datos del curso

En el siguiente ejemplo, leemos la base de datos y nos quedamos únicamente con la información de producción de carbón vegetal ("Charcoal") para el año 2019:

```
data_charcoal <- read_csv("UNdata_Charcoal.csv",  
                           show_col_types = FALSE)  
  
charcoal_prd19 <- data_charcoal %>%  
  filter(Year == 2019 &  
         Commodity == "Charcoal - Production") %>%  
  select(-Commodity)
```

5. Datos y estructura

Antes de calcular cualquier medida, es indispensable entender la estructura de la base de datos con la que trabajaremos:

- **Unidad estadística:** la entidad que se observa. En nuestro caso, un país-área.
- **Variable de interés:** lo que medimos en cada unidad. En nuestro caso, `Quantity`.

Una base de datos es, en esencia, una tabla rectangular:

- Cada **fila** es una unidad estadística (un país).
- Cada **columna** es una variable (una característica medida).

Saber identificar estos dos elementos es el punto de partida de cualquier análisis, sin importar qué tan sofisticado sea.

6. Conceptos Fundamentales

Cuatro palabras que usaremos constantemente durante el curso:

- **Variable:** una característica que puede tomar distintos valores entre unidades.
- **Dato:** el valor concreto que observamos para esa variable en una unidad específica.
- **Población:** el conjunto completo de unidades que nos interesa estudiar.
- **Muestra:** el subconjunto de la población que efectivamente logramos observar.

En la práctica casi nunca tenemos la población completa: el análisis descriptivo trabaja con la muestra disponible.

6.1. Clasificación de Variables

No todas las variables se pueden tratar de la misma forma. Clasificarlas bien evita errores de interpretación.

- **Nominal:** categorías sin orden. *Ej: color de un carro.*
- **Ordinal:** categorías con orden. *Ej: nivel educativo.*
- **Intervalo:** diferencias con sentido, cero arbitrario. *Ej: temperatura en °C.*
- **Razón:** como la anterior, pero con cero absoluto. *Ej: ingresos, cantidad producida.*

Quantity, nuestra variable de interés, es de **razón**. Esto nos permite:

- Hacer comparaciones proporcionales (el doble, la mitad).
- Todas las características de las escalas anteriores.

6.2. Distribución Univariada

Cuando hablamos de la “distribución” de una variable, nos referimos a cómo se reparten sus valores.

Estudiar una sola variable a la vez nos permite responder preguntas básicas pero esenciales:

- ¿Dónde se concentran la mayoría de los valores? (tendencia central)
- ¿Qué tan dispersos o parecidos son entre sí? (dispersión)
- ¿Es una distribución simétrica o está “cargada” hacia un lado? (forma)
- ¿Hay valores que se salen notablemente del resto? (atipicidades)

Estas cuatro preguntas organizan el resto de la sesión.

6.3. Medidas de Tendencia Central

Media (promedio)

La media es, sencillamente, el promedio: se suman todos los valores y se dividen entre el número de datos.

$$\bar{x} = \frac{\text{suma de todos los valores}}{\text{número de valores}}$$

Se puede pensar como el “punto de equilibrio” de la distribución.

```
mean(charcoal_prd19$Quantity, na.rm = TRUE)
```

```
## [1] 429.075
```

Mediana

La mediana es el valor que queda exactamente en la mitad cuando ordenamos todos los datos de menor a mayor.

A diferencia de la media, no se deja “arrastrar” por valores extremos. Por eso, cuando la distribución tiene valores muy extremos, la mediana suele ser más representativa.

```
median(charcoal_prd19$Quantity, na.rm = TRUE)
```

```
## [1] 21.1975
```

6.4. Medidas de Dispersión

Saber dónde se concentran los datos no es suficiente: también necesitamos saber qué tan dispersos están.

Imaginemos dos grupos de estudiantes en una clase que inicia a las 10:00 a.m., y medimos cuántos minutos antes o después llegan:

```
set.seed(123)
llegada_consistente <- c(4, 5, 6, 5, 5, 6, 4, 5, 6, 5)
llegada_dispersa    <- c(-5, 0, 15, 2, 20, -3, 8, 1, -8, 12)

mean(llegada_consistente)

## [1] 5.1

mean(llegada_dispersa)

## [1] 4.2
```

Ambos grupos llegan, en promedio, alrededor de 5 minutos tarde.

¿Llegan igual de “parecido”?



Mismo promedio, pero el Grupo 2 es mucho más disperso. Esa diferencia es lo que buscamos medir.

Varianza y desviación estándar

La **varianza** calcula qué tan lejos está, en promedio, cada dato de la media (elevado al cuadrado, para que las distancias no se cancelen entre sí).

La **desviación estándar** es la raíz cuadrada de la varianza, expresada en las mismas unidades que la variable original.

```
var(llegada_consistente)
```

```
## [1] 0.5444444
```

```
var(llegada_dispersa)
```

```
## [1] 84.4
```

El grupo disperso tiene una varianza mucho mayor, tal como esperábamos al ver el gráfico.

De vuelta a nuestros datos

```
sd(charcoal_prd19$Quantity, na.rm = TRUE)
```

```
## [1] 962.7235
```

Esta desviación estándar nos dice, en las mismas unidades de Quantity, qué tan lejos está en promedio cada país de la producción media.

Rango intercuartílico (IQR)

Otra forma de medir dispersión, más robusta ante valores extremos, es el **rango intercuartílico**: qué tan “ancho” es el 50% central de los datos.

$$IQR = Q_3 - Q_1$$


- Q_1 : deja el 25% de los datos por debajo.
- Q_3 : deja el 75% de los datos por debajo.

```
IQR(charcoal_prd19$Quantity, na.rm = TRUE)
```

```
## [1] 338.6513
```

6.5. Forma: Asimetría

La asimetría nos dice si la distribución es simétrica o si tiene una “cola” más larga hacia un lado.



Interpretación:

- Cercana a 0: distribución aproximadamente simétrica.
- Positiva: cola larga hacia la derecha (piensen en los salarios de una empresa: la mayoría gana un salario “normal”, pero unos pocos gerentes con salarios muy altos elevan la media).
- Negativa: cola larga hacia la izquierda.


Una forma práctica de detectarla, sin fórmulas: si la media es mayor que la mediana, hay asimetría positiva.

```
skewness(charcoal_prd19$Quantity, na.rm = TRUE)
```

```
## [1] 3.439393
```

6.6. Forma: Curtosis

La curtosis complementa a la asimetría: mide qué tan “pesadas” son las colas, es decir, qué tan frecuentes son los valores extremos.



- Curtosis alta: hay más valores extremos de lo esperado (colas pesadas).
- Curtosis baja: los valores están más concentrados, con pocos extremos.


No necesitan memorizar la fórmula: la curtosis es una alerta sobre qué tan propensos son los datos a sorprendernos con valores muy alejados del centro. Es especialmente relevante en el análisis de riesgo financiero.

```
kurtosis(charcoal_prd19$Quantity, na.rm = TRUE)
```

```
## [1] 16.20926
```

6.7. Atipicidades

Un **valor atípico** (outlier) es una observación que se aleja notablemente del resto de los datos.



Un valor atípico evidente

Una regla práctica, basada en el IQR: consideramos atípico cualquier valor que esté a más de 1.5 veces el IQR por encima de Q_3 o por debajo de Q_1 .

```
Q1 <- quantile(charcoal_prd19$Quantity, 0.25, na.rm = TRUE)
Q3 <- quantile(charcoal_prd19$Quantity, 0.75, na.rm = TRUE)
iqr <- IQR(charcoal_prd19$Quantity, na.rm = TRUE)
```

```
sum(charcoal_prd19$Quantity < Q1 - 1.5 * iqr |
     charcoal_prd19$Quantity > Q3 + 1.5 * iqr,
     na.rm = TRUE)
```

```
## [1] 22
```


Un valor atípico **no es automáticamente un error**: puede ser un dato real e importante. Siempre hay que investigar su origen antes de eliminarlo.

7. Visualización


Los números resumen la información, pero los gráficos nos permiten *verla* de un solo vistazo.

Histograma y boxplot

```
ggplot(charcoal_prd19,  
       aes(x = Quantity)) +  
  geom_histogram(bins = 25) +  
  theme_minimal(base_size = 9)
```



```
ggplot(charcoal_prd19,  
       aes(x = Quantity)) +  
  geom_boxplot() +  
  theme_minimal()
```




Histograma

- Es la versión para variables numéricas de un diagrama de barras.
- La variable se agrupa primero en intervalos, o “clases”.
- La altura de cada barra muestra cuántas observaciones caen en ese intervalo.

```
hist(charcoal_prd19$Quantity,  
     main = 'Histograma',  
     xlab = 'Int. de clase',  
     ylab = 'Frecuencia abs.')
```

Histograma



Boxplot





Figure 2: Elaboración de un boxplot o diagrama de caja

8. Covarianza

Hasta ahora hemos analizado una sola variable a la vez. Pero muchas preguntas interesantes involucran **dos variables al tiempo**: ¿las regiones más calurosas venden más helado? ¿los países con más ingresos producen más carbón vegetal?

Un ejemplo simulado con temperatura y ventas de helado:



La covarianza

La **covarianza** mide si dos variables tienden a moverse juntas. La idea, en palabras simples: para cada observación, revisamos si ambas variables están por encima (o por debajo) de su propia media al mismo tiempo, y promediamos esa coincidencia.

```
cov(temperatura, ventas_helado)
```

```
## [1] 60.49776
```

Interpretación del resultado:

- **Positiva:** cuando una sube, la otra tiende a subir (temperatura y helado).
- **Negativa:** cuando una sube, la otra tiende a bajar.
- **Cercana a cero:** no hay una relación lineal clara.

De vuelta a nuestros datos

```
cov(charcoal_prd19$Quantity,  
    charcoal_prd19$Quantity,  
    use = "complete.obs")
```

```
## [1] 926836.5
```

Depende directamente de la escala de medición de las variables involucradas.

Una advertencia importante

El valor de la covarianza, por sí solo, es difícil de interpretar: depende de las unidades de medida.

Por ejemplo, la covarianza entre ingresos y edad cambiaría de magnitud si midiéramos los ingresos en dólares en lugar de pesos, aunque la relación sea exactamente la misma.

Más adelante en el curso normalizaremos esta medida (dando lugar a la **correlación**), que sí permite comparar la fuerza de la relación entre distintos pares de variables sin importar sus unidades.

Por ahora: la covarianza nos dice la **dirección** de la relación, aunque no todavía su magnitud relativa.

9. Ejercicios

1. Comparen la media y la mediana de un grupo de datos con un valor muy extremo. ¿Cuál cambia más y por qué?
2. Expliquen por qué la varianza le da más peso a los valores extremos que a los cercanos al promedio.
3. Piensen en una variable de su campo de estudio que probablemente tenga asimetría positiva. Justifiquen.
4. Den un ejemplo, distinto a los vistos en clase, de dos variables con covarianza negativa.

10. Síntesis

La estadística descriptiva:

- Resume grandes cantidades de información en unos pocos números y gráficos.
- Reduce la incertidumbre al tomar decisiones.
- Nos da un lenguaje común, basado en evidencia, para comparar y argumentar.
- Es el fundamento del análisis multivariado que veremos en el resto del curso.

La covarianza es la puerta de entrada al estudio conjunto de variables: de aquí en adelante, dejaremos de ver los datos de “a una variable a la vez” para ver cómo se relacionan entre sí.

TAREA Revisar el cuaderno de clase.