

Análisis Estadístico de Datos

Sesión 2: Probabilidad y Pensamiento Bivariado

Profesor: Nicolás López

Universidad del Rosario

Puente con la Sesión 1

En la primera sesión aprendimos a **describir una sola variable**:

- **R y RStudio**: el lenguaje y el paquete tidyverse
- **Tipos de variable**: cuantitativas vs. cualitativas
- **Histograma y boxplot**: formas visuales de ver una distribución

- **Medidas de centro:** media, mediana, moda
- **Medidas de dispersión:** varianza, desviación estándar
- **Forma:** asimetría (¿la cola es más larga a un lado?)
- **Atípicos:** valores que se salen del patrón general
- **Covarianza:** una primera idea de cómo dos variables se mueven juntas

¿Por qué no basta con mirar una variable a la vez?

El mundo casi nunca tiene una sola variable relevante:

Un país puede producir mucho carbón — pero ¿cuánto consume?
¿Los países que más producen son también los que más consumen?

Hoy vamos a dar dos pasos:

1. Aprender un lenguaje formal para hablar de **incertidumbre** (probabilidad)
2. Aprender a comparar **dos variables al tiempo** (pensamiento bivariado)

Tabla de contenidos

Puente con la Sesión 1

1. Datos de la sesión
2. Probabilidad, de manera intuitiva
3. La curva que describe una variable: la densidad
4. ¿Cómo estimamos esa curva con datos reales?
5. Pensamiento bivariado: comparando dos variables
6. Síntesis

Puente hacia la Sesión 3

Anexo

1. Datos de la sesión

Paquetes necesarios

```
install.packages("tidyverse")  
install.packages("ggExtra")
```

Usaremos el mismo conjunto de datos de carbón de la Sesión 1.

Cargando los datos

```
library(tidyverse)
data_charcoal = read_csv("UNdata_Charcoal.csv",
                        show_col_types = FALSE)
charcoal_chh19 = data_charcoal %>%
  filter(Year == 2019 &
         Commodity == "Charcoal - Consumption by households") %>%
  select(-Commodity)
charcoal_prd19 = data_charcoal %>%
  filter(Year == 2019 &
         Commodity == "Charcoal - Production") %>%
  select(-Commodity)
```

Dos tablas: una de **producción** y otra de **consumo** de carbón por país, en 2019.

2. Probabilidad, de manera intuitiva

¿Qué es un experimento aleatorio?

Un **experimento aleatorio** es cualquier situación en la que:

- No sabemos con certeza qué va a pasar
- Pero si lo repetimos muchas veces, aparece un **patrón**

Ejemplos cotidianos:

- Lanzar una moneda
- Lanzar un dado
- Elegir al azar un país y mirar cuánto carbón produjo

El espacio de resultados posibles

Al conjunto de **todos los resultados posibles** de un experimento lo llamamos espacio muestral, y lo denotamos S .

- Moneda: $S = \{Cara, Sello\}$
- Dado: $S = \{1, 2, 3, 4, 5, 6\}$
- País elegido al azar: $S = \{\text{todos los países con datos}\}$

Conexión con los datos

Al filtrar los datos de carbón para 2019 obtenemos una **muestra aleatoria** de países. Uzbekistán no aparece en los datos — su ausencia es parte de la aleatoriedad del proceso de recolección.

Ponerle un número a lo aleatorio

Una **variable aleatoria** es simplemente una forma de convertir el resultado de un experimento en un **número**.

Por ejemplo, si lanzamos un dado y llamamos X al resultado:

$$Cara_1 \rightarrow 1, \quad Cara_2 \rightarrow 2, \quad \dots, \quad Cara_6 \rightarrow 6$$

Antes de lanzar el dado, no sabemos el valor — es aleatorio. Después de lanzarlo, ya es un número concreto.

Ejemplo con los datos del curso

Si X es la edad de un estudiante, y el estudiante #3 (Pepito) tiene 27 años:

$$x_3 = 27$$

Con $n = 13$ estudiantes en el curso, tenemos 13 edades: $x_1, x_2, \dots, x_{13}$.

Un pequeño detalle de notación

X (mayúscula) = la variable, **antes** de observarla (todavía es incierta)

x (minúscula) = el valor **ya observado** (un número concreto)

Este detalle aparece todo el tiempo en estadística, así que vale la pena acostumbrarse a él desde ya.

Dos grandes familias de variables

Tipo	Descripción	Ejemplo
Discreta	Se puede contar	N. de caras en 10 lanzamientos
Continua	Cualquier valor en un rango	Producción de carbón (miles ton.)

En este curso

Trabajaremos casi siempre con variables **continuas**: cosas que se miden (dinero, peso, tiempo, toneladas), no que se cuentan.

¿Cómo describimos el comportamiento de una variable continua?

Para una variable discreta (como un dado), podemos simplemente listar la probabilidad de cada valor.

Para una variable **continua**, hay infinitos valores posibles, así que en vez de una lista usamos una **curva**: la función de densidad. Ese es el tema de la siguiente sección.

3. La curva que describe una variable: la densidad

Los modelos matemáticos son mapas simplificados

Muchas áreas de la ciencia usan ecuaciones sencillas para describir fenómenos complejos:


Modelo	Ecuación
Teorema de Pitágoras	$a^2 = b^2 + c^2$
Relatividad especial	$E = mc^2$
Línea recta	$f(x m, b) = mx + b$

La **función de densidad** hace lo mismo para una variable aleatoria: es una curva (un “mapa”) que describe qué tan probable es cada rango de valores.

Una familia de curvas: el ejemplo de la recta

Antes de llegar a la densidad, pensemos en algo más simple: la familia de rectas $f(x) = mx + b$. Cambiar m y b nos da rectas distintas:

```
f_lineal = function(x, m, b) { m * x + b }  
ggplot() + xlim(-3, 3) +  
  geom_function(fun=f_lineal, args=list(m=1, b=1), color="gold", linewidth=1) +  
  geom_function(fun=f_lineal, args=list(m=1, b=-1), color="steelblue", linewidth=1) +  
  geom_function(fun=f_lineal, args=list(m=-1, b=-1), color="tomato", linewidth=1) +  
  theme_minimal() +  
  labs(y="f(x)", title="Familia de líneas rectas: distintos (m, b)")
```



La curva más famosa: la distribución normal

La **distribución normal** (la “campana”) es una familia de curvas, igual que la recta, pero controlada por dos parámetros: μ y σ .

- μ : dónde está el **centro** de la campana
- σ : qué tan **ancha** (dispersa) es la campana

$$f(x \mid \mu, \sigma) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2} \left(\frac{x - \mu}{\sigma}\right)^2\right)$$


No es necesario memorizar esta fórmula; lo importante es entender qué hace cada parámetro. Eso es justo lo que veremos a continuación.

Cambiando el centro: el parámetro μ

Tres campanas con el mismo ancho ($\sigma = 1$), pero centros distintos:

dnorm(x, mean, sd) es la función nativa de R para la densidad normal


```
ggplot() + xlim(-5, 5) +  
  geom_function(fun=dnorm, args=list(mean=-1, sd=1), color="gold", linewidth=1) +  
  geom_function(fun=dnorm, args=list(mean=0, sd=1), color="steelblue", linewidth=1) +  
  geom_function(fun=dnorm, args=list(mean=1, sd=1), color="tomato", linewidth=1) +  
  annotate("text", x=c(-2.7, 0.6, 2.7), y=c(0.31, 0.42, 0.31),  
    label = c("mu=-1", "mu=0", "mu=1"), size=3) +  
  theme_minimal() +  
  labs(y="Densidad", title="Normal: variando mu (sigma=1 fijo)")
```



Cambiando el ancho: el parámetro σ

Ahora fijamos el centro ($\mu = 0$) y cambiamos qué tan dispersa es la campana:

```
ggplot() + xlim(-6, 6) +  
  geom_function(fun=dnorm, args=list(mean=0, sd=0.5), color="gold", linewidth=1) +  
  geom_function(fun=dnorm, args=list(mean=0, sd=1), color="steelblue", linewidth=1) +  
  geom_function(fun=dnorm, args=list(mean=0, sd=2), color="tomato", linewidth=1) +  
  annotate("text", x=c(0.8, 1.8, 3.2), y=c(0.72, 0.36, 0.16),  
    label = c("sigma=0.5", "sigma=1", "sigma=2"), size=3) +  
  theme_minimal() +  
  labs(y="Densidad", title="Normal: variando sigma (mu=0 fijo)")
```



La regla práctica del 68-95-99.7

Para una normal **estándar** ($\mu = 0$, $\sigma = 1$) existe una regla muy útil para recordar cómo se reparten los datos:

Rango	Porcentaje de datos dentro
$\mu \pm 1\sigma$	$\approx 68\%$
$\mu \pm 2\sigma$	$\approx 95\%$
$\mu \pm 3\sigma$	$\approx 99.7\%$

Conexión con la Sesión 1

Un **outlier** es, en el fondo, un dato que cae fuera de $\mu \pm 3\sigma$: ahora tenemos una regla de probabilidad detrás de esa intuición.

¿Por qué la normal aparece en todas partes?

Una observación empírica

Muchas cosas que medimos en la vida real (estaturas, errores de medición, promedios) se agrupan de forma simétrica alrededor de un valor central.

Hay además una razón matemática de fondo: el **Teorema Central del Límite**.

El Teorema Central del Límite, en palabras simples

Si sumamos (o promediamos) muchas variables aleatorias independientes, sin importar de dónde vengan, **el resultado se parece a una normal**.

$$\bar{X}_n \xrightarrow{d} \text{una normal, cuando } n \text{ es grande}$$

Ejemplo simple: el resultado de un solo dado es “plano” — los 6 valores son igual de probables, no hay ninguna campana ahí. Pero si lanzamos el dado muchas veces y calculamos el **promedio** de los resultados, ese promedio sí se empieza a comportar como una normal, centrada en 3.5.

Esta es la razón por la que la normal es el modelo más usado en estadística.

Ejemplo: el promedio de los salarios

Los salarios de una población suelen ser muy **asimétricos a la derecha**: la mayoría gana un monto moderado, y unos pocos ganan muchísimo más.

Pero si tomamos muchas muestras de, digamos, 40 personas y calculamos el **promedio** de cada muestra, esos promedios sí se comportan como una normal — aunque los salarios individuales no lo sean.



La clave

El TCL no dice que los datos originales sean normales. Dice que el **promedio** de muchos datos sí tiende a serlo.

Comprobándolo con una simulación simple

```
set.seed(1)
salarios = rlnorm(100000, meanlog = 8, sdlog = 0.6) # poblacion asimetrica
promedios = replicate(2000, mean(sample(salarios, 40)))

par(mfrow = c(1, 2))
hist(salarios, breaks = 60, col = "lightblue",
     main = "Salarios individuales", xlab = "")
hist(promedios, breaks = 30, col = "tomato",
     main = "Promedio de 40 salarios", xlab = "")
```



A la izquierda, los datos originales son asimétricos. A la derecha, el promedio de 40 de ellos ya parece una campana.

El área bajo la curva es una probabilidad

La idea clave de la densidad: el **área bajo la curva** entre dos puntos nos da la probabilidad de caer en ese rango.

$$P(a \leq X \leq b) = \text{área bajo } f(x) \text{ entre } a \text{ y } b$$


Dos propiedades siempre se cumplen:

- El área **total** bajo toda la curva es 1 (100% de probabilidad)
- Para una normal, el área a la izquierda de μ es exactamente 0.5 (simetría)

Ejemplo: la edad de los estudiantes

Si X = edad de los estudiantes y suponemos $X \sim \mathcal{N}(27, 5)$:

```
ggplot() + xlim(10, 45) +  
  geom_function(fun=dnorm, args=list(mean=27, sd=5),  
               color="steelblue", linewidth=1.2) +  
  geom_vline(xintercept=27, linetype="dashed", color="tomato") +  
  annotate("text", x=30, y=0.063,  
          label="mu = 27", color="tomato", size=3.5) +  
  theme_minimal() +  
  labs(y="Densidad", x="Edad (anos)",  
       title="Distribucion normal: edad de estudiantes",  
       subtitle="mu=27, sigma=5")
```




4. ¿Cómo estimamos esa curva con datos reales?

El histograma como primera aproximación

Hasta ahora, la densidad era un modelo teórico. Pero con datos reales, ¿cómo la estimamos? El primer intento es el **histograma**, pero cambiando el eje y de “conteo” a “densidad” (para que el área total sea 1):

```
h_dens = hist(charcoal_prd19$Quantity, prob=TRUE,  
  main = "Produccion de carbon - densidad (2019)",  
  xlab = "Produccion (miles de ton. metricas)",  
  ylab = "Densidad", col="lightblue")
```



Verificando que el área total es 1

```
l_base    = diff(h_dens$breaks)  # base de cada rectangulo
l_altura  = h_dens$density        # altura de cada rectangulo
sum(l_base * l_altura)           # suma de areas = 1
```

```
## [1] 1
```

Esto no es casualidad: es una propiedad que **toda** curva de densidad debe cumplir, porque el 100% de los datos tiene que estar en algún lado.

Usando el histograma para calcular probabilidades

¿Qué probabilidad hay de elegir un país con producción entre 1000 y 1500 miles de toneladas? Basta multiplicar base $\times$ altura del rectángulo:

```
base_1000_1500 = 500
altu_1000_1500 = h_dens$density[h_dens$mids == 1250]
prob_A_hist     = base_1000_1500 * altu_1000_1500
paste0("P(1000 <= X <= 1500) aprox. ",
       round(100 * prob_A_hist, 2), "%")

## [1] "P(1000 <= X <= 1500) aprox. 4.05%"
```

Ejercicio 1


Ejercicio 1

Calcule la probabilidad del evento $B =$ “producción de carbón entre 0 y 500 miles de ton.” usando el histograma anterior.

```
## [1] "P(0 <= X <= 500) aprox. 79.05%"
```

El problema del histograma: ¿cuántas barras usar?

El resultado del histograma **cambia mucho** según el número de barras k que elijamos:



Pocas barras = imagen muy borrosa. Muchas barras = imagen muy ruidosa.

¿Por qué pasa esto?

El histograma decide la densidad de un punto x mirando **solo** si cae dentro de una barra o no — una regla muy rígida:

- Todos los puntos dentro de una misma barra reciben **exactamente** la misma densidad, sin importar si están al centro o al borde
- Dos puntos casi iguales, pero en barras vecinas, pueden recibir densidades muy distintas

Idea clave

El histograma solo pregunta "¿estás dentro o fuera de la barra?" — no tiene en cuenta *qué tan cerca* está un punto de otro.

Una idea mejor: pesos que dependen de la distancia

En vez de una regla de “dentro/fuera”, ¿qué tal si cada observación **le pasa algo de densidad a sus vecinos**, con más fuerza mientras más cerca estén?

Histograma	Nueva idea (KDE)
Peso 1 si esta en la barra	El peso baja suavemente con la distancia
Peso 0 si no	Ningun salto brusco
Resultado: escalones	Resultado: curva suave

Esta idea se llama **Estimación Kernel de la Densidad**, o **KDE**.


Imagina que ponemos una **pequeña campana** encima de cada dato observado, y luego sumamos todas esas campanitas:

- Donde hay muchos datos juntos, las campanas se apilan → curva alta
- Donde hay pocos datos, las campanas casi no se tocan → curva baja

El resultado es una curva continua y suave, sin los escalones del histograma.

Viendo la construcción paso a paso

Cada línea punteada es una “campanita” puesta sobre una observación (marcada en rojo); la línea negra es la suma de todas:



La forma de la campanita: el kernel gaussiano


La campanita más usada (y la que usa R por defecto) es, de nuevo, la curva normal:



Existen otras formas de campanita (triangular, rectangular, etc.), pero en la práctica la elección de la forma importa poco.

Lo que sí importa mucho: el ancho de la campanita

Lo verdaderamente importante no es la **forma** de la campanita, sino su **ancho**, llamado ancho de banda h :



h chico: curva muy ruidosa. h grande: curva muy plana, pierde detalle.

¿Cómo elige R el ancho de banda automáticamente?

Existen reglas automáticas para escoger h sin tener que adivinar. La más común es la **regla de Silverman**, que R usa por defecto:

```
# bw.nrd0() implementa la regla de Silverman en R
h_nrd0 = bw.nrd0(charcoal_prd19$Quantity)
h_sj   = bw.SJ(charcoal_prd19$Quantity)  # otra regla: Sheather-Jones
round(c(Silverman = h_nrd0, Sheather_Jones = h_sj), 2)

##           Silverman Sheather_Jones
##           83.72           11.10
```


Nota práctica

Para datos muy asimétricos (como los nuestros), la regla de Silverman puede "emparejar" demasiado la curva. `bw.SJ()` suele funcionar mejor en esos casos. Lo ideal es comparar ambas y usar criterio propio.

Comparando las dos reglas automáticas

```
x_plot = charcoal_prd19$Quantity
hist(x_plot, prob=TRUE, xlim=c(-500, 6500), ylim=c(0, 0.0030),
     main="Comparacion de anchos de banda", col="grey90", border="white")
lines(density(x_plot, bw=h_nrd0), col="steelblue", lwd=2)
lines(density(x_plot, bw=h_sj), col="tomato", lwd=2)
legend("topright", bty="n", lwd=2, cex=0.8,
     col=c("steelblue", "tomato"),
     legend=c("Silverman", "Sheather-Jones"))
```

Comparacion de anchos de banda



Las dos curvas son parecidas, pero Sheather-Jones (roja) sigue un poco más de cerca los datos cerca de cero.


La sintaxis de `density()` en R

```
density(  
  x,                                # vector de datos  
  bw      = "nrd0",                 # regla para elegir h (o un numero direct  
  kernel = "gaussian", # forma de la campanita  
  n       = 512                     # puntos donde se evalua la curva  
)
```

Con los valores por defecto, R ya nos da una KDE razonable, como la que hemos venido usando en las diapositivas anteriores.

KDE con los valores por defecto de R

```
hist(charcoal_prd19$Quantity, prob=TRUE,  
     ylim=c(0, 0.0030), xlim=c(-4, 6500),  
     main="Histograma + KDE - Produccion carbon 2019",  
     xlab="Produccion (miles de ton.)", ylab="Densidad",  
     col="lightblue", border="white")  
lines(density(charcoal_prd19$Quantity), lwd=2, col="tomato")
```



¿Qué nos muestra la KDE que el histograma no?

- Cerca de cero, la KDE muestra que la concentración de datos es todavía **más alta** de lo que sugería el histograma
- La probabilidad que calculamos antes con el histograma estaba algo sobreestimada
- Una limitación: la KDE puede “regalar” densidad a valores negativos, aunque la producción nunca sea negativa

Conexión con la Sesión 1


La producción de carbón es muy **asimétrica a la derecha** — lo mismo que vimos con el boxplot en la Sesión 1. La KDE lo confirma.

Ejercicio 2

Ejercicio 2

Para `charcoal_chh19` (consumo), elabore el histograma de densidad junto con la KDE de Quantity. ¿Se parece a la de producción? Compare también `bw.SJ()` contra la regla por defecto.

Histograma + KDE – Consumo carbon 2019



Ejercicio 3 (reto, opcional)

Ejercicio 3 — Reto

Usando el objeto que devuelve `density()` (tiene `$x` y `$y`), aproxime el área bajo la curva KDE de `charcoal_chh19` sumando pequeños rectángulos. ¿Se acerca a 1?

```
## [1] "Area total bajo la curva: 0.9991"
```


Para qué nos sirve todo esto

En resumen, tanto la densidad teórica como sus estimaciones (histograma, KDE) nos permiten:

- Calcular **probabilidades** como áreas bajo la curva
- Ver qué valores son **típicos** y cuáles son raros
- Sentar las bases de herramientas más avanzadas: pruebas de hipótesis, intervalos de confianza, etc. (temas de sesiones futuras)

5. Pensamiento bivariado: comparando dos variables

De un número a un par de números

Hasta ahora cada país nos daba **un solo número** (por ejemplo, su producción):

```
charcoal_prd19$Quantity[2]
```

```
## [1] 1159.8
```

```
charcoal_prd19$Country_Area[2]
```

```
## [1] "Angola"
```

Ahora cada país nos va a dar **dos números a la vez**: producción y consumo. A esto lo llamamos análisis **bivariado**.

Uniando producción y consumo en una sola tabla

```
charcoal_bivar =  
  charcoal_prd19 %>%  
    select(Country_Area, Charcoal_Production = Quantity) %>%  
  inner_join(  
    charcoal_chh19 %>%  
      select(Country_Area, Charcoal_Consumption = Quantity),  
    by = "Country_Area")  
  
charcoal_bivar %>% filter(Country_Area == "Argentina")  
  
## # A tibble: 1 x 3  
##   Country_Area Charcoal_Production Charcoal_Consumption  
##   <chr>          <dbl>          <dbl>  
## 1 Argentina      411            247
```

Argentina produce **411** pero consume **247** miles de ton. — es decir, exporta carbón.

Un par de valores por país

Ahora cada observación es una pareja (x_i, y_i) :

$$(x_i, y_i) = (\text{producción}_i, \text{consumo}_i)$$

donde x_i es la producción del país i y y_i su consumo.

Dos formas de mirar los mismos datos

Marginal: mirar X sola, o Y sola — como en la Sesión 1

Conjunta: mirar X y Y al tiempo — ¿se mueven juntas?

El análisis bivariado se enfoca en esta segunda mirada.

Repaso rápido: la covarianza

De la Sesión 1 recordamos que la **covarianza** nos dice si dos variables suben y bajan juntas:

$$\text{Cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Signo	Interpretación
Positiva	Cuando X sube, Y tiende a subir
Negativa	Cuando X sube, Y tiende a bajar
Cerca de 0	No hay relación lineal aparente

El problema de la covarianza

Limitación: el valor de la covarianza depende de las **unidades** de medida (toneladas, dólares, años. . .), así que es difícil comparar dos covarianzas entre sí.

Solución: la **correlación de Pearson**, que siempre vive entre -1 y 1 , sin importar las unidades originales.

La correlación de Pearson

La correlación r es la covarianza “reescalada” para que quede entre -1 y 1 :

$$r = \frac{\text{Cov}(X, Y)}{\sigma_X \cdot \sigma_Y} \in [-1, 1]$$


Funciones nativas de R para covarianza y correlacion

```
cov_xy = cov(charcoal_bivar$Charcoal_Production,  
             charcoal_bivar$Charcoal_Consumption)  
cor_xy = cor(charcoal_bivar$Charcoal_Production,  
             charcoal_bivar$Charcoal_Consumption)  
round(c(Covarianza = cov_xy, Correlacion = cor_xy), 3)
```

```
## Covarianza Correlacion
```

```
## 752861.088      0.857
```



Cómo leer distintos valores de r



$r = 1$: relación positiva perfecta $r = -1$: relación negativa perfecta $r = 0$:
sin relación lineal

La correlación en nuestros datos de carbón

```
ggplot(charcoal_bivar,
  aes(x=Charcoal_Production, y=Charcoal_Consumption)) +
  geom_point(alpha=0.5, color="steelblue") +
  geom_smooth(method="lm", color="tomato", se=FALSE, linewidth=0.8) +
  annotate("text", x=4200, y=350,
    label=paste0("r = ", round(cor_xy, 3)), color="tomato") +
  theme_minimal() +
  labs(x="Produccion (miles ton.)", y="Consumo (miles ton.)")
```




Una r alta y positiva: los países que más producen tienden a ser también los que más consumen.

El diagrama de dispersión

La forma más natural de “ver” la relación entre dos variables es el **diagrama de dispersión** (un punto por país):

```
plot(charcoal_bivar$Charcoal_Production,  
     charcoal_bivar$Charcoal_Consumption,  
     xlab = "Produccion (miles ton.)", ylab = "Consumo (miles ton.)",  
     pch = 19, col = adjustcolor("steelblue", 0.6))
```



¿Qué patrones podemos buscar en un diagrama de dispersión?


Patrón	Qué significa
Nube alargada (diagonal)	Relación lineal (positiva o negativa)
Forma de "U" o curva	Relación no lineal
Nube redonda, sin forma	No hay relación lineal
Forma de embudo	La dispersión cambia a lo largo del eje
Puntos muy alejados	Posibles atípicos bivariados

En nuestros datos vemos una **relación lineal positiva clara**, aunque la dispersión crece un poco para valores altos de producción.

Viendo las tres cosas al tiempo: conjunta + marginales

Podemos combinar el diagrama de dispersión con un histograma de cada variable al lado:

```
library(ggExtra)
g_base = ggplot(charcoal_bivar,
                aes(x=Charcoal_Production, y=Charcoal_Consumption)) +
  geom_point(alpha=0.5, color="steelblue") +
  theme_minimal() + labs(x="Produccion", y="Consumo")
ggMarginal(g_base, type="histogram")
```




- **Centro:** la relación **conjunta** entre producción y consumo
- **Margen de arriba:** distribución de consumo, ella sola (marginal de Y)
- **Margen del lado:** distribución de producción, ella sola (marginal de X)

Conexión con la Sesión 1

Ambas distribuciones marginales están **sesgadas a la derecha**, tal como vimos con el histograma y el boxplot en la Sesión 1: la mayoría de países produce y consume poco, y unos pocos mucho.


La misma idea, con KDE en los márgenes

```
ggMarginal(g_base, type="density")
```



La misma idea, con boxplots en los márgenes

```
ggMarginal(g_base, type="boxplot")
```



Los boxplots confirman lo que ya sabíamos: hay **valores atípicos** en ambas variables, consistente con la fuerte asimetría de la Sesión 1.

6. Síntesis

Lo que aprendimos hoy: probabilidad y densidad

- Las variables aleatorias nos permiten hablar de incertidumbre con números
- La **normal** es el modelo más importante, y depende de (μ, σ)
- El **histograma** y la **KDE** son formas de estimar la densidad con datos
- El área bajo la curva de densidad = probabilidad

Lo que aprendimos hoy: pensamiento bivariado

- Pasamos de mirar una variable a mirar **parejas** de variables (x_i, y_i)
- La **correlación de Pearson** r resume qué tan fuerte es la relación lineal entre dos variables
- El **diagrama de dispersión** es la herramienta visual más importante
- Las distribuciones **marginales** complementan la vista conjunta

Uniendo los hilos entre sesiones

Sesion 1	Sesion 2	Sesion 3
Una variable (histograma, boxplot)	Densidad de una variable	Normal Multivariada
Covarianza (2 var.)	Relacion entre 2 variables (r)	Estructura de varias variables

Puente hacia la Sesión 3

¿Qué sigue? De dos variables a muchas

Hoy trabajamos con **dos** variables al tiempo (producción y consumo). En la Sesión 3 daremos el siguiente paso natural: **muchas** variables a la vez.

Hoy (2 variables)	Sesión 3 (varias variables)
Un centro μ por variable	Un vector de centros
Una dispersión σ por variable	Una matriz de dispersión
Campana en 2D (dispersión + marginales)	Campana en muchas dimensiones

La idea, sin la fórmula completa

La distribución normal multivariada extiende exactamente la misma lógica que vimos hoy: un centro y una forma de dispersión, pero ahora para varias variables a la vez.

Conexión hacia adelante

El diagrama de dispersión de esta sesión es, en el fondo, una **fotografía en 2D** de esta idea más general. Ya construimos la intuición visual que necesitamos para la Sesión 3.

Preguntas para llevarnos a la Sesión 3

1. ¿Cómo se ve una “campana” en 3, 10 o 100 dimensiones?
2. Si ya no son 2 variables sino muchas, ¿cómo resumimos todas sus relaciones a la vez?
3. ¿Cómo detectamos un país “raro” cuando miramos varias variables juntas, no solo una?


Estas preguntas guiarán la **Sesión 3: Distribución Normal Multivariada**.

Anexo

Otra forma de ver la probabilidad acumulada

La **función de distribución acumulada** $F(x)$ nos dice qué proporción de datos es menor o igual a x : $F(x) = P(X \leq x)$. En R se calcula con `pnorm(x, mean, sd)`:

```
x = seq(-4, 4, length=200)
df_fda = tibble(x=x,
  "sigma=0.5" = pnorm(x, 0, 0.5),
  "sigma=1"   = pnorm(x, 0, 1),
  "sigma=2"   = pnorm(x, 0, 2)) %>%
  pivot_longer(-x, names_to="Parametro", values_to="Fx")
ggplot(df_fda, aes(x=x, y=Fx, color=Parametro)) +
  geom_line(linewidth=1) + theme_minimal() + labs(y="F(x)")
```



- Mendenhall, W., Beaver, R. J., & Beaver, B. M. (2012). *Introducción a la probabilidad y estadística*. Cengage Learning.
- Johnson, R. A., & Wichern, D. W. (2007). *Applied Multivariate Statistical Analysis* (6a ed.). Pearson.
- Wickham, H., & Golemund, G. (2017). *R for Data Science*. O'Reilly Media.
- Silverman, B. W. (1986). *Density Estimation for Statistics and Data Analysis*. Chapman & Hall.