

Análisis Estadístico de Datos

Sesión 3: Distribución Normal Multivariada

Profesor: Nicolás López

Universidad del Rosario

Puente con la Sesión 2

En la segunda sesión establecimos los fundamentos probabilísticos y bivariados:

- **Variables aleatorias:** discretas vs. continuas
- **Distribución normal** $\mathcal{N}(\mu, \sigma)$: familia paramétrica, regla 68-95-99.7, Teorema Central del Límite
- **Histograma y KDE** como estimadores empíricos de la fdp
- **Pensamiento bivariado:** del escalar al vector (x_i, y_i)
- **Correlación de Pearson** $r \in [-1, 1]$ y diagrama de dispersión

Lo prometido: 5 preguntas para hoy

Al cerrar la Sesión 2 dejamos cinco preguntas. Esta sesión las responde todas:

1. ¿Cómo se generaliza la campana normal a 3, 10 o 100 dimensiones?
2. ¿Cómo resumimos la relación entre **múltiples** variables con Σ ?
3. ¿Qué rol juega la **forma** de Σ en la distribución conjunta?
4. ¿Cómo detectamos **outliers multivariados** invisibles en las marginales?
5. ¿Cómo evaluamos si los datos siguen una distribución normal multivariada?

Tabla de contenidos

Puente con la Sesión 2

1. Cierre de la normal univariada
2. Estadística multivariada
3. Parámetros de la normal multivariada
4. Estructura de correlación
5. Estadísticos muestrales
6. Visualización de la normal multivariada
7. Distancia de Mahalanobis y outliers
8. El Q-Q plot y normalidad
9. Propiedades de la normal multivariada
10. Simulación de datos
11. Aplicaciones reales
12. Síntesis

Bibliografía


Anexo: Cálculo manual de estadísticos

1. Cierre de la normal univariada

La distribución con $\mu = 0$ y $\sigma = 1$ se llama **normal estándar** (Z):

$$f(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}z^2}, \quad -\infty < z < +\infty$$

```
ggplot() + xlim(-3.5, 3.5) +
  geom_function(fun=dnorm, args=list(mean=0, sd=1),
               color="tomato", linewidth=1.2) +
  geom_vline(xintercept=0, linetype="dashed", color="grey50") +
  theme_minimal() +
  labs(y="Densidad", x="z",
       title="Normal estandar Z ~ N(0,1)")
```



Cualquier $X \sim \mathcal{N}(\mu, \sigma)$ se transforma a la estándar:

$$Z = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1)$$

¿Para qué sirve?

- Comparar variables en **distintas unidades** en una escala común
- Calcular probabilidades con `pnorm()` sin necesidad de tablas
- Base conceptual de la estandarización **multivariada** con $\Sigma^{-1/2}$

```
set.seed(1)
edad = rnorm(200, mean=35, sd=8)
z     = (edad - mean(edad)) / sd(edad)
round(c(media_z = mean(z), sd_z = sd(z)), 5)
```

```
## media_z    sd_z
##         0         1
```

Parámetro vs. estadístico

Los parámetros (μ, σ) son usualmente **desconocidos** y se estiman con la muestra:

$$\hat{\mu} = \bar{x} = \frac{1}{n} \sum x_i \quad \hat{\sigma} = s = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n - 1}}$$

Distinción fundamental

Parametro (μ, σ) : fijo, propio de la **población**, desconocido.

Estadístico $(\bar{x}, s)$: calculado de la **muestra**, varía entre muestras.

Esta distinción se extiende al caso multivariado: $(\vec{\mu}, \Sigma)$ son parámetros; $(\bar{\mathbf{x}}, S)$ son sus estimadores.

Otras distribuciones de probabilidad

La normal no es la única. Algunas distribuciones frecuentes:

Distribucion	Tipo	Parametros	Uso tipico
Normal	Continua	μ, σ	Fenomenos simetricos
Exponencial	Continua	λ	Tiempos de espera
Chi-cuadrado	Continua	k g.l.	Pruebas de hipotesis
t Student	Continua	ν g.l.	Medias, n pequeno
F Fisher	Continua	d_1, d_2	Comparacion varianzas
Binomial	Discreta	n, p	N. exitos en n ensayos
Poisson	Discreta	λ	Conteo de eventos raros

Nota

El foco del curso es la familia **normal**, fundamento de la mayoría de técnicas del análisis multivariado clásico.

2. Estadística multivariada

¿Qué es la estadística multivariada?

Definición

Conjunto de herramientas que permiten analizar **mas de una variable** sobre las mismas unidades estadísticas (UE), buscando explorar su **interrelacion** (Díaz Monroy & Morales Rivera, 2012).

¿Por qué no analizar cada variable por separado?

- Las variables suelen estar **correlacionadas**: analizarlas aisladas pierde información
- Los fenómenos del mundo real son inherentemente **multidimensionales**
- Algunos patrones (outliers, grupos, estructuras) solo son visibles en el **espacio conjunto**

La matriz de datos $\mathbb{X}$

El objeto central es la **matriz de datos** de dimensión $n \times p$:

$$\mathbb{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}$$

Elemento	Interpretacion
Fila i	Vector de observaciones del individuo i
Columna j	Realizaciones de la variable j
x_{ij}	Valor de la variable j para el individuo i

Notación: filas, columnas y vector aleatorio

Individuo i (vector fila $1 \times p$): $\mathbf{x}_{i.} = [x_{i1}, x_{i2}, \dots, x_{ip}]$

Variable j (vector columna $n \times 1$): $\mathbf{x}_{.j} = [x_{1j}, x_{2j}, \dots, x_{nj}]^\top$

Vector aleatorio p -dimensional:

$$\vec{X} = (X_1, X_2, \dots, X_p)^\top$$

Univariado	Multivariado
Escalar $X \in \mathbb{R}$	Vector $\vec{X} \in \mathbb{R}^p$
Observacion x_i	Observacion $\mathbf{x}_{i.}$
Muestra $x_1, \dots, x_n$	Matriz $\mathbb{X} (n \times p)$
fdp $f(x \mid \mu, \sigma)$	fdp conjunta $f(\vec{x} \mid \vec{\mu}, \Sigma)$

3. Parámetros de la normal multivariada

Si $\vec{X} \sim \mathcal{N}_p(\vec{\mu}, \Sigma)$, el primer parámetro es:

$$\vec{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix} \quad \text{donde} \quad \mu_j = E[X_j]$$

Interpretación geométrica: $\vec{\mu}$ es el **centroide** de la distribución — el punto en $\mathbb{R}^p$ alrededor del cual se concentra la masa de probabilidad.

Es la generalización directa de μ en el caso univariado: así como μ es el centro de la campana en 1D, $\vec{\mu}$ es el centro del elipsoide en p D.

Matriz de covarianza Σ

El segundo parámetro es la **matriz de covarianza** de dimensión $p \times p$:

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix}$$

- **Diagonal:** $\sigma_{jj} = \text{Var}(X_j)$ — varianzas de cada variable
- **Fuera de diagonal:** $\sigma_{jk} = \text{Cov}(X_j, X_k)$
- Σ es **simétrica** ($\sigma_{jk} = \sigma_{kj}$) y semidefinida positiva
- Contiene p varianzas y $\binom{p}{2}$ covarianzas únicas

Respuesta 2: Σ resume toda la estructura de relaciones

Respuesta a la Pregunta 2

Σ codifica **toda** la variabilidad y correlación lineal entre las p variables en una sola matriz.

Ejemplo $p = 3$:

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \sigma_{13} \\ \sigma_{12} & \sigma_2^2 & \sigma_{23} \\ \sigma_{13} & \sigma_{23} & \sigma_3^2 \end{bmatrix}$$

3 varianzas en la diagonal + 3 covarianzas únicas = 6 parámetros en total.

En general para p variables: $p + \binom{p}{2} = \frac{p(p+1)}{2}$ parámetros en Σ .

$$f(\vec{x} \mid \vec{\mu}, \Sigma) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\vec{x} - \vec{\mu})^\top \Sigma^{-1}(\vec{x} - \vec{\mu})\right)$$

Componente	Rol
$(2\pi)^{p/2} \Sigma ^{1/2}$	Constante de normalizacion (area = 1)
$ \Sigma $	Determinante: "volumen" de la distribucion
$(\vec{x} - \vec{\mu})^\top \Sigma^{-1}(\vec{x} - \vec{\mu})$	Distancia de Mahalanobis ²

Cuando $\vec{\mu} = \vec{0}$ y $\Sigma = I_p$, las p componentes son **independientes**:


$$f(\vec{z} \mid \vec{0}, I_p) = \prod_{i=1}^p \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}z_i^2}$$

```

set.seed(42)
z_std = as.data.frame(mvrnorm(800, mu=c(0,0), Sigma=diag(2)))
colnames(z_std) = c("Z1", "Z2")
ggplot(z_std, aes(x=Z1, y=Z2)) +
  geom_point(alpha=0.18, size=0.6, color="steelblue") +
  geom_density_2d(color="tomato", linewidth=0.5) +
  coord_fixed() + theme_minimal(base_size=9) +
  labs(title="Normal estandar bivariada N2(0, I)",
        subtitle="Contornos circulares = independencia")

```

Normal estandar bivariada $N_2(0, I)$
 Contornos circulares = independencia



4. Estructura de correlación

Respuesta 3: el rol geométrico de Σ


Respuesta a la Pregunta 3

La **forma** y **orientación** del elipsoide de densidad están completamente determinadas por Σ . μ solo controla su **ubicación** en $\mathbb{R}^p$.

Estructura de Σ	Forma del elipsoide
$\Sigma = I_p$ (identidad)	Círculos / esferas
Diagonal con valores distintos	Elipses alineadas con los ejes
Covarianza positiva fuera diagonal	Elipses rotadas en sentido +
Covarianza negativa fuera diagonal	Elipses rotadas en sentido -


Contornos bajo distintas estructuras de Σ

Forma del elipsoide segun la estructura de Sigma



Panel completo: distintos valores de correlación

Contornos para distintos valores de correlacion



5. Estadísticos muestrales

Estimación de $\vec{\mu}$ y Σ

Al igual que en el caso univariado, los parámetros se estiman con los datos:

Vector de medias muestral (estimador de $\vec{\mu}$):

$$\bar{\mathbf{x}} = \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \vdots \\ \bar{x}_p \end{bmatrix} \quad \text{con} \quad \bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}$$

Covarianza muestral entre variables j y k (estimador de σ_{jk}):

$$s_{jk} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k)$$

Cuando $j = k$, s_{jj} es la **varianza muestral** de la variable j .

Ejercicio 1: datos de salud

Muestra de $n = 1000$ individuos, $p = 4$ variables: edad, estatura, peso y perímetro abdominal.

```
X = read_delim("health_data.csv", show_col_types=FALSE)
head(X, 3)
```

```
## # A tibble: 3 x 4
##   Edad Estatura  Peso Perimetro_abdominal
##   <dbl>   <dbl> <dbl>          <dbl>
## 1    36    178.  81.3          106.
## 2    34    165.  72.7          101.
## 3    26    187.  88.8          114.
```

Vector de medias y matriz de covarianza en R

```
# Vector de medias
```

```
colMeans(X)
```

```
##           Edad           Estatura           Peso Perimetro_abdominal
##           35.4020           175.6458           77.9449           102.3585
```

```
# Matriz de varianzas y covarianzas (p x p)
```

```
round(cov(X), 2)
```

```
##           Edad Estatura  Peso Perimetro_abdominal
## Edad           121.37   -8.50  6.68                0.36
## Estatura       -8.50    87.88 39.90                5.71
## Peso           6.68    39.90 81.53                98.91
## Perimetro_abdominal 0.36     5.71 98.91            150.36
```


La diagonal son las **varianzas**; fuera de la diagonal, las **covarianzas**. La matriz es simétrica por definición.

6. Visualización de la normal multivariada

Ejercicio 2: diagrama de dispersión bivariado


Retomando lo aprendido en la Sesión 2, comenzamos con el diagrama de dispersión entre dos variables:

```
plot(X$Peso, X$Perimetro_abdominal,  
     main="Peso vs. Perimetro abdominal",  
     xlab="Peso (kg)", ylab="Perimetro (cm)",  
     pch=19, cex=0.4,  
     col=adjustcolor("steelblue", 0.4))
```



Densidad univariada marginal de cada variable

```
X %>%
  pivot_longer(everything(),
               names_to="Variable", values_to="Valor") %>%
  ggplot(aes(x=Valor)) +
  geom_density(fill="steelblue", alpha=0.25,
              color="steelblue", linewidth=0.7) +
  facet_wrap(~Variable, scales="free") +
  theme_minimal(base_size=8) +
  labs(x="", y="Densidad",
       title="Densidad marginal por variable")
```



Interpretación de las densidades marginales

Cada densidad marginal presenta indicios de normalidad:


- **Unimodalidad:** un solo pico bien definido
- **Simetría aproximada:** colas similares a izquierda y derecha
- **Colas ligeras:** la masa decae progresivamente

Advertencia importante

La normalidad **marginal** de cada variable es condición **necesaria pero no suficiente** para la normalidad **conjunta**. Existen distribuciones conjuntas no normales cuyas marginales son normales. La evaluación completa requiere herramientas multivariadas.

Matriz de dispersión: pairs.panels()

```
library(psych)
pairs.panels(X, scale=FALSE, density=TRUE,
  method="pearson", cor=TRUE, jiggle=FALSE)
```



El gráfico es un arreglo $p \times p = 4 \times 4$:


Zona	Contenido
Diagonal	Histograma + KDE marginal de cada variable
Triángulo inf.	Diagrama de dispersion entre cada par
Triángulo sup.	Correlacion de Pearson r entre cada par

Las nubes elípticas en los diagramas de dispersión y las distribuciones marginales con forma de campana son indicios de normalidad multivariada.

Gráfico de contorno bivariado

```
ggplot(X, aes(x=Edad, y=Peso)) +  
  geom_point(alpha=0.25, size=0.6, color="steelblue") +  
  geom_density_2d(color="tomato", linewidth=0.6) +  
  theme_minimal() +  
  labs(title="Contornos de densidad: Edad vs. Peso",  
       x="Edad (anos)", y="Peso (kg)")
```

Contornos de densidad: Edad vs. Peso



Densidad bivariada en 3D (solo en RStudio)

Este grafico interactivo solo renderiza en RStudio o HTML. La campana sobre el vector (102, 79) apunta hacia la normalidad bivariada del par (Perimetro abdominal, Peso). Esta visualizacion es un **indicio grafico**, no una prueba formal.

```
library(plotly)
dens = kde2d(X$Perimetro_abdominal, X$Peso)
plot_ly(x=dens$x, y=dens$y, z=dens$z) %>% add_surface()
```


7. Distancia de Mahalanobis y outliers

Del caso univariado al multivariado

En la Sesión 1 vimos que un outlier univariado es un valor que cae **lejos de la media**, medido en unidades de desviación estándar:

$$z_i = \frac{x_i - \bar{x}}{s} \quad \text{outlier si } |z_i| > 3$$

Esta es la **distancia estandarizada univariada**. Elevada al cuadrado:

$$z_i^2 = \frac{(x_i - \bar{x})^2}{s^2}$$

Resultado fundamental

Si $X \sim \mathcal{N}(\mu, \sigma)$, entonces $Z = (X - \mu)/\sigma \sim \mathcal{N}(0, 1)$ y por lo tanto:

$$Z^2 \sim \chi_1^2 \quad (\text{chi-cuadrado con 1 grado de libertad})$$

El cuadrado de una normal estandar sigue una distribucion chi-cuadrado con 1 g.l.

Generalización: la distancia de Mahalanobis

La distancia de Mahalanobis extiende z_i^2 al caso p -dimensional, **teniendo en cuenta** la correlación entre variables:

$$d_M^2(\mathbf{x}_i) = (\mathbf{x}_i - \bar{\mathbf{x}})^\top S^{-1}(\mathbf{x}_i - \bar{\mathbf{x}})$$


Univariado	Multivariado
$z_i^2 = (x_i - \bar{x})^2 / s^2$	$d_M^2 = (\mathbf{x}_i - \bar{\mathbf{x}})^\top S^{-1}(\mathbf{x}_i - \bar{\mathbf{x}})$
$z_i^2 \sim \chi_1^2$	$d_M^2 \sim \chi_p^2$
Umbral $z^2 = 9$ (i.e. $ z > 3$)	Umbral $\chi_p^2(0.975)$

Propiedades: - Adimensional: no depende de las unidades de medida -
Para $p = 1$: se reduce exactamente a z_i^2

Outliers invisibles en las marginales

Respuesta a la Pregunta 4

Un punto puede ser normal en cada variable marginal y ser al mismo tiempo un **outlier multivariado**, invisible en histogramas y boxplots individuales.



Cálculo de la distancia de Mahalanobis en R

```
# mahalanobis() devuelve d^2 para cada observacion
d2 = mahalanobis(X,
                  center = colMeans(X),
                  cov     = cov(X))


# Umbral: percentil 97.5 de chi^2 con p = 4 g.l.
umbral = qchisq(0.975, df=ncol(X))
n_outliers = sum(d2 > umbral)

paste0("Outliers detectados: ", n_outliers,
       " / ", nrow(X),
       " (umbral chi2 = ", round(umbral, 2), ")")

## [1] "Outliers detectados: 34 / 1000 (umbral chi2 = 11.14)"
```

Visualización de outliers multivariados

```
tibble(indice=seq_along(d2), d2=d2,  
       outlier = d2 > umbral) %>%  
ggplot(aes(x=indice, y=d2, color=outlier)) +  
  geom_point(size=0.6, alpha=0.7) +  
  geom_hline(yintercept=umbral,  
            linetype="dashed", color="tomato", linewidth=0.8) +  
  scale_color_manual(values=c("steelblue", "tomato")) +  
  theme_minimal(base_size=9) +  
  labs(x="Individuo", y="d^2 (Mahalanobis)",  
       title="Deteccion de outliers multivariados", color="Outlier")
```



8. El Q-Q plot y normalidad

¿Por qué importa el Q-Q plot?

Motivacion

El Q-Q plot es la herramienta gráfica más usada para evaluar si un conjunto de datos sigue una distribución teórica. En este curso la usaremos para verificar normalidad — supuesto central de casi todas las técnicas multivariadas.

Idea central: si los datos $x_1, \dots, x_n$ provienen realmente de una $\mathcal{N}(\mu, \sigma)$, sus valores ordenados deben parecerse a los **cuantiles teóricos** de esa distribución normal.

Graficando cuantiles empíricos (datos) vs. cuantiles teóricos (normal), esperamos ver una **nube de puntos sobre la recta** $y = x$.

Cualquier desviación sistemática de esa recta revela que los datos **no son normales**: sesgo, colas pesadas, bimodalidad, etc.

Ejemplo paso a paso: estaturas de 10 estudiantes

Suponga que medimos la estatura (en cm) de 10 estudiantes:

168, 172, 165, 180, 170, 175, 163, 178, 169, 174

Paso 1 — Ordenar los datos de menor a mayor:

i	1	2	3	4	5	6	7	8	9	10
$x_{(i)}$	163	165	168	169	170	172	174	175	178	180

Paso 2 — Estandarizar con $\bar{x} = 171.4$ y $s = 5.46$:

i	1	2	3	4	5	6	7	8	9	10
$z_{(i)}$	-1.54	-1.17	-0.62	-0.44	-0.26	0.11	0.48	0.66	1.21	1.57

Paso 3: calcular los cuantiles teóricos

Para $n = 10$ datos, los **puntos de probabilidad** son:

$$p_i = \frac{i - 0.5}{n} \Rightarrow p_1 = 0.05, p_2 = 0.15, \dots, p_{10} = 0.95$$

Los **cuantiles teóricos** son $q_i = \Phi^{-1}(p_i)$, es decir, `qnorm(p_i)`:

i	1	2	3	4	5	6	7	8	9	10
p_i	.05	.15	.25	.35	.45	.55	.65	.75	.85	.95
q_i	-1.64	-1.04	-0.67	-0.39	-0.13	0.13	0.39	0.67	1.04	1.64

Paso 4: armar la tabla final y graficar


Cada punto del Q-Q plot es el par $(q_i, z_{(i)})$:

i	Cuantil teórico q_i	Cuantil empírico $z_{(i)}$
1	-1.64	-1.54
2	-1.04	-1.17
3	-0.67	-0.62
4	-0.39	-0.44
5	-0.13	-0.26
6	0.13	0.11
7	0.39	0.48
8	0.67	0.66
9	1.04	1.21
10	1.64	1.57

Si los pares $(q_i, z_{(i)})$ caen sobre la recta $y = x$, los datos son consistentes con la normal.

Paso 5: el gráfico resultante

```
q_teo = c(-1.64,-1.04,-0.67,-0.39,-0.13,0.13, 0.39, 0.67, 1.04, 1.64)
z_emp = c(-1.54,-1.17,-0.62,-0.44,-0.26,0.11, 0.48, 0.66, 1.21, 1.57)
ggplot(data.frame(q_teo, z_emp), aes(x=q_teo, y=z_emp)) +
  geom_point(size=2.5, color="steelblue") +
  geom_abline(slope=1, intercept=0,color="tomato", linewidth=0.9) +
  geom_text(aes(label=paste0("(",round(q_teo,2),",",
                             round(z_emp,2),")")),
            size=1.8, vjust=-0.7, color="grey40") +
  theme_minimal(base_size=9) +
  labs(x="Cuantiles teóricos N(0,1)",y="Cuantiles empíricos (z estandarizados)",
       title="Q-Q plot manual: estaturas de 10 estudiantes",
       subtitle="Puntos cercanos a la recta = evidencia de normalidad")
```



Los 10 puntos se distribuyen **cerca de la recta** $y = x$:

- Los puntos extremos ($i = 1$ e $i = 10$) se alejan levemente — normal con $n = 10$, no es evidencia contra la normalidad
- No hay curvatura sistemática ni puntos muy alejados
- Conclusión: los datos son **consistentes con una distribución normal**

Regla practica de lectura


- Puntos **sobre la recta**: normalidad
- **Curva en S**: datos sesgados (asimetria)
- **Cola superior alejada**: colas más pesadas que la normal
- **Punto(s) aislados** lejos de la recta: outliers

Q-Q plot con R: qqnorm() y qqline()

```
estaturas = c(168,172,165,180,170,175,163,178,169,174)
qqnorm(estaturas, pch=19, col="steelblue",
       main="Q-Q plot: estaturas de 10 estudiantes",
       xlab="Cuantiles teoricos N(0,1)",
       ylab="Cuantiles empiricos")
qqline(estaturas, col="tomato", lwd=2)
```


Cuantiles empiricos

Q-Q plot: estaturas de 10 estudiantes



Tres patrones posibles en el Q-Q plot

Patrones en el Q-Q plot segun la distribucion subyacente



- **Normal:** puntos sobre la recta
- **Sesgado:** curvatura en arco (los extremos se desvían hacia el mismo lado)
- **Colas pesadas:** los extremos se alejan en direcciones opuestas

Del Q-Q univariado al multivariado

El puente es el resultado que ya conocemos:

$$Z^2 \sim \chi_1^2 \quad \xrightarrow{\text{generaliza a}} \quad d_M^2 \sim \chi_p^2$$

Construcción del Q-Q plot multivariado — mismos 5 pasos, diferente distribución de referencia:

1. Calcular $d_M^2(\mathbf{x}_i)$ para cada individuo
2. Ordenar: $\{d_M^2\}_{(1)} \leq \{d_M^2\}_{(2)} \leq \dots \leq \{d_M^2\}_{(n)}$
3. Calcular cuantiles teóricos de χ_p^2 en los puntos $p_i = (i - 0.5)/n$
4. Graficar cuantiles empíricos vs. teóricos
5. Normalidad multivariada $\Leftrightarrow$ puntos sobre la recta $y = x$

Respuesta 5: Q-Q plot multivariado

Respuesta a la Pregunta 5


El Q-Q plot de d_M^2 vs. χ_p^2 es la herramienta grafica estandar para evaluar normalidad multivariada.

```

p_var = ncol(X); n_obs = nrow(X)
qt_teo_mv = qchisq(ppoints(n_obs), df=p_var)
qt_emp_mv = sort(d2)
ggplot(data.frame(teo=qt_teo_mv, emp=qt_emp_mv),
      aes(x=teo, y=emp)) +
  geom_point(size=0.7, alpha=0.5, color="steelblue") +
  geom_abline(slope=1, intercept=0,
      color="tomato", linewidth=0.8) +
  theme_minimal(base_size=9) +
  labs(x=paste0("Cuantiles teóricos  $\chi^2$  (", p_var, " g.l.)"),
      y="Cuantiles empíricos  $d^2$ ",
      title="Q-Q plot multivariado - datos de salud")

```

Q-Q plot multivariado – datos de salud



¿Qué buscar?

- **Puntos sobre la recta:** datos consistentes con $\mathcal{N}_p$
- **Puntos alejados en la cola superior:** candidatos a outliers multivariados
- **Curvatura hacia arriba:** colas mas pesadas (curtosis alta)
- **Curvatura hacia abajo:** colas mas ligeras que la normal
- **Curvatura en S:** asimetria en la distribucion conjunta

Nota

El Q-Q plot es un metodo **grafico**, no una prueba formal. Pruebas formales como Mardia (1970) o Henze-Zirkler (1990) están disponibles en el paquete MVN de R. Para los datos de salud, la alineación aproximada es un indicio favorable.

9. Propiedades de la normal multivariada

Propiedad 1: Linealidad

Propiedad de linealidad

Si $\vec{X} \sim \mathcal{N}_p(\vec{\mu}, \Sigma)$, para cualquier matriz A ($q \times p$) y vector $\mathbf{b}$ ($q \times 1$):

$$\vec{Y} = A\vec{X} + \mathbf{b} \sim \mathcal{N}_q(A\vec{\mu} + \mathbf{b}, A\Sigma A^\top)$$

Consecuencias clave:

- Cualquier **combinacion lineal** de variables normales multivariadas es normal
- Las **marginales** de una $\mathcal{N}_p$ son normales univariadas
- Base de tecnicas como regresion multivariada, MANOVA y componentes principales

Propiedad 2: Estandarización multivariada

Propiedad de estandarización

Si $\vec{X} \sim \mathcal{N}_p(\vec{\mu}, \Sigma)$ con Σ no singular:

$$\vec{Z} = \Sigma^{-1/2}(\vec{X} - \vec{\mu}) \sim \mathcal{N}_p(\vec{0}, I_p)$$

Analogía directa con el caso univariado:

$$\underbrace{Z = \frac{X - \mu}{\sigma}}_{\text{univariado: } Z \sim \mathcal{N}(0,1)} \longleftrightarrow \underbrace{\vec{Z} = \Sigma^{-1/2}(\vec{X} - \vec{\mu})}_{\text{multivariado: } \vec{Z} \sim \mathcal{N}_p(\vec{0}, I_p)}$$

Ambas transformaciones **centran** en cero y **normalizan** la escala, convirtiendo el elipsoide en una esfera / la campana en estándar.

10. Simulación de datos

Simulación con mvrnorm()

La función `mvrnorm()` del paquete MASS genera muestras de $\mathcal{N}_p(\vec{\mu}, \Sigma)$:

```
mi_mu      = c(0, 0)
mi_Sigma   = matrix(c(1, 0.6, 0.6, 1), ncol=2)


set.seed(42)
M_norm = mvrnorm(n=500, mu=mi_mu, Sigma=mi_Sigma)
head(M_norm, 3)
```

```
##           [,1]      [,2]
## [1,]  0.7659768  1.68646823
## [2,] -0.9141812 -0.09598164
## [3,]  0.3258904  0.32369345
```

Distintas estructuras de correlación simuladas

```
set.seed(42)
mu0 = c(0, 0)
# Visualizamos solo r = -0.8 y r = 0.8 para que caben en la diapo
for (r in c(-0.8, 0, 0.8)){
  Sr = matrix(c(1, r, r, 1), ncol=2)
  M = mvnrm(n=400, mu=mu0, Sigma=Sr)
  pairs.panels(M, main=paste0("Correlacion = ", r),
    density=TRUE, method="pearson",
    cor=TRUE, scale=FALSE, jiggle=FALSE)
}
```

Correlacion = -0.8



Correlacion = 0

Para cada valor de r simulado:

- **Diagonal:** KDE marginal siempre normal, independientemente de r
- **Dispersión:** nube circular ($r = 0$) o lineal ($|r| \rightarrow 1$)
- **Correlacion reportada:** debe coincidir con el r especificado en Σ

Actividad

Modifique `mi_Sigma` usando varianzas distintas en la diagonal, por ejemplo $\sigma_1^2 = 4$, $\sigma_2^2 = 1$, y observe cómo el elipsoide se estira en la dirección de mayor varianza.

11. Aplicaciones reales

La distribución normal en la vida cotidiana

La distribución normal aparece en fenómenos cotidianos que vivimos sin notarlo:

- **Tallas de ropa y calzado:** los fabricantes diseñan inventarios con base en la distribución normal de estaturas y pesos de la población objetivo. Las tallas “M” y “L” cubren el 68 % central ($\mu \pm \sigma$); “XS” y “XL” cubren las colas.
- **Pruebas Saber / ICFES:** los puntajes de las pruebas de Estado están diseñados para seguir una distribución aproximadamente normal alrededor de la media nacional, lo que permite ubicar a un estudiante dentro de la distribución de todos los presentantes.
- **Errores de medición:** cualquier instrumento de medición (báscula, termómetro, GPS, glucómetro) comete errores pequeños y simétricos alrededor del valor verdadero — errores que siguen una distribución normal.

- **Presion arterial y valores de laboratorio:** la medicina define rangos “normales” (e.g. colesterol, glucosa) usando percentiles de distribuciones aproximadamente normales en poblaciones saludables.
- **Control de calidad:** una fábrica de pastillas que debe dosificar 500 mg modela la variación del proceso como $\mathcal{N}(500, \sigma^2)$ y usa la regla $\mu \pm 3\sigma$ para detectar lotes fuera de especificación.

- **Valor en Riesgo (VaR):** los bancos calculan cuánto dinero pueden perder en un día “normal” usando cuantiles de la distribución normal. La regulación bancaria (Basilea III) usa este concepto.
- **Seguros de vida:** las aseguradoras modelan la distribución de reclamaciones para fijar primas. Si una cartera de riesgos es suficientemente grande, el TCL garantiza que el total de reclamaciones se aproxima a la normal.

La normal multivariada: más allá de una sola variable

La distribución normal multivariada tiene aplicaciones aún más poderosas cuando las variables están correlacionadas:

- **Medicina personalizada:** un perfil de paciente (*edad, IMC, presión, glucosa*) se modela como un vector aleatorio. La distancia de Mahalanobis identifica pacientes atípicos que merecen atención prioritaria — exactamente el ejercicio de hoy.
- **Detección de fraude:** las transacciones bancarias (*monto, hora, ubicación, frecuencia*) se modelan con una $\mathcal{N}_p$ bajo comportamiento “normal”. Una transacción con d_M^2 alto es candidata a fraude.
- **Recomendaciones:** sistemas de Netflix o Spotify modelan los gustos de un usuario como un vector en un espacio de alta dimensión. La similitud entre usuarios usa distancias que generalizan la Mahalanobis.

- **Manufactura avanzada:** el control estadístico de procesos (SPC) monitorea simultáneamente múltiples variables de calidad (*temperatura, presión, viscosidad*) usando la estadística T^2 de Hotelling, que no es más que $n \cdot d_M^2$ bajo $\mathcal{N}_p$.
- **Inteligencia artificial:** los modelos generativos modernos (VAEs, diffusion models) aprenden distribuciones de alta dimension que localmente se aproximan a distribuciones normales multivariadas.

De los datos de carbón a las aplicaciones

Volviendo a nuestro conjunto de datos del curso, los mismos conceptos aplican:

- El **diagrama de dispersión** de producción vs. consumo de carbón es exactamente una proyección 2D de la distribución conjunta $(X_{\text{prod}}, X_{\text{cons}})$
- La **correlación** $r \approx 0.9$ que observamos indica que Σ tiene covarianza alta fuera de la diagonal
- Un país con producción muy alta pero consumo muy bajo sería un **outlier multivariado** detectable con d_M^2 aunque ninguna de las dos variables sea extrema por separado
- En política energética, modelar múltiples variables $(\text{produccion}, \text{consumo}, \text{exportacion}, \text{precio})$ conjuntamente bajo $\mathcal{N}_4$ permitiría detectar países con perfiles energéticos atípicos

12. Síntesis

Respuestas a las 5 preguntas

Pregunta	Respuesta
1. Campana en pD	fdp con exponente de Mahalanobis; elipsoide en $\mathbb{R}^p$
2. Relaciones en Σ	p varianzas + $\binom{p}{2}$ covarianzas en una sola matriz
3. Rol de Σ	Forma y orientacion del elipsoide de densidad
4. Outliers multivariados	$d_M^2 > \chi_p^2(0.975)$; invisibles en las marginales
5. Evaluar normalidad	Q-Q plot de d_M^2 vs. cuantiles de χ_p^2

Conclusiones de la Sesión 3

- La $\mathcal{N}_p(\vec{\mu}, \Sigma)$ generaliza la campana univariada: $\vec{\mu}$ ubica el elipsoide, Σ define su forma y orientacion
- Σ es el objeto central del analisis multivariado: codifica toda la estructura de variabilidad y correlacion
- $\bar{\mathbf{x}}$ y S son los estimadores muestrales de $\vec{\mu}$ y Σ
- La distancia de Mahalanobis generaliza $z^2 \sim \chi_1^2$ al caso p -dimensional: $d_M^2 \sim \chi_p^2$
- El Q-Q plot (univariado y multivariado) es la herramienta grafica para evaluar normalidad
- La distribucion normal tiene aplicaciones en salud, finanzas, ingenieria, tecnologia y vida cotidiana

Conexión entre las tres sesiones

Sesion 1	Sesion 2	Sesion 3
Distribución univariada (hist., KDE, medidas desc.)	Funcion de densidad, KDE, TCL	Normal Multivariada $\mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$
Outliers $(\mu \pm 3\sigma)$	Covarianza y correlacion r	Mahalanobis $d_M^2 \sim \chi_p^2$
Q-Q univariado (nuevo)	Pensamiento bivariado	Q-Q multivariado (normalidad conjunta)

Bibliografía

1. Díaz Monroy, L. G., & Morales Rivera, M. A. (2012). *Análisis estadístico de datos multivariados*. UNAL.
2. Everitt, B., & Hothorn, T. (2011). *Applied Multivariate Analysis with R*. Springer.
3. Johnson, R. A., & Wichern, D. W. (2007). *Applied Multivariate Statistical Analysis* (6a ed.). Pearson.
4. Blanco Castañeda, L. (2013). *Probabilidad*. Editorial UN.
5. Mood, A. M. (1950). *Introduction to the Theory of Statistics*. McGraw-Hill.

Anexo: Cálculo manual de estadísticos

Cálculo manual del vector de medias

El siguiente código calcula el vector de medias variable por variable. En la práctica siempre se usa `colMeans()`:

```
n      = nrow(X)
nombres = colnames(X)
x_mean = c()
for (i in nombres){
  prom  = mean(X[[i]])
  x_mean = c(x_mean, prom)
  cat("Promedio de", i, ":", round(prom, 3), "\n")
}
```

```
## Promedio de Edad : 35.402
## Promedio de Estatura : 175.646
## Promedio de Peso : 77.945
## Promedio de Perimetro_abdominal : 102.359
names(x_mean) = nombres
```

Cálculo manual de la matriz de covarianza

```
p = ncol(X)
S = matrix(NA, nrow=p, ncol=p)
for (j in 1:p){
  for (k in 1:p){
    S[j,k] = 1/(n-1) *
      sum((X[[nombres[j]]] - x_mean[nombres[j]]) *
          (X[[nombres[k]]] - x_mean[nombres[k]]))
  }
}
rownames(S) = colnames(S) = nombres
round(S, 2)
```

```
##              Edad Estatura  Peso Perimetro_abdominal
## Edad          121.37    -8.50  6.68                  0.36
## Estatura      -8.50    87.88 39.90                  5.71
## Peso          6.68    39.90 81.53                  98.91
## Perimetro_abdominal 0.36    5.71 98.91             150.36
```

Este cálculo es meramente pedagógico — `cov()` lo realiza de forma eficiente y robusta. El resultado debe ser idéntico al obtenido en la

Sección 5.