

Análisis Estadístico de Datos

Sesión 3: Distribución Normal Multivariada

Profesor: Nicolás López

Universidad del Rosario

Puente con la Sesión 2

En la segunda sesión sentamos las bases para hoy:

- **Variables aleatorias:** discretas vs. continuas
- **Distribución normal** $\mathcal{N}(\mu, \sigma)$: la campana, regla 68-95-99.7
- **Histograma y KDE:** dos formas de estimar la campana con datos reales
- **Pensamiento bivariado:** pasar de mirar una variable a mirar dos al tiempo
- **Correlación de Pearson** $r \in [-1, 1]$ y el diagrama de dispersión

De dos variables a muchas

Hasta ahora comparamos **dos** variables a la vez (ej. peso vs. estatura).

La pregunta natural de hoy: ¿qué pasa cuando queremos analizar **muchas** variables al mismo tiempo, todas relacionadas entre sí?

Ejemplo cotidiano

Un chequeo médico no mide solo el peso: mide edad, estatura, peso, presión arterial, glucosa... y esas variables **no son independientes**. Analizarlas juntas revela cosas que ninguna por separado muestra.

Lo prometido: 4 preguntas para hoy

Esta sesión responde cuatro preguntas guía:

1. ¿Cómo se generaliza la campana normal a muchas variables a la vez?
2. ¿Cómo resumimos cómo se relacionan **varias** variables en un solo objeto?
3. ¿Cómo detectamos **valores atípicos** que no se ven mirando una variable a la vez?
4. ¿Cómo revisamos, con un gráfico simple, si los datos parecen normales?

Tabla de contenidos

Puente con la Sesión 2

1. Repaso rápido: la normal de una variable
2. Pensando en varias variables a la vez
3. La campana en muchas dimensiones
4. La forma de la nube de puntos
5. Estimando $\vec{\mu}$ y Σ con datos reales
6. Visualizando la normal multivariada
7. Detectando valores atípicos con varias variables
8. El Q-Q plot: ¿los datos parecen normales?
9. Dos propiedades que vale la pena conocer
10. Simulación de datos
11. Aplicaciones reales
12. Síntesis

Bibliografía


Anexo: material adicional para quien quiera profundizar

1. Repaso rápido: la normal de una variable

La distribución normal estándar

Cuando $\mu = 0$ y $\sigma = 1$, la llamamos **normal estándar** (Z). Es la misma campana de siempre, pero en una escala común:

```
ggplot() + xlim(-3.5, 3.5) +  
  geom_function(fun=dnorm, args=list(mean=0, sd=1),  
               color="tomato", linewidth=1.2) +  
  geom_vline(xintercept=0, linetype="dashed", color="grey50") +  
  theme_minimal() +  
  labs(y="Densidad", x="z",  
       title="Normal estandar Z ~ N(0,1)")
```



Estandarizar: llevar todo a la misma escala

Cualquier $X \sim \mathcal{N}(\mu, \sigma)$ se puede reescalar así:

$$Z = \frac{X - \mu}{\sigma}$$

¿Para qué sirve? Piense en comparar una nota de un examen (sobre 5) con un puntaje Saber (sobre 500): las unidades son distintas, pero al estandarizar ambas quedan en la misma escala, en “número de desviaciones respecto al promedio”.

```
set.seed(1)
edad = rnorm(200, mean=35, sd=8)
z     = (edad - mean(edad)) / sd(edad)
round(c(media_z = mean(z), sd_z = sd(z)), 5)
```

```
## media_z    sd_z
##         0         1
```

Note que Z siempre queda con media 0 y desviación 1, sin importar la variable original.

Parámetro vs. estadístico

Distinción clave

Parámetro (μ, σ) : el valor real en la **población completa**. Casi nunca lo conocemos.

Estadístico $(\bar{x}, s)$: lo que **calculamos con la muestra** que sí tenemos. Cambia si cambiamos la muestra.

Esta misma distinción se aplicará hoy, solo que en vez de un número tendremos una **lista de promedios** y una **tabla de relaciones** entre variables.

Otras distribuciones: un mapa de referencia

La normal no es la única distribución que usaremos en el curso. Este mapa le servirá de referencia a lo largo del semestre:

Distribucion	Tipo	Se usa para	Ejemplo
Normal	Continua	Fenomenos simetricos	Estaturas
Exponencial	Continua	Tiempos de espera	Fila en un banco
Chi-cuadrado	Continua	Pruebas de hipotesis	Bondad de ajuste
Binomial	Discreta	Numero de exitos	Caras al lanzar monedas
Poisson	Discreta	Conteo de eventos raros	Llamadas por hora

Nota

Hoy nos concentramos en la familia **normal**, porque es la base de la mayoría de las técnicas multivariadas que veremos en el curso.

2. Pensando en varias variables a la vez

¿Qué es el análisis multivariado?

Definición

Conjunto de herramientas para analizar **mas de una variable** sobre las mismas unidades (personas, paises, empresas...), buscando entender cómo se **relacionan entre sí** (Díaz Monroy & Morales Rivera, 2012).

En pocas palabras: en vez de mirar una foto a la vez, miramos el álbum completo y buscamos el patrón que las conecta.

¿Por qué no basta con analizar cada variable por separado?

- Las variables del mundo real casi siempre están **correlacionadas**: separarlas hace perder información
- Los fenómenos reales son **multidimensionales** por naturaleza (una persona no es solo "su peso")
- Ciertos patrones — valores atípicos, grupos, estructuras — **solo se ven cuando miramos las variables juntas**

Adelanto

Más adelante veremos un caso real donde una persona es "normal" en cada variable por separado, pero **atípica** cuando se miran todas juntas.

La tabla de datos: la forma en que organizamos todo

Imagine una hoja de cálculo típica: cada **fila** es una persona (o país, o empresa) y cada **columna** es una variable.

Elemento	Interpretacion
Fila i	Todas las variables de la observacion i
Columna j	Todos los valores de la variable j
x_{ij}	Valor de la variable j para la observacion i

Con n filas (observaciones) y p columnas (variables), a esta tabla la llamamos matriz de datos $\mathbb{X}$ ($n \times p$).

De una fila (o columna) al “vector aleatorio”

Una persona (una fila) es simplemente su lista de valores:

$$\mathbf{x}_{i\cdot} = [x_{i1}, x_{i2}, \dots, x_{ip}]$$

Una variable (una columna) es la lista de todos los valores que tomó en la muestra: $\mathbf{x}_{\cdot j} = [x_{1j}, x_{2j}, \dots, x_{nj}]$

Cuando hablamos de “la distribución de p variables juntas”, usamos la notación $\vec{X} = (X_1, X_2, \dots, X_p)$: es solo una forma compacta de decir “estas p variables, consideradas como un solo paquete”.

Una variable	Varias variables (paquete)
Escalar X	Vector $\vec{X}$
Una observacion x_i	Una fila $\mathbf{x}_i$.
Muestra $x_1, \dots, x_n$	Tabla de datos $\mathbb{X}$

3. La campana en muchas dimensiones

Primer ingrediente: el centro ($\vec{\mu}$)

Si empaquetamos p variables normales, la distribución resultante se llama **normal multivariada**: $\vec{X} \sim \mathcal{N}_p(\vec{\mu}, \Sigma)$.

El primer parámetro, $\vec{\mu}$, es simplemente la lista de promedios de cada variable:

$$\vec{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix}$$

Interpretación: $\vec{\mu}$ es el **centro** de la nube de puntos — el “punto promedio” alrededor del cual se agrupan todas las observaciones.

Segundo ingrediente: la matriz de covarianza (Σ)

Σ es simplemente **una tabla** que guarda, en un solo lugar:

- en la **diagonal**: qué tan dispersa es cada variable (su varianza)
- **fuera de la diagonal**: cómo se relaciona cada par de variables (su covarianza)

Es exactamente la misma idea de la correlación r que vimos en la Sesión 2, pero guardando **todas las parejas de variables a la vez** en una sola tabla, en vez de calcular un r para cada pareja por separado.

Σ en detalle: ejemplo con 3 variables

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \sigma_{13} \\ \sigma_{12} & \sigma_2^2 & \sigma_{23} \\ \sigma_{13} & \sigma_{23} & \sigma_3^2 \end{bmatrix}$$

Posicion	Que significa
Diagonal (σ_j^2)	Varianza de la variable j sola
Fuera de diagonal (σ_{jk})	Covarianza entre variables j y k

Con $p = 3$ variables: 3 varianzas + 3 covarianzas = 6 números en total.
 Σ es siempre **simétrica** (la relación entre j y k es la misma que entre k y j).

Respuesta a la pregunta 2

Respuesta a la Pregunta 2

Σ resume en **una sola tabla** toda la variabilidad y toda la correlacion lineal entre las p variables. No necesitamos p graficos de dispersion separados: Σ ya contiene esa informacion.

La fórmula de la densidad (solo como referencia)

No es necesario memorizar esta fórmula; lo importante es reconocer sus piezas, porque las volveremos a ver durante todo el curso:

$$f(\vec{x} \mid \vec{\mu}, \Sigma) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\vec{x} - \vec{\mu})^\top \Sigma^{-1}(\vec{x} - \vec{\mu})\right)$$


Pieza	Para que sirve
$\vec{\mu}, \Sigma$	Ubican y dan forma a la campana
$(2\pi)^{p/2} \Sigma ^{1/2}$	Constante para que el area total sea 1
El termino dentro de $\exp$	Una "distancia" ajustada por Σ

Caso especial: variables independientes

Cuando $\vec{\mu} = \vec{0}$ y Σ no tiene relaciones (matriz identidad I_p), las variables son **independientes** entre sí: la nube de puntos es una esfera perfectamente redonda.

```
set.seed(42)
z_std = as.data.frame(mvrnorm(800, mu=c(0,0), Sigma=diag(2)))
colnames(z_std) = c("Z1", "Z2")
ggplot(z_std, aes(x=Z1, y=Z2)) +
  geom_point(alpha=0.18, size=0.6, color="steelblue") +
  geom_density_2d(color="tomato", linewidth=0.5) +
  coord_fixed() + theme_minimal(base_size=9) +
  labs(title="Normal estandar bivariada N2(0, I)",
       subtitle="Contornos circulares = variables independientes")
```

Variables independientes: la nube resultante



4. La forma de la nube de puntos

Respuesta a la pregunta 3: el papel geométrico de Σ

Respuesta a la Pregunta 3


La **forma** de la nube de puntos la determina Σ . μ solo mueve la nube de un lado a otro, sin cambiar su forma.

Si Σ dice...	La nube se ve...
Sin relacion entre variables	Circulo
Variables con distinta dispersion	Ovalo alineado con los ejes
Correlacion positiva	Ovalo inclinado hacia arriba
Correlacion negativa	Ovalo inclinado hacia abajo

Viéndolo con datos simulados: el código

```
set.seed(7)
casos = list(
  list(S=diag(2),          lbl="Sin relacion (r=0)"),
  list(S=matrix(c(1,0.85,0.85,1),2),    lbl="Relacion positiva (r=0.85)"),
  list(S=matrix(c(1,-0.75,-0.75,1),2),   lbl="Relacion negativa (r=-0.75)")
)
df_s = map_dfr(casos, function(c){
  m = as.data.frame(mvrnorm(500, mu=c(0,0), Sigma=c$S))
  colnames(m)=c("X1", "X2"); m$tipo=c$lbl; m
})
ggplot(df_s, aes(x=X1,y=X2)) +
  geom_point(alpha=0.13, size=0.5, color="steelblue") +
  geom_density_2d(color="tomato", linewidth=0.45) +
  facet_wrap(~tipo, nrow=1) +
  coord_fixed() + theme_minimal(base_size=8) +
  labs(x="X1", y="X2",
       title="La forma de la nube cambia con Sigma")
```


Viéndolo con datos simulados: el resultado



Panel completo: el código

```
set.seed(9)
rhos = c(-0.9, -0.4, 0, 0.4, 0.9)
df_r = map_dfr(rhos, function(r){
  S = matrix(c(1,r,r,1),2)
  m = as.data.frame(mvrnorm(350, mu=c(0,0), Sigma=S))
  colnames(m)=c("X1", "X2")
  m$rho = paste0("r=",r); m
})
df_r$rho = factor(df_r$rho, levels=paste0("r=",sort(rhos)))
ggplot(df_r, aes(x=X1,y=X2)) +
  geom_point(alpha=0.18, size=0.4, color="steelblue") +
  geom_density_2d(color="tomato", linewidth=0.35) +
  facet_wrap(~rho, nrow=2) +
  coord_fixed() + theme_minimal(base_size=8) +
  labs(title="Mientras mas cerca de -1 o 1, mas 'delgado' el ovalo",
       x="X1", y="X2")
```

Panel completo: distintos niveles de correlación



5. Estimando $\vec{\mu}$ y Σ con datos reales

De la teoría a la muestra

Al igual que con μ y σ , casi nunca conocemos $\vec{\mu}$ y Σ : los **estimamos** con la muestra que tenemos.

Parametro (teorico)	Estimador (con datos)
$\vec{\mu}$ (vector de medias)	$\bar{x}$ = promedio de cada columna
Σ (matriz de covarianza)	S = version muestral, misma idea

En R, esto es tan simple como `colMeans()` y `cov()` — lo vemos ahora.

Ejercicio 1: datos de salud

Muestra de $n = 1000$ personas, con 4 variables: edad, estatura, peso y perímetro abdominal.

```
X = read_delim("health_data.csv", show_col_types=FALSE)
head(X, 3)
```

```
## # A tibble: 3 x 4
##   Edad Estatura  Peso Perimetro_abdominal
##   <dbl>    <dbl> <dbl>          <dbl>
## 1    36     178.  81.3          106.
## 2    34     165.  72.7          101.
## 3    26     187.  88.8          114.
```

Vector de medias en R

```
# Promedio de cada variable (estimador de  $\mu$ )  
colMeans(X)
```

##	Edad	Estatura	Peso	Perimetro_abdominal
##	35.4020	175.6458	77.9449	102.3585

Es literalmente la lista de promedios, columna por columna: nada nuevo respecto a lo que ya sabíamos hacer en la Sesión 1.

Matriz de covarianza en R

```
# Matriz de varianzas y covarianzas (estimador de Sigma)  
round(cov(X), 2)
```


```
##           Edad Estatura  Peso Perimetro_abdominal  
## Edad      121.37    -8.50  6.68                0.36  
## Estatura   -8.50    87.88 39.90                5.71  
## Peso        6.68    39.90 81.53               98.91  
## Perimetro_abdominal 0.36     5.71 98.91          150.36
```

La diagonal son las **varianzas**; fuera de la diagonal, las **covarianzas**. Es simétrica, tal como esperábamos.

6. Visualizando la normal multivariada


Ejercicio 2: retomando el diagrama de dispersión

```
plot(X$Peso, X$Perimetro_abdominal,  
     main="Peso vs. Perimetro abdominal",  
     xlab="Peso (kg)", ylab="Perimetro (cm)",  
     pch=19, cex=0.4,  
     col=adjustcolor("steelblue", 0.4))
```



Cada variable, vista por separado

```
X %>%  
  pivot_longer(everything(),  
               names_to="Variable", values_to="Valor") %>%  
  ggplot(aes(x=Valor)) +  
  geom_density(fill="steelblue", alpha=0.25,  
              color="steelblue", linewidth=0.7) +  
  facet_wrap(~Variable, scales="free") +  
  theme_minimal(base_size=8) +  
  labs(x="", y="Densidad",  
       title="Densidad marginal por variable")
```



¿Qué buscamos en cada densidad marginal?


- **Un solo pico:** no dos ni tres montañas
- **Simetría aproximada:** colas parecidas a lado y lado
- **Colas que se adelgazan:** sin caídas ni picos abruptos

Advertencia importante

Que cada variable **por separado** se vea normal **no garantiza** que las variables juntas sigan una normal multivariada. Necesitamos herramientas que miren todas las variables al tiempo — eso es lo que sigue.

Matriz de dispersión: pairs.panels()

```
library(psych)
pairs.panels(X, scale=FALSE, density=TRUE,
  method="pearson", cor=TRUE, jiggle=FALSE)
```




Cómo leer `pairs.panels()`

Un solo gráfico resume la relación entre las 4 variables, dos a dos:

Zona	Contenido
Diagonal	Histograma + curva de densidad de cada variable
Triángulo inf.	Diagrama de dispersión entre cada pareja
Triángulo sup.	Correlación de Pearson r entre cada pareja

Un gráfico de contorno

```
ggplot(X, aes(x=Edad, y=Peso)) +  
  geom_point(alpha=0.25, size=0.6, color="steelblue") +  
  geom_density_2d(color="tomato", linewidth=0.6) +  
  theme_minimal() +  
  labs(title="Contornos de densidad: Edad vs. Peso",  
       x="Edad (años)", y="Peso (kg)")
```



7. Detectando valores atípicos con varias variables

Recordando el outlier de una sola variable

En la Sesión 1 un outlier era un valor lejos de la media, medido en desviaciones estándar:

$$z_i = \frac{x_i - \bar{x}}{s} \quad \text{outlier si } |z_i| > 3$$

El problema: ¿y si hay más de una variable?

Ejemplo intuitivo

Piense en una persona con estatura **normal** y peso **normal**, cada uno por separado. Pero si esa estatura es muy alta y ese peso es muy bajo **al mismo tiempo**, la combinación es rara — aunque ningún valor individual dispare la alarma de $|z| > 3$.

Necesitamos una “distancia” que tenga en cuenta **cómo se relacionan** las variables entre sí, no solo qué tan lejos está cada una por separado.

La distancia de Mahalanobis (la idea)

La distancia de Mahalanobis generaliza la idea de z_i a varias variables, **ajustando por la correlación** entre ellas:

- Si dos variables están muy correlacionadas, alejarse "en contra" de esa correlación pesa **más**
- Si no hay correlación, se parece a sumar las distancias individuales, como ya conocíamos
- El resultado es un solo número por persona: d_M^2

La fórmula matricial completa (para quien quiera verla) está en el anexo; para el curso, lo importante es **saber interpretarla y calcularla en R**.

Ejemplo: el mismo punto, dos correlaciones distintas

Para entender por qué d_M^2 depende de la correlación, comparemos el mismo punto $(2, -1)$ bajo dos matrices Σ distintas: una sin relación entre variables y otra con relación fuerte y positiva.

```
punto = c(2, -1)
mu2    = c(0, 0)

Sigmas = list(
  "r = 0"    = diag(2),
  "r = 0.9"  = matrix(c(1, 0.9, 0.9, 1), ncol=2)
)

d2_ejemplo = map_dbl(Sigmas, ~ mahalanobis(matrix(punto, nrow=1),
                                              center = mu2, cov = .x))

round(d2_ejemplo, 2)

##    r = 0 r = 0.9
##    5.00 45.26
```

¿Por qué cambia tanto la distancia?

- Con $r = 0$: d_M^2 es solo la suma de las distancias en cada eje, sin ningún ajuste
- Con $r = 0.9$: las dos variables casi siempre suben o bajan juntas. El punto $(2, -1)$ va **en contra** de ese patrón, y eso se penaliza con una distancia mucho mayor


La distancia de Mahalanobis no solo mide “qué tan lejos”, sino **qué tan raro es el patrón**, dada la correlación esperada entre las variables.

Viéndolo en la nube de puntos: el código

```
set.seed(5)
df_ejemplo = map2_dfr(Sigmas, names(Sigmas), function(S, lbl){
  m = as.data.frame(mvrnorm(400, mu=mu2, Sigma=S))
  colnames(m) = c("X1", "X2")
  m$caso = lbl
  m
})
punto_df = tibble(X1=punto[1], X2=punto[2], caso=names(Sigmas))

ggplot(df_ejemplo, aes(x=X1, y=X2)) +
  geom_point(alpha=0.15, size=0.5, color="steelblue") +
  geom_point(data=punto_df, color="tomato", size=3) +
  facet_wrap(~caso) +
  coord_fixed() + theme_minimal(base_size=9) +
  labs(title="Mismo punto (2,-1), distinta Sigma",
       x="X1", y="X2")
```

Viéndolo en la nube de puntos: el resultado




En el panel izquierdo ($r = 0$) el punto rojo cae dentro de la nube; en el derecho ($r = 0.9$) el mismo punto queda claramente **fuera** de la forma alargada de la nube — mayor d_M^2 , tal como calculamos.

Propiedades útiles de d_M^2

Una variable	Varias variables
z_i^2	d_M^2 (Mahalanobis)
Se compara con χ_1^2	Se compara con χ_p^2
Umbral: $z^2 = 9$ (i.e. $ z > 3$)	Umbral: percentil 97.5 de χ_p^2

En palabras simples: cuanto más lejos esté una persona del “centro” de la nube de datos — teniendo en cuenta la forma de esa nube — más grande es su d_M^2 .

Un outlier invisible en las variables por separado



Respuesta a la pregunta 3

Respuesta a la Pregunta 3

Un punto puede parecer normal en **cada** variable por separado, y al mismo tiempo ser un **outlier multivariado**: invisible en un histograma, pero evidente cuando miramos todas las variables juntas.

En el gráfico anterior, el punto rojo tiene valores individuales perfectamente razonables en X_1 y en X_2 por separado — pero rompe la relación de correlación positiva que siguen los demás puntos.

Calculando d_M^2 en R

```
# mahalanobis() devuelve d^2 para cada observacion
d2 = mahalanobis(X,
                 center = colMeans(X),
                 cov      = cov(X))

# Umbral: percentil 97.5 de chi^2 con p = 4 g.l.
umbral      = qchisq(0.975, df=ncol(X))
n_outliers  = sum(d2 > umbral)


paste0("Outliers detectados: ", n_outliers,
       " / ", nrow(X),
       " (umbral chi2 = ", round(umbral, 2), ")")

## [1] "Outliers detectados: 34 / 1000 (umbral chi2 = 11.14)"
```

Una sola función de R hace todo el cálculo por nosotros.

Visualizando los outliers detectados

```
tibble(indice=seq_along(d2), d2=d2,  
       outlier = d2 > umbral) %>%  
ggplot(aes(x=indice, y=d2, color=outlier)) +  
  geom_point(size=0.6, alpha=0.7) +  
  geom_hline(yintercept=umbral,  
            linetype="dashed", color="tomato", linewidth=0.8) +  
  scale_color_manual(values=c("steelblue", "tomato")) +  
  theme_minimal(base_size=9) +  
  labs(x="Individuo", y="d^2 (Mahalanobis)",  
       title="Deteccion de outliers multivariados", color="Outlier")
```



El individuo más atípico: sus valores reales

Miremos de cerca al individuo con el d_M^2 más alto: ¿se ve raro variable por variable, o solo en conjunto?

```
i_atipico = which.max(d2)
comparacion = tibble(
  Variable = names(X),
  Valor_individuo = round(as.numeric(X[i_atipico, ]), 1),
  Promedio_muestra = round(as.numeric(colMeans(X)), 1)
)
comparacion
```


```
## # A tibble: 4 x 3
##   Variable      Valor_individuo Promedio_muestra
##   <chr>          <dbl>          <dbl>
## 1 Edad          -10            35.4
## 2 Estatura      183.           176.
## 3 Peso          101.           77.9
## 4 Perimetro_abdominal 141            102.
```

Ningún valor individual salta a la vista como extremo frente al promedio — por eso este caso es difícil de detectar mirando las variables por separado.

Ubicándolo en la distribución de cada variable: el código

```
X_long = X %>%  
  mutate(id = row_number()) %>%  
  pivot_longer(-id, names_to="Variable", values_to="Valor")  
  
punto_long = X_long %>% filter(id == i_atipico)  
  
ggplot(X_long, aes(x=Variable, y=Valor)) +  
  geom_boxplot(fill="steelblue", alpha=0.25, outlier.alpha=0.15) +  
  geom_point(data=punto_long, color="tomato", size=3) +  
  facet_wrap(~Variable, scales="free", nrow=1) +  
  theme_minimal(base_size=8) +  
  theme(axis.text.x=element_blank(), axis.ticks.x=element_blank()) +  
  labs(title="El individuo mas atipico, variable por variable",  
       x="", y="Valor")
```

Ubicándolo en la distribución de cada variable: el resultado



El punto rojo cae **dentro** de la caja o muy cerca de ella en cada variable por separado — ningún boxplot individual lo marcaría como atípico. Solo la distancia de Mahalanobis, que usa la correlación entre variables, lo detecta.

8. El Q-Q plot: ¿los datos parecen normales?

¿Por qué importa el Q-Q plot?

Motivacion

El Q-Q plot es la herramienta grafica mas usada para revisar si unos datos siguen una distribucion teorica. En este curso lo usaremos para revisar normalidad, un supuesto que aparece en casi todas las tecnicas multivariadas.

Idea central: si los datos realmente vienen de una normal, sus valores ordenados deben parecerse a los **cuantiles teóricos** de esa normal.

Al graficar “lo que observamos” contra “lo que esperaríamos si fuera normal”, buscamos ver los puntos **sobre la recta** $y = x$.

Ejemplo paso a paso: estaturas de 10 estudiantes

Suponga que medimos la estatura (en cm) de 10 estudiantes:

168, 172, 165, 180, 170, 175, 163, 178, 169, 174

Paso 1 — Ordenar los datos de menor a mayor:

i	1	2	3	4	5	6	7	8	9	10
$x_{(i)}$	163	165	168	169	170	172	174	175	178	180

Paso 2: estandarizar

Con $\bar{x} = 171.4$ y $s = 5.46$, calculamos $z_{(i)} = (x_{(i)} - \bar{x})/s$:

i	1	2	3	4	5	6	7	8	9	10
$z_{(i)}$	-1.54	-1.17	-0.62	-0.44	-0.26	0.11	0.48	0.66	1.21	1.57

Esto es justo lo que aprendimos en la primera parte de la sesión de hoy.

Paso 3: calcular los cuantiles teóricos

Para $n = 10$ datos, calculamos “puntos de probabilidad” igualmente espaciados: $p_i = (i - 0.5)/n$, es decir $p_1 = 0.05, \dots, p_{10} = 0.95$.

Los **cuantiles teóricos** son $q_i = \Phi^{-1}(p_i)$ — lo que R llama `qnorm(p_i)`:

i	1	2	3	4	5	6	7	8	9	10
p_i	.05	.15	.25	.35	.45	.55	.65	.75	.85	.95
q_i	-1.64	-1.04	-0.67	-0.39	-0.13	0.13	0.39	0.67	1.04	1.64

Paso 4: emparejar teórico con empírico


Cada punto del Q-Q plot es el par $(q_i, z_{(i)})$:

i	Cuantil teórico q_i	Cuantil empírico $z_{(i)}$
1	-1.64	-1.54
2	-1.04	-1.17
3	-0.67	-0.62
4	-0.39	-0.44
5	-0.13	-0.26
6	0.13	0.11
7	0.39	0.48
8	0.67	0.66
9	1.04	1.21
10	1.64	1.57

Si estos pares caen sobre la recta $y = x$, los datos son consistentes con la normal.

Paso 5: el gráfico resultante

```
q_teo = c(-1.64,-1.04,-0.67,-0.39,-0.13,0.13, 0.39, 0.67, 1.04, 1.64)
z_emp = c(-1.54,-1.17,-0.62,-0.44,-0.26,0.11, 0.48, 0.66, 1.21, 1.57)
ggplot(data.frame(q_teo, z_emp), aes(x=q_teo, y=z_emp)) +
  geom_point(size=2.5, color="steelblue") +
  geom_abline(slope=1, intercept=0,color="tomato", linewidth=0.9) +
  theme_minimal(base_size=9) +
  labs(x="Cuantiles teoricos N(0,1)",y="Cuantiles empiricos (z estandarizados)",
       title="Q-Q plot manual: estaturas de 10 estudiantes",
       subtitle="Puntos cercanos a la recta = evidencia de normalidad")
```



- Los puntos extremos ($i = 1$ e $i = 10$) se alejan un poco — normal con solo $n = 10$ datos, no es evidencia en contra
- No hay curvatura sistemática ni puntos muy alejados
- Conclusión: los datos son **consistentes con una distribución normal**

Regla practica de lectura


- Puntos **sobre la recta**: normalidad
- **Curva en forma de S**: datos sesgados (asimetria)
- **Extremos alejados en ambas colas**: colas mas pesadas que la normal
- **Puntos aislados** lejos de la recta: posibles outliers

Haciéndolo con una función de R

```
estaturas = c(168,172,165,180,170,175,163,178,169,174)
qqnorm(estaturas, pch=19, col="steelblue",
       main="Q-Q plot: estaturas de 10 estudiantes",
       xlab="Cuantiles teoricos N(0,1)",
       ylab="Cuantiles empiricos")
qqline(estaturas, col="tomato", lwd=2)
```


Cuantiles empiricos

Q-Q plot: estaturas de 10 estudiantes



Cuantiles teoricos N(0,1)

Tres patrones posibles en el Q-Q plot



- **Normal:** puntos sobre la recta
- **Sesgado:** los puntos se curvan hacia un solo lado
- **Colas pesadas:** los extremos se alejan en direcciones opuestas

Usamos el mismo puente que ya vimos con Mahalanobis:

$$z_i^2 \xrightarrow{\text{generaliza a}} d_M^2$$

Construcción del Q-Q plot multivariado — exactamente los mismos 5 pasos de antes, solo que comparamos d_M^2 contra los cuantiles teóricos de χ_p^2 en vez de comparar z contra los de $\mathcal{N}(0, 1)$.


Respuesta a la Pregunta 4

El Q-Q plot de d_M^2 contra χ_p^2 es la herramienta grafica estandar para revisar normalidad multivariada — la misma logica de siempre, aplicada a la distancia de Mahalanobis.

```

p_var = ncol(X); n_obs = nrow(X)
qt_teo_mv = qchisq(ppoints(n_obs), df=p_var)
qt_emp_mv = sort(d2)
ggplot(data.frame(teo=qt_teo_mv, emp=qt_emp_mv),
       aes(x=teo, y=emp)) +
  geom_point(size=0.7, alpha=0.5, color="steelblue") +
  geom_abline(slope=1, intercept=0,
             color="tomato", linewidth=0.8) +
  theme_minimal(base_size=9) +
  labs(x=paste0("Cuantiles teoricos chi^2 (", p_var, " g.l.)"),
       y="Cuantiles empiricos d^2",
       title="Q-Q plot multivariado - datos de salud")

```



Interpretación del Q-Q plot multivariado

- **Puntos sobre la recta:** datos consistentes con normalidad multivariada
- **Puntos alejados en la cola superior:** posibles outliers multivariados
- **Curvatura sistemática:** la distribución conjunta se aleja de la normal

Nota

El Q-Q plot es un método **gráfico**, no una prueba formal. Existen pruebas estadísticas más rigurosas (Mardia, Henze-Zirkler) que verá en cursos más avanzados; para este curso, el Q-Q plot es suficiente.

9. Dos propiedades que vale la pena conocer

Buenas noticias: la normalidad “se mantiene”

Sin entrar en el álgebra matricial (disponible en el anexo para quien le interese), estas dos propiedades son la razón por la que la normal multivariada es tan usada en la práctica:

- **Combinaciones y promedios se quedan normales:** si combinamos o promediamos variables que siguen una normal multivariada, el resultado también es normal
- **Cada variable por separado también es normal:** las "marginales" de una normal multivariada son siempre normales univariadas

¿Por qué nos importa esto?

Consecuencia practica

Estas propiedades son la base de tecnicas que vera mas adelante en el programa, como la regresion multivariada y componentes principales. Todas dependen de que las combinaciones de variables normales sigan siendo normales.

Por ahora, quédese con la idea: **trabajar con normales multivariadas es “seguro”**, porque las operaciones más comunes no rompen la normalidad.

10. Simulación de datos

Simulación con `mvrnorm()`

La función `mvrnorm()` del paquete MASS genera muestras de una normal multivariada, dados $\vec{\mu}$ y Σ :

```
mi_mu      = c(0, 0)
mi_Sigma   = matrix(c(1, 0.6, 0.6, 1), ncol=2)

set.seed(42)
M_norm = mvrnorm(n=500, mu=mi_mu, Sigma=mi_Sigma)
head(M_norm, 3)
```


```
##           [,1]      [,2]
## [1,]  0.7659768  1.68646823
## [2,] -0.9141812 -0.09598164
## [3,]  0.3258904  0.32369345
```

Esto es útil para **probar** ideas antes de aplicarlas a datos reales.

Distintas estructuras de correlación simuladas

```
set.seed(42)
mu0 = c(0, 0)
for (r in c(-0.8, 0, 0.8)){
  Sr = matrix(c(1, r, r, 1), ncol=2)
  M = mvrnorm(n=400, mu=mu0, Sigma=Sr)
  pairs.panels(M, main=paste0("Correlacion = ", r),
    density=TRUE, method="pearson",
    cor=TRUE, scale=FALSE, jiggle=FALSE)
}
```

Correlacion = -0.8



Para cada valor de r simulado:

- **Diagonal:** la curva marginal siempre se ve normal, sin importar r
- **Dispersión:** nube circular ($r = 0$) o alargada ($|r| \rightarrow 1$)
- **Correlación reportada:** coincide con el r que usamos en Σ

Actividad

Modifique `mi_Sigma` usando varianzas distintas en la diagonal, por ejemplo $\sigma_1^2 = 4$, $\sigma_2^2 = 1$, y observe cómo el óvalo se estira en la dirección de mayor varianza.

11. Aplicaciones reales

La distribución normal en la vida cotidiana

- **Tallas de ropa y calzado:** las marcas diseñan sus inventarios según cómo se distribuyen las estaturas y pesos de la población. Las tallas “M” y “L” cubren el 68 % central; “XS” y “XL” cubren las colas.
- **Pruebas Saber / ICFES:** los puntajes están diseñados para seguir aproximadamente una normal alrededor de la media nacional, lo que permite ubicar a cada estudiante dentro del grupo de todos los presentantes.
- **Errores de medición:** cualquier instrumento (báscula, termómetro, GPS) comete errores pequeños y simétricos alrededor del valor real, y esos errores siguen una distribución normal.

- **Presión arterial y exámenes de laboratorio:** la medicina define rangos "normales" (colesterol, glucosa) usando percentiles de distribuciones aproximadamente normales en poblaciones sanas.
- **Control de calidad:** una fábrica que debe dosificar 500 mg de un medicamento modela la variación del proceso como $\mathcal{N}(500, \sigma^2)$ y usa la regla $\mu \pm 3\sigma$ para detectar lotes defectuosos.

- **Valor en Riesgo (VaR):** los bancos calculan cuánto podrían perder en un día "normal" usando cuantiles de la normal. La regulación bancaria (Basilea III) se apoya en este concepto.
- **Seguros de vida:** las aseguradoras modelan la distribución de reclamaciones para fijar las primas. Con carteras grandes, el Teorema Central del Límite garantiza que el total de reclamaciones se aproxima a una normal.

Cuando varias variables cuentan la historia completa

La normal **multivariada** tiene aplicaciones aún más poderosas cuando las variables están correlacionadas entre sí:

- **Medicina personalizada:** un perfil de paciente (edad, IMC, presión, glucosa) se trata como un solo paquete de variables. La distancia de Mahalanobis identifica pacientes atípicos que merecen atención prioritaria — exactamente el ejercicio de hoy.
- **Detección de fraude:** las transacciones bancarias (monto, hora, ubicación, frecuencia) se modelan bajo comportamiento "normal". Una transacción con d_M^2 alto es candidata a fraude.

- **Recomendaciones:** Netflix o Spotify representan los gustos de un usuario como un vector de muchas variables; la similitud entre usuarios se mide con distancias que generalizan la idea de Mahalanobis.
- **Manufactura avanzada:** el control estadístico de procesos monitorea simultáneamente varias variables de calidad (temperatura, presión, viscosidad) con una estadística que no es más que una versión reescalada de d_M^2 .

Volviendo a nuestro ejercicio de hoy, los mismos conceptos aplican directamente:

- El **diagrama de dispersión** de peso vs. perímetro abdominal es exactamente una "foto" 2D de la distribución conjunta de esas dos variables
- La **correlación** que observamos entre ellas indica que Σ tiene una covarianza alta fuera de la diagonal
- Una persona con estatura muy alta pero peso muy bajo sería un **outlier multivariado** detectable con d_M^2 , aunque ninguna variable sea extrema por separado

12. Síntesis

Respuestas a las 4 preguntas

Pregunta	Respuesta
1. Campana en p dimensiones	Centro $\vec{\mu}$ + tabla de relaciones Σ
2. Relaciones entre variables	Σ guarda varianzas y correlaciones en un solo objeto
3. Outliers multivariados	d_M^2 ajusta por correlación; invisibles variable por variable
4. Evaluar normalidad	Q-Q plot de d_M^2 vs. cuantiles de χ_p^2

Conclusiones de la Sesión 3

- La normal multivariada generaliza la campana de una variable: $\vec{\mu}$ ubica la nube, Σ define su forma
- Σ es el objeto central del análisis multivariado: guarda toda la estructura de variabilidad y correlación
- $\bar{x}$ y S son los estimadores muestrales de $\vec{\mu}$ y Σ
- La distancia de Mahalanobis generaliza el z^2 de una variable al caso de muchas variables a la vez
- El Q-Q plot (de una variable o de varias) es la herramienta gráfica que usamos para evaluar normalidad
- La distribución normal aparece en salud, finanzas, tecnología y en muchos fenómenos de la vida cotidiana

Conexión entre las tres sesiones

Sesion 1	Sesion 2	Sesion 3
Una variable (hist., KDE, medidas desc.)	Funcion de densidad, KDE, TCL	Normal Multivariada
Outliers ($\mu \pm 3\sigma$)	Covarianza y correlacion r	Mahalanobis d_M^2
Q-Q univariado (nuevo)	Pensamiento bivariado	Q-Q multivariado (normalidad conjunta)

Bibliografía

1. Díaz Monroy, L. G., & Morales Rivera, M. A. (2012). *Análisis estadístico de datos multivariados*. UNAL.
2. Everitt, B., & Hothorn, T. (2011). *Applied Multivariate Analysis with R*. Springer.
3. Johnson, R. A., & Wichern, D. W. (2007). *Applied Multivariate Statistical Analysis* (6a ed.). Pearson.
4. Blanco Castañeda, L. (2013). *Probabilidad*. Editorial UN.
5. Mood, A. M. (1950). *Introduction to the Theory of Statistics*. McGraw-Hill.

**Anexo: material adicional para
quien quiera profundizar**

Anexo: fórmula matricial de la distancia de Mahalanobis

Para quien quiera ver la expresión completa que usa internamente `mahalanobis()`:

$$d_M^2(\mathbf{x}_i) = (\mathbf{x}_i - \bar{\mathbf{x}})^\top S^{-1}(\mathbf{x}_i - \bar{\mathbf{x}})$$

Una variable	Varias variables
$z_i^2 = (x_i - \bar{x})^2 / s^2$	$d_M^2 = (\mathbf{x}_i - \bar{\mathbf{x}})^\top S^{-1}(\mathbf{x}_i - \bar{\mathbf{x}})$

Para $p = 1$, esta fórmula se reduce exactamente a z_i^2 : es la misma idea de siempre, generalizada con álgebra de matrices.

Anexo: estandarización multivariada

Así como $Z = (X - \mu)/\sigma$ estandariza una variable, existe una versión matricial que estandariza p variables a la vez:

$$\vec{Z} = \Sigma^{-1/2}(\vec{X} - \vec{\mu}) \sim \mathcal{N}_p(\vec{0}, I_p)$$

$$\underbrace{Z = \frac{X - \mu}{\sigma}}_{\text{una variable}} \longleftrightarrow \underbrace{\vec{Z} = \Sigma^{-1/2}(\vec{X} - \vec{\mu})}_{\text{varias variables}}$$

Ambas transformaciones **centran** en cero y **normalizan** la escala, convirtiendo el óvalo en un círculo perfecto.

Propiedad de linealidad

Si $\vec{X} \sim \mathcal{N}_p(\vec{\mu}, \Sigma)$, para cualquier matriz A y vector $\mathbf{b}$:

$$\vec{Y} = A\vec{X} + \mathbf{b} \sim \mathcal{N}_q(A\vec{\mu} + \mathbf{b}, A\Sigma A^\top)$$

Esta es la propiedad matemática detrás de la afirmación “las combinaciones de variables normales siguen siendo normales” que vimos en la sección 9.

Anexo: cálculo manual del vector de medias

El siguiente código calcula el vector de medias variable por variable. En la práctica siempre se usa `colMeans()`:

```
n      = nrow(X)
nombres = colnames(X)
x_mean = c()
for (i in nombres){
  prom  = mean(X[[i]])
  x_mean = c(x_mean, prom)
  cat("Promedio de", i, ":", round(prom, 3), "\n")
}
```

```
## Promedio de Edad : 35.402
## Promedio de Estatura : 175.646
## Promedio de Peso : 77.945
## Promedio de Perimetro_abdominal : 102.359
```

```
names(x_mean) = nombres
```

Anexo: cálculo manual de la matriz de covarianza

```
p = ncol(X)
S = matrix(NA, nrow=p, ncol=p)
for (j in 1:p){
  for (k in 1:p){
    S[j,k] = 1/(n-1) *
      sum((X[[nombres[j]]] - x_mean[nombres[j]]) *
        (X[[nombres[k]]] - x_mean[nombres[k]]))
  }
}
rownames(S) = colnames(S) = nombres
round(S, 2)
```

```
##              Edad Estatura  Peso Perimetro_abdominal
## Edad          121.37    -8.50  6.68                0.36
## Estatura      -8.50    87.88 39.90                5.71
## Peso          6.68    39.90 81.53                98.91
## Perimetro_abdominal 0.36    5.71 98.91            150.36
```

Este cálculo es meramente pedagógico — `cov()` lo realiza de forma eficiente y robusta. El resultado debe ser idéntico al obtenido en la

Sección 5.