

Análisis Estadístico de Datos

Sesión 4: Análisis de Componentes Principales (ACP)

Profesor: Nicolás López

Universidad del Rosario

Puente desde la Sesión 3

Resumen Sesión 3

En la Sesión 3 establecimos los fundamentos de la distribución normal multivariada:

- $\vec{X} \sim \mathcal{N}_p(\vec{\mu}, \Sigma)$: campana generalizada a p dimensiones
- $\vec{\mu}$: vector de medias — ubica el centroide en $\mathbb{R}^p$
- Σ : matriz de covarianza — codifica variabilidad y correlaciones
- Distancia de Mahalanobis $d_M^2 \sim \chi_p^2$: detección de outliers
- Q-Q plot multivariado: evaluación de normalidad conjunta

Pregunta central de la Sesión 4

¿Cómo **explotar** la estructura de Σ para resumir, visualizar y entender datos de alta dimensión cuando p es grande?

Tabla de contenidos

Puente desde la Sesión 3

1. Motivación: el problema de la alta dimensión
2. El problema de la dimensionalidad
3. La descomposición espectral
4. Intuición geométrica del ACP
5. El ACP en R
6. Varianza explicada y selección de CPs
7. Visualización con factoextra
8. Outliers y el ACP
9. Funciones en R
10. El ACP en el mundo moderno
11. Síntesis y puente

Puente hacia la Sesión 5: Clustering

Bibliografía

Anexo

1. Motivación: el problema de la alta dimensión

La metáfora del cilindro

La “gran verdad” de los datos vive en $\mathbb{R}^p$.

El ACP busca las proyecciones más informativas de esa gran verdad.

Imagine un cilindro en 3D. Según desde dónde se mire produce proyecciones distintas: círculo, rectángulo, óvalo. Cada una es **verdad parcial**: correcta pero incompleta.

La idea del ACP:

- Los datos viven en p dimensiones (una por variable)
- Buscamos proyecciones de baja dimensión que capturen la **mayor variabilidad posible**
- Estas proyecciones son las **componentes principales** (CP)
- Con pocas CP resumimos y visualizamos la estructura multivariada

¿Por qué no mirar todas las parejas?

Con p variables hay $\binom{p}{2}$ diagramas de dispersión posibles:

Variables (p)	Diagramas posibles	Factible?
2	1	Facil
5	10	Tedioso
10	45	Difícil
20	190	Inviabile
100	4950	Imposible

El ACP reemplaza esos miles de graficas por **1 o 2** que capturan la mayor parte de la informacion.

Contexto

En genomica, p puede ser el numero de genes activos en una celula: decenas de miles. El ACP es el primer paso estandar en casi todo analisis genomico moderno.

El ejemplo de esta sesión: datos de automóviles

Los datos `mtcars` (Motor Trend, 1974): 32 modelos, 9 variables cuantitativas.


Variable	Descripcion
<code>mpg</code>	Consumo (millas por galon)
<code>cyl</code>	Numero de cilindros
<code>disp</code>	Desplazamiento del motor (pulg. cubicas)
<code>hp</code>	Potencia (caballos de fuerza)
<code>drat</code>	Relacion del eje trasero
<code>wt</code>	Peso (miles de libras)
<code>qsec</code>	Tiempo en 1/4 de milla
<code>gear</code>	Numero de marchas
<code>carb</code>	Numero de carburadores

Las variables tienen **unidades y escalas muy distintas** — problema que resolveremos.

2. El problema de la dimensionalidad

Visualizando en 1 y 2 dimensiones


```
mtcars$car = rownames(mtcars)
ggplot(mtcars, aes(x=mpg, y=rep(0,nrow(mtcars)), label=car)) +
  geom_point(size=1.5) +
  geom_text_repel(size=1.6, box.padding=1.0, max.overlaps=Inf) +
  xlab("Millas por galon") + ylab("") +
  theme_minimal() +
  theme(axis.text.y=element_blank(), axis.ticks.y=element_blank())
```



Con 1 variable: Fiat 128 y Toyota Corolla son similares entre si y diferentes a Lincoln Continental y Cadillac Fleetwood.

Dos variables: el diagrama de dispersión

```
ggplot(mtcars, aes(x=mpg, y=wt, label=car)) +  
  geom_point(size=1.2) +  
  geom_text_repel(size=1.6, box.padding=0.3, max.overlaps=Inf) +  
  xlab("Millas por galon") + ylab("Peso") + theme_minimal()
```




Con 2 variables confirmamos: los livianos de alto rendimiento se oponen a los pesados de bajo rendimiento. ¿Qué pasa con las 7 variables restantes?

Exploración univariada de las 9 variables


vs y am son binarias sin estructura ordinal: se excluyen

```
mtcars2 = mtcars %>% select(-c(vs, am, car))
```

Distribucion univariada de cada variable



La estructura de correlación entre las 9 variables



Muchas variables están muy correlacionadas: `disp`, `hp`, `wt`, `cyl` comparten información. Esto sugiere que **pocos ejes** pueden resumir bien los datos.

3. La descomposición espectral

¿Qué es la descomposición espectral?

Cualquier matriz de covarianza Σ (simétrica, semidefinida positiva) puede escribirse como:

$$\Sigma = P\Lambda P^\top$$

donde:

- $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_p)$, con $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$: los **valores propios** (autovalores)
- $P = [\mathbf{p}_1 \mid \mathbf{p}_2 \mid \dots \mid \mathbf{p}_p]$: los **vectores propios** (autovectores), ortonormales ($PP^\top = I$)

Significado intuitivo: Σ rota, estira y gira el espacio. La descomposición separa esas dos acciones: P da las **direcciones** (rotación) y Λ da los **tamaños** de estiramiento.

Ejemplo de computo: descomposicion espectral 2x2

Considere la siguiente matriz de covarianza para dos variables:

$$\Sigma = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$$

```

Sigma = matrix(c(3, 1, 1, 2), nrow=2)
descomp = eigen(Sigma)           # funcion base de R

lambda = descomp$values          # valores propios
P       = descomp$vectors        # vectores propios (columnas)

cat("Valores propios:\n"); round(lambda, 3)

## Valores propios:

## [1] 3.618 1.382
cat("\nVectores propios (columnas de P):\n"); round(P, 3)

##
## Vectores propios (columnas de P):

##      [,1]  [,2]
## [1,] -0.851  0.526
## [2,] -0.526 -0.851

```

Verificando: $\Sigma = P\Lambda P^\top$

```
Lambda = diag(lambda)           # matriz diagonal de val. propios
```

```
# Reconstruccion: debe ser igual a Sigma original
```

```
Sigma_reconstruida = P %*% Lambda %*% t(P)
```

```
round(Sigma_reconstruida, 6)
```

```
##      [,1] [,2]
```

```
## [1,]    3    1
```

```
## [2,]    1    2
```

```
# Verificando ortogonalidad de P:  $P * P^T = I$ 
```

```
round(P %*% t(P), 6)
```

```
##      [,1] [,2]
```

```
## [1,]    1    0
```


```
## [2,]    0    1
```

La reconstruccion es exacta. $PP^\top = I$ confirma que los vectores propios son ortonormales.

¿Qué nos dice la descomposición de este ejemplo?

Vectores propios de Sigma

Rojo = CP1 (mayor varianza), Dorado = CP2



Los vectores propios apuntan en las **direcciones de mayor variabilidad**

Conexión fundamental

Los componentes principales son exactamente los vectores propios de Σ , ordenados de mayor a menor valor propio.

Elemento	En la descomp. espectral	En el ACP
$\mathbf{p}_k$	Vector propio k de Σ	Cargas del CP k
λ_k	Valor propio k de Σ	Varianza del CP k
z_{ik}	—	Puntaje del individuo i en CP k


Ejecutar `prcomp()` en R es esencialmente aplicar `eigen()` a la matriz de covarianza (o correlación si se estandarizan los datos), de forma numéricamente estable vía descomposición en valores singulares (SVD).

4. Intuición geométrica del ACP

Centrar los datos: el primer paso

El ACP siempre trabaja con datos **centrados** (media = 0):


```
mtcars_c = mtcars %>%  
  mutate(mpg_c = mpg - mean(mpg), wt_c = wt - mean(wt))  
ggplot(mtcars_c, aes(x=mpg_c, y=wt_c, label=car)) +  
  geom_point(size=1.2) +  
  geom_text_repel(size=1.5, box.padding=0.25, max.overlaps=Inf) +  
  geom_hline(yintercept=0, linetype="dashed", color="grey50") +  
  geom_vline(xintercept=0, linetype="dashed", color="grey50") +  
  xlab("mpg centrado") + ylab("wt centrado") + theme_minimal()
```



Rotar hasta encontrar el eje de mayor varianza

CP1 = la línea a través del origen que maximiza la varianza proyectada:

```
gg_c = ggplot(mtcars_c, aes(x=mpg_c, y=wt_c)) +  
  geom_point(size=0.9, color="steelblue") + theme_minimal() +  
  xlab("mpg centrado") + ylab("wt centrado")  
for(s in c(-1,-0.5,-0.1,0.1,0.5,1)){  
  col_ = if(s == -0.1) "tomato" else "grey70"  
  lw_ = if(s == -0.1) 1.1 else 0.4  
  gg_c = gg_c + geom_abline(intercept=0, slope=s,  
                           color=col_, linewidth=lw_, linetype="dashed")  
}  
gg_c + labs(title="Candidatos para CP1. La linea roja es la mejor")
```




La geometría del CP1: proyecciones

*CP1 minimiza la distancia de cada punto a su proyección sobre la línea
(equivalente a maximizar la varianza de las proyecciones)*

Proyecciones sobre CP1 (puntos rojos sobre la línea)

Los segmentos grises son los residuos minimizados



El valor propio como suma de distancias proyectadas

Interpretacion del valor propio λ_k

λ_k es **proporcional a la suma de distancias cuadradas** desde las proyecciones de cada observacion sobre CP_k hasta el centroide (el origen, tras centrar los datos):

$$\lambda_k \propto \sum_{i=1}^n z_{ik}^2 = \sum_{i=1}^n (\mathbf{p}_k^\top (\mathbf{x}_i - \bar{\mathbf{x}}))^2$$

Intuitivamente: entre más dispersas estén las proyecciones alrededor del centroide, mayor es λ_k , y más información captura el CP k .

CP1 tiene el λ_1 más grande — es la dirección donde las proyecciones quedan **más alejadas del centroide**, es decir, donde los datos están más “esparcidos”.

Verificando la interpretación del valor propio

```
# Puntajes en CP1 y CP2 (datos estandarizados)
pc_c = prcomp(mtcars2, scale=TRUE)
scores = pc_c$x

# Suma de cuadrados de puntajes / (n-1) = varianza = valor propio
varpc1 = sum(scores[, "PC1"]^2) / (nrow(scores) - 1)
varpc2 = sum(scores[, "PC2"]^2) / (nrow(scores) - 1)

# Valores propios del ACP
lambdas = pc_c$sdev^2

cat("Var. puntajes CP1:", round(varpc1, 4),
    " lambda_1:", round(lambdas[1], 4), "\n")

## Var. puntajes CP1: 5.6559 lambda_1: 5.6559
cat("Var. puntajes CP2:", round(varpc2, 4),
    " lambda_2:", round(lambdas[2], 4), "\n")

## Var. puntajes CP2: 2.0821 lambda_2: 2.0821
```

La varianza de los puntajes en cada CP es **exactamente** el valor propio correspondiente.

Los CPs son ortogonales: ¿qué significa?

Los ejes de los componentes principales son **perpendiculares entre sí**:

- **Geométricamente**: CP2 es perpendicular a CP1, CP3 a ambos, etc. Forman un nuevo sistema de coordenadas rotado respecto al original
- **Estadísticamente**: los puntajes en distintos CPs tienen correlación cero — cada CP captura información **no redundante**
- **Consecuencia**: la varianza total de los datos se “reparte” entre los CPs sin solapamiento: $\lambda_1 + \lambda_2 + \dots + \lambda_p = \text{traza}(\Sigma)$

Correlación entre puntajes en distintos CPs: debe ser ~0

```
round(cor(pc_c$x)[1:3, 1:3], 6)
```

```
##      PC1 PC2 PC3
## PC1    1  0  0
## PC2    0  1  0
## PC3    0  0  1
```

5. El ACP en R

Escalamiento: por qué es crítico

```
pc_b = prcomp(mtcars2)           # SIN estandarizar
pc_c = prcomp(mtcars2, scale=TRUE) # CON estandarizar (recomendado)

# % varianza explicada por los 2 primeros CPs
sin_esc = summary(pc_b)$importance[2, 1:2]
con_esc = summary(pc_c)$importance[2, 1:2]
rbind(sin_escala=round(sin_esc,3), con_escala=round(con_esc,3))

##              PC1    PC2
## sin_escala 0.927 0.072
## con_escala 0.628 0.231
```

Sin estandarizar, `disp` (valores en cientos de pulgadas cubicas) domina completamente. Con estandarizar, cada variable aporta en igualdad de condiciones.

Regla practica

Siempre estandarizar con `scale=TRUE` cuando las variables tienen unidades o escalas distintas.

Cargas e individuos

```
pc_f = prcomp(mtcars2, scale=TRUE, rank.=2)
round(pc_f$rotation, 3) # Cargas: contribucion de cada variable a cada CP
```

```
##          PC1      PC2
## mpg  -0.393  0.028
## cyl   0.403  0.016
## disp  0.397 -0.089
## hp    0.367  0.269
## drat -0.312  0.342
## wt    0.373 -0.172
## qsec -0.224 -0.484
## gear -0.209  0.551
## carb  0.245  0.484
```


`round(pc_f$x, 2)` # Puntajes: coordenadas de cada auto en el nuevo espacio

##	PC1	PC2
## Mazda RX4	-0.66	1.17
## Mazda RX4 Wag	-0.64	0.98
## Datsun 710	-2.30	-0.33
## Hornet 4 Drive	-0.22	-1.98
## Hornet Sportabout	1.59	-0.83
## Valiant	0.05	-2.45
## Duster 360	2.71	0.36
## Merc 240D	-2.04	-0.80
## Merc 230	-2.30	-1.31
## Merc 280	-0.38	0.58
## Merc 280C	-0.37	0.41
## Merc 450SE	1.88	-0.72
## Merc 450SL	1.67	-0.71
## Merc 450SLC	1.78	-0.84
## Cadillac Fleetwood	3.65	-0.95
## Lincoln Continental	3.71	-0.84
## Chrysler Imperial	3.33	-0.48
## Fiat 128	-3.45	-0.43
## Honda Civic	-3.85	0.71
## Toyota Corolla	-3.85	-0.39
## Toyota Corona	-1.90	-1.57
## Dodge Challenger	1.80	-1.13
## AMC Javelin	1.46	-0.98
## Camaro Z28	2.60	0.76
## Pontiac Firebird	1.87	-0.98
## Fiat X1-9	-3.15	-0.26
## Porsche 914-2	-2.78	1.64

Interpretación de las cargas

Elemento	Nombre	Descripción
u_j	Cargas (<i>loadings</i>)	Pesos de cada variable en el CP j
z_{ij}	Puntaje (<i>score</i>)	Coordenada del individuo i en el CP j
λ_j	Valor propio	Varianza (dispersion) a lo largo del CP j
$\sqrt{\lambda_j}$	Valor singular	Desv. estandar a lo largo del CP j

- **CP1:** cargas altas en disp, hp, wt, cyl (positivas) y mpg (negativa). Es un **índice de tamaño y consumo**: autos grandes y poco eficientes tienen CP1 alto
- **CP2:** carga alta en qsec (positiva) y hp (negativa). Es un **índice de rendimiento en pista**

6. Varianza explicada y selección de CPs

Proporción de varianza explicada


```
round(summary(pc_c)$importance, 3)
```

##	PC1	PC2	PC3	PC4	PC5	PC6	PC7	PC8	PC9
## Standard deviation	2.378	1.443	0.710	0.515	0.428	0.352	0.324	0.242	0.149
## Proportion of Variance	0.628	0.231	0.056	0.029	0.020	0.014	0.012	0.006	0.002
## Cumulative Proportion	0.628	0.860	0.916	0.945	0.966	0.979	0.991	0.998	1.000

Con solo **2 componentes** explicamos el 86% de la variabilidad total de las 9 variables originales.

El screeplot

```
screeplot(pc_c, col="tomato", pch=16,  
          type="lines", cex=1.5, lwd=2,  
          main="Screeplot - mtcars")
```



Leer el screeplot: tres reglas prácticas

- **Regla del codo:** elegir k donde la curva dobla abruptamente.
Despues del codo, cada CP adicional aporta poca varianza nueva
- **Regla del 80%:** seleccionar los CPs que acumulen $\geq 80\%$ de la varianza
- **Regla de Kaiser:** retener los CPs con $\lambda_k > 1$ en datos estandarizados (el CP explica mas que una sola variable original)


Para mtcars

El codo esta en $k = 2$, que explica el 86% de la variabilidad. Con 2 componentes resumimos 9 variables con minima perdida de informacion.

7. Visualización con factoextra

Gráfico de variables: el círculo de correlaciones

```
fviz_pca_var(pc_c,col.var="contrib",gradient.cols=c("steelblue","gold","tomato"),repel=T)
```




Cómo leer el círculo de correlaciones

- **Longitud de la flecha:** carga total de la variable en los 2 CPs graficados. Mas larga = mas informativa en este plano
- **Angulo entre dos flechas:** correlacion entre las variables correspondientes. Angulo pequeno = alta correlacion positiva; 180° = correlacion negativa alta; 90° = sin correlacion lineal
- **Posicion en el eje:** indica en que sentido del CP aumenta esa variable

disp, hp, wt apuntan juntas (correlacionadas). mpg apunta en sentido opuesto (correlacion negativa con las anteriores). qsec apunta hacia el eje vertical (CP2), casi independiente de las otras.

Gráfico de individuos: el primer plano factorial

```
fviz_pca_ind(pc_c,col.ind=mtcars$mpg,gradient.cols=c("tomato","gold","steelblue"),  
  repel=TRUE, label="all")
```



Leyendo el primer plano factorial


- **Autos a la izquierda (azul):** alto rendimiento, ligeros, pocos cilindros (Fiat 128, Toyota Corolla, Honda Civic)
- **Autos a la derecha (rojo):** bajo rendimiento, pesados, muy potentes (Lincoln Continental, Cadillac Fleetwood)
- **Eje vertical (CP2):** separa los autos rapidos en pista (Maserati Bora, Ferrari Dino, arriba) de los lentos

Regla de lectura del plano factorial

Dos autos **cercanos** en el plano son similares en las 9 variables originales. Dos autos **lejanos** son muy distintos. La distancia en el plano es una aproximacion a su distancia real en $\mathbb{R}^9$.

El biplot: variables e individuos juntos

```
fviz_pca_biplot(pc_c, repel=TRUE,col.var="tomato", col.ind="steelblue",label="all")
```



El biplot superpone el círculo de correlaciones y el plano factorial: permite ver simultaneamente que variables caracterizan a que individuos.

8. Outliers y el ACP

El ACP es sensible a outliers

El ACP maximiza varianza. Un outlier aumenta artificialmente la varianza en su dirección, pudiendo sesgar los ejes principales:

```
d2 = mahalanobis(mtcars2,
                 center=colMeans(mtcars2),
                 cov=cov(mtcars2))
outliers_idx = which(d2 > qchisq(0.975, df=ncol(mtcars2)))
paste0("Outliers detectados: ", length(outliers_idx),
      " -> ", paste(rownames(mtcars2)[outliers_idx], collapse=", "))

## [1] "Outliers detectados: 1 -> Ford Pantera L"
```

Conexion con la Sesión 3

Antes de ejecutar el ACP, use la **distancia de Mahalanobis** para detectar y evaluar outliers multivariados. Un punto con $d_M^2 > \chi_p^2(0.975)$ merece revisión antes de incluirlo.

9. Funciones en R

prcomp() vs princomp()

Salida	prcomp()	princomp()
Desv. estandar de CPs	\$sdev	\$sdev
Cargas (vectores prop.)	\$rotation	\$loadings
Media de las variables	\$center	\$center
Escalamiento aplicado	\$scale	\$scale
Puntajes (scores)	\$x	\$scores

Recomendacion

Prefiera `prcomp()` por mayor precision numerica (usa SVD en lugar de la descomposicion espectral directa de la matriz de covarianza muestral).

Flujo completo de un ACP

1. **Explorar** variables: tipos, unidades, outliers, correlaciones
2. **Excluir** variables no cuantitativas continuas
3. **Detectar outliers** con distancia de Mahalanobis
4. **Ejecutar** `prcomp(datos, scale=TRUE)`
5. **Seleccionar** numero de CPs con screeplot y % varianza acumulada
6. **Interpretar** cargas (`$rotation`) de los CPs seleccionados
7. **Visualizar** con `factoextra`: circulo de correlaciones y plano factorial
8. **Comunicar** que captura cada CP en terminos del dominio del problema

10. El ACP en el mundo moderno

- **Genomica:** la reduccion de expresion genica ($p > 20.000$ genes) a 2–3 CPs para visualizar tipos celulares es el primer paso estandar en RNA-seq y datos de celula unica (*single-cell*)
- **Reconocimiento facial (eigenfaces):** Turk & Pentland (1991) representaron imagenes de caras como combinaciones lineales de “caras propias” — los vectores propios de la matriz de covarianza de pixeles. Cada cara nueva es proyectada sobre estos CPs para su identificacion
- **Calidad del aire:** el CP1 de un conjunto de contaminantes medidos en varias estaciones resume el **nivel general de contaminacion**, mientras que CP2 puede distinguir contaminacion industrial de no industrial — exactamente lo que veremos en la Sesion 5

Más aplicaciones: finanzas y señales

- **Finanzas cuantitativas:** el modelo de factores de Fama-French reduce cientos de retornos de activos a unos pocos factores de riesgo via ACP. Los gestores de portafolio usan los primeros CPs para identificar exposicion a riesgo de mercado, tamaño y valor
- **Neurociencia y EEG:** las senales de electrodos en el cerebro son altamente correlacionadas. El ACP separa componentes independientes de actividad neuronal de ruido electrico ambiental
- **Clima y meteorologia:** el ACP de temperatura y precipitacion en cientos de estaciones meteorologicas produce patrones espaciales llamados *teleconexiones* (como El Nino) que resumen la variabilidad climatica global

ACP como puerta de entrada al machine learning

- **Preprocesamiento:** reducir dimensionalidad antes de entrenar modelos de ML previene la “maldicion de la dimensionalidad”
- **Regularizacion:** la regresion sobre los primeros CPs (PCR, *Principal Component Regression*) estabiliza coeficientes cuando hay muchas variables correlacionadas
- **Deteccion de anomalias:** reconstruir datos desde pocos CPs y medir el error de reconstruccion detecta outliers. Usado en fraude bancario y mantenimiento predictivo industrial

Generalizaciones modernas del ACP

El ACP lineal es el caso mas simple de una familia de metodos:

t-SNE y **UMAP** (no lineales, para visualizacion)

Autoencoders (redes neuronales que generalizan el ACP)

Kernel PCA (ACP en espacios de alta dimension via kernel trick)

- **Solo relaciones lineales:** si las variables tienen relaciones curvilíneas, los CPs pueden ser poco informativos
- **Interpretabilidad no automática:** las cargas requieren análisis cuidadoso para asignarles significado en el dominio del problema
- **Sensible a outliers:** un outlier multivariado puede sesgar los ejes — usar Mahalanobis previamente
- **Dependiente del escalamiento:** cambiar la escala de una variable puede cambiar completamente los resultados
- **No es un método de agrupamiento:** revela estructura pero no asigna grupos formalmente

11. Síntesis y puente

Conclusiones de la Sesión 4

- $\Sigma = P\Lambda P^T$: el ACP es la descomposicion espectral de Σ
- Los vectores propios de Σ son las **direcciones de los CPs**; los valores propios son su **varianza** (suma de distancias proyectadas al cuadrado desde el centroide)
- Los CPs son combinaciones lineales de las variables, ortogonales entre si
- **Siempre estandarizar** cuando las escalas son distintas
- El screeplot y el % de varianza acumulada guian la seleccion del numero de CPs
- Las cargas interpretan cada CP; los puntajes ubican individuos en el nuevo espacio

Sesiones 1-2	Sesion 3	Sesion 4	Sesion 5
Distribuciones univariada y bivariada	Normal multivariada $\mathcal{N}_p$	ACP Reduccion de dimensionalidad	Clustering K-means y jerarquico
Covarianza y correlacion r	Matriz Σ Mahalanobis	Vec. propios de Σ	Distancia y centroides


Puente hacia la Sesión 5:

Clustering

El ACP revela estructura, el clustering la formaliza

Primer plano factorial: cuantos grupos naturales hay?

Sesion 5: K-means y clustering jerarquico responderan esta pregunta



¿Qué es el clustering?

Definición

Los metodos de agrupamiento buscan particiones de las n observaciones en grupos (*clusters*) homogeneos internamente y heterogeneos entre si, sin usar etiquetas previas (**aprendizaje no supervisado**).

Dos metodos principales (Sesion 5):

- **K-medias (K-means)**: particion en K grupos minimizando distancias internas. Simple, rapido. Requiere definir K a priori.
- **Agrupamiento jerarquico**: construye grupos progresivamente. No requiere K a priori; produce un **dendograma**.

La Sesión 5 en contexto

La Sesión 5 usará el dataset de calidad del aire de Bogotá (RMCAB): 15 estaciones de monitoreo, 5 contaminantes a las 8 am.

Variable	Descripción
CO (<i>ppm</i>)	Monóxido de carbono
NO (<i>ppb</i>)	Óxido nítrico
NO2 (<i>ppb</i>)	Dióxido de nitrógeno
OZONO (<i>ppb</i>)	Ozono
PM2.5 ($\mu\text{g}/\text{m}^3$)	Material particulado fino

Pregunta de la Sesión 5

¿Que estaciones de Bogotá tienen perfiles de contaminación similares?

¿Podemos recuperar agrupaciones espaciales (por localidad) usando solo datos de sensores?

Preguntas para la Sesión 5

1. ¿Como medir formalmente que dos observaciones son “similares” en $\mathbb{R}^p$?
2. ¿Como encontrar grupos automaticamente sin asignarlos a mano?
3. ¿Como elegir el numero optimo de grupos K ?
4. ¿En que se diferencia K-means del agrupamiento jerarquico?
5. ¿Como visualizar grupos obtenidos usando el primer plano factorial del ACP?

Bibliografía

1. Hanif, M. et al. (2019). *Multivariate Techniques*. Cambridge Scholars Publishing.
2. Zeltermann, D. (2015). *Applied Multivariate Statistics with R*. Springer.
3. Schumacker, R. E. (2016). *Using R with Multivariate Statistics*. SAGE.
4. Everitt, B., & Hothorn, T. (2011). *Applied Multivariate Analysis with R*. Springer.
5. Boehmke, B. & Greenwell, B. (2020). *Hands-On Machine Learning with R*. CRC Press.
6. Turk, M. & Pentland, A. (1991). Eigenfaces for recognition. *J. Cognitive Neuroscience*, 3(1).

Anexo

princomp() como alternativa

```
# princomp() usa descomposicion espectral directa de la cov. muestral
# prcomp() usa SVD -- mas numericamente estable (preferida)
pc_a = princomp(mtcars2)
summary(pc_a)
```



```
## Importance of components:
```

##	Comp.1	Comp.2	Comp.3	Comp.4
## Standard deviation	134.3820274	37.54656204	3.0181295838	1.254845e+00
## Proportion of Variance	0.9270116	0.07236743	0.0004676043	8.083193e-05
## Cumulative Proportion	0.9270116	0.99937900	0.9998466012	9.999274e-01

##	Comp.5	Comp.6	Comp.7	Comp.8
## Standard deviation	8.904901e-01	6.371404e-01	3.006062e-01	2.814188e-01
## Proportion of Variance	4.070624e-05	2.083882e-05	4.638724e-06	4.065453e-06
## Cumulative Proportion	9.999681e-01	9.999890e-01	9.999936e-01	9.999977e-01

##	Comp.9
## Standard deviation	2.124807e-01
## Proportion of Variance	2.317617e-06
## Cumulative Proportion	1.000000e+00

princomp() y prcomp() producen los mismos CPs pero con distintas notaciones en sus salidas (ver tabla en la Seccion 9).