Análisis Estadístico de Datos

Sesión 4: Análisis de Componentes Principales (ACP)

Profesor: Nicolás López

2026-03-28

Puente desde la Sesión 3

Resumen Sesión 3

En la Sesión 3 establecimos los fundamentos de la distribución normal multivariada:

- $\vec{X} \sim \mathcal{N}_p(\vec{\mu}, \Sigma)$: campana generalizada a p dimensiones
- $\vec{\mu}$: vector de medias — ubica el centroide en $\mathbb{R}^p$
- $\boldsymbol{\Sigma}$: matriz de covarianza — codifica variabilidad y correlaciones
- Distancia de Mahalanobis $d_M^2 \sim \chi_p^2$: detección de outliers
- Q-Q plot multivariado: evaluación de normalidad conjunta

Pregunta central de la Sesion 4

¿Cómo **explotar** la estructura de $\boldsymbol{\Sigma}$ para resumir, visualizar y entender datos de alta dimensión cuando p es grande?

Tabla de contenidos

Puente desde la Sesión 3

1. Motivación: el problema de la alta dimensión
2. El problema de la dimensionalidad
3. La descomposición espectral
4. Intuición geométrica del ACP
5. El ACP en R
6. Varianza explicada y selección de CPs
7. Visualización con `factoextra`
8. Outliers y el ACP
9. Funciones en R
10. El ACP en el mundo moderno
11. Síntesis y puente

Puente hacia la Sesión 5: Clustering

Bibliografía

Anexo

1. Motivación: el problema de la alta dimensión

La metáfora del cilindro

La "gran verdad" de los datos vive en $\mathbb{R}^p$.
El ACP busca las proyecciones más informativas de esa gran verdad.

Imagine un cilindro en 3D. Según desde dónde se mire produce proyecciones distintas: círculo, rectángulo, óvalo. Cada una es **verdad parcial**: correcta pero incompleta.

La idea del ACP:

- Los datos viven en p dimensiones (una por variable)
- Buscamos proyecciones de baja dimensión que capturen la **mayor variabilidad posible**
- Estas proyecciones son las **componentes principales** (CP)
- Con pocas CP resumimos y visualizamos la estructura multivariada

¿Por qué no mirar todas las parejas?

Con p variables hay $\binom{p}{2}$ diagramas de dispersión posibles:

Variables (p)	**Diagramas posibles**	**Factible?**
2	1	Facil
5	10	Tedioso
10	45	Dificil
20	190	Inviable
100	4950	Imposible

El ACP reemplaza esos miles de graficas por **1 o 2** que capturan la mayor parte de la informacion.

Contexto

En genomica, p puede ser el numero de genes activos en una celula: decenas de miles. El ACP es el primer paso estandar en casi todo analisis genomico moderno.

El ejemplo de esta sesión: datos de automóviles

Los datos `mtcars` (Motor Trend, 1974): 32 modelos, 9 variables cuantitativas.

Variable	Descripcion
`mpg`	Consumo (millas por galon)
`cyl`	Numero de cilindros
`disp`	Desplazamiento del motor (pulg. cubicas)
`hp`	Potencia (caballos de fuerza)
`drat`	Relacion del eje trasero
`wt`	Peso (miles de libras)
`qsec`	Tiempo en 1/4 de milla
`gear`	Numero de marchas
`carb`	Numero de carburadores

Las variables tienen **unidades y escalas muy distintas** — problema que resolveremos.

2. El problema de la dimensionalidad

Visualizando en 1 y 2 dimensiones

```
mtcars$car = rownames(mtcars)
ggplot(mtcars, aes(x=mpg, y=rep(0,nrow(mtcars)), label=car)) +
  geom_point(size=1.5) +
  geom_text_repel(size=1.6, box.padding=1.0, max.overlaps=Inf) +
  xlab("Millas por galon") + ylab("") +
  theme_minimal() +
  theme(axis.text.y=element_blank(), axis.ticks.y=element_blank())
```

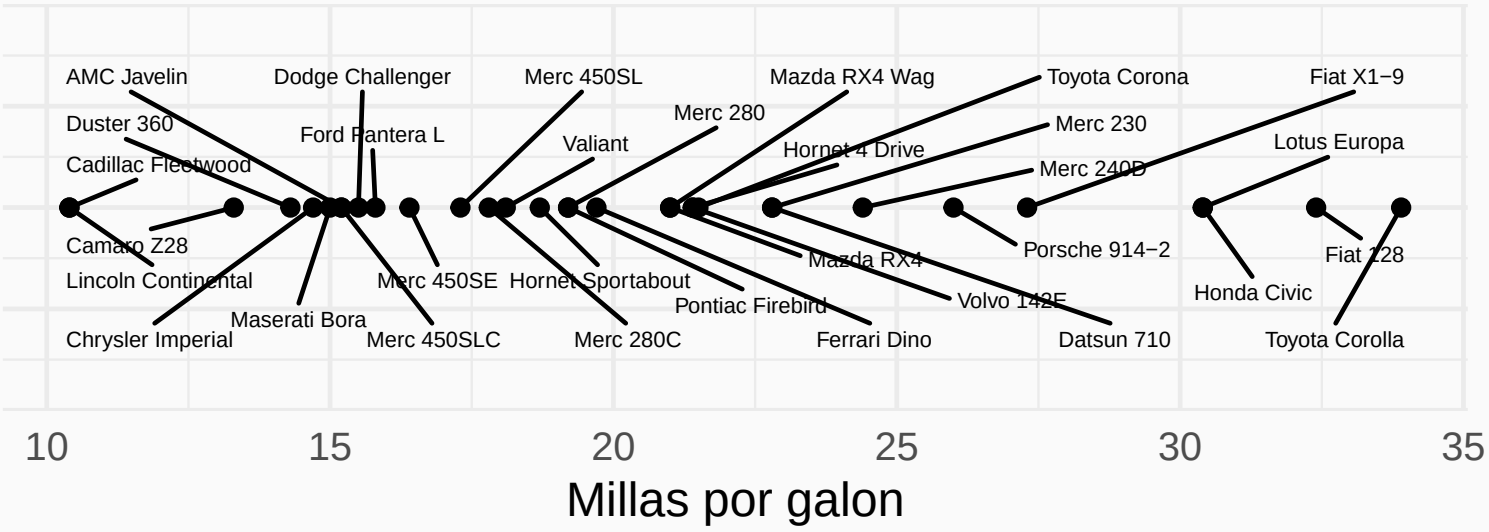

Con 1 variable: Fiat 128 y Toyota Corolla son similares entre si y diferentes a Lincoln Continental y Cadillac Fleetwood.

Dos variables: el diagrama de dispersión

```
ggplot(mtcars, aes(x=mpg, y=wt, label=car)) +
  geom_point(size=1.2) +
  geom_text_repel(size=1.6, box.padding=0.3, max.overlaps=Inf) +
  xlab("Millas por galon") + ylab("Peso") + theme_minimal()
```

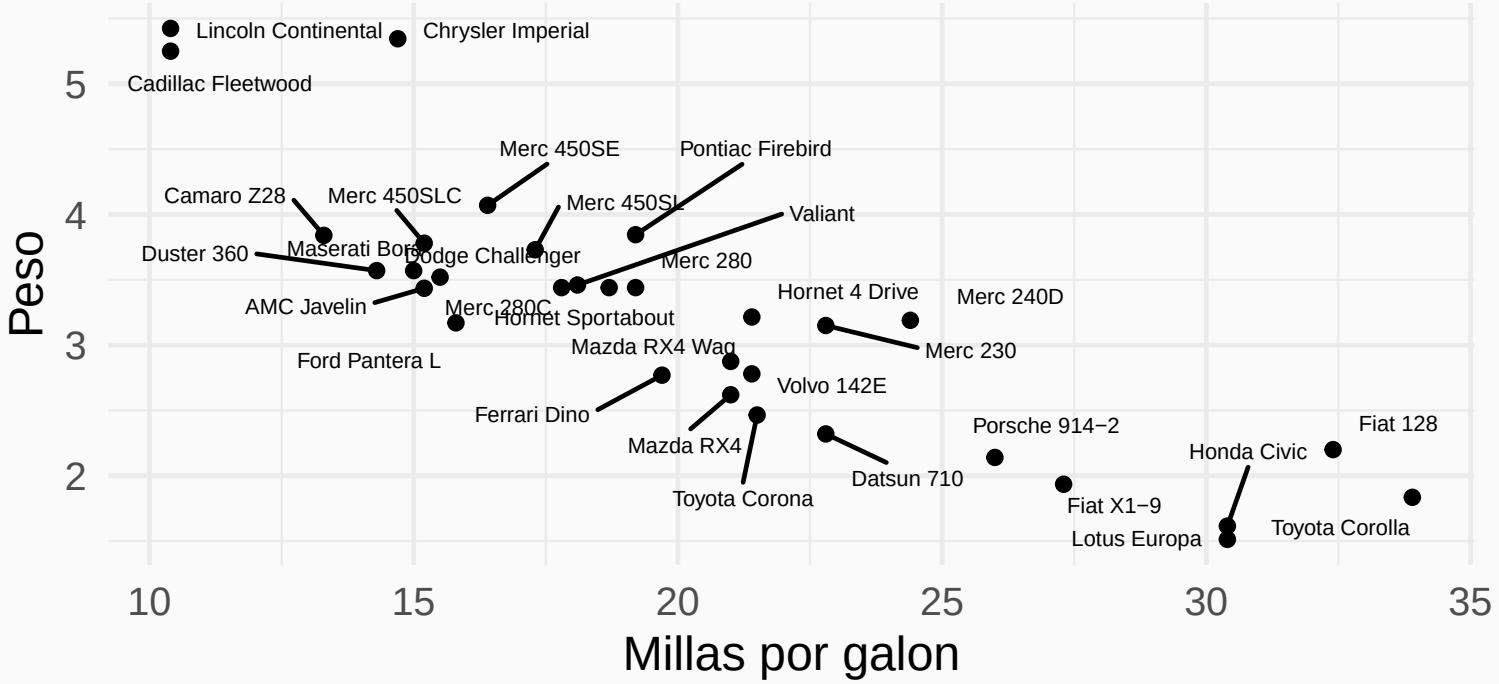

Con 2 variables confirmamos: los livianos de alto rendimiento se oponen a los pesados de bajo rendimiento. ¿Qué pasa con las 7 variables restantes?

Exploración univariada de las 9 variables

```r
# vs y am son binarias sin estructura ordinal: se excluyen
mtcars2 = mtcars %>% select(-c(vs, am, car))
```

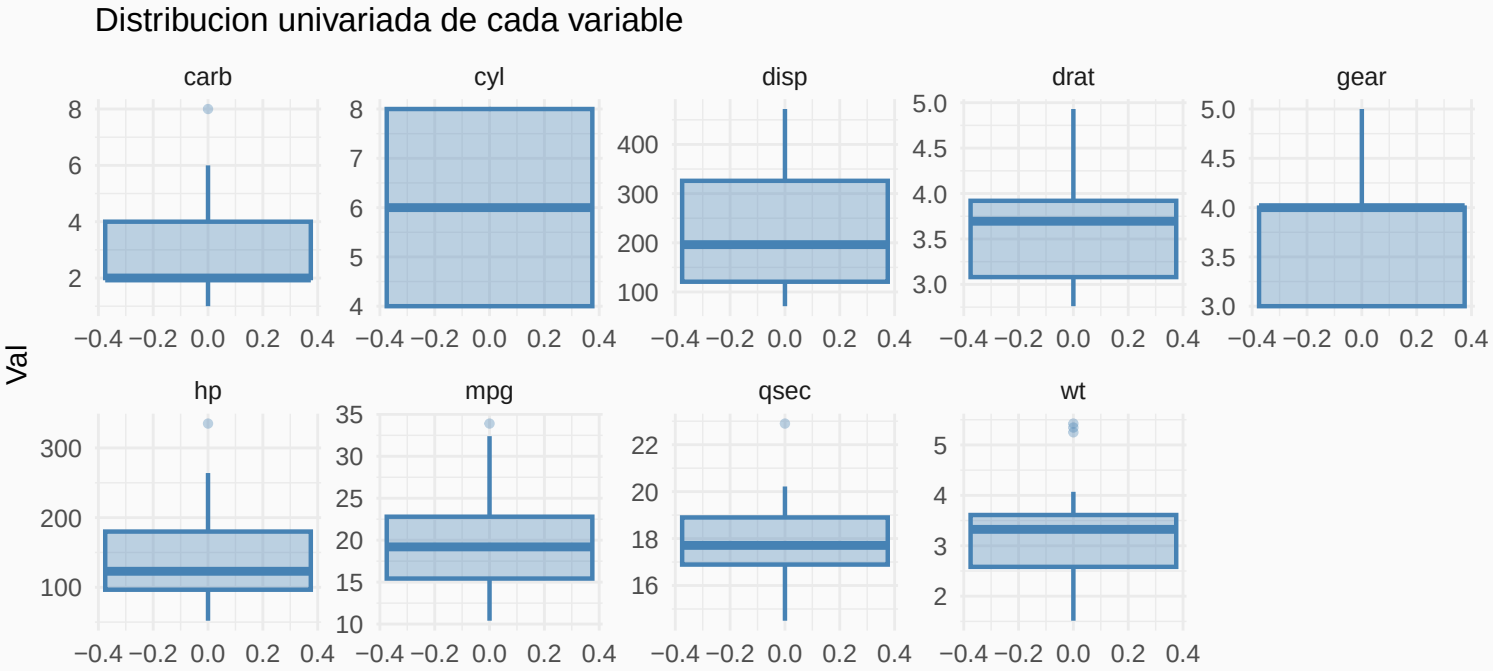

La estructura de correlación entre las 9 variables

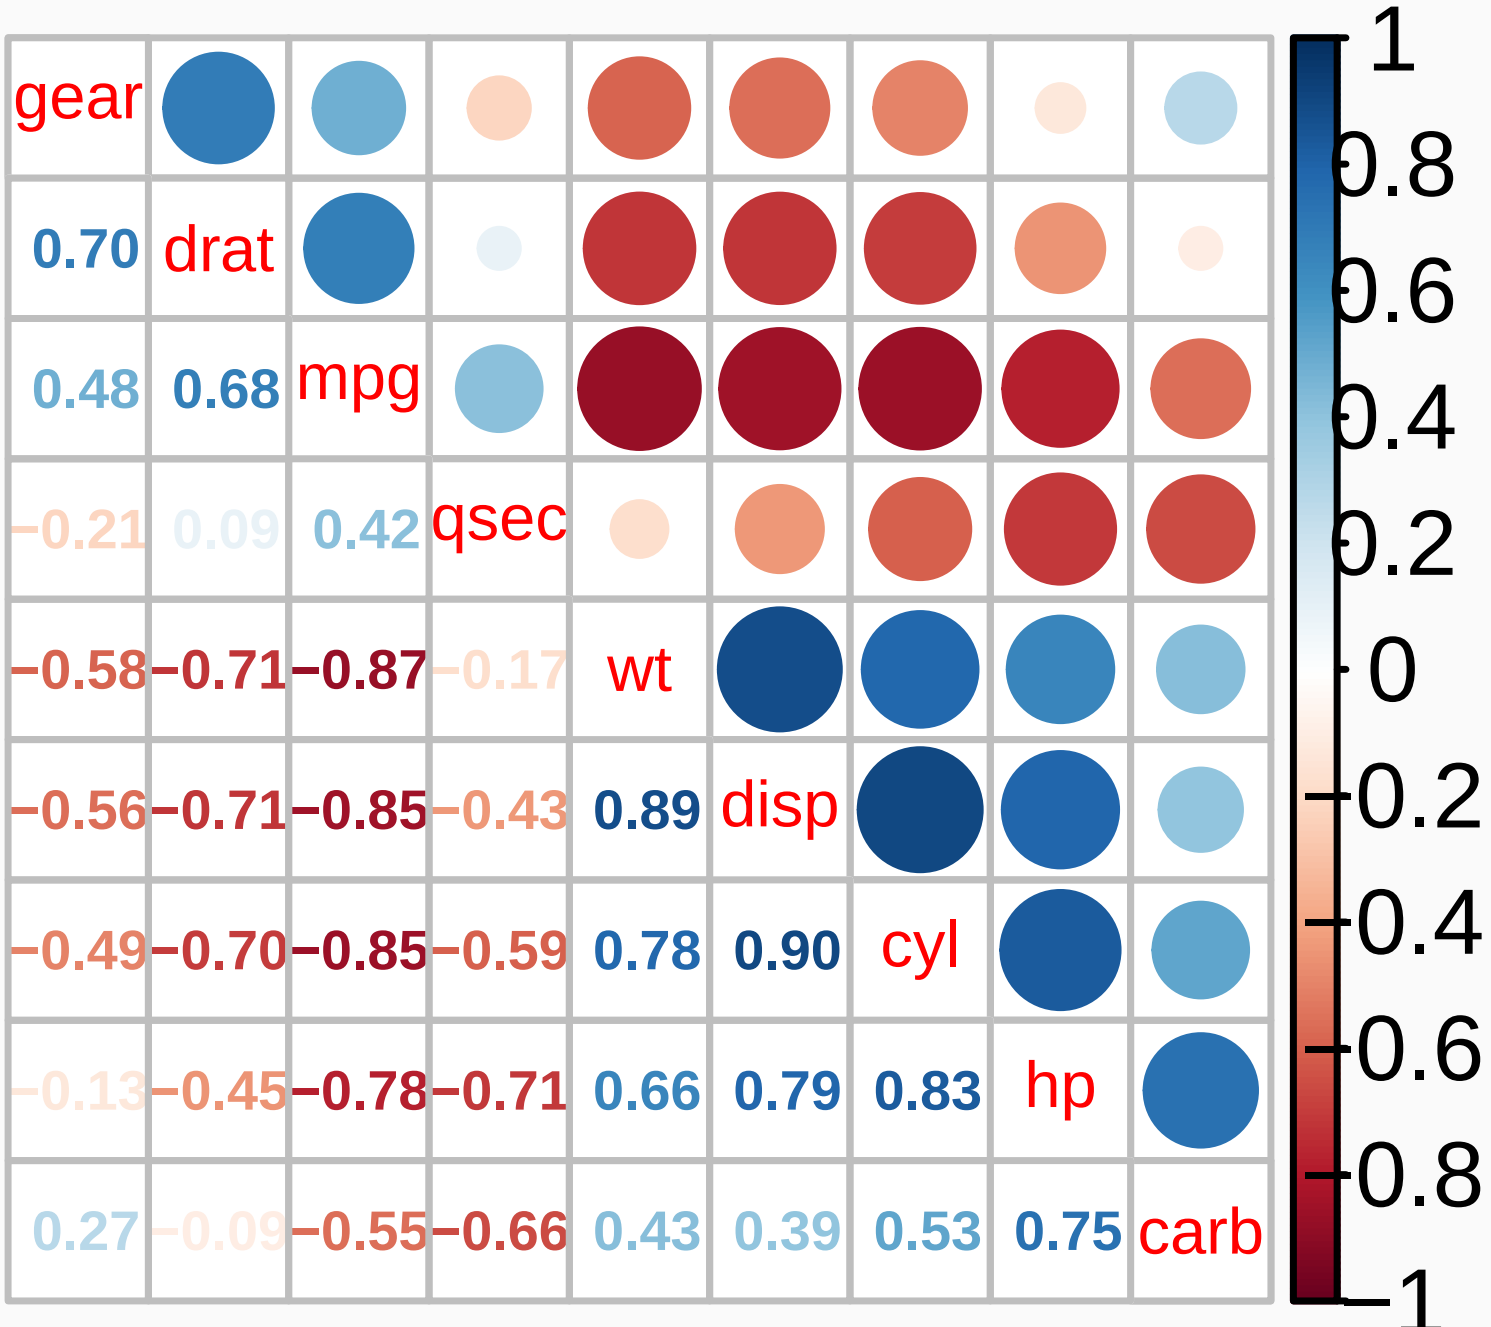

Muchas variables están muy correlacionadas: `disp`, `hp`, `wt`, `cyl` comparten información. Esto sugiere que **pocos ejes** pueden resumir bien los datos.

3. La descomposición espectral

¿Qué es la descomposición espectral?

Cualquier matriz de covarianza Σ (simétrica, semidefinida positiva) puede escribirse como:

$$\Sigma = P\Lambda P^\top$$

donde:

- $\Lambda = \text{diag}(\lambda_1, \lambda_2, \ldots, \lambda_p)$, con $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0$: los **valores propios** (autovalores)
- $P = [\mathbf{p}_1 \mid \mathbf{p}_2 \mid \cdots \mid \mathbf{p}_p]$: los **vectores propios** (autovectores), ortonormales ($PP^\top = I$)

Significado intuitivo: Σ rota, estira y gira el espacio. La descomposición separa esas dos acciones: P da las **direcciones** (rotación) y Λ da los **tamaños** de estiramiento.

Ejemplo de computo: descomposicion espectral 2x2

Considere la siguiente matriz de covarianza para dos variables:

$$\Sigma = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$$

```r
Sigma = matrix(c(3, 1, 1, 2), nrow=2)
descomp = eigen(Sigma)            # funcion base de R

lambda = descomp$values           # valores propios
P      = descomp$vectors          # vectores propios (columnas)

cat("Valores propios:\n"); round(lambda, 3)
```

```
## Valores propios:
```

```
## [1] 3.618 1.382
```

```r
cat("\nVectores propios (columnas de P):\n"); round(P, 3)
```

```
##
## Vectores propios (columnas de P):
```

```
##        [,1]   [,2]
## [1,] -0.851  0.526
## [2,] -0.526 -0.851
```

Verificando: $\Sigma = P\Lambda P^\top$

```r
Lambda = diag(lambda)            # matriz diagonal de val. propios

# Reconstruccion: debe ser igual a Sigma original
Sigma_reconstruida = P %*% Lambda %*% t(P)
round(Sigma_reconstruida, 6)
```

```
##      [,1] [,2]
## [1,]    3    1
## [2,]    1    2
```

```r
# Verificando ortogonalidad de P: P * P^T = I
round(P %*% t(P), 6)
```

```
##      [,1] [,2]
## [1,]    1    0
## [2,]    0    1
```

La reconstruccion es exacta. $PP^\top = I$ confirma que los vectores propios son ortonormales.

¿Qué nos dice la descomposición de este ejemplo?

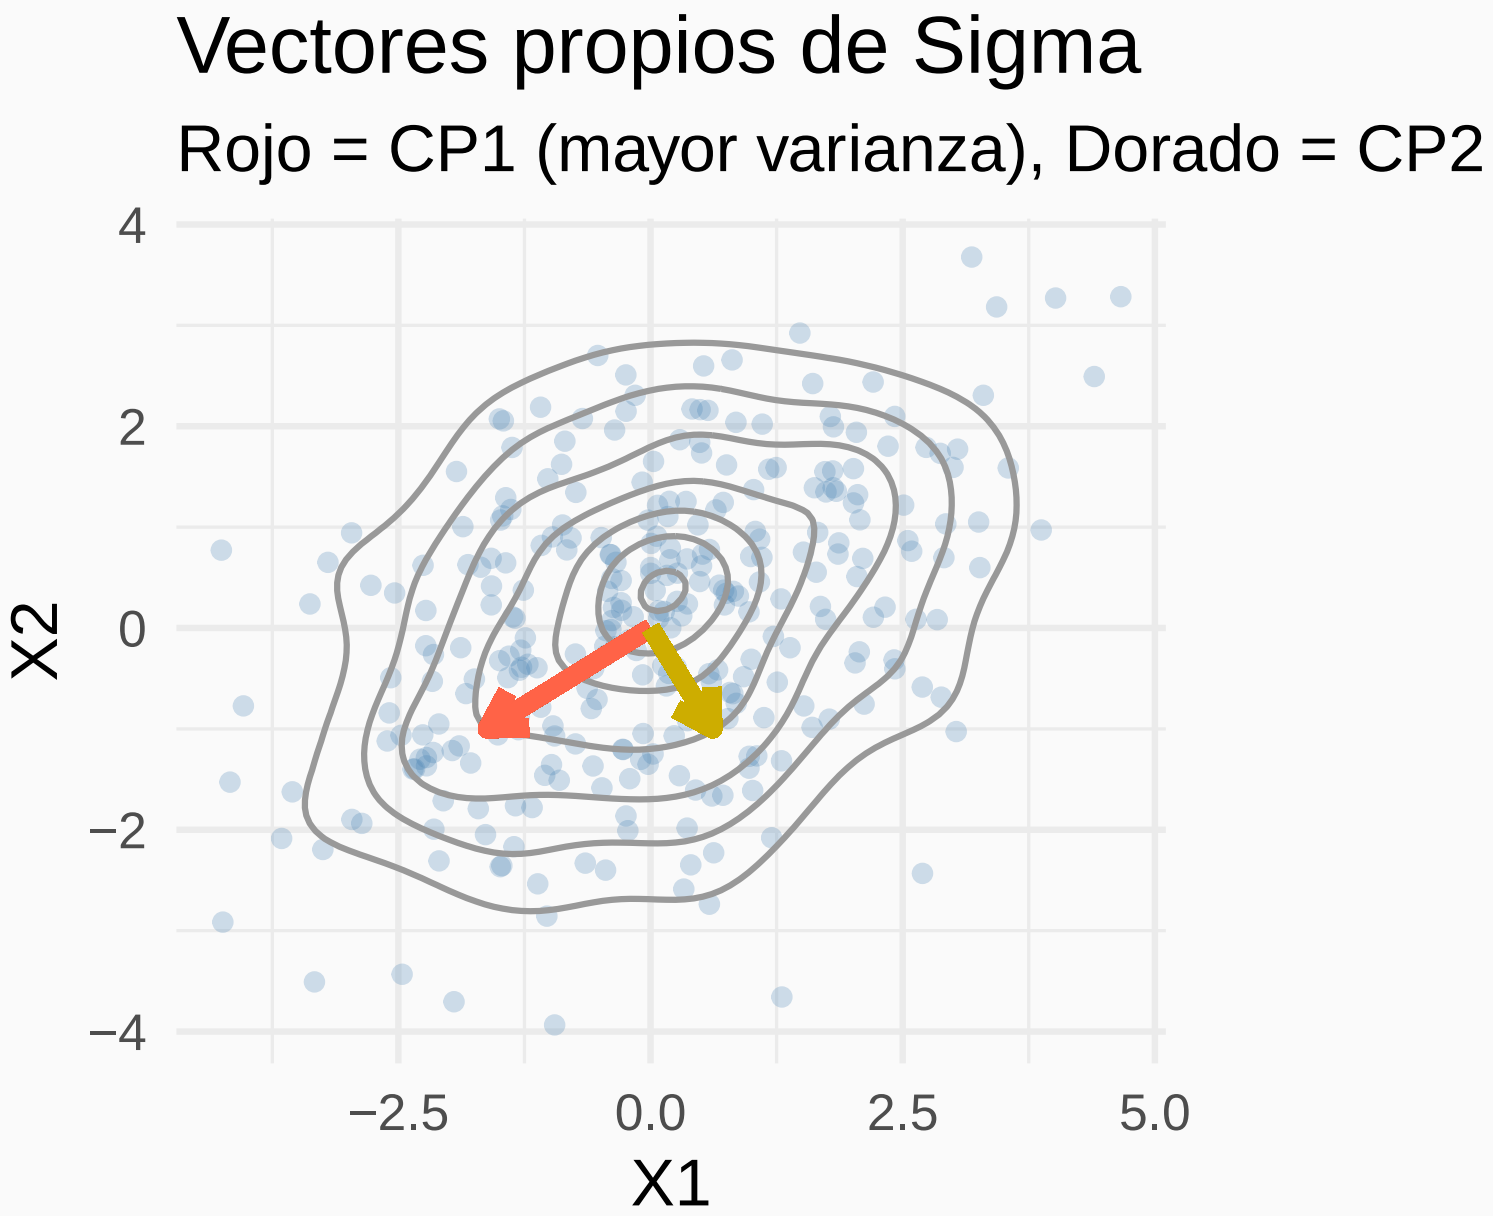

Los vectores propios apuntan en las **direcciones de mayor variabilidad**

La conexión con el ACP

Conexion fundamental
Los componentes principales son exactamente los vectores propios de Σ, ordenados de mayor a menor valor propio.

Elemento	En la descomp. espectral	En el ACP
$\mathbf{p}_k$	Vector propio k de Σ	Cargas del CP k
λ_k	Valor propio k de Σ	Varianza del CP k
z_{ik}	—	Puntaje del individuo i en CP k

Ejecutar `prcomp()` en R es esencialmente aplicar `eigen()` a la matriz de covarianza (o correlacion si se estandarizan los datos), de forma numericamente estable via descomposicion en valores singulares (SVD).

4. Intuición geométrica del ACP

Centrar los datos: el primer paso

El ACP siempre trabaja con datos **centrados** (media = 0):

```
mtcars_c = mtcars %>%
  mutate(mpg_c = mpg - mean(mpg), wt_c = wt - mean(wt))
ggplot(mtcars_c, aes(x=mpg_c, y=wt_c, label=car)) +
  geom_point(size=1.2) +
  geom_text_repel(size=1.5, box.padding=0.25, max.overlaps=Inf) +
  geom_hline(yintercept=0, linetype="dashed", color="grey50") +
  geom_vline(xintercept=0, linetype="dashed", color="grey50") +
  xlab("mpg centrado") + ylab("wt centrado") + theme_minimal()
```

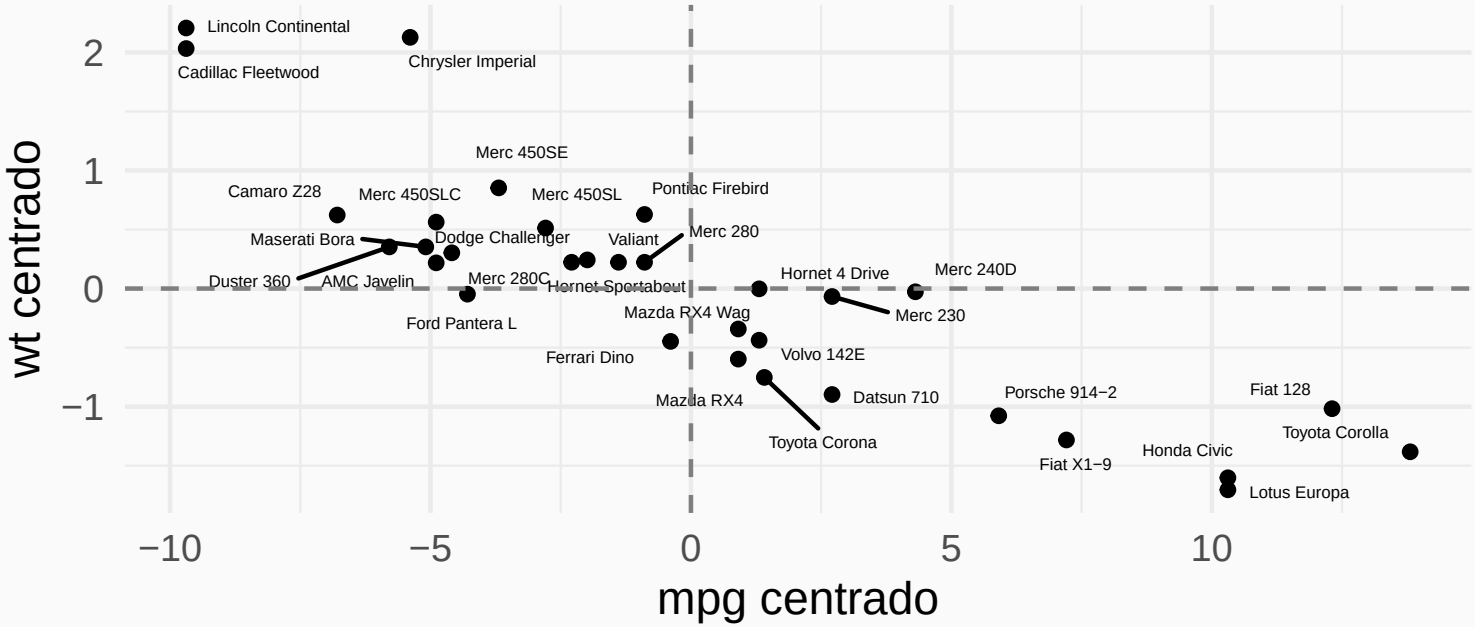

Rotar hasta encontrar el eje de mayor varianza

CP1 = la línea a través del origen que maximiza la varianza proyectada:

```
gg_c = ggplot(mtcars_c, aes(x=mpg_c, y=wt_c)) +
  geom_point(size=0.9, color="steelblue") + theme_minimal() +
  xlab("mpg centrado") + ylab("wt centrado")
for(s in c(-1,-0.5,-0.1,0.1,0.5,1)){
  col_ = if(s  == -0.1) "tomato" else "grey70"
  lw_  = if(s  == -0.1) 1.1 else 0.4
  gg_c = gg_c + geom_abline(intercept=0, slope=s,
                            color=col_, linewidth=lw_, linetype="dashed")
}
gg_c + labs(title="Candidatos para CP1. La linea roja es la mejor")
```

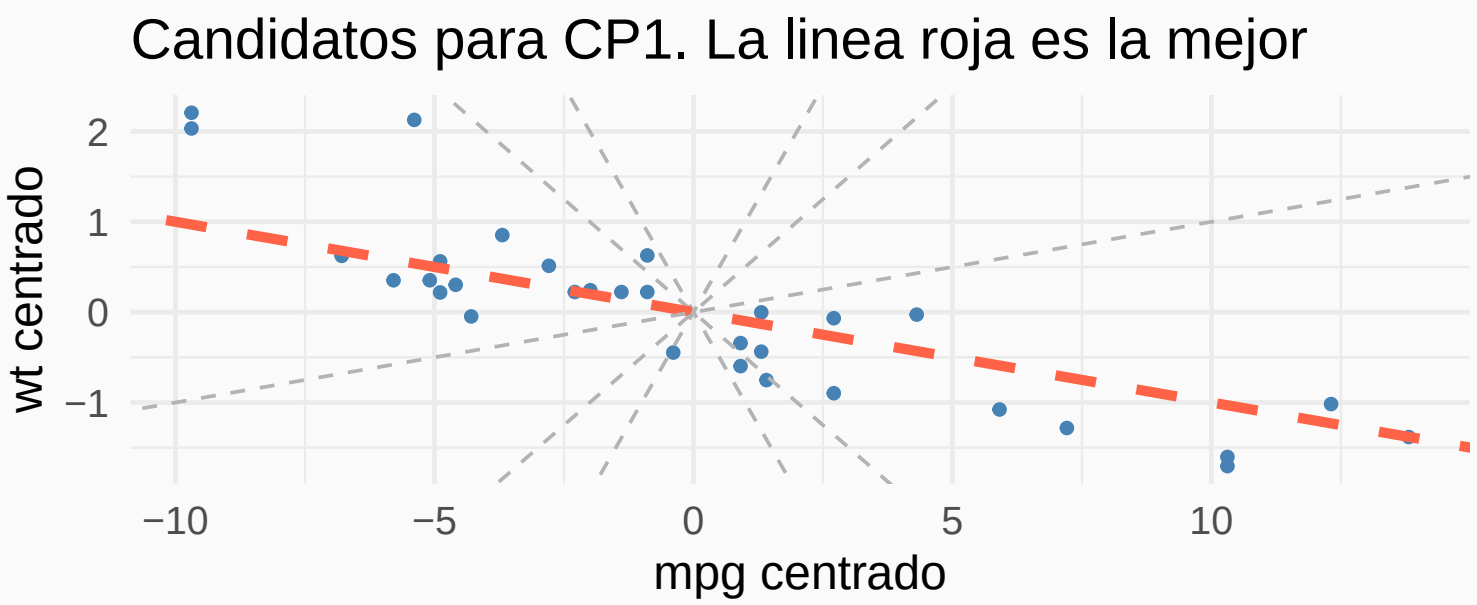

La geometría del CP1: proyecciones

CP1 minimiza la distancia de cada punto a su proyeccion sobre la linea (equivalente a maximizar la varianza de las proyecciones)

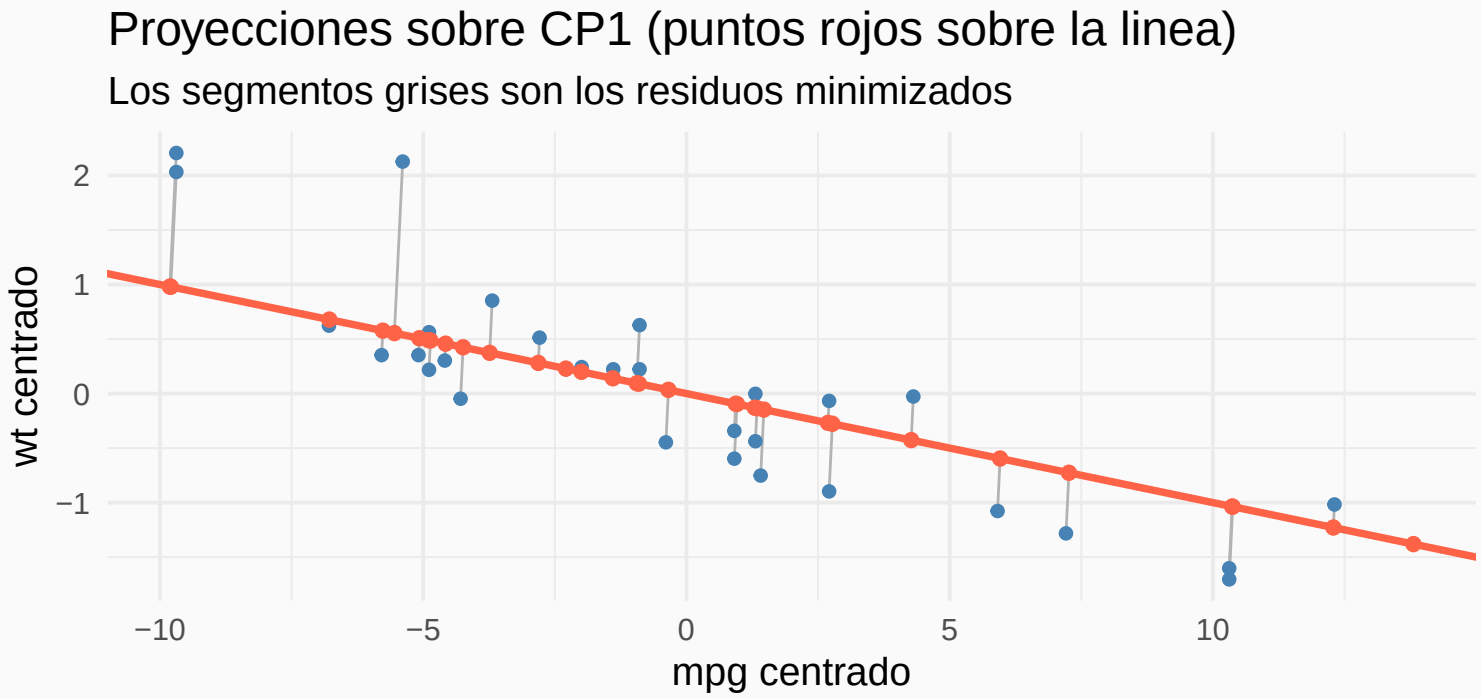

El valor propio como suma de distancias proyectadas

Interpretacion del valor propio λ_k
λ_k es **proporcional a la suma de distancias cuadradas** desde las proyecciones de cada observacion sobre CP$_k$ hasta el centroide (el origen, tras centrar los datos):

$$\lambda_k \propto \sum_{i=1}^{n} z_{ik}^2 = \sum_{i=1}^{n} \left(\mathbf{p}_k^\top (\mathbf{x}_i - \bar{\mathbf{x}})\right)^2$$

Intuitivamente: entre más dispersas estén las proyecciones alrededor del centroide, mayor es λ_k, y más información captura el CP k.

CP1 tiene el λ_1 más grande — es la dirección donde las proyecciones quedan **más alejadas del centroide**, es decir, donde los datos están más "esparcidos''.

Verificando la interpretación del valor propio

```r
# Puntajes en CP1 y CP2 (datos estandarizados)
pc_c   = prcomp(mtcars2, scale=TRUE)
scores = pc_c$x

# Suma de cuadrados de puntajes / (n-1) = varianza = valor propio
varpc1 = sum(scores[,"PC1"]^2) / (nrow(scores) - 1)
varpc2 = sum(scores[,"PC2"]^2) / (nrow(scores) - 1)

# Valores propios del ACP
lambdas = pc_c$sdev^2

cat("Var. puntajes CP1:", round(varpc1, 4),
    "  lambda_1:", round(lambdas[1], 4), "\n")
```

```
## Var. puntajes CP1: 5.6559   lambda_1: 5.6559
```

```r
cat("Var. puntajes CP2:", round(varpc2, 4),
    "  lambda_2:", round(lambdas[2], 4), "\n")
```

```
## Var. puntajes CP2: 2.0821   lambda_2: 2.0821
```

La varianza de los puntajes en cada CP **es exactamente** el valor propio correspondiente.

Los CPs son ortogonales: ¿qué significa?

Los ejes de los componentes principales son **perpendiculares entre sí**:

- **Geometricamente**: CP2 es perpendicular a CP1, CP3 a ambos, etc. Forman un nuevo sistema de coordenadas rotado respecto al original
- **Estadisticamente**: los puntajes en distintos CPs tienen correlacion cero — cada CP captura informacion **no redundante**
- **Consecuencia**: la varianza total de los datos se "reparte" entre los CPs sin solapamiento: $\lambda_1 + \lambda_2 + \cdots + \lambda_p = \text{traza}(\Sigma)$

```r
# Correlacion entre puntajes en distintos CPs: debe ser ~0
round(cor(pc_c$x)[1:3, 1:3], 6)
```

```
##     PC1 PC2 PC3
## PC1   1   0   0
## PC2   0   1   0
## PC3   0   0   1
```

5. El ACP en R

Escalamiento: por qué es crítico

```r
pc_b = prcomp(mtcars2)              # SIN estandarizar
pc_c = prcomp(mtcars2, scale=TRUE) # CON estandarizar (recomendado)

# % varianza explicada por los 2 primeros CPs
sin_esc = summary(pc_b)$importance[2, 1:2]
con_esc = summary(pc_c)$importance[2, 1:2]
rbind(sin_escala=round(sin_esc,3), con_escala=round(con_esc,3))
```

```
##              PC1   PC2
## sin_escala 0.927 0.072
## con_escala 0.628 0.231
```

Sin estandarizar, `disp` (valores en cientos de pulgadas cubicas) domina completamente. Con estandarizar, cada variable aporta en igualdad de condiciones.

Regla practica
Siempre estandarizar con `scale=TRUE` cuando las variables tienen unidades o escalas distintas.

Cargas e individuos

```r
pc_f = prcomp(mtcars2, scale=TRUE, rank.=2)
round(pc_f$rotation, 3) # Cargas: contribucion de cada variable a cada CP
```

```
##         PC1    PC2
## mpg  -0.393  0.028
## cyl   0.403  0.016
## disp  0.397 -0.089
## hp    0.367  0.269
## drat -0.312  0.342
## wt    0.373 -0.172
## qsec -0.224 -0.484
## gear -0.209  0.551
## carb  0.245  0.484
```

```r
round(pc_f$x, 2)# Puntajes: coordenadas de cada auto en el nuevo espacio
```

```
##                      PC1   PC2
## Mazda RX4          -0.66  1.17
## Mazda RX4 Wag      -0.64  0.98
## Datsun 710         -2.30 -0.33
## Hornet 4 Drive     -0.22 -1.98
## Hornet Sportabout   1.59 -0.83
## Valiant             0.05 -2.45
## Duster 360          2.71  0.36
## Merc 240D          -2.04 -0.80
## Merc 230           -2.30 -1.31
## Merc 280           -0.38  0.58
## Merc 280C          -0.37  0.41
## Merc 450SE          1.88 -0.72
## Merc 450SL          1.67 -0.71
## Merc 450SLC         1.78 -0.84
## Cadillac Fleetwood  3.65 -0.95
## Lincoln Continental 3.71 -0.84
## Chrysler Imperial   3.33 -0.48
## Fiat 128           -3.45 -0.43
## Honda Civic        -3.85  0.71
## Toyota Corolla     -3.85 -0.39
## Toyota Corona      -1.90 -1.57
## Dodge Challenger    1.80 -1.13
## AMC Javelin         1.46 -0.98
## Camaro Z28          2.60  0.76
## Pontiac Firebird    1.87 -0.98
## Fiat X1-9          -3.15 -0.26
## Porsche 914-2      -2.78  1.64
```

Interpretación de las cargas

Elemento	Nombre	Descripcion
$\mathbf{u}_j$	Cargas (*loadings*)	Pesos de cada variable en el CP j
z_{ij}	Puntaje (*score*)	Coordenada del individuo i en el CP j
λ_j	Valor propio	Varianza (dispersion) a lo largo del CP j
$\sqrt{\lambda_j}$	Valor singular	Desv. estandar a lo largo del CP j

- **CP1**: cargas altas en `disp`, `hp`, `wt`, `cyl` (positivas) y `mpg` (negativa). Es un **indice de tamano y consumo**: autos grandes y poco eficientes tienen CP1 alto
- **CP2**: carga alta en `qsec` (positiva) y `hp` (negativa). Es un **indice de rendimiento en pista**

6. Varianza explicada y selección de CPs

Proporción de varianza explicada

```r
round(summary(pc_c)$importance, 3)
```

```
##                           PC1   PC2   PC3   PC4   PC5   PC6   PC7   PC8   PC9
## Standard deviation     2.378 1.443 0.710 0.515 0.428 0.352 0.324 0.242 0.149
## Proportion of Variance 0.628 0.231 0.056 0.029 0.020 0.014 0.012 0.006 0.002
## Cumulative Proportion  0.628 0.860 0.916 0.945 0.966 0.979 0.991 0.998 1.000
```

Con solo **2 componentes** explicamos el 86% de la variabilidad total de las 9 variables originales.

El screeplot

```r
screeplot(pc_c, col="tomato", pch=16,
          type="lines", cex=1.5, lwd=2,
          main="Screeplot - mtcars")
```

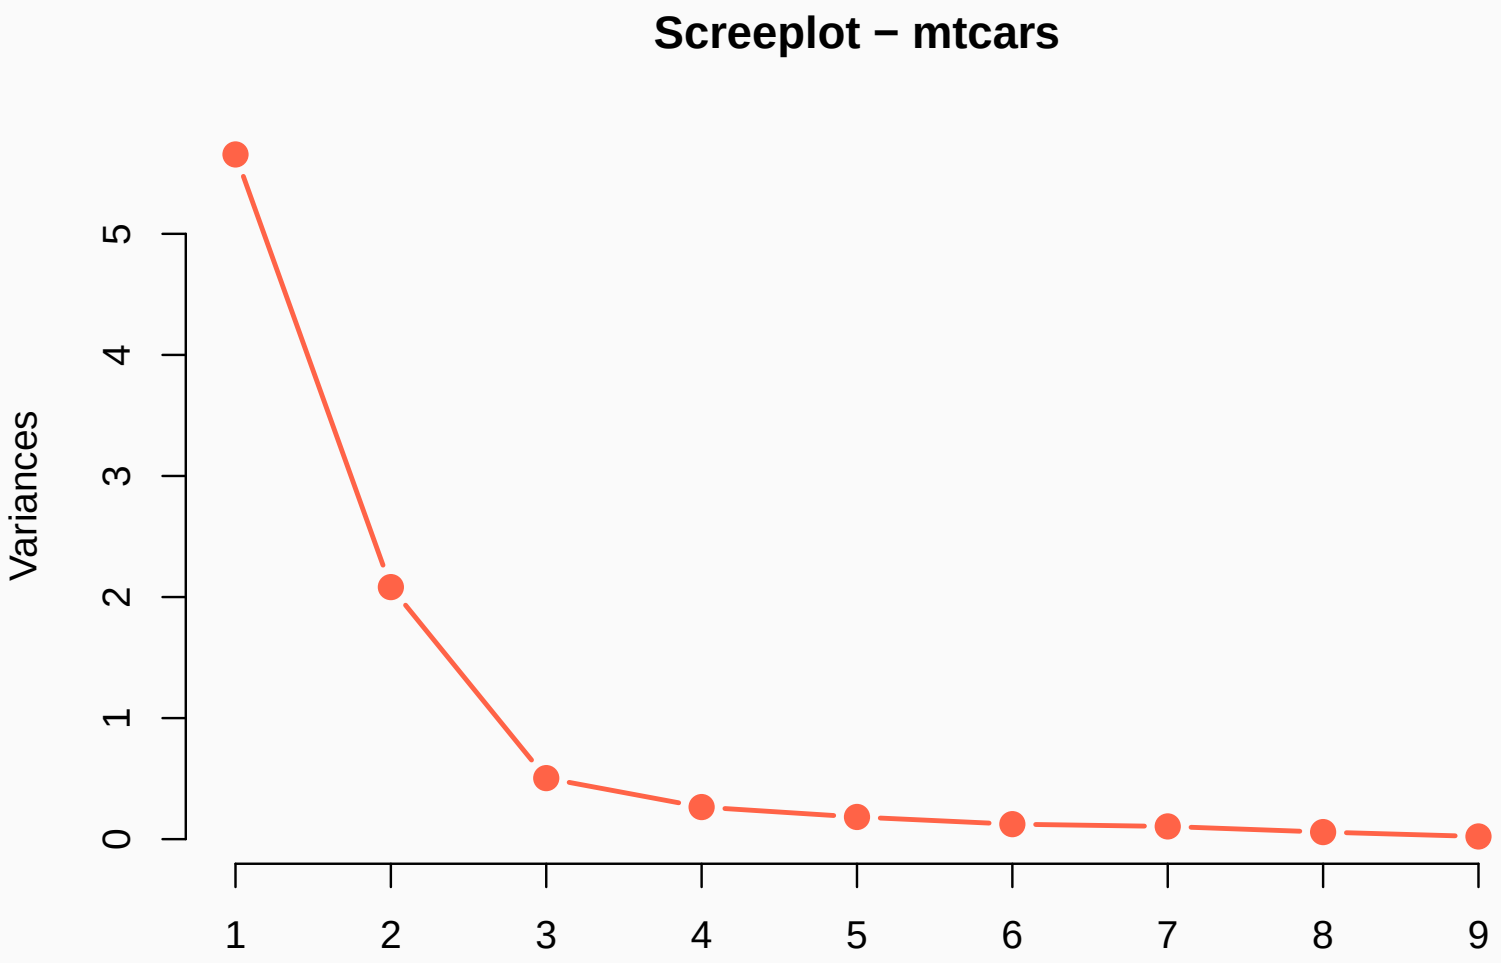

Leer el screeplot: tres reglas prácticas

- **Regla del codo**: elegir k donde la curva dobla abruptamente. Despues del codo, cada CP adicional aporta poca varianza nueva
- **Regla del 80%**: seleccionar los CPs que acumulen $\geq 80\%$ de la varianza
- **Regla de Kaiser**: retener los CPs con $\lambda_k > 1$ en datos estandarizados (el CP explica mas que una sola variable original)

Para mtcars
El codo esta en $k = 2$, que explica el 86% de la variabilidad. Con 2 componentes resumimos 9 variables con minima perdida de informacion.

7. Visualización con `factoextra`

Gráfico de variables: el círculo de correlaciones

```
fviz_pca_var(pc_c,col.var="contrib",gradient.cols=c("steelblue","gold","tomato"),repel=T)
```

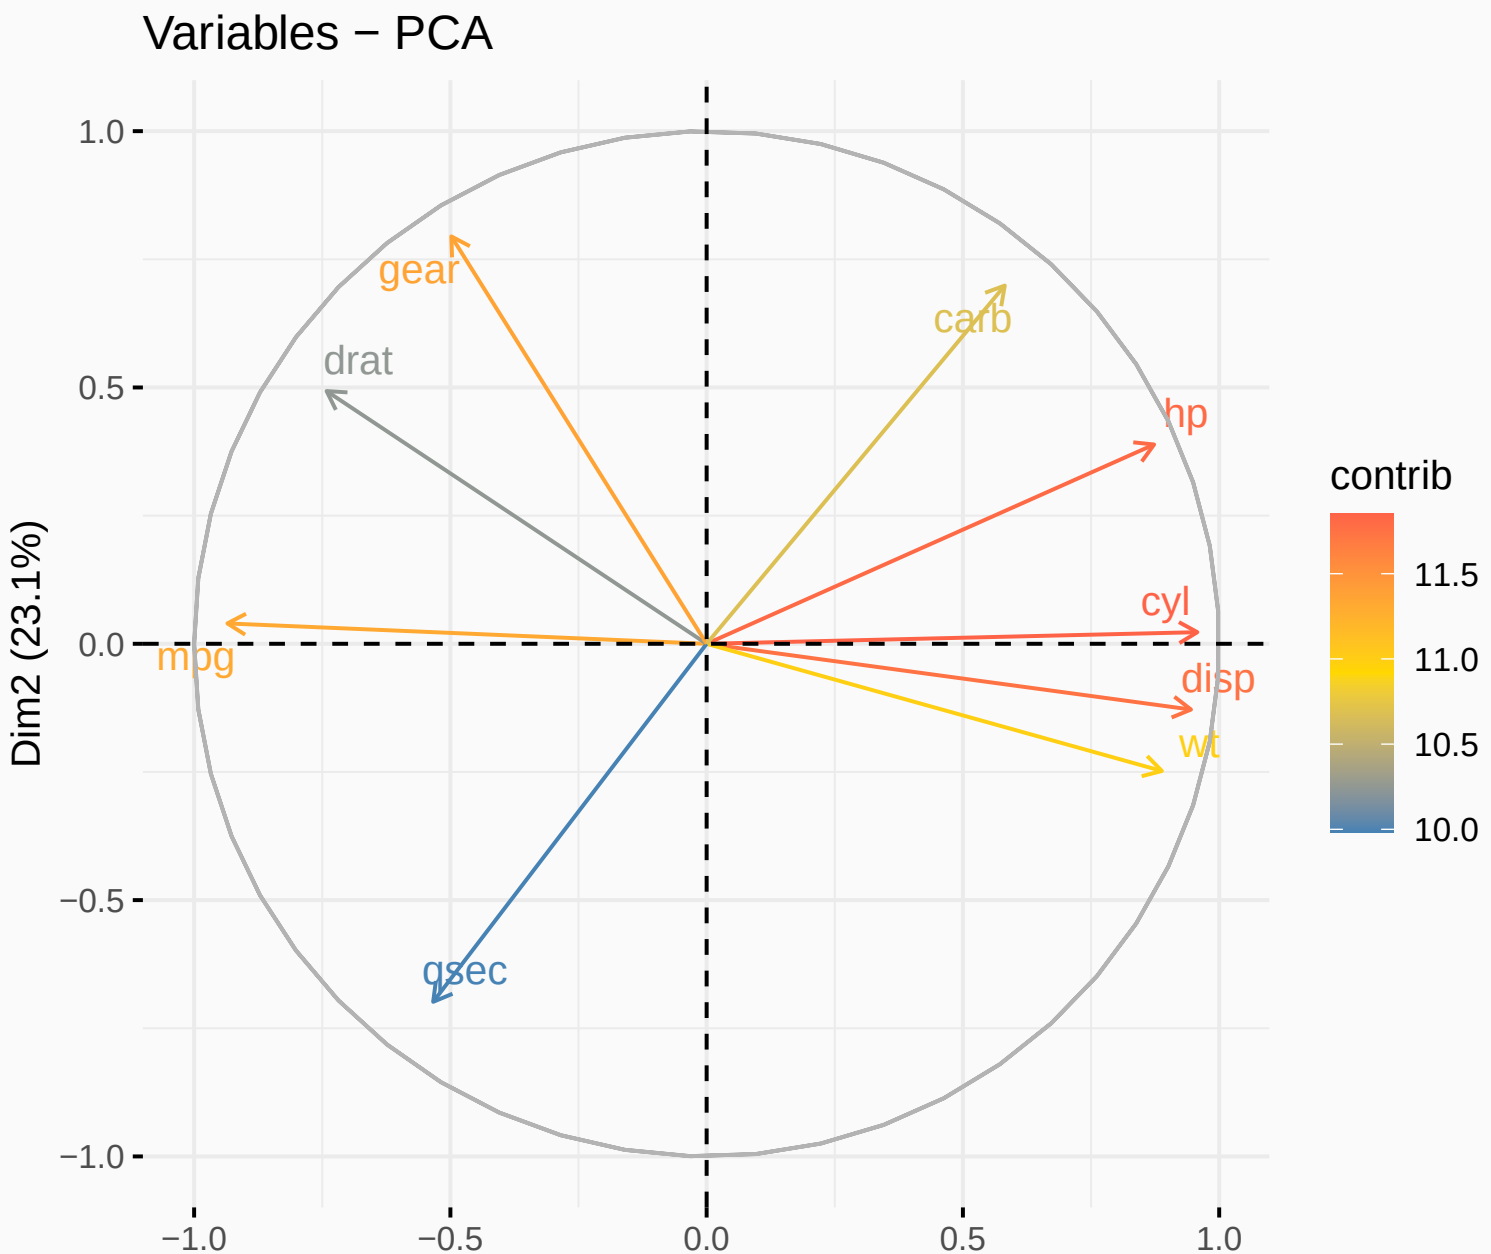

Cómo leer el círculo de correlaciones

- **Longitud de la flecha**: carga total de la variable en los 2 CPs graficados. Mas larga = mas informativa en este plano
- **Angulo entre dos flechas**: correlacion entre las variables correspondientes. Angulo pequeno = alta correlacion positiva; $180°$ = correlacion negativa alta; $90°$ = sin correlacion lineal
- **Posicion en el eje**: indica en que sentido del CP aumenta esa variable

`disp`, `hp`, `wt` apuntan juntas (correlacionadas). `mpg` apunta en sentido opuesto (correlacion negativa con las anteriores). `qsec` apunta hacia el eje vertical (CP2), casi independiente de las otras.

Gráfico de individuos: el primer plano factorial

```
fviz_pca_ind(pc_c,col.ind=mtcars$mpg,gradient.cols=c("tomato","gold","steelblue"),
             repel=TRUE, label="all")
```

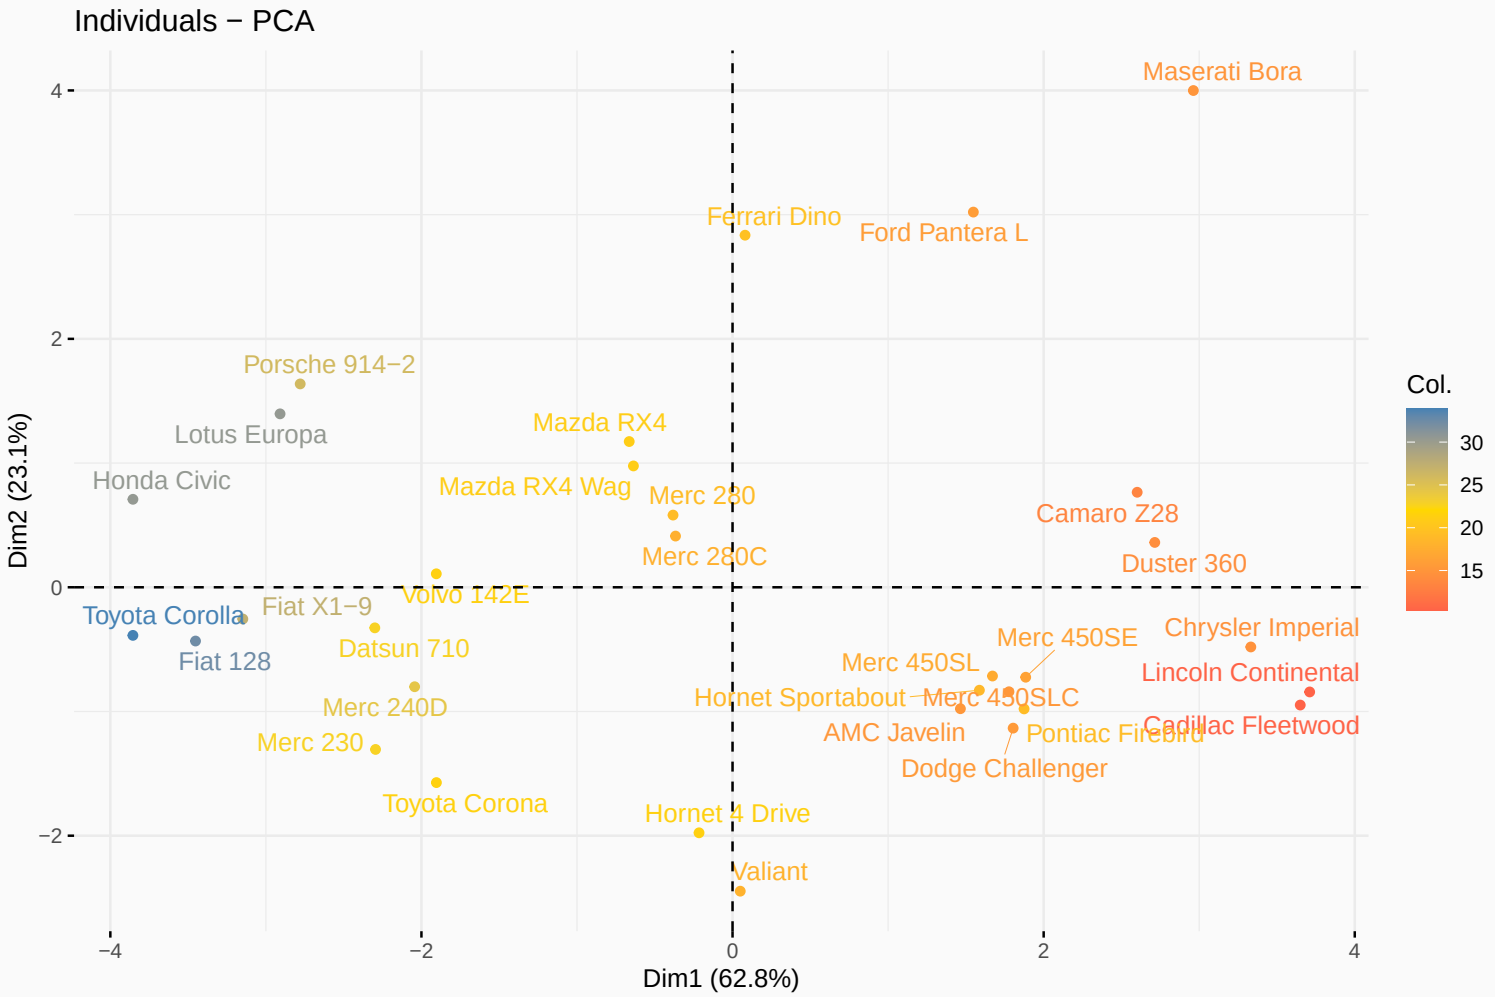

Leyendo el primer plano factorial

- **Autos a la izquierda (azul)**: alto rendimiento, ligeros, pocos cilindros (Fiat 128, Toyota Corolla, Honda Civic)
- **Autos a la derecha (rojo)**: bajo rendimiento, pesados, muy potentes (Lincoln Continental, Cadillac Fleetwood)
- **Eje vertical (CP2)**: separa los autos rapidos en pista (Maserati Bora, Ferrari Dino, arriba) de los lentos

Regla de lectura del plano factorial
Dos autos **cercanos** en el plano son similares en las 9 variables originales. Dos autos **lejanos** son muy distintos. La distancia en el plano es una aproximacion a su distancia real en $\mathbb{R}^9$.

El biplot: variables e individuos juntos

```
fviz_pca_biplot(pc_c, repel=TRUE,col.var="tomato", col.ind="steelblue",label="all")
```

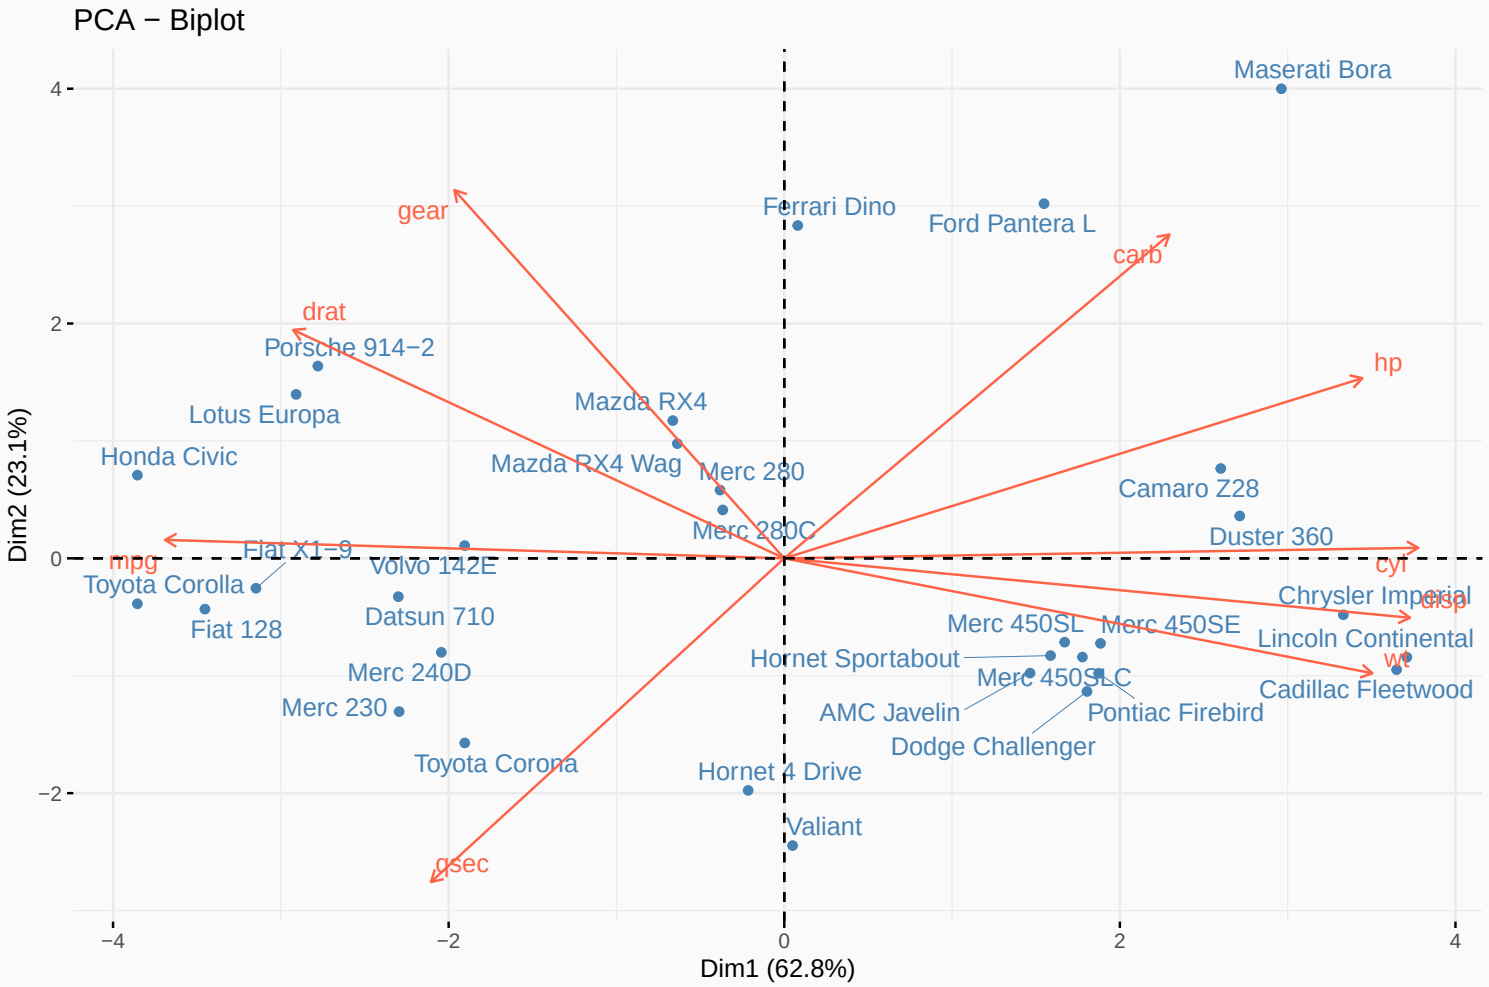

El biplot superpone el circulo de correlaciones y el plano factorial: permite ver simultaneamente que variables caracterizan a que individuos.

8. Outliers y el ACP

El ACP es sensible a outliers

El ACP maximiza varianza. Un outlier aumenta artificialmente la varianza en su dirección, pudiendo sesgar los ejes principales:

```
d2 = mahalanobis(mtcars2,
                 center=colMeans(mtcars2),
                 cov=cov(mtcars2))
outliers_idx = which(d2 > qchisq(0.975, df=ncol(mtcars2)))
paste0("Outliers detectados: ", length(outliers_idx),
       " -> ", paste(rownames(mtcars2)[outliers_idx], collapse=", "))
```

```
## [1] "Outliers detectados: 1 -> Ford Pantera L"
```

Conexion con la Sesion 3

Antes de ejecutar el ACP, use la **distancia de Mahalanobis** para detectar y evaluar outliers multivariados. Un punto con $d_M^2 > \chi_p^2(0.975)$ merece revision antes de incluirlo.

9. Funciones en R

`prcomp()` vs `princomp()`

Salida	prcomp()	princomp()
Desv. estandar de CPs	`$sdev`	`$sdev`
Cargas (vectores prop.)	`$rotation`	`$loadings`
Media de las variables	`$center`	`$center`
Escalamiento aplicado	`$scale`	`$scale`
Puntajes (scores)	`$x`	`$scores`

Recomendacion

Prefiera `prcomp()` por mayor precision numerica (usa SVD en lugar de la descomposicion espectral directa de la matriz de covarianza muestral).

Flujo completo de un ACP

1. **Explorar** variables: tipos, unidades, outliers, correlaciones
2. **Excluir** variables no cuantitativas continuas
3. **Detectar outliers** con distancia de Mahalanobis
4. **Ejecutar** `prcomp(datos, scale=TRUE)`
5. **Seleccionar** numero de CPs con screeplot y % varianza acumulada
6. **Interpretar** cargas (`$rotation`) de los CPs seleccionados
7. **Visualizar** con `factoextra`: circulo de correlaciones y plano factorial
8. **Comunicar** que captura cada CP en terminos del dominio del problema

10. El ACP en el mundo moderno

Aplicaciones de alto impacto

- **Genomica**: la reduccion de expresion genica ($p > 20.000$ genes) a 2–3 CPs para visualizar tipos celulares es el primer paso estandar en RNA-seq y datos de celula unica (*single-cell*)
- **Reconocimiento facial (eigenfaces)**: Turk & Pentland (1991) representaron imagenes de caras como combinaciones lineales de "caras propias" — los vectores propios de la matriz de covarianza de pixeles. Cada cara nueva es proyectada sobre estos CPs para su identificacion
- **Calidad del aire**: el CP1 de un conjunto de contaminantes medidos en varias estaciones resume el **nivel general de contaminacion**, mientras que CP2 puede distinguir contaminacion industrial de no industrial — exactamente lo que veremos en la Sesion 5

Más aplicaciones: finanzas y señales

- **Finanzas cuantitativas**: el modelo de factores de Fama-French reduce cientos de retornos de activos a unos pocos factores de riesgo via ACP. Los gestores de portafolio usan los primeros CPs para identificar exposicion a riesgo de mercado, tamano y valor
- **Neurociencia y EEG**: las senales de electrodos en el cerebro son altamente correlacionadas. El ACP separa componentes independientes de actividad neuronal de ruido electrico ambiental
- **Clima y meteorologia**: el ACP de temperatura y precipitacion en cientos de estaciones meteorologicas produce patrones espaciales llamados *teleconexiones* (como El Nino) que resumen la variabilidad climatica global

ACP como puerta de entrada al machine learning

- **Preprocesamiento**: reducir dimensionalidad antes de entrenar modelos de ML previene la "maldicion de la dimensionalidad"
- **Regularizacion**: la regresion sobre los primeros CPs (PCR, *Principal Component Regression*) estabiliza coeficientes cuando hay muchas variables correlacionadas
- **Deteccion de anomalias**: reconstruir datos desde pocos CPs y medir el error de reconstruccion detecta outliers. Usado en fraude bancario y mantenimiento predictivo industrial

Generalizaciones modernas del ACP
El ACP lineal es el caso mas simple de una familia de metodos:

t-SNE y **UMAP** (no lineales, para visualizacion)

Autoencoders (redes neuronales que generalizan el ACP)

Kernel PCA (ACP en espacios de alta dimension via kernel trick)

Limitaciones del ACP

- **Solo relaciones lineales**: si las variables tienen relaciones curvilineas, los CPs pueden ser poco informativos
- **Interpretabilidad no automatica**: las cargas requieren analisis cuidadoso para asignarles significado en el dominio del problema
- **Sensible a outliers**: un outlier multivariado puede sesgar los ejes — usar Mahalanobis previamente
- **Dependiente del escalamiento**: cambiar la escala de una variable puede cambiar completamente los resultados
- **No es un metodo de agrupamiento**: revela estructura pero no asigna grupos formalmente

11. Síntesis y puente

Conclusiones de la Sesión 4

- $\boldsymbol{\Sigma} = P\Lambda P^\top$: el ACP es la descomposicion espectral de Σ
- Los vectores propios de Σ son las **direcciones de los CPs**; los valores propios son su **varianza** (suma de distancias proyectadas al cuadrado desde el centroide)
- Los CPs son combinaciones lineales de las variables, ortogonales entre si
- **Siempre estandarizar** cuando las escalas son distintas
- El screeplot y el % de varianza acumulada guian la seleccion del numero de CPs
- Las cargas interpretan cada CP; los puntajes ubican individuos en el nuevo espacio

Conexión entre sesiones

Sesiones 1-2	**Sesion 3**	**Sesion 4**	**Sesion 5**
Distribuciones univariada y bivariada	Normal multivariada $\mathcal{N}_p$	ACP Reduccion de dimensionalidad	Clustering K-means y jerarquico
Covarianza y correlacion r	Matriz Σ Mahalanobis	Vec. propios de Σ	Distancia y centroides

Puente hacia la Sesión 5: Clustering

El ACP revela estructura, el clustering la formaliza

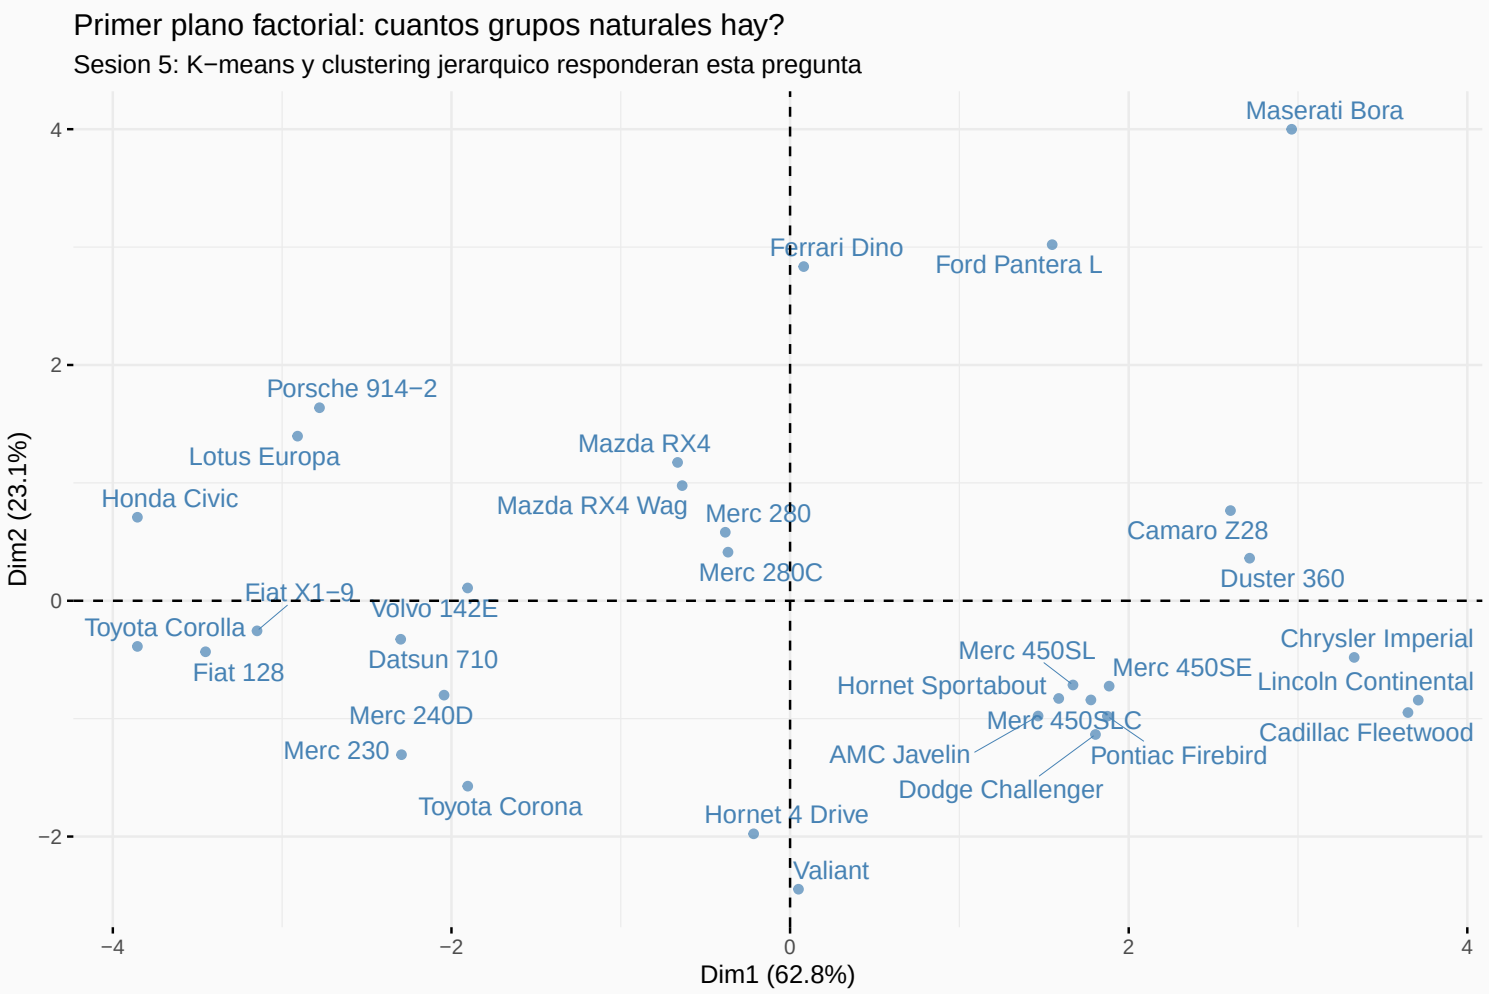

¿Qué es el clustering?

Definicion
Los metodos de agrupamiento buscan particiones de las n observaciones en grupos (*clusters*) homogeneos internamente y heterogeneos entre si, sin usar etiquetas previas (**aprendizaje no supervisado**).

Dos metodos principales (Sesion 5):

- **K-medias (K-means)**: particion en K grupos minimizando distancias internas. Simple, rapido. Requiere definir K a priori.
- **Agrupamiento jerarquico**: construye grupos progresivamente. No requiere K a priori; produce un **dendograma**.

La Sesión 5 en contexto

La Sesion 5 usara el dataset de calidad del aire de Bogota (RMCAB): 15 estaciones de monitoreo, 5 contaminantes a las 8 am.

Variable	**Descripcion**
CO (ppm)	Monoxido de carbono
NO (ppb)	Oxido nitrico
NO2 (ppb)	Dioxido de nitrogeno
OZONO (ppb)	Ozono
PM2.5 ($\mu g/m^3$)	Material particulado fino

Pregunta de la Sesion 5

¿Que estaciones de Bogota tienen perfiles de contaminacion similares?

¿Podemos recuperar agrupaciones espaciales (por localidad) usando solo datos de sensores?

Preguntas para la Sesión 5

1. ¿Como medir formalmente que dos observaciones son "similares" en $\mathbb{R}^p$?
2. ¿Como encontrar grupos automaticamente sin asignarlos a mano?
3. ¿Como elegir el numero optimo de grupos K?
4. ¿En que se diferencia K-means del agrupamiento jerarquico?
5. ¿Como visualizar grupos obtenidos usando el primer plano factorial del ACP?

Bibliografía

Bibliografía

1. Hanif, M. et al. (2019). *Multivariate Techniques*. Cambridge Scholars Publishing.
2. Zelterman, D. (2015). *Applied Multivariate Statistics with R*. Springer.
3. Schumacker, R. E. (2016). *Using R with Multivariate Statistics*. SAGE.
4. Everitt, B., & Hothorn, T. (2011). *Applied Multivariate Analysis with R*. Springer.
5. Boehmke, B. & Greenwell, B. (2020). *Hands-On Machine Learning with R*. CRC Press.
6. Turk, M. & Pentland, A. (1991). Eigenfaces for recognition. *J. Cognitive Neuroscience*, 3(1).

Anexo

princomp() como alternativa

```r
# princomp() usa descomposicion espectral directa de la cov. muestral
# prcomp() usa SVD -- mas numericamente estable (preferida)
pc_a = princomp(mtcars2)
summary(pc_a)
```

```
## Importance of components:
##                             Comp.1      Comp.2       Comp.3       Comp.4
## Standard deviation     134.3820274 37.54656204 3.0181295838 1.254845e+00
## Proportion of Variance   0.9270116  0.07236743 0.0004676043 8.083193e-05
## Cumulative Proportion    0.9270116  0.99937900 0.9998466012 9.999274e-01
##                              Comp.5       Comp.6       Comp.7       Comp.8
## Standard deviation     8.904901e-01 6.371404e-01 3.006062e-01 2.814188e-01
## Proportion of Variance 4.070624e-05 2.083882e-05 4.638724e-06 4.065453e-06
## Cumulative Proportion  9.999681e-01 9.999890e-01 9.999936e-01 9.999977e-01
##                              Comp.9
## Standard deviation     2.124807e-01
## Proportion of Variance 2.317617e-06
## Cumulative Proportion  1.000000e+00
```

princomp() y prcomp() producen los mismos CPs pero con distintas notaciones en sus salidas (ver tabla en la Seccion 9).