

Análisis Estadístico de Datos

Sesión 4: Análisis de Componentes Principales (ACP)

Profesor: Nicolás López

Universidad del Rosario

Puente desde la Sesión 3

En la Sesión 3 estudiamos la **distribución normal multivariada**: la campana de Gauss, pero con p variables a la vez.

- $\vec{\mu}$ (vector de medias): el **centro** de la nube de puntos
- Σ (matriz de covarianza): cuánto varía cada variable y cómo se **relacionan** entre sí
- Distancia de Mahalanobis: detecta observaciones **atípicas** (*outliers*)
- Gráfico Q-Q multivariado: ¿se parece nuestra nube a una normal multivariada?

Pregunta central de la Sesión 4

¿Cómo **aprovechar** la estructura de Σ para resumir, visualizar y entender datos con **muchas variables**?

Un ejemplo: un auto se describe con 9 características (peso, potencia, consumo, ...).

¿Podemos resumir esos 9 números en solo 2, perdiendo muy poca información?

Tabla de contenidos

Puente desde la Sesión 3

1. Motivación: el problema de la alta dimensión
2. El problema de la dimensionalidad
3. Una intuición sencilla: las notas de los estudiantes
4. Intuición geométrica del ACP
5. El ACP en R
6. Varianza explicada y selección de CPs
7. Visualización con `factoextra`
8. Valores atípicos y el ACP
9. Funciones en R
10. El ACP en el mundo moderno
11. Síntesis y puente

Puente hacia la Sesión 5: Clustering

Bibliografía

Anexos

1. Motivación: el problema de la alta dimensión

La metáfora del cilindro

La “gran verdad” de los datos vive en un espacio de p dimensiones.

El ACP busca las vistas más informativas de esa gran verdad.

Imagine un cilindro en 3D. Según desde dónde se mire, produce sombras distintas: un círculo, un rectángulo, un óvalo. Cada una es una **verdad parcial**: correcta, pero incompleta.

Las sombras de una nube de puntos



Es **la misma nube** vista desde dos ángulos. Un buen ángulo revela la estructura; uno malo la esconde.

- Los datos viven en p dimensiones (una por variable)
- Buscamos **vistas de baja dimensión** que conserven la mayor variabilidad posible
- Esas vistas son las **componentes principales** (CP)
- Con pocas CP resumimos y visualizamos la estructura de muchas variables

Resumir muchas variables en pocas: ejemplos cotidianos

- **Notas de un estudiante:** en vez de mirar 8 materias, miramos su “rendimiento general”
- **Nivel socioeconómico de un hogar:** ¿tiene nevera, televisor, agua potable, computador...? Esas decenas de respuestas se resumen en **un solo índice de riqueza**; con ACP se construyen índices de este tipo en encuestas de hogares (Filmer & Pritchett, 2001)
- **Comparar ciudades o universidades:** decenas de indicadores resumidos en 2 ejes para ubicarlas en un mapa

¿Por qué no mirar todas las parejas?

Con p variables hay $\binom{p}{2}$ diagramas de dispersión posibles:

Variables (p)	Diagramas posibles	¿Factible?
2	1	Fácil
5	10	Tedioso
10	45	Difícil
20	190	Inviabile
100	4950	Imposible

El ACP reemplaza esos miles de gráficos por **1 o 2** que capturan la mayor parte de la información.

Un caso extremo: la genómica

Contexto

En genómica, p puede ser el número de genes activos en una célula: decenas de miles. El ACP es un paso estándar en muchos análisis genómicos modernos.

Nadie puede mirar 20.000 variables a la vez. Con 2 o 3 componentes se dibuja un mapa donde las células **parecidas quedan cerca**.

El ejemplo de esta sesión: datos de automóviles

Los datos `mtcars` (Motor Trend, 1974): 32 modelos, 9 variables cuantitativas.

Variable	Descripción
<code>mpg</code>	Consumo (millas por galón)
<code>cyl</code>	Número de cilindros
<code>disp</code>	Desplazamiento del motor (pulg. cúbicas)
<code>hp</code>	Potencia (caballos de fuerza)
<code>drat</code>	Relación del eje trasero
<code>wt</code>	Peso (miles de libras)
<code>qsec</code>	Tiempo en 1/4 de milla (segundos)
<code>gear</code>	Número de marchas
<code>carb</code>	Número de carburadores

Un problema a resolver

Las variables tienen **unidades y escalas muy distintas**:


- `disp` se mide en cientos de pulgadas cúbicas
- `wt` se mide en unos pocos miles de libras
- `cyl` solo toma los valores 4, 6 u 8

Veremos más adelante cómo evitar que una variable “grite más fuerte” que las demás.

2. El problema de la dimensionalidad

Visualizando en 1 dimensión


```
mtcars$car = rownames(mtcars)
ggplot(mtcars, aes(x=mpg, y=rep(0,nrow(mtcars)), label=car)) +
  geom_point(size=1.5) +
  geom_text_repel(size=1.6, box.padding=1.0, max.overlaps=Inf) +
  xlab("Millas por galon") + ylab("") +
  theme_minimal() +
  theme(axis.text.y=element_blank(), axis.ticks.y=element_blank())
```



Con 1 variable: Fiat 128 y Toyota Corolla se parecen entre sí y se diferencian de Lincoln Continental y Cadillac Fleetwood.

Dos variables: el diagrama de dispersión

```
ggplot(mtcars, aes(x=mpg, y=wt, label=car)) +  
  geom_point(size=1.2) +  
  geom_text_repel(size=1.6, box.padding=0.3, max.overlaps=Inf) +  
  xlab("Millas por galon") + ylab("Peso") + theme_minimal()
```




Con 2 variables confirmamos: los livianos de alto rendimiento se oponen a los pesados de bajo rendimiento. ¿Qué pasa con las 7 variables restantes?

Exploración univariada de las 9 variables


vs y am son binarias sin estructura ordinal: se excluyen

```
mtcars2 = mtcars %>% select(-c(vs, am, car))
```

Distribucion univariada de cada variable



La estructura de correlación entre las 9 variables



Muchas variables están muy correlacionadas: `disp`, `hp`, `wt`, `cyl` comparten información. Esto sugiere que **pocos ejes** pueden resumir bien los datos.

La intuición clave: información repetida

Si dos amigos **siempre llegan juntos** a clase, basta con saber a qué hora llegó uno: el otro no aporta información nueva.

Variables muy correlacionadas $\Rightarrow$ información **repetida** $\Rightarrow$ se pueden resumir

- Un auto pesado casi siempre tiene motor grande y muchos cilindros
- Entonces `wt`, `disp` y `cyl` se pueden **resumir en una sola idea**:
“tamaño del auto”

El ACP encuentra esas ideas resumen de forma automática.

3. Una intuición sencilla: las notas de los estudiantes


Simulemos las notas de 60 estudiantes

Dos materias, escala de 0 a 5. Un “talento general” (que no observamos) influye en ambas notas.

```
set.seed(2024)
n = 60
talento = rnorm(n) # talento general (no se observa)
notas = tibble(
  calculo = pmin(5, pmax(0, 3.5 + 0.6*talento + rnorm(n, 0, 0.25))),
  estadistica = pmin(5, pmax(0, 3.6 + 0.6*talento + rnorm(n, 0, 0.25)))
)
round(cor(notas), 2)
```

```
##           calculo estadistica
## calculo      1.00      0.85
## estadistica  0.85      1.00
```

Dos notas casi dicen lo mismo



La nube es alargada. **CP1** (rojo) apunta hacia donde más se extiende; **CP2** (dorado) es perpendicular y captura lo que queda.

¿Qué significa cada componente?


```
round(pc_n$rotation, 2)                                # cargas

##           PC1    PC2
## calculo    0.74 -0.68
## estadistica 0.68  0.74
round(pc_n$sdev^2 / sum(pc_n$sdev^2), 2)               # proporcion de varianza

## [1] 0.93 0.07
```

- **CP1** (0,7 en ambas materias): un **promedio**, es decir, el **rendimiento general**
- **CP2** (signos opuestos): un **contraste**: ¿le fue mejor en estadística o en cálculo?

Los estudiantes en el nuevo sistema de coordenadas




A: rinde alto en todo. **B:** mejor en estadística que en cálculo. **C:** lo contrario de B.

De 2 a 6 materias: el mismo mecanismo

Ahora hay dos “talentos” ocultos: uno **general** y una inclinación **cuantitativa vs. verbal**.

```
set.seed(99)
n = 80
general = rnorm(n)      # talento general
inclin  = rnorm(n)      # inclinacion cuantitativa (+) o verbal (-)
nota = function(base, wg, wi)
  round(pmin(5, pmax(0, base + wg*general + wi*inclin + rnorm(n, 0, 0.3))), 1)
boletin = tibble(
  calculo = nota(3.4, .5, .4), algebra = nota(3.3, .5, .4),
  estadistica = nota(3.5, .5, .4),
  literatura = nota(3.6, .5, -.4), historia = nota(3.5, .5, -.4),
  filosofia = nota(3.4, .5, -.4))
pc_bol = prcomp(boletin, scale = TRUE)
pc_bol = orienta(pc_bol, "calculo", "calculo")
```

Leyendo las cargas del boletín



- **CP1:** todas las cargas tienen el mismo signo $\Rightarrow$ “rendimiento general”
- **CP2:** cuantitativas de un lado, verbales del otro $\Rightarrow$ “perfil cuantitativo vs. verbal”

Regla práctica: cargas del mismo signo se suman; cargas de signo opuesto se contrastan.


4. Intuición geométrica del ACP

Paso 1: centrar los datos

El ACP siempre trabaja con datos **centrados** (media = 0). Además, aquí los **estandarizamos** para que ambas variables queden en la misma escala:

```
mz = mtcars %>%
```

```
  mutate(mpg_z = as.numeric(scale(mpg)), wt_z = as.numeric(scale(wt)))
```




El punto $(0,0)$ es el “**auto promedio**”. Cada auto se mide por cuánto se aleja de él.

Paso 2: rotar hasta encontrar el mejor eje

CP1 = la línea que pasa por el origen y que mejor “recorre” la nube:

```
u1 = prcomp(mz[, c("mpg_z", "wt_z")])$rotation[, 1]  
pend = u1[2] / u1[1] # pendiente del mejor eje
```


Candidatos para CP1. La línea roja es



Probando todos los ángulos

Giramos la línea de 0 a 180 grados y medimos la **dispersión de las proyecciones** en cada ángulo:

```
angulos = seq(0, pi, length.out = 181)
varianza = sapply(angulos, function(a) var(mz$mpg_z*cos(a) + mz$wt_z*sin(a)))
curva = tibble(grados = angulos*180/pi, varianza = varianza)
mejor = curva[which.max(curva$varianza), ]
```




Con los ejes originales la varianza vale 1. En el mejor ángulo sube a **1.87**: ese es CP1. El peor ángulo está a 90 grados del mejor: ese es CP2.

La geometría del CP1: proyecciones

*CP1 minimiza la distancia de cada punto a su proyección sobre la línea
(equivale a maximizar la varianza de las proyecciones)*

Proyecciones sobre CP1 (puntos rojos sobre
Los segmentos grises son las distancias que se minim



¿Cuánta información captura un componente?

Varianza de un componente (valor propio λ_k)

Mide qué tan **dispersas** quedan las proyecciones alrededor del centro:

$$\lambda_k \propto \sum_{i=1}^n z_{ik}^2$$

donde z_{ik} es la posición del individuo i sobre el eje k (su **puntaje**).

- Proyecciones **muy esparcidas** $\Rightarrow \lambda_k$ grande $\Rightarrow$ el CP captura **mucha** información
- Proyecciones **amontonadas** cerca del centro $\Rightarrow \lambda_k$ pequeño $\Rightarrow$ el CP captura **poca**

CP1 tiene el λ_1 más grande: es la dirección donde los datos están más “esparcidos”.

Analogía: si todos los estudiantes sacan casi la misma nota, esa nota no sirve para distinguirlos; si las notas están muy dispersas, sí.

Verificando con los datos

```
# Puntajes en CP1 y CP2 (datos estandarizados)
pc_c = prcomp(mtcars2, scale=TRUE)
scores = pc_c$x

# Suma de cuadrados de puntajes / (n-1) = varianza = valor propio
varpc1 = sum(scores[, "PC1"]^2) / (nrow(scores) - 1)
varpc2 = sum(scores[, "PC2"]^2) / (nrow(scores) - 1)

# Valores propios del ACP
lambdas = pc_c$sdev^2

cat("Var. puntajes CP1:", round(varpc1, 4),
    " lambda_1:", round(lambdas[1], 4), "\n")

## Var. puntajes CP1: 5.6559 lambda_1: 5.6559
cat("Var. puntajes CP2:", round(varpc2, 4),
    " lambda_2:", round(lambdas[2], 4), "\n")

## Var. puntajes CP2: 2.0821 lambda_2: 2.0821
```

La varianza de los puntajes en cada CP es **exactamente** el valor propio correspondiente.

Los CP son ortogonales: ¿qué significa?

Los ejes de los componentes principales son **perpendiculares entre sí**:

- **Geométricamente**: CP2 es perpendicular a CP1, CP3 a ambos, etc. Forman un sistema de coordenadas **rotado** respecto al original
- **Estadísticamente**: los puntajes de distintos CP tienen correlación cero. Cada CP aporta información **no redundante**
- **Consecuencia**: la varianza total se **reparte** entre los CP sin solaparse

Verificando la ortogonalidad

```
# Correlacion entre puntajes de distintos CP: debe ser ~0
```

```
round(cor(pc_c$x)[1:3, 1:3], 6)
```

```
##      PC1 PC2 PC3
```

```
## PC1   1   0   0
```

```
## PC2   0   1   0
```

```
## PC3   0   0   1
```

```
# La suma de los valores propios es la varianza total (= p si estandarizamos)
```

```
round(sum(lambdas), 2)
```

```
## [1] 9
```

Con 9 variables estandarizadas, la varianza total es 9: cada CP se queda con una parte.

5. El ACP en R

¿Por qué estandarizar?

Varianza de cada variable original:

```
round(apply(mtcars2, 2, var), 1)
```

##	mpg	cyl	disp	hp	drat	wt	qsec	gear	carb
##	36.3	3.2	15360.8	4700.9	0.3	1.0	3.2	0.5	2.6

disp tiene una varianza de miles; drat o gear, menos de 1. Como el ACP busca **máxima varianza**, sin estandarizar se dejaría llevar solo por disp y hp.

Con y sin estandarizar

```
pc_b = prcomp(mtcars2)           # SIN estandarizar
pc_c = prcomp(mtcars2, scale=TRUE) # CON estandarizar (recomendado)

# % varianza explicada por los 2 primeros CPs
sin_esc = summary(pc_b)$importance[2, 1:2]
con_esc = summary(pc_c)$importance[2, 1:2]
rbind(sin_escal=round(sin_esc,3), con_escal=round(con_esc,3))

##              PC1    PC2
## sin_escal 0.927 0.072
## con_escal 0.628 0.231
```

Sin estandarizar, el CP1 “explica” casi todo, pero solo porque disp domina. Con estandarizar, cada variable aporta en igualdad de condiciones.

Regla práctica

Siempre estandarizar con `scale=TRUE` cuando las variables tienen unidades o escalas distintas.

Analogía: sumar una variable en pesos (millones) con otra en años de educación (de 0 a 20) es como sumar manzanas con kilómetros. El ingreso “ganaría” solo por sus unidades.

Las cargas (*loadings*)

```
pc_f = prcomp(mtcars2, scale=TRUE, rank.=2)

round(pc_f$rotation, 3) # Cargas: contribucion de cada variable a cada CP

##          PC1      PC2
## mpg  -0.393  0.028
## cyl   0.403  0.016
## disp  0.397 -0.089
## hp    0.367  0.269
## drat -0.312  0.342
## wt    0.373 -0.172
## qsec -0.224 -0.484
## gear -0.209  0.551
## carb  0.245  0.484
```

Los puntajes (*scores*)

Coordenadas de cada auto en el nuevo espacio (primeros 8 autos):


```
round(head(pc_f$x, 8), 2)
```

##	PC1	PC2
## Mazda RX4	-0.66	1.17
## Mazda RX4 Wag	-0.64	0.98
## Datsun 710	-2.30	-0.33
## Hornet 4 Drive	-0.22	-1.98
## Hornet Sportabout	1.59	-0.83
## Valiant	0.05	-2.45
## Duster 360	2.71	0.36
## Merc 240D	-2.04	-0.80

Elemento	Nombre	Descripción
$\mathbf{u}_j$	Cargas (<i>loadings</i>)	Pesos de cada variable en el CP j
z_{ij}	Puntaje (<i>score</i>)	Coordenada del individuo i en el CP j
λ_j	Valor propio	Varianza (dispersión) a lo largo del CP j
$\sqrt{\lambda_j}$	Valor singular	Desv. estándar a lo largo del CP j

Las **cargas** describen a las **variables**; los **puntajes** describen a los **individuos**.

Las cargas en un gráfico



Barras azules: carga positiva. Barras rojas: carga negativa.

Interpretando CP1: tamaño y consumo

- Cargas **positivas** altas: cyl, disp, hp, wt
- Cargas **negativas**: mpg y drat

Índice de tamaño y consumo

Autos grandes, pesados y poco eficientes tienen CP1 **alto**. Autos pequeños y eficientes tienen CP1 **bajo**.

Interpretando CP2: perfil deportivo

- Cargas **positivas**: carb, gear, hp, drat
- Carga **negativa**: qsec. Un qsec bajo es un tiempo de cuarto de milla corto, es decir, un auto **rápido**

Índice de perfil deportivo (rendimiento en pista)

Autos con muchos carburadores, muchas marchas y gran potencia, que además son rápidos en pista, tienen CP2 **alto**.

Un detalle: el signo de un CP es arbitrario

- Multiplicar un CP por -1 **no cambia nada**: el eje es el mismo, solo cambia el sentido
- Por eso, en otro computador o versión de R, un CP puede salir con los signos invertidos
- Lo que importa es la **estructura relativa**: qué variables van juntas y cuáles se oponen

Idea clave

Se interpretan los **contrastes** entre cargas, no su signo absoluto.

6. Varianza explicada y selección de CPs

Proporción de varianza explicada

```
round(summary(pc_c)$importance[, 1:5], 3)  # primeros 5 componentes
```


##	PC1	PC2	PC3	PC4	PC5
## Standard deviation	2.378	1.443	0.710	0.515	0.428
## Proportion of Variance	0.628	0.231	0.056	0.029	0.020
## Cumulative Proportion	0.628	0.860	0.916	0.945	0.966

Con solo **2 componentes** explicamos el 86% de la variabilidad total de las 9 variables originales.

El screeplot (gráfico de sedimentación)

```
screeplot(pc_c, col="tomato", pch=16,  
          type="lines", cex=1.5, lwd=2,  
          main="Screeplot - mtcars")
```

Screeplot - mtcars



Leer el screeplot: tres reglas prácticas

- **Regla del codo:** elegir k donde la curva dobla abruptamente.
Después del codo, cada CP adicional aporta poca varianza nueva
- **Regla del 80%:** seleccionar los CP que acumulen $\geq 80\%$ de la varianza
- **Regla de Kaiser:** retener los CP con $\lambda_k > 1$ en datos estandarizados (el CP explica más que una sola variable original)


Una analogía para el codo

Estudiar para un examen: las primeras horas rinden mucho; la hora 10 seguida casi no suma.

Cada componente adicional aporta menos: el codo marca dónde dejar de “estudiar” más componentes.

La varianza acumulada

```
tibble(k = 1:9, acumulada = cumsum(lambdas) / sum(lambdas)) %>%  
  ggplot(aes(k, acumulada)) +  
  geom_hline(yintercept = 0.8, linetype = "dashed", color = "grey50") +  
  geom_line(color = "steelblue") + geom_point(color = "tomato", size = 2) +  
  scale_x_continuous(breaks = 1:9) + theme_minimal() +  
  labs(x = "Numero de componentes", y = "Varianza acumulada")
```



Aplicando las tres reglas a mtcars

```
round(lambdas, 2)                                # valores propios

## [1] 5.66 2.08 0.50 0.27 0.18 0.12 0.11 0.06 0.02
sum(lambdas > 1)                                  # Kaiser: cuantos CP tienen lambda > 1

## [1] 2
round(cumsum(lambdas)/sum(lambdas), 2)           # varianza acumulada

## [1] 0.63 0.86 0.92 0.95 0.97 0.98 0.99 1.00 1.00
```

Para mtcars


Las tres reglas coinciden: el codo está en $k = 2$, Kaiser retiene 2 componentes y con 2 superamos el 80%. Resumimos 9 variables con mínima pérdida de información.

¿Cuándo funciona bien el ACP? Dos escenarios

Simulamos 6 variables en dos situaciones: **correlacionadas** (comparten un factor) e **independientes**.

```
set.seed(7)
n = 100
f = rnorm(n)
corr_ = sapply(1:6, function(j) f + rnorm(n, 0, 0.6)) # comparten un factor
indep_ = sapply(1:6, function(j) rnorm(n))             # sin relacion
prop = function(m) prcomp(m, scale=TRUE)$sdev^2 / 6    # varianza por CP
```

El ACP necesita correlación




- **Correlacionadas:** un CP concentra la mayor parte $\Rightarrow$ el ACP resume bien
- **Independientes:** la varianza se reparte parejo $\Rightarrow$ no hay nada que resumir

7. Visualización con factoextra

Gráfico de variables: el círculo de correlaciones

```
fviz_pca_var(pc_c,col.var="contrib",gradient.cols=c("steelblue","gold","tomato"),repel=T)
```




- **Longitud de la flecha:** carga total de la variable en los 2 CP graficados. Más larga = más informativa en este plano
- **Ángulo entre dos flechas:** correlación entre las variables. Ángulo pequeño = correlación positiva alta; 180° = correlación negativa alta; 90° = sin correlación lineal
- **Posición en el eje:** indica en qué sentido del CP aumenta esa variable

- `disp`, `hp`, `wt`, `cyl` apuntan juntas hacia la derecha (están correlacionadas)
- `mpg` apunta en sentido opuesto (correlación negativa con las anteriores)
- `gear`, `carb` y `hp` apuntan hacia arriba (CP2); `qsec` apunta hacia abajo

Flechas **largas** = variables bien representadas en este plano.

Gráfico de individuos: el primer plano factorial

```
fviz_pca_ind(pc_c, col.ind=mtcars$mpg, gradient.cols=c("tomato", "gold", "steelblue"),  
  repel=TRUE, label="all")
```



Leyendo el primer plano factorial

- **Autos a la izquierda (azul):** alto rendimiento, ligeros, pocos cilindros (Fiat 128, Toyota Corolla, Honda Civic)
- **Autos a la derecha (rojo):** bajo rendimiento, pesados, muy potentes (Lincoln Continental, Cadillac Fleetwood)
- **Eje vertical (CP2):** separa los autos deportivos (Maserati Bora, Ford Pantera L, Ferrari Dino, arriba) de los sedanes tranquilos (Valiant, Hornet 4 Drive, abajo)

Cercanía = parecido


Dos autos **cercanos** en el plano son similares en las 9 variables originales.

Dos autos **lejanos** son muy distintos.

La distancia en el plano es una **aproximación** a la distancia real entre los autos en el espacio de 9 variables.

El biplot: variables e individuos juntos

```
fviz_pca_biplot(pc_c, repel=TRUE,col.var="tomato", col.ind="steelblue",label="all")
```




El biplot superpone el círculo de correlaciones y el plano factorial: permite ver a la vez qué variables caracterizan a qué individuos.

8. Valores atípicos y el ACP

Un atípico puede torcer los ejes

El ACP maximiza varianza. Un valor atípico (*outlier*) **aumenta artificialmente** la varianza en su dirección:

CP1 sin el atípico (gris) y con el atípico (rojo)



Analogía: una sola persona millonaria en un grupo de asalariados mueve mucho el promedio. Aquí, un solo punto **gira el eje principal**.

Detectando atípicos antes del ACP

```
d2 = mahalanobis(mtcars2,
                 center=colMeans(mtcars2),
                 cov=cov(mtcars2))
outliers_idx = which(d2 > qchisq(0.975, df=ncol(mtcars2)))
paste0("Outliers detectados: ", length(outliers_idx),
      " -> ", paste(rownames(mtcars2)[outliers_idx], collapse=", "))

## [1] "Outliers detectados: 1 -> Ford Pantera L"
```

Conexión con la Sesión 3

Antes de ejecutar el ACP, use la **distancia de Mahalanobis** para detectar y evaluar atípicos multivariados. Un punto con $d_M^2 > \chi_p^2(0,975)$ merece revisión antes de incluirlo.

“Revisar” no es “eliminar”: primero se investiga si es un error de digitación o un caso real e interesante.

9. Funciones en R

prcomp() vs princomp()

Salida	prcomp()	princomp()
Desv. estándar de CPs	\$sdev	\$sdev
Cargas (vectores prop.)	\$rotation	\$loadings
Media de las variables	\$center	\$center
Escalamiento aplicado	\$scale	\$scale
Puntajes (scores)	\$x	\$scores

Recomendación

Prefiera `prcomp()`: es numéricamente más preciso (usa una descomposición llamada SVD en lugar de la descomposición espectral directa de la matriz de covarianza).

Los detalles de la descomposición espectral y un ejemplo con `princomp()` están en los **Anexos**.

Flujo completo de un ACP: antes de ejecutar

1. **Explorar** las variables: tipos, unidades, atípicos, correlaciones
2. **Excluir** variables que no sean cuantitativas continuas
3. **Detectar atípicos** con la distancia de Mahalanobis

4. **Ejecutar** `prcomp(datos, scale=TRUE)`
5. **Seleccionar** el número de CP con el screeplot y el % de varianza acumulada
6. **Interpretar** las cargas (`$rotation`) de los CP seleccionados
7. **Visualizar** con `factoextra`: círculo de correlaciones y plano factorial
8. **Comunicar** qué captura cada CP en términos del problema

10. El ACP en el mundo moderno

- **Genómica:** reducir la expresión de más de 20.000 genes a 2–3 CP para visualizar tipos celulares es un paso estándar en RNA-seq y en datos de célula única (*single-cell*)
- **Reconocimiento facial (*eigenfaces*):** Turk & Pentland (1991) representaron cada cara como una combinación de “caras propias”, los vectores propios de la covarianza de los píxeles. Una cara nueva se proyecta sobre esos CP para identificarla

- **Calidad del aire:** el CP1 de varios contaminantes medidos en distintas estaciones resume el **nivel general de contaminación**; el CP2 puede distinguir contaminación industrial de no industrial. Lo veremos en la Sesión 5
- **Clima y meteorología:** el ACP de temperatura y precipitación en cientos de estaciones identifica **patrones dominantes** de variabilidad climática, como el asociado a El Niño

- **Finanzas:** las tasas de interés de distintos plazos se mueven juntas. Con solo 3 CP se describe la mayor parte de los movimientos de la curva de tasas: un desplazamiento general (**nivel**), una inclinación (**pendiente**) y una curvatura (Litterman & Scheinkman, 1991)
- **Neurociencia (EEG):** los electrodos registran señales muy correlacionadas. El ACP ayuda a resumirlas y depurarlas (por ejemplo, retirar artefactos como parpadeos)

- **Mercadeo:** mapas de percepción de marcas. Si los clientes califican 15 atributos de varias marcas, un plano de 2 CP muestra qué marcas se perciben como similares
- **Encuestas de hogares:** índice de riqueza a partir de bienes y servicios del hogar (Filmer & Pritchett, 2001)
- **Riesgo de crédito:** antes de modelar, resumir muchos indicadores financieros correlacionados en pocos factores

- **Preprocesamiento:** reducir dimensionalidad antes de entrenar modelos previene la “maldición de la dimensionalidad”
- **Regresión sobre componentes** (PCR, *Principal Component Regression*): estabiliza los coeficientes cuando hay muchas variables correlacionadas
- **Detección de anomalías:** si un dato no se reconstruye bien con pocos CP, es sospechoso. Se usa en fraude bancario y mantenimiento predictivo

Ejemplo práctico: detectar anomalías

Tres sensores de una máquina que normalmente se mueven **juntos**.

Plantamos 3 casos que rompen ese patrón:


```
set.seed(3)
n = 200
z = rnorm(n)
datos = tibble(x1 = z + rnorm(n, 0, 0.3),
               x2 = 2*z + rnorm(n, 0, 0.5),
               x3 = -z + rnorm(n, 0, 0.3))
datos$x1[1:3] = c(2, -2, 1.5)      # 3 casos que rompen el patron
datos$x2[1:3] = c(-3, 3, -4)
datos$x3[1:3] = c(2, -1, 3)
```

Reconstruir con 1 solo componente

```
pc = prcomp(datos, scale = TRUE)
# reconstruir con solo el CP1 y volver a la escala original
X1 = pc$x[, 1, drop = FALSE] %*% t(pc$rotation[, 1, drop = FALSE])
X1 = sweep(sweep(X1, 2, pc$scale, "*"), 2, pc$center, "+")
error = rowSums((as.matrix(datos) - X1)^2)
round(sort(error, decreasing = TRUE)[1:5], 1)

## [1] 12.6 12.5 12.0  1.6  1.6
```

Los casos anómalos tienen el mayor error



En la práctica no sabemos cuáles son las anomalías: se fija un **umbral** (por ejemplo, el percentil 99 del error) y se revisan los casos que lo superan.

El ACP lineal es el caso más simple de una familia de métodos t-SNE y UMAP (no lineales, para visualización)

Autoencoders (redes neuronales que generalizan el ACP)


Kernel PCA (ACP en espacios de alta dimensión mediante *kernels*)

Limitaciones del ACP (1/2)

- **Solo relaciones lineales:** si las variables tienen relaciones curvas, los CP pueden ser poco informativos
- **Interpretabilidad no automática:** las cargas requieren análisis cuidadoso para darles significado
- **Sensible a atípicos:** un atípico multivariado puede torcer los ejes

Limitación: relaciones curvas

Una curva: en el fondo, un fenómeno de 1 sola dimension



El ACP necesita **2 componentes** para describir algo que en realidad se recorre con un solo parámetro.

- **Dependiente del escalamiento:** cambiar la escala de una variable puede cambiar completamente los resultados
- **No es un método de agrupamiento:** revela estructura, pero no asigna grupos formalmente

11. Síntesis y puente

Conclusiones de la Sesión 4 (1/2)

- El ACP **resume muchas variables correlacionadas** en pocas componentes
- Cada CP es una **combinación lineal** de las variables, y los CP son ortogonales entre sí
- La **varianza** de cada CP (su valor propio) mide cuánta información captura

- **Siempre estandarizar** cuando las escalas son distintas
- El screeplot y el % de varianza acumulada guían la elección del número de CP
- Las **cargas** interpretan cada CP; los **puntajes** ubican a los individuos en el nuevo espacio
- El ACP se calcula con la descomposición espectral de Σ (ver Anexo A)

1. Si todas las variables de un estudio fueran independientes, ¿qué esperaríamos ver en el screeplot?
2. Un CP tiene carga $+0,7$ en *ingreso* y $+0,7$ en *educación*. ¿Cómo lo llamaría?
3. ¿Por qué sería un error aplicar ACP sin estandarizar a variables en pesos y en años?

Conexión entre sesiones

Sesiones 1-2	Sesión 3	Sesión 4	Sesión 5
Distribuciones univariada y bivariada	Normal multivariada $\mathcal{N}_p$	ACP Reducción de dimensionalidad	Agrupamiento K-medias y jerárquico
Covarianza y correlación r	Matriz Σ Mahalanobis	Vec. propios de Σ	Distancia y centroides


Puente hacia la Sesión 5:

Clustering

El ACP revela estructura, el agrupamiento la formaliza

Primer plano factorial: cuantos grupos naturales hay?

Sesion 5: K-means y clustering jerarquico responderan esta pregunta



¿Qué es el agrupamiento (*clustering*)?

Definición

Los métodos de agrupamiento buscan dividir las n observaciones en grupos (*clusters*) homogéneos por dentro y distintos entre sí, sin usar etiquetas previas (**aprendizaje no supervisado**).

Dos métodos principales (Sesión 5)

- **K-medias (K-means)**: partición en K grupos minimizando distancias internas. Simple y rápido, pero requiere definir K de antemano
- **Agrupamiento jerárquico**: construye grupos progresivamente. No requiere K de antemano y produce un **dendrograma**

La Sesión 5 usará el conjunto de datos de calidad del aire de Bogotá (RMCAB): 15 estaciones de monitoreo, 5 contaminantes a las 8 am.

Variable	Descripción
CO (<i>ppm</i>)	Monóxido de carbono
NO (<i>ppb</i>)	Óxido nítrico
NO2 (<i>ppb</i>)	Dióxido de nitrógeno
OZONO (<i>ppb</i>)	Ozono
PM2.5 ($\mu g/m^3$)	Material particulado fino

Pregunta de la Sesión 5

¿Qué estaciones de Bogotá tienen perfiles de contaminación similares?

¿Podemos recuperar agrupaciones espaciales (por localidad) usando solo datos de sensores?

Preguntas para la Sesión 5

1. ¿Cómo medir formalmente que dos observaciones son “similares”?
2. ¿Cómo encontrar grupos automáticamente, sin asignarlos a mano?
3. ¿Cómo elegir el número óptimo de grupos K ?
4. ¿En qué se diferencia K-means del agrupamiento jerárquico?
5. ¿Cómo visualizar los grupos usando el primer plano factorial del ACP?

Bibliografía

Bibliografía (1/2)

1. Hanif, M. et al. (2019). *Multivariate Techniques*. Cambridge Scholars Publishing.
2. Zeltermann, D. (2015). *Applied Multivariate Statistics with R*. Springer.
3. Schumacker, R. E. (2016). *Using R with Multivariate Statistics*. SAGE.
4. Everitt, B., & Hothorn, T. (2011). *Applied Multivariate Analysis with R*. Springer.
5. Boehmke, B. & Greenwell, B. (2020). *Hands-On Machine Learning with R*. CRC Press.

6. Turk, M. & Pentland, A. (1991). Eigenfaces for recognition. *J. Cognitive Neuroscience*, 3(1).
7. Jolliffe, I. T. & Cadima, J. (2016). Principal component analysis: a review and recent developments. *Phil. Trans. R. Soc. A*, 374(2065).
8. Filmer, D. & Pritchett, L. H. (2001). Estimating wealth effects without expenditure data—or tears. *Demography*, 38(1), 115–132.
9. Litterman, R. & Scheinkman, J. (1991). Common factors affecting bond returns. *Journal of Fixed Income*, 1(1), 54–61.

Anexos

Este anexo contiene la parte matemática que **sustenta** el ACP:

- ¿Qué es la descomposición espectral de Σ ?
- Un ejemplo de cálculo 2×2 con `eigen()`
- Su significado geométrico
- La conexión exacta con el ACP

Para seguir la sesión **no es necesario** dominarlo; sirve para quien quiera ver “qué hay debajo” de `prcomp()`.

¿Qué es la descomposición espectral?

Cualquier matriz de covarianza Σ (simétrica, semidefinida positiva) puede escribirse como:

$$\Sigma = P\Lambda P^\top$$

donde:

- $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_p)$, con $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$: los **valores propios** (autovalores)
- $P = [\mathbf{p}_1 \mid \mathbf{p}_2 \mid \dots \mid \mathbf{p}_p]$: los **vectores propios** (autovectores), ortonormales ($PP^\top = I$)

Significado intuitivo: Σ rota, estira y gira el espacio. La descomposición separa esas dos acciones: P da las **direcciones** (rotación) y Λ da los **tamaños** de estiramiento.

Ejemplo de cómputo: descomposición espectral 2x2

Considere la siguiente matriz de covarianza para dos variables:

$$\Sigma = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$$

```

Sigma = matrix(c(3, 1, 1, 2), nrow=2)
descomp = eigen(Sigma)           # funcion base de R

lambda = descomp$values          # valores propios
P       = descomp$vectors        # vectores propios (columnas)

cat("Valores propios:\n"); round(lambda, 3)

## Valores propios:

## [1] 3.618 1.382
cat("\nVectores propios (columnas de P):\n"); round(P, 3)

##
## Vectores propios (columnas de P):

##      [,1]  [,2]
## [1,] -0.851  0.526
## [2,] -0.526 -0.851

```

Verificando: $\Sigma = P\Lambda P^\top$

```
Lambda = diag(lambda)           # matriz diagonal de val. propios
```

```
# Reconstruccion: debe ser igual a Sigma original
```

```
Sigma_reconstruida = P %*% Lambda %*% t(P)
```

```
round(Sigma_reconstruida, 6)
```

```
##      [,1] [,2]
```

```
## [1,]    3    1
```

```
## [2,]    1    2
```

```
# Verificando ortogonalidad de P: P * P^T = I
```

```
round(P %*% t(P), 6)
```

```
##      [,1] [,2]
```

```
## [1,]    1    0
```


```
## [2,]    0    1
```

La reconstrucción es exacta. $PP^\top = I$ confirma que los vectores propios son ortonormales.

¿Qué nos dice la descomposición de este ejemplo?

Vectores propios de Sigma

Rojo = CP1 (mayor varianza), Dorado = CP2



Los vectores propios apuntan en las **direcciones de mayor variabilidad**

Conexión fundamental

Los componentes principales son exactamente los vectores propios de Σ , ordenados de mayor a menor valor propio.

Elemento	En la descomp. espectral	En el ACP
$\mathbf{p}_k$	Vector propio k de Σ	Cargas del CP k
λ_k	Valor propio k de Σ	Varianza del CP k
z_{ik}	—	Puntaje del individuo i en CP k

Ejecutar `prcomp()` en R es esencialmente aplicar `eigen()` a la matriz de covarianza (o de correlación, si se estandarizan los datos), pero de forma numéricamente estable mediante la descomposición en valores singulares (SVD).

Anexo B: princomp() como alternativa

```
# princomp() usa descomposicion espectral directa de la cov. muestral
# prcomp() usa SVD -- mas numericamente estable (preferida)
pc_a = princomp(mtcars2)
summary(pc_a)
```



```
## Importance of components:
```

##	Comp.1	Comp.2	Comp.3	Comp.4
## Standard deviation	134.3820274	37.54656204	3.0181295838	1.254845e+00
## Proportion of Variance	0.9270116	0.07236743	0.0004676043	8.083193e-05
## Cumulative Proportion	0.9270116	0.99937900	0.9998466012	9.999274e-01

##	Comp.5	Comp.6	Comp.7	Comp.8
## Standard deviation	8.904901e-01	6.371404e-01	3.006062e-01	2.814188e-01
## Proportion of Variance	4.070624e-05	2.083882e-05	4.638724e-06	4.065453e-06
## Cumulative Proportion	9.999681e-01	9.999890e-01	9.999936e-01	9.999977e-01

##	Comp.9
## Standard deviation	2.124807e-01
## Proportion of Variance	2.317617e-06
## Cumulative Proportion	1.000000e+00

princomp() y prcomp() producen los mismos CP, pero con distintas notaciones en sus salidas (ver tabla en la Sección 9).