

Análisis Estadístico de Datos

Sesión 5: Métodos de Agrupamiento (Clustering)

Profesor: Nicolás López

Universidad del Rosario

Puente desde las sesiones anteriores

El arco del curso hasta hoy

Sesion	Tema	Pregunta central	Tipo
1-2	E. descriptiva	¿Como describir variables?	Univariado
3	Normal multi.	¿Como modelar conjuntamente?	Multivariado
4	ACP	¿Como reducir dimensiones?	No supervisado
5	Clustering	¿Como detectar grupos?	No supervisado
6	Regresion lineal	¿Como predecir Y desde X ?	Supervisado

Cambio de paradigma en la Sesión 6

Las Sesiones 4 y 5 son **no supervisadas**: no hay variable respuesta. La Sesión 6 introduce el aprendizaje **supervisado**: tenemos una variable Y que queremos predecir o explicar a partir de otras variables X .

Aprendizaje supervisado vs. no supervisado

Característica	No supervisado	Supervisado
Variable respuesta Y	No existe	Si existe
Objetivo	Descubrir estructura	Predecir / explicar Y
Evaluacion	Subjetiva / interna	Objetiva (error de pred.)
Ejemplos	ACP, Clustering	Regresion, clasificacion
Etiquetas en datos	No se requieren	Necesarias para entrenar

En la Sesión 4 vimos que el primer plano factorial (CP1 vs. CP2) revela estructura en los datos pero **no asigna grupos formalmente**.

Las preguntas que la Sesión 5 responde:

1. ¿Como medir formalmente que dos observaciones son similares en $\mathbb{R}^p$?
2. ¿Como encontrar grupos automaticamente sin asignarlos a mano?
3. ¿Como elegir el numero optimo de grupos K ?
4. ¿En que se diferencia K-means del agrupamiento jerarquico?
5. ¿Como visualizar los grupos obtenidos en el plano factorial del ACP?

Tabla de contenidos

Puente desde las sesiones anteriores

1. Los datos: calidad del aire en Bogotá
2. Clustering: concepto general
3. K-medias (K-means)
4. Selección del número de grupos K
5. K-means sobre la tabla completa
6. Agrupamiento jerárquico
7. Agrupamientos duros vs. suaves: la vision completa
8. Síntesis y puente

Bibliografía

Anexo

1. Los datos: calidad del aire en Bogotá

Descripción del conjunto de datos

Red de Monitoreo de Calidad del Aire de Bogotá (RMCAB): 15 estaciones, 5 contaminantes medidos a las 8 am del 8 de enero de 2022.

Variable	Unidad	Descripcion
CO	<i>ppm</i>	Monoxido de carbono
NO	<i>ppb</i>	Oxido nitrico
NO2	<i>ppb</i>	Dioxido de nitrogeno
OZONO	<i>ppb</i>	Ozono
PM2.5	$\mu g/m^3$	Material particulado fino

Pregunta de la sesion

¿Que estaciones de Bogota tienen perfiles de contaminacion similares?

¿Podemos recuperar agrupaciones espaciales (por localidad o zona) usando solamente datos de sensores, sin conocer la ubicacion geografica?

Carga y exploración inicial

```
datos_aire = read_csv("ReporteContaminante_08012022_8am.csv",  
                      show_col_types=FALSE)
```

```
datos_aire
```

```
## # A tibble: 15 x 6
```

##	Estaciones	CO	NO	NO2	OZONO	PM2.5
##	<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
##	1 Bolivia	0.484	23.3	21.2	2.77	7.8
##	2 Carvajal Sevillana	1.19	50.1	19.1	5.13	26
##	3 Centro de Alto Rendimiento	0.730	37.1	12.3	2.22	22
##	4 Colina	0.502	16.6	15.4	1.73	3.9
##	5 Fontibon	0.908	42.2	21.6	6.49	20.9
##	6 Guaymaral	0.101	5.92	3.27	13.4	6
##	7 Kennedy	1.40	60.1	28.4	8.25	17
##	8 Las Ferias	0.787	20.7	11.3	8.83	19
##	9 MinAmbiente	1.24	39.6	17.8	2.86	8
##	10 Movil Fontibon	1.23	47.2	22.4	3.82	21.6
##	11 Puente Aranda	1.53	48.6	21.9	1.61	3.2
##	12 San Cristobal	1.17	32.6	19.9	1.30	14
##	13 Suba	0.353	7.93	7.07	6.42	8
##	14 Tunal	1.10	25.3	11.0	9.49	14
##	15 Usaquen	0.268	3.61	4.26	15.1	8

Ejercicio 1: ¿qué estaciones son similares?

Ejercicio 1 – Discusion en clase


Mirando la tabla de datos a ojo,

- ¿cuales estaciones presentan mayor similaridad en las diferentes variables medidas? - ¿Que variables adicionales (geograficas, de trafico, industriales) serian interesantes para entender mejor la similaridad?

Esta es la pregunta que los metodos de clustering resuelven de forma **objetiva y automatica**, sin depender del ojo del analista.

Ejercicio 2: descripción univariada

```
datos_vars = datos_aire %>% select(-Estaciones)
datos_vars %>%
  pivot_longer(everything(), names_to="Contaminante", values_to="Valor") %>%
  ggplot(aes(y=Valor)) +
  geom_boxplot(fill="steelblue", alpha=0.35, color="steelblue",
               outlier.size=0.8) +
  facet_wrap(~Contaminante, scales="free", nrow=1) +
  theme_minimal(base_size=8) +
  labs(title="Distribucion univariada de contaminantes (8am, 8-ene-2022)")
```



Ejercicio 3: estructura de correlación

```
matriz_cor = cor(datos_vars)
round(matriz_cor, 3)
```

```
##           CO      NO      NO2  OZONO  PM2.5
## CO      1.000  0.892  0.770 -0.474  0.357
## NO      0.892  1.000  0.873 -0.490  0.529
## NO2     0.770  0.873  1.000 -0.610  0.304
## OZONO   -0.474 -0.490 -0.610  1.000 -0.046
## PM2.5   0.357  0.529  0.304 -0.046  1.000
```


CO, NO y NO2 presentan alta correlación positiva entre sí — son contaminantes de origen similar (combustión de vehículos). El OZONO tiene correlación negativa con los anteriores (se destruye en presencia de NO).

Ejercicio 4: ACP sobre los datos de aire

```
pc_1 = prcomp(datos_vars, scale=TRUE)
round(summary(pc_1)$importance, 3)
```

##	PC1	PC2	PC3	PC4	PC5
## Standard deviation	1.810	0.996	0.689	0.456	0.222
## Proportion of Variance	0.655	0.199	0.095	0.042	0.010
## Cumulative Proportion	0.655	0.854	0.949	0.990	1.000

```
screeplot(pc_1, col="tomato", pch=16,  
          type="lines", cex=1.5, lwd=2, main="Screeplot - aire Bogota")
```



Ejercicio 5: interpretación de los componentes

```
round(pc_1$rotation[, 1:2], 3)
```

##	PC1	PC2
## CO	0.500	-0.003
## NO	0.533	-0.128
## NO2	0.508	0.158
## OZONO	-0.361	-0.579
## PM2.5	0.278	-0.789

- **PC1: Gases de Combustión y Tráfico**

- **Valor Alto (+):** Estación con **"trancón" o mucho tráfico**. Muchos gases de escape y casi nada de ozono.
- **Valor Bajo (-):** Zona con **aire más fresco** o menos influencia directa de tubos de escape en ese momento.


- **PC2: Humo Fino (Partículas) y Aire Estancado**

- **Valor Alto (+):** Aire **más despejado** de polvo y hollín.
- **Valor Bajo (-):** Aire **muy pesado y cargado** de partículas finas (PM2.5). Es donde el humo se queda "pegado" al suelo.

Ejercicio 6: primer plano factorial de las estaciones

```
pc_f = prcomp(datos_vars, scale=TRUE, rank.=2)
scores_aire = as_tibble(pc_f$x)
scores_aire$Estacion = datos_aire$Estaciones

ggplot(scores_aire, aes(x=PC1, y=PC2, label=Estacion)) +
  geom_point(size=1.5) +
  geom_text_repel(size=2.0, box.padding=0.4, max.overlaps=Inf) +
  geom_vline(xintercept=0, linetype="dashed", color="grey50") +
  geom_hline(yintercept=0, linetype="dashed", color="grey50") +
  theme_minimal() + labs(x="CP1 (indice general)", y="CP2 (indice especifico)")
```



2. Clustering: concepto general

¿Qué es el clustering?

Definicion

Los metodos de agrupamiento buscan particiones de las n observaciones en K grupos (*clusters*) que sean **homogeneos internamente** (dentro de cada grupo las observaciones son similares entre si) y **heterogeneos externamente** (los grupos son distintos entre si).

No confundir con clasificacion supervisada:

Clustering (no supervisado)	Clasificacion (supervisado)
No hay etiquetas previas	Se tienen etiquetas de clase
Los grupos emergen de los datos	Las clases estan definidas a priori
El resultado es explorado	El resultado es evaluado en error

Métodos duros vs. métodos suaves

Una distinción fundamental en el mundo del clustering:

Característica	Metodos duros	Metodos suaves
Asignación	Cada obs. a un grupo	P de pertenencia a c. grupo
Límite de grupos	Fronteras rígidas	Fronteras difusas
Ejemplos	K-means, jerárquico	Modelos de mezcla
Salida	Etiqueta $g_i \in \{1, \dots, K\}$	Vector $\pi_i = (\pi_{i1}, \dots, \pi_{iK})$
Cuándo usar	Grupos bien separados	Grupos solapados

Esta sesión

Nos enfocamos en métodos **duros**: K-medias y agrupamiento jerárquico. Son los más usados en la práctica y los mejores puntos de entrada conceptual.

La noción de distancia: la base de todo clustering

El clustering duro compara observaciones mediante una **medida de distancia**. La mas comun es la distancia euclidiana entre dos puntos $\mathbf{x}_i$ y $\mathbf{x}_j$:

$$d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{\sum_{k=1}^p (x_{ik} - x_{jk})^2}$$


- Dos observaciones **identicas** tienen distancia 0
- Dos observaciones muy **diferentes** tienen distancia grande
- Las variables deben estar en la misma escala: **estandarizar siempre**

Conexion con la Sesión 3

La distancia de Mahalanobis d_M que vimos en la Sesión 3 generaliza la euclidiana teniendo en cuenta la correlación entre variables. Para datos estandarizados con estructura de identidad, ambas coinciden.

Visualización del concepto de distancia

Partiendo del índice de contaminación (CP1) en 1 dimensión:



A ojo se distinguen entre 3 y 4 grupos. ¿Como formalizarlo?

3. K-medias (K-means)

Definición del problema

K-means busca la partición $\{G_1, G_2, \dots, G_K\}$ de las n observaciones que **minimiza la distancia cuadrada total dentro de cada grupo**:

$$d^2(\text{Agrupamiento}) = \sum_{k=1}^K \frac{1}{n_k} \sum_{i,j \in G_k} (z_i - z_j)^2$$

donde n_k es el numero de observaciones en el grupo k y z_i es la coordenada del individuo i .

Midiendo la calidad de una partición

Dos agrupamientos posibles para $K = 3$ sobre el CP1:

```
scores_aire = scores_aire %>%  
  mutate(  
    Agrup_A = case_when(  
      Estacion %in% c("Guaymaral", "Usaquen", "Suba") ~ "G1",  
      Estacion %in% c("Kennedy", "Movil Fontibon",  
                      "Carvajal Sevillana", "Puente Aranda") ~ "G2",  
      TRUE ~ "G3"),  
    Agrup_B = case_when(  
      Estacion %in% c("Guaymaral", "Usaquen", "Suba", "Colina") ~ "G1",  
      Estacion %in% c("Kennedy", "Movil Fontibon",  
                      "Carvajal Sevillana", "Puente Aranda",  
                      "San Cristobal", "Fontibon") ~ "G2",  
      TRUE ~ "G3"))
```

Calculando d^2 de cada partición

```
calcular_d2 = function(datos, col_grupo, col_val) {  
  total = 0  
  for(G in unique(datos[[col_grupo]])) {  
    vals = datos %>% filter(.data[[col_grupo]] == G) %>%  
      pull(.data[[col_val]])  
    total = total + sum(dist(vals)^2) / length(vals)  
  }  
  round(total, 3)  
}  
  
d2_A = calcular_d2(scores_aire, "Agrup_A", "PC1")  
d2_B = calcular_d2(scores_aire, "Agrup_B", "PC1")  
cat("d^2 Agrupamiento A:", d2_A, "\n")  
  
## d^2 Agrupamiento A: 5.889  
cat("d^2 Agrupamiento B:", d2_B, "\n")  
  
## d^2 Agrupamiento B: 7.072  
cat("Mejor agrupamiento: el de menor d^2 ->",  
    ifelse(d2_A < d2_B, "A", "B"), "\n")  
  
## Mejor agrupamiento: el de menor d^2 -> A
```

El algoritmo de Lloyd (1957) encuentra la particion optima de forma eficiente:

1. **Inicializacion:** seleccionar K puntos aleatorios como centroides iniciales
2. **Iteracion:** repetir hasta convergencia:
 - 2.1 **Asignacion:** cada observacion se asigna al centroide mas cercano
 - 2.2 **Actualizacion:** cada centroide se recalcula como la media de su grupo

Advertencia importante

El resultado **depende de la inicializacion aleatoria** del paso 1. Con distintas semillas pueden obtenerse distintos grupos. Por esto es recomendable:

- Ejecutar el algoritmo varias veces con distintas semillas
- Verificar que el agrupamiento es estable
- R usa `nstart=1` por defecto; considere `nstart=25`

K-means en R: caso univariado

```
set.seed(42)
kmedias = kmeans(scores_aire %>% select(PC1), centers=3)
scores_aire$Agrup_K = paste0("G", kmedias$cluster)


# Distancias cuadradas dentro de cada grupo
round(kmedias$withinss, 3)

## [1] 1.064 1.628 0.975
cat("d^2 total K-means:", round(sum(kmedias$withinss), 3), "\n")

## d^2 total K-means: 3.667
```



```
ggplot(scores_aire, aes(x=PC1, y=rep(0,nrow(scores_aire)),
                        color=Agrup_K, label=Estacion)) +
  geom_point(size=2.0) + theme_minimal() +
  geom_text_repel(size=1.8, box.padding=1.2, max.overlaps=Inf) +
  theme(axis.text.y=element_blank(), axis.ticks.y=element_blank()) +
  xlab("Indice de contaminacion (CP1)")
```



K-means en p dimensiones

El algoritmo generaliza directamente a $p > 1$ dimensiones:

- **Paso 1:** elegir K puntos aleatoriamente en $\mathbb{R}^p$
- **Paso 2:** iterar asignacion y actualizacion usando la distancia euclidiana en $\mathbb{R}^p$

Importante

- No es necesario aplicar ACP antes de K-means. El ACP ayuda a **visualizar** los grupos, pero el clustering opera directamente sobre la tabla de datos estandarizada.
- **Sin embargo:** si las variables tienen distintas escalas, **estandarizar siempre** antes de calcular distancias.


4. Selección del número de grupos K

El problema de elegir K

K-means requiere definir K **antes** de ejecutar el algoritmo. Dos guías prácticas

Guia 1: inspección visual del primer plano factorial


Cuantos grupos hay en el plano factorial?



A medida que K crece, d^2 decrece (cada punto se vuelve su propio cluster).
El numero optimo de K es donde el decrecimiento se vuelve marginal:

```
datos_univ = scores_aire %>% select(PC1)
dist_tot   = sum(dist(datos_univ)^2) / nrow(datos_univ)
reducc     = sapply(1:10, function(k) {
  dist_tot - sum(kmeans(datos_univ, centers=k,
                        nstart=10)$withinss)
})
```

Metodo del codo (CP1 univariado)



Interpretando el método del codo

El grafico muestra la **reduccion de varianza intra-cluster** al agregar cada grupo adicional:

- $K = 1$: sin agrupamiento, reduccion = 0
- $K = 2, 3$: grandes saltos en reduccion — estos grupos son muy informativos
- $K = 4, 5, \dots$: el incremento marginal decrece rapidamente
- **Codo en $K = 3$** : a partir de ahi, agregar mas grupos aporta poco

Regla practica

El metodo del codo es **heuristico**, no una prueba estadistica. Se complementa con la inspeccion visual del plano factorial. Si los dos metodos coinciden en K , hay mayor confianza en la eleccion.


5. K-means sobre la tabla completa

Método del codo en $p = 5$ dimensiones

```
datos_esc = scale(datos_vars)
dist_tot_p = sum(dist(datos_esc)^2) / nrow(datos_esc)
reducc_p = sapply(1:10, function(k) {
  dist_tot_p - sum(kmeans(datos_esc, centers=k,
                           nstart=15)$withinss)
})
```

```
plot(1:10, reducc_p, type="b", pch=16, col="tomato",  
     xlab="Numero de clusters K",  
     ylab="Reduccion de varianza",  
     main="Metodo del codo (5 contaminantes)")
```

Metodo del codo (5 contaminantes)



El codo sugiere $K = 4$ al trabajar con la tabla completa.

K-means con $K = 4$: verificando estabilidad

```
set.seed(123); km_4a = kmeans(datos_esc, centers=4, nstart=25)
set.seed(456); km_4b = kmeans(datos_esc, centers=4, nstart=25)
# Misimos grupos bajo distintas semillas: el resultado es **estable**
resultados = tibble(
  Estacion = datos_aire$Estaciones,
  Cluster_A = paste0("G", km_4a$cluster), Cluster_B = paste0("G", km_4b$cluster)
) %>% arrange(Cluster_A) ; resultados
```


```
## # A tibble: 15 x 3
```

##	Estacion	Cluster_A	Cluster_B
##	<chr>	<chr>	<chr>
##	1 Carvajal Sevillana	G1	G2
##	2 Fontibon	G1	G2
##	3 Kennedy	G1	G2
##	4 Movil Fontibon	G1	G2
##	5 Guaymaral	G2	G4
##	6 Suba	G2	G4
##	7 Usaquen	G2	G4
##	8 Bolivia	G3	G3
##	9 Colina	G3	G3
##	10 MinAmbiente	G3	G3
##	11 Puente Aranda	G3	G3
##	12 San Cristobal	G3	G3
##	13 Centro de Alto Rendimiento	G4	G1
##	14 Las Ferias	G4	G1
##	15 Tunal	G4	G1

Visualización K-means en el plano factorial

```
res_plot = resultados %>%  
  left_join(scores_aire %>% select(PC1, PC2, Estacion),  
            by="Estacion")
```

K-means K=4 visualizado en el plano factorial



6. Agrupamiento jerárquico

Motivación: la limitación de K-means

K-means tiene dos limitaciones importantes:

1. Requiere definir K **antes** de ejecutar
2. El resultado depende de la **inicialización aleatoria** (mínimo local, no global)

El **agrupamiento jerárquico aglomerativo** resuelve ambas: construye los grupos de forma progresiva, sin necesidad de especificar K a priori, y produce el mismo resultado en cada ejecución (sin aleatoriedad).

El algoritmo aglomerativo

1. **Inicio:** tratar cada observacion como un cluster de tamano 1.
Calcular la matriz de distancias entre todos los pares ($n \times n$)
2. **Fusion iterativa:** repetir $n - 1$ veces:
 - 2.1 Encontrar el par de clusters mas cercanos
 - 2.2 Fusionarlos en un solo cluster
 - 2.3 Actualizar la matriz de distancias
3. **Resultado:** un **dendograma** que muestra el historial completo de fusiones

La altura en el dendograma donde dos clusters se fusionan indica la **distancia a la que se unieron** — cortes a distintas alturas dan distintos K .

¿Cómo medir la distancia entre grupos?

La medida de distancia **entre dos clusters** (no entre dos puntos) define el criterio de enlace:

Enlace	Distancia entre grupos	Característica
Completo	Max entre pares de puntos	Clusters compactos
Promedio	Med entre todos los pares	Balance entre completo y simple
Simple	Min entre pares de puntos	Puede producir cadenas largas

Recomendación


El enlace **promedio** suele ser el mas robusto en la practica. El enlace simple (también el completo) es sensible a observaciones atípicas y tiende a formar cadenas (“chaining effect”).

Dendrograma univariado: los tres criterios

```
datos_jer_1d = data.frame(CP1=scores_aire$PC1)
rownames(datos_jer_1d) = scores_aire$Estacion
```

```
jer_comp = hclust(dist(datos_jer_1d), method="complete")
jer_prom = hclust(dist(datos_jer_1d), method="average")
jer_simp = hclust(dist(datos_jer_1d), method="single")
```

```
par(mfrow=c(1,3), mar=c(2,2,2,1), cex=0.55)
plot(as.dendrogram(jer_comp), main="Completo")
plot(as.dendrogram(jer_prom), main="Promedio")
plot(as.dendrogram(jer_simp), main="Simple")
```



```
par(mfrow=c(1,1))
```

Leer el dendrograma: cómo cortar el árbol


```
# Ajustar márgenes para que no se corte el texto
par(mar=c(5, 4, 4, 2))

plot(as.dendrogram(jer_prom),
     main="Dendrograma de Calidad del Aire - PC1",
     ylab="Distancia Euclídea",
     nodePar = list(lab.cex = 0.8, pch = NA)) # Nombres de estaciones más claros

# Línea de corte elegante
abline(h=1.5, col="royalblue", lwd=2, lty=3)

# Texto
text(x=5, y=1.1, "Corte óptimo: 3 Grupos", col="royalblue", font=2, cex=0.8)
```

Dendrograma de Calidad del Aire – PC1




El corte horizontal divide el árbol en ramas: cada rama es un grupo.
Cortar mas alto da menos grupos; cortar mas bajo da mas grupos.

Agrupamiento jerárquico sobre la tabla completa


```
datos_jer_p = scale(datos_vars)
rownames(datos_jer_p) = datos_aire$Estaciones

jer_comp_p = hclust(dist(datos_jer_p), method="complete")
jer_prom_p = hclust(dist(datos_jer_p), method="average")
jer_simp_p = hclust(dist(datos_jer_p), method="single")

par(mfrow=c(1,3), mar=c(2,2,2,1), cex=0.55)
plot(as.dendrogram(jer_comp_p), main="Completo")
plot(as.dendrogram(jer_prom_p), main="Promedio")
plot(as.dendrogram(jer_simp_p), main="Simple")
```




```
par(mfrow=c(1,1))
```




```
grupos_jer = cutree(jer_prom_p, k=4)
resultados_jer = tibble(
  Estacion = names(grupos_jer),
  Cluster_J = paste0("G", grupos_jer))
```

Comparación K-means vs. jerárquico



Comparación: agrupamiento jerárquico



¿Qué tan concordantes son los dos métodos?

```
tabla_conc = table(K_means = comp$Cluster_A,  
                   Jerarquico = comp$Cluster_J)  
print(tabla_conc)
```

```
##           Jerarquico  
## K_means G1 G2 G3 G4  
##      G1  0  4  0  0  
##      G2  0  0  3  0  
##      G3  5  0  0  0  
##      G4  0  1  0  2
```

Los grupos son en general concordantes, con diferencias menores. Estas diferencias revelan observaciones que están en la **frontera entre grupos** — zona donde los dos metodos discrepan.

7. Agrupamientos duros vs. suaves: la vision completa

¿Por qué existir los métodos suaves?

Los metodos duros (K-means, jerarquico) asignan cada observacion a **un solo grupo**. Pero en la practica:

- Las estaciones en la **frontera** entre clusters podrian pertenecer razonablemente a mas de uno
- Los grupos pueden **solaparse**: no hay una frontera nitida
- En algunos dominios, la **incertidumbre en la asignacion** es informacion valiosa

Los metodos suaves resuelven esto asignando a cada observacion un **vector de probabilidades de pertenencia** $\pi_i = (\pi_{i1}, \dots, \pi_{iK})$ con $\sum_k \pi_{ik} = 1$.

Métodos suaves: modelos de mezcla gaussiana (GMM)

El metodo suave mas importante es el **Modelo de Mezcla Gaussiana** (GMM):

$$f(\mathbf{x}) = \sum_{k=1}^K \pi_k \cdot \mathcal{N}_p(\mathbf{x} \mid \vec{\mu}_k, \Sigma_k)$$

- Cada componente k es una distribucion normal $\mathcal{N}_p(\vec{\mu}_k, \Sigma_k)$
- π_k es la proporcion del grupo k en la poblacion
- Para cada observacion se calcula $P(\text{pertenece a } k \mid \mathbf{x}_i)$

Conexion con la Sesion 3

El GMM es una extension directa de la distribucion normal multivariada: en lugar de **una** campana, son K campanas superpuestas. La distancia de Mahalanobis determina la probabilidad de pertenencia a cada grupo.

Comparación final: agrupamientos duros vs. suaves

Aspecto	K-means	Jerarquico	GMM
Tipo	Duro	Duro	Suave
K a priori	Si	No	Si
Aleatoriedad	Si	No	Si
Forma grupos	Esfera	Cualquiera	Elipsoide
Frontera	Rigida	Rigida	Probabilistica
Costo comp.	Bajo	Medio-alto	Alto
Interpretable	Facil	Facil	Requiere probabilidades

En este curso trabajamos con K-means y jerarquico por su transparencia conceptual. Los GMM requieren metodos de estimacion (algoritmo EM) que se estudian en cursos mas avanzados.

8. Síntesis y puente

Conclusiones de la Sesión 5

- El clustering es **aprendizaje no supervisado**: no hay variable respuesta
- **Metodos duros**: asignacion unica por observacion (K-means, jerarquico)
- **Metodos suaves**: probabilidades de pertenencia (GMM, fuzzy C-means)
- **K-means**: minimiza d^2 intra-cluster; rapido, sensible a inicializacion
- **Jerarquico**: no requiere K a priori; dendograma permite distintos cortes
- El **codo en d^2** y la **inspeccion visual del plano factorial** guian la seleccion de K
- Los resultados de clustering se visualizan mejor sobre el **primer plano factorial del ACP**
- El ACP y el clustering son **complementarios**, no sustitutos

El paso siguiente: regresión lineal (Sesión 6)

Las Sesiones 4 y 5 fueron **no supervisadas**: exploramos estructura sin una variable a predecir. La Sesión 6 introduce el cambio de paradigma:

De explorar a predecir

Regresión lineal: dado un conjunto de variables predictoras $X_1, X_2, \dots, X_p$, modelamos y predecimos una variable respuesta cuantitativa Y :

$$Y = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p + \varepsilon$$

Ahora si hay una variable privilegiada (Y) y un objetivo claro de predicción.

Las diferencias fundamentales con lo que hemos visto

Concepto	Sesiones 4–5	Sesion 6
Objetivo	Descubrir estructura	Predecir / explicar Y
Variable resp.	No existe	Y cuantitativa
Evaluacion	d^2 , varianza	Error cuadratico medio
Supuesto clave	(ninguno fuerte)	Linealidad, normalidad de errores
Salida	Grupos / ejes	Ecuacion de prediccion $\hat{Y}$

Conexion con el ACP

En regresion con muchas variables correlacionadas, la **regresion en componentes principales** (PCR) usa los CPs como predictores, conectando directamente las Sesiones 4 y 6.

Conexión completa del arco del curso

Ses.	Herramienta	Supervisado	Variable Y
1-2	Estadística descriptiva	—	No
3	Normal multivariada	No	No
4	ACP	No	No
5	Clustering (K-means, jer.)	No	No
6	Regresión lineal	Si	Si (Y cuant.)

Bibliografía

1. Hanif, M. et al. (2019). *Multivariate Techniques*. Cambridge Scholars Publishing.
2. Zeltermann, D. (2015). *Applied Multivariate Statistics with R*. Springer.
3. Everitt, B. & Hothorn, T. (2011). *Applied Multivariate Analysis with R*. Springer.
4. James, G. et al. (2021). *An Introduction to Statistical Learning* (2a ed.). Springer.
5. RMCAB. Red de Monitoreo de Calidad del Aire de Bogota.
<http://201.245.192.252:81/>

Anexo

Correlación espacial de los clusters

Un resultado notable: los grupos obtenidos por clustering sobre datos de contaminación corresponden aproximadamente a **zonas geograficas** de Bogota.

Resultado

Sin usar ninguna informacion de ubicacion geografica, los metodos de clustering recuperan una estructura espacial en los datos. Esto ocurre porque la contaminación del aire esta correlacionada espacialmente: estaciones cercanas tienden a medir valores similares.

Esto ilustra el poder del clustering como herramienta exploratoria: puede revelar estructura latente en los datos que no fue medida directamente.