Análisis Estadístico de Datos

Sesión 5: Métodos de Agrupamiento (Clustering)

Profesor: Nicolás López

Universidad del Rosario

Puente desde las sesiones anteriores

El arco del curso hasta hoy

Sesión	Tema	Pregunta central	Tipo
1–2	Estadística descriptiva	¿Cómo describir variables?	Univariado
3	Normal multivariada	¿Cómo modelar conjuntamente?	Multivariado
4	ACP	¿Cómo reducir dimensiones?	No supervisado
5	**Clustering**	**¿Cómo detectar grupos?**	**No supervisado**
6	Regresión lineal	¿Cómo predecir Y desde X?	Supervisado

Cambio de paradigma en la Sesión 6

Las Sesiones 4 y 5 son **no supervisadas**: no hay variable respuesta. La Sesión 6 introduce el aprendizaje **supervisado**: tenemos una variable Y que queremos predecir o explicar a partir de otras variables X.

Aprendizaje supervisado vs. no supervisado

Característica	**No supervisado**	**Supervisado**
Variable respuesta Y	No existe	Sí existe
Objetivo	Descubrir estructura	Predecir / explicar Y
Evaluación	Subjetiva / interna	Objetiva (error de predicción)
Ejemplos	ACP, Clustering	Regresión, clasificación
Etiquetas en los datos	No se requieren	Necesarias para entrenar

Una analogía para recordarlo

Supervisado = estudiar con las respuestas del libro
Hay un "profesor" (la variable Y) que nos dice si acertamos o no.

Ejemplo: predecir si un cliente pagará su crédito.

No supervisado = explorar una ciudad sin mapa
Nadie nos dice cuáles son los grupos: los descubrimos mirando los datos.

Ejemplo: descubrir qué tipos de clientes tiene un banco.

El ACP nos llevó hasta aquí

En la Sesión 4 vimos que el primer plano factorial (CP1 vs. CP2) revela estructura en los datos, pero **no asigna grupos formalmente**.

Hoy damos el paso que faltaba
Pasar de *"se ve que hay grupos"* a *"estos son los grupos"*.

Las preguntas de la sesión

1. ¿Cómo medir si dos observaciones son similares?
2. ¿Cómo encontrar grupos automáticamente, sin asignarlos a mano?
3. ¿Cómo elegir el número de grupos K?
4. ¿En qué se diferencia K-means del agrupamiento jerárquico?
5. ¿Cómo visualizar los grupos en el plano factorial del ACP?

Antes de empezar: una analogía

La fiesta de matrimonio
Nadie le entregó el plano de las mesas. Usted agrupa a los invitados por lo que tienen en común: edad, intereses, familia.

- Invitados parecidos $\rightarrow$ la **misma mesa**
- Invitados distintos $\rightarrow$ **mesas distintas**

Clustering = armar las mesas a partir de los datos.

Tabla de contenidos

Puente desde las sesiones anteriores

1. Los datos: calidad del aire en Bogotá
2. Clustering: concepto general
3. K-medias (K-means)
4. Selección del número de grupos K
5. K-means sobre la tabla completa
6. Agrupamiento jerárquico
7. Agrupamientos duros vs. suaves: la visión completa
8. Aplicaciones prácticas
9. Síntesis y puente

Bibliografía

Anexo

1. Los datos: calidad del aire en Bogotá

Descripción del conjunto de datos

Red de Monitoreo de Calidad del Aire de Bogotá (RMCAB): 15 estaciones, 5 contaminantes medidos a las 8 am del 8 de enero de 2022.

Variable	**Unidad**	**Descripción**
CO	ppm	Monóxido de carbono
NO	ppb	Óxido nítrico
NO2	ppb	Dióxido de nitrógeno
OZONO	ppb	Ozono
PM2.5	$\mu g/m^3$	Material particulado fino

La pregunta de la sesión

Pregunta de la sesión
¿Qué estaciones de Bogotá tienen perfiles de contaminación similares?

Un reto adicional
¿Podemos recuperar agrupaciones espaciales (por localidad o zona) usando solamente datos de sensores, sin conocer la ubicación geográfica?

Carga y exploración inicial

```
datos_aire = read_csv("ReporteContaminante_08012022_8am.csv",
                      show_col_types=FALSE)
datos_aire
```

```
## # A tibble: 15 x 6
##    Estaciones                    CO    NO   NO2 OZONO PM2.5
##    <chr>                      <dbl> <dbl> <dbl> <dbl> <dbl>
##  1 Bolivia                    0.484 23.3  21.2   2.77   7.8
##  2 Carvajal Sevillana         1.19  50.1  19.1   5.13  26
##  3 Centro de Alto Rendimiento 0.730 37.1  12.3   2.22  22
##  4 Colina                     0.502 16.6  15.4   1.73   3.9
##  5 Fontibon                   0.908 42.2  21.6   6.49  20.9
##  6 Guaymaral                  0.101  5.92  3.27 13.4    6
##  7 Kennedy                    1.40  60.1  28.4   8.25  17
##  8 Las Ferias                 0.787 20.7  11.3   8.83  19
##  9 MinAmbiente                1.24  39.6  17.8   2.86   8
## 10 Movil Fontibon             1.23  47.2  22.4   3.82  21.6
## 11 Puente Aranda              1.53  48.6  21.9   1.61   3.2
## 12 San Cristobal              1.17  32.6  19.9   1.30  14
## 13 Suba                       0.353  7.93  7.07  6.42   8
## 14 Tunal                      1.10  25.3  11.0   9.49  14
## 15 Usaquen                    0.268  3.61  4.26 15.1    8
```

Ejercicio 1: ¿qué estaciones son similares?

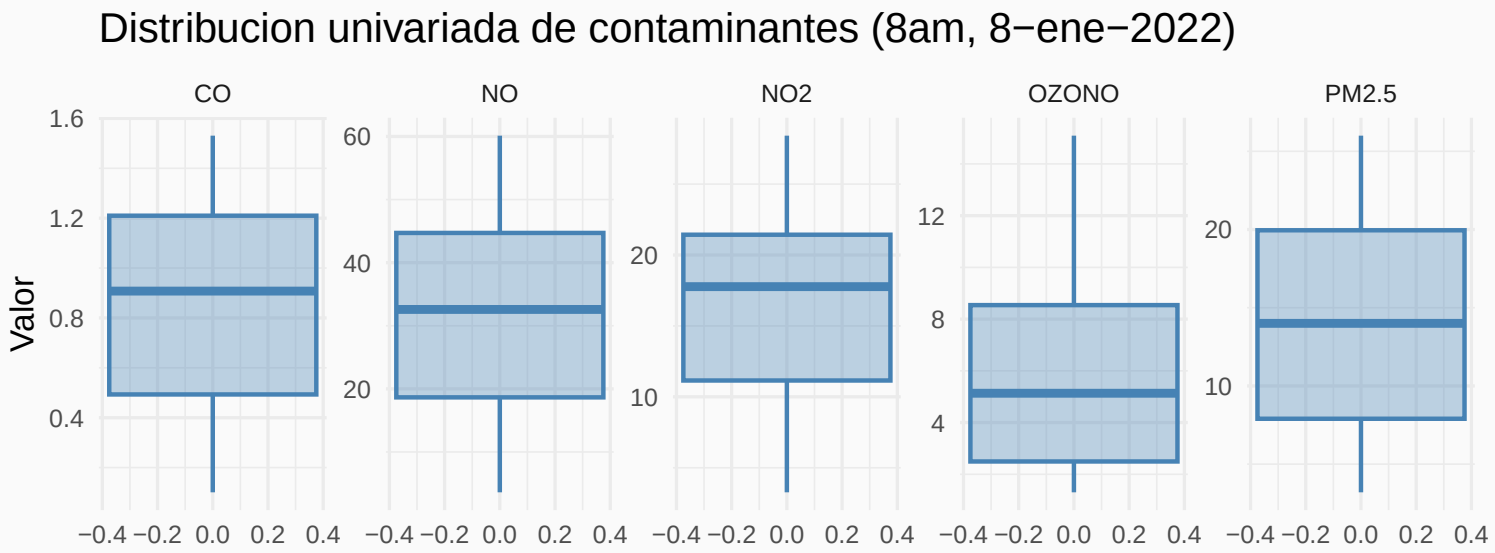
Ejercicio 1 – Discusión en clase
Mirando la tabla de datos a ojo:

- ¿Cuáles estaciones presentan mayor similaridad en las diferentes variables medidas?
- ¿Qué variables adicionales (geográficas, de tráfico, industriales) serían interesantes para entender mejor la similaridad?

Esta es la pregunta que los métodos de clustering resuelven de forma **objetiva y automática**, sin depender del ojo del analista.

Ejercicio 2: descripción univariada

```
datos_vars = datos_aire %>% select(-Estaciones)
datos_vars %>%
  pivot_longer(everything(), names_to="Contaminante", values_to="Valor") %>%
  ggplot(aes(y=Valor)) +
  geom_boxplot(fill="steelblue", alpha=0.35, color="steelblue",
               outlier.size=0.8) +
  facet_wrap(~Contaminante, scales="free", nrow=1) +
  theme_minimal(base_size=8) +
  labs(title="Distribucion univariada de contaminantes (8am, 8-ene-2022)")
```



Cada caja resume lo que miden las 15 estaciones para un contaminante.

Ejercicio 3: estructura de correlación

```r
matriz_cor = cor(datos_vars)
round(matriz_cor, 3)
```

```
##             CO     NO    NO2  OZONO  PM2.5
## CO      1.000  0.892  0.770 -0.474  0.357
## NO      0.892  1.000  0.873 -0.490  0.529
## NO2     0.770  0.873  1.000 -0.610  0.304
## OZONO -0.474 -0.490 -0.610  1.000 -0.046
## PM2.5  0.357  0.529  0.304 -0.046  1.000
```

Ejercicio 3: ¿qué nos dice la correlación?

- **CO, NO y NO2**: correlación positiva alta. Suben y bajan juntos porque tienen el mismo origen: la combustión de los vehículos.
- **OZONO**: correlación negativa con los anteriores. Se destruye en presencia de NO.

Idea clave

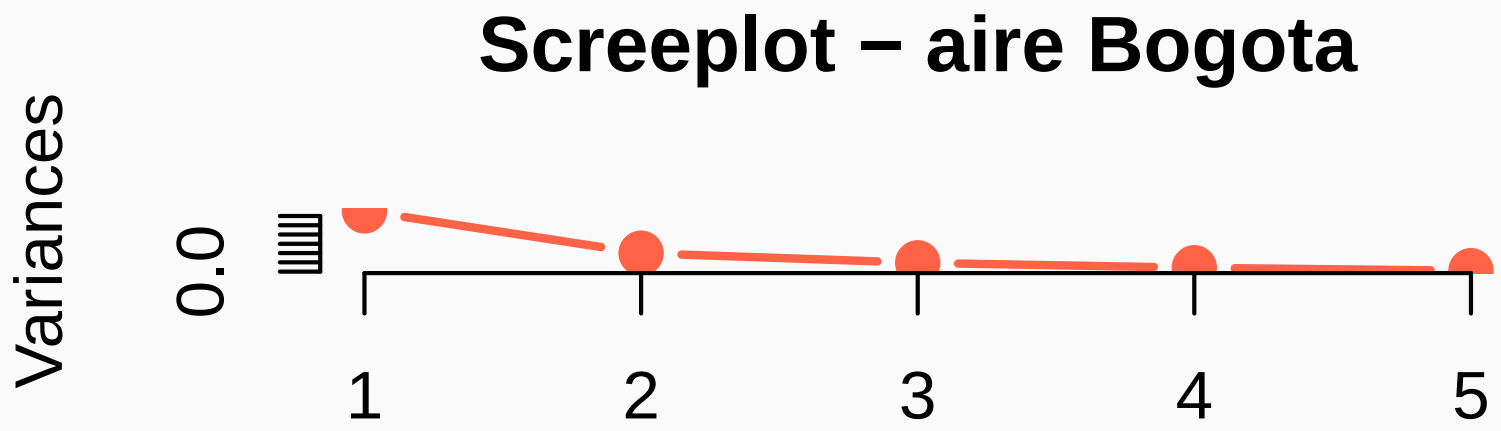
Muchas variables cuentan casi la misma historia. Por eso el ACP puede resumirlas en pocos ejes.

Ejercicio 4: ACP sobre los datos de aire

```
pc_1 = prcomp(datos_vars, scale=TRUE)
round(summary(pc_1)$importance, 3)
```

```
##                           PC1   PC2   PC3   PC4   PC5
## Standard deviation     1.810 0.996 0.689 0.456 0.222
## Proportion of Variance 0.655 0.199 0.095 0.042 0.010
## Cumulative Proportion  0.655 0.854 0.949 0.990 1.000
```

```r
screeplot(pc_1, col="tomato", pch=16,
          type="lines", cex=1.5, lwd=2, main="Screeplot - aire Bogota")
```



Ejercicio 5: interpretación de los componentes

```
round(pc_1$rotation[, 1:2], 3)
```

```
##           PC1    PC2
## CO      0.500 -0.003
## NO      0.533 -0.128
## NO2     0.508  0.158
## OZONO -0.361 -0.579
## PM2.5   0.278 -0.789
```

CP1: gases de combustión y tráfico

CP1 = índice de tráfico

- **Valor alto (+):** estación con **"trancón"** o mucho tráfico. Muchos gases de escape y casi nada de ozono.
- **Valor bajo (−):** zona con **aire más fresco**, con menos influencia directa de tubos de escape en ese momento.

CP2: humo fino (partículas) y aire estancado

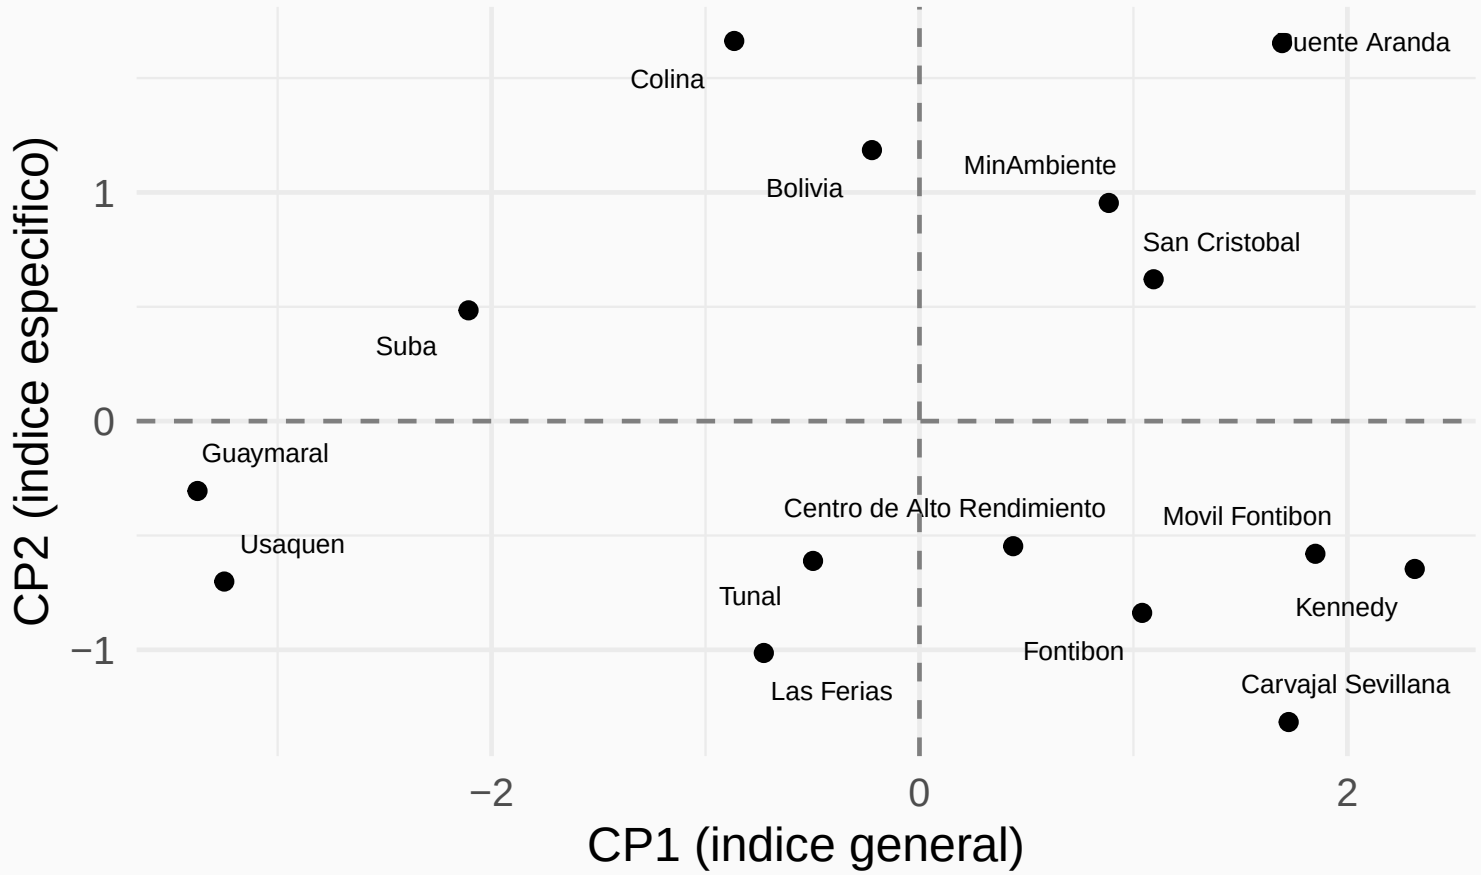
CP2 = índice de aire pesado

- **Valor alto (+):** aire **más despejado** de polvo y hollín.
- **Valor bajo (–):** aire **muy pesado y cargado** de partículas finas (PM2.5). Es donde el humo se queda "pegado" al suelo.

Ejercicio 6: primer plano factorial de las estaciones

```
pc_f = prcomp(datos_vars, scale=TRUE, rank.=2)
scores_aire = as_tibble(pc_f$x)
scores_aire$Estacion = datos_aire$Estaciones

g_plano = ggplot(scores_aire, aes(x=PC1, y=PC2, label=Estacion)) +
  geom_point(size=1.5) +
  geom_text_repel(size=2.0, box.padding=0.4, max.overlaps=Inf) +
  geom_vline(xintercept=0, linetype="dashed", color="grey50") +
  geom_hline(yintercept=0, linetype="dashed", color="grey50") +
  theme_minimal() + labs(x="CP1 (indice general)", y="CP2 (indice especifico)")
```



Cada punto es una estación: puntos cercanos = perfiles de contaminación parecidos.

2. Clustering: concepto general

¿Qué es el clustering?

Definición
Los métodos de agrupamiento buscan dividir las n observaciones en K grupos (*clusters*) tales que:

- **Dentro** de cada grupo, las observaciones sean **parecidas** (homogeneidad interna)
- **Entre** grupos, las observaciones sean **distintas** (heterogeneidad externa)

Un ejemplo simulado: clientes de un banco

Simulamos 90 clientes con dos variables, ambas en millones de pesos al mes.

```
set.seed(2024)
clientes = tibble(
  ingreso = c(rnorm(30, 2.5, 0.5), rnorm(30, 6, 0.8), rnorm(30, 10, 1)),
  gasto   = c(rnorm(30, 1.0, 0.3), rnorm(30, 3.5, 0.6), rnorm(30, 2.0, 0.5)))
```



¿Cuántos grupos de clientes ven a ojo?

No confundir con clasificación supervisada

Clustering (no supervisado)	**Clasificación (supervisado)**
No hay etiquetas previas	Se tienen etiquetas de clase
Los grupos emergen de los datos	Las clases están definidas a priori
El resultado se explora	El resultado se evalúa con el error

Métodos duros vs. métodos suaves

Una distinción fundamental en el mundo del clustering:

Característica	**Métodos duros**	**Métodos suaves**
Asignación	Cada obs. a **un grupo**	Probabilidad de pertenecer a **cada grupo**
Límite de grupos	Fronteras rígidas	Fronteras difusas
Ejemplos	K-means, jerárquico	Modelos de mezcla
Salida	Una etiqueta: G2	Un reparto: G2 70%, G3 30%
Cuándo usar	Grupos bien separados	Grupos solapados

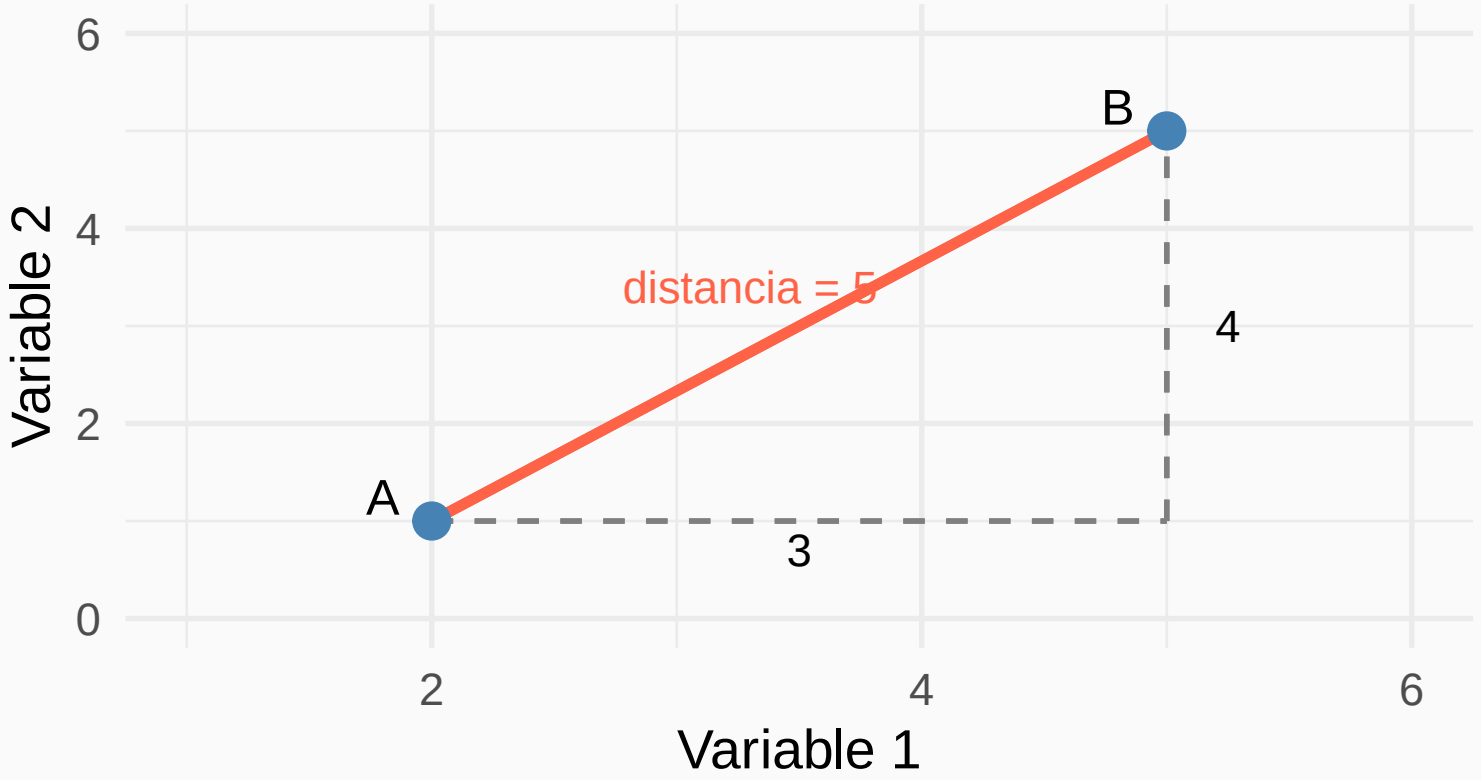
Esta sesión

Nos enfocamos en métodos **duros**: K-medias y agrupamiento jerárquico.

Son los más usados en la práctica y los mejores puntos de entrada conceptual.

La noción de distancia: parecido = cercanía

Todo clustering duro compara observaciones con una **medida de distancia**.



Con el triángulo 3-4-5: $\sqrt{3^2 + 4^2} = 5$.

La distancia euclidiana

Para p variables, la distancia entre las observaciones $\mathbf{x}_i$ y $\mathbf{x}_j$ es:

$$d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{\sum_{k=1}^{p} (x_{ik} - x_{jk})^2}$$

- Dos observaciones **idénticas** tienen distancia 0
- Dos observaciones muy **diferentes** tienen distancia grande
- Con 5 contaminantes es lo mismo: solo se suman más términos

Distancia y escalas: estandarizar siempre

Regla de oro
Las variables deben estar en la misma escala antes de calcular distancias: **estandarizar siempre**.

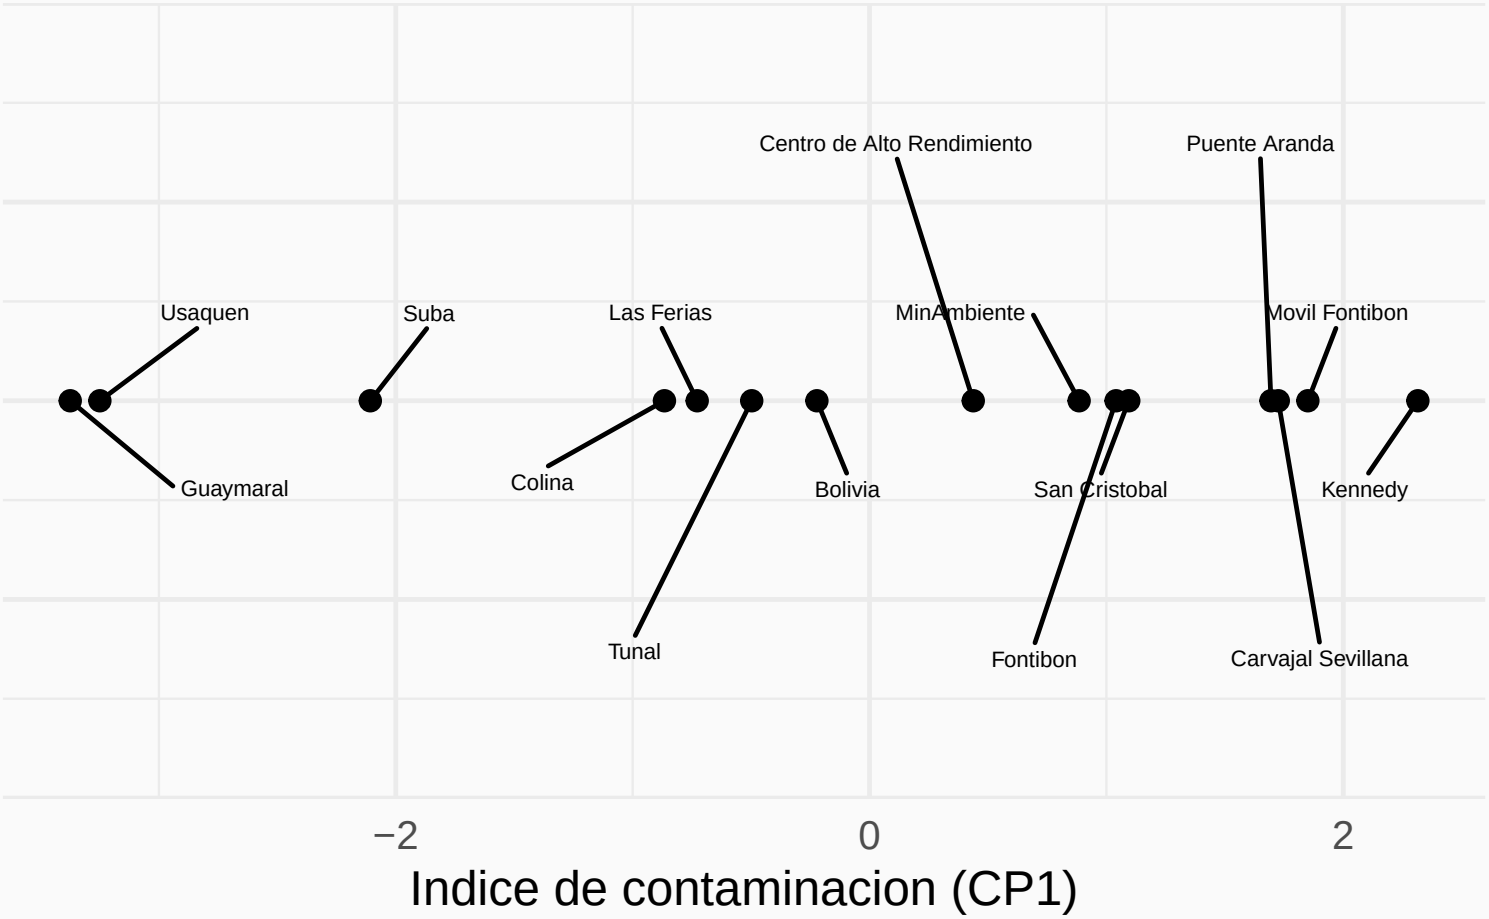
Más adelante lo veremos con una simulación.

Conexión con la Sesión 3

La distancia de Mahalanobis d_M que vimos en la Sesión 3 generaliza la euclidiana teniendo en cuenta la correlación entre variables. Para datos estandarizados con estructura de identidad, ambas coinciden.

Visualización del concepto de distancia

Partiendo del índice de contaminación (CP1) en 1 dimensión:



A ojo se distinguen entre 3 y 4 grupos. ¿Cómo formalizarlo?

3. K-medias (K-means)

La idea intuitiva

Ubicar centros de atención
Imagine que debe ubicar 3 puntos de atención al cliente para que todos los clientes queden lo más cerca posible de alguno.

- Cada punto de atención sirve a **su grupo** de clientes
- El mejor lugar para cada punto es el **promedio** de las ubicaciones de sus clientes

Eso es exactamente K-means.

Definición del problema

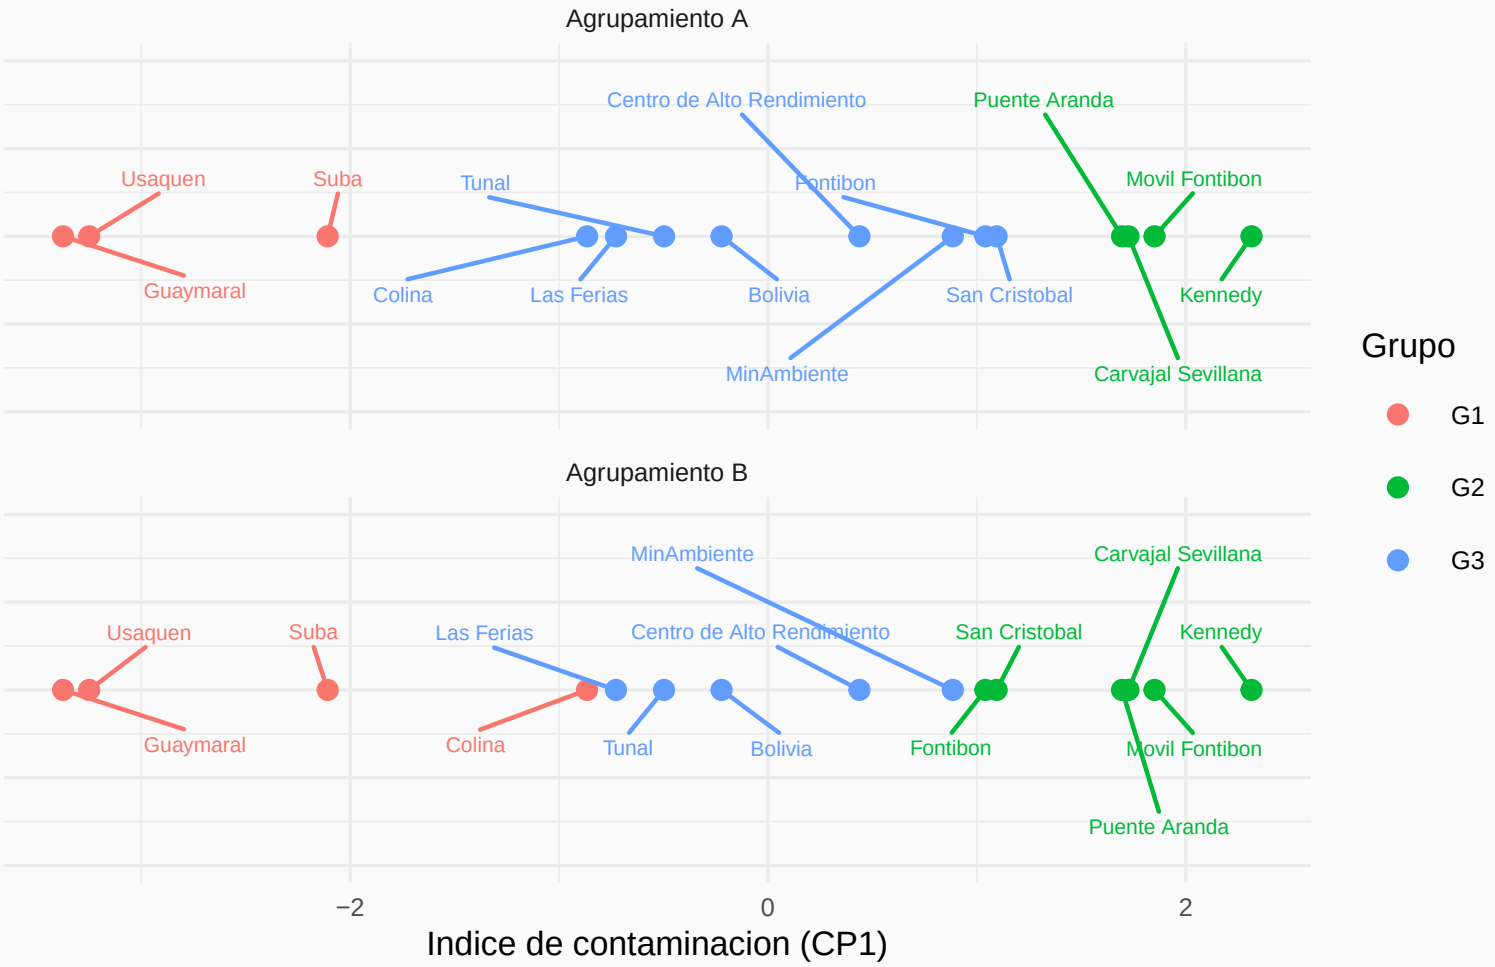
K-means busca la partición de las n observaciones en K grupos que **minimiza la dispersión dentro de los grupos**, llamada d^2.

- $d^2 =$ suma de las distancias **al cuadrado** de cada punto al centro de su grupo
- d^2 pequeño $\rightarrow$ grupos compactos $\rightarrow$ mejor partición

Nota
La expresión formal de d^2 está en el Anexo.

Midiendo la calidad de una partición

Dos agrupamientos posibles para $K = 3$ sobre el CP1. ¿Cuál es mejor?



Calculando d^2 de cada partición

```
d2_A = calcular_d2(scores_aire, "Agrup_A", "PC1")
d2_B = calcular_d2(scores_aire, "Agrup_B", "PC1")
cat("d^2 Agrupamiento A:", d2_A, "\n")
```

```
## d^2 Agrupamiento A: 5.889
```

```
cat("d^2 Agrupamiento B:", d2_B, "\n")
```

```
## d^2 Agrupamiento B: 7.072
```

```
cat("Mejor agrupamiento: el de menor d^2 ->",
    ifelse(d2_A < d2_B, "A", "B"), "\n")
```

```
## Mejor agrupamiento: el de menor d^2 -> A
```

K-means busca automáticamente la partición con el d^2 más bajo posible.

El algoritmo de K-means

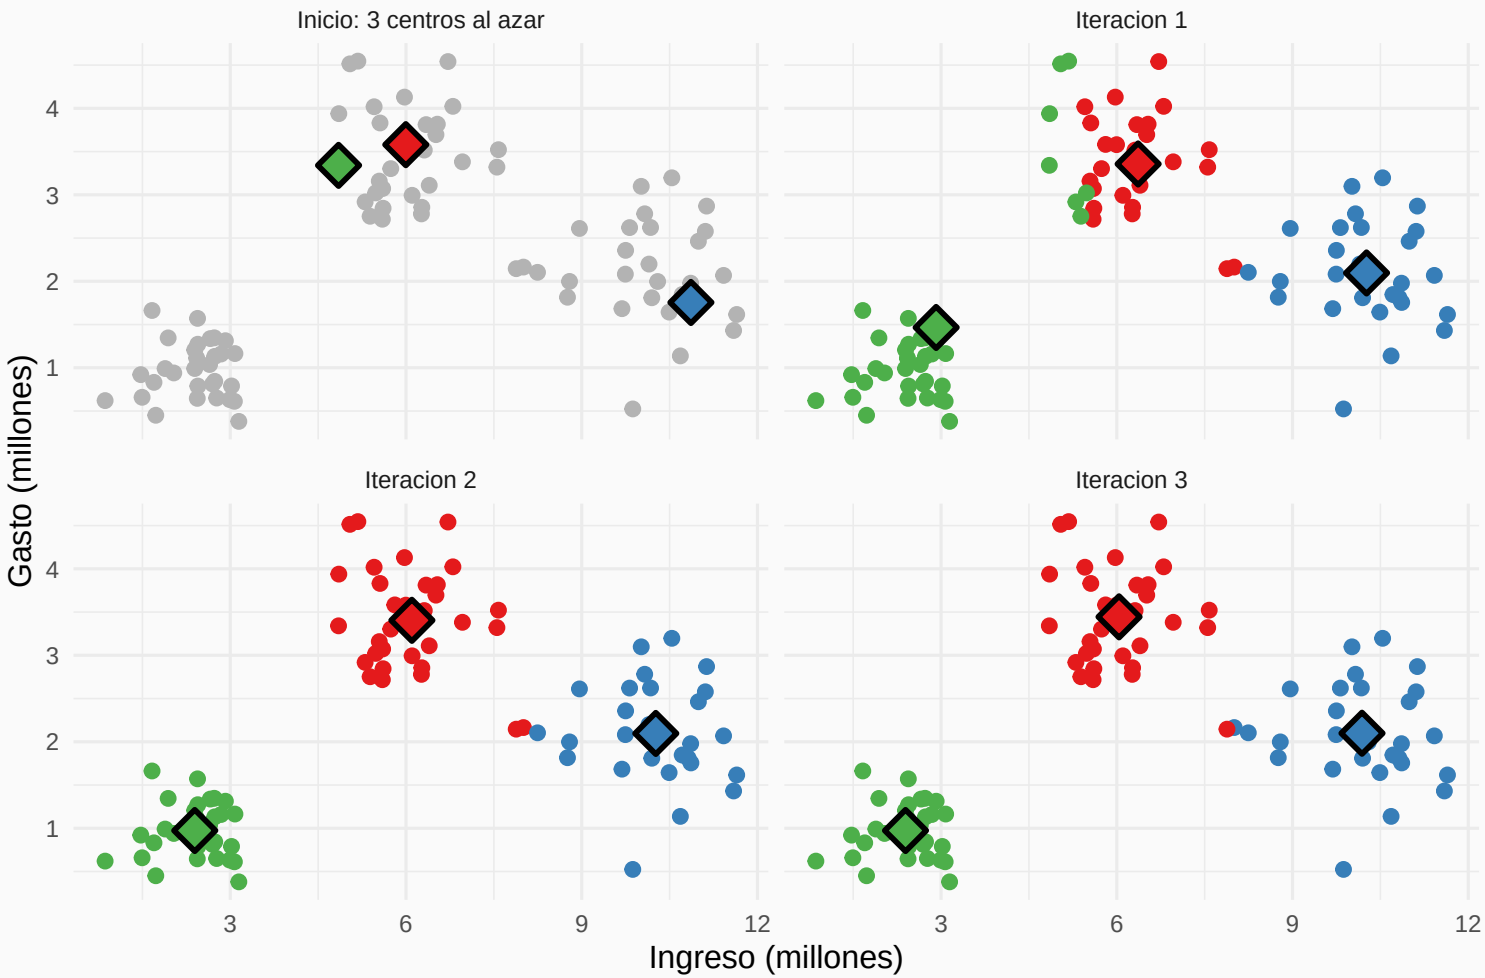
El algoritmo de Lloyd (1957) encuentra la partición de forma eficiente:

1. **Inicio**: elegir K centros al azar
2. **Asignar**: cada observación va al centro más cercano
3. **Actualizar**: cada centro se mueve al promedio de su grupo

Repetir los pasos 2 y 3 hasta que nada cambie.

K-means paso a paso (simulación)

Con los clientes simulados y $K = 3$:



¿Qué vimos en la simulación?

- Los **centros** (rombos) se mueven hacia el promedio de sus puntos
- Un cliente cambia de grupo solo si otro centro le queda **más cerca**
- En pocas iteraciones los centros **dejan de moverse**: el algoritmo convergió

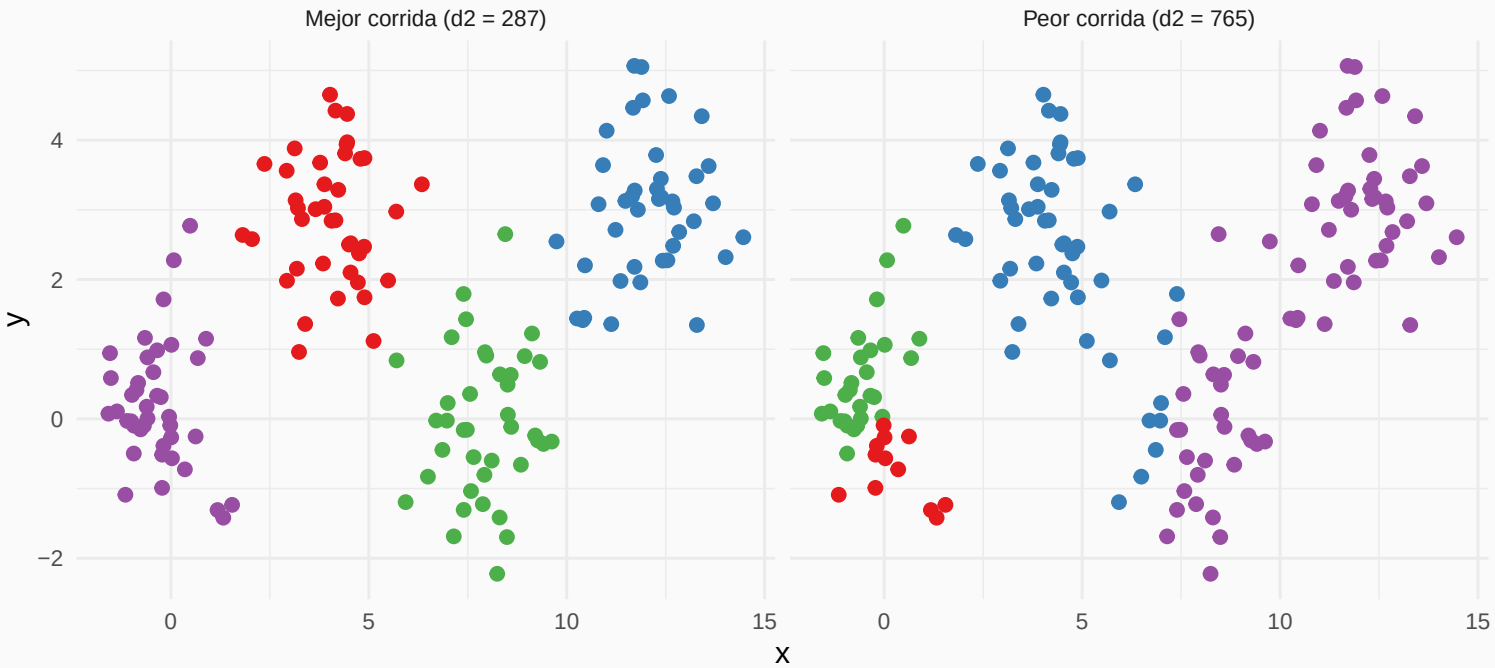
Pregunta para la clase
¿Qué habría pasado si los 3 centros iniciales hubieran caído en el mismo grupo de clientes?

Advertencia: la inicialización es aleatoria

Advertencia importante
El resultado **depende de los centros iniciales** (paso 1). Con distintas semillas pueden obtenerse distintos grupos.

- Ejecutar el algoritmo varias veces con distintas semillas
- Verificar que el agrupamiento es estable
- R usa `nstart=1` por defecto; considere `nstart=25`

Simulación: ¿y si cambiamos el punto de partida?



Mismos datos, mismo $K = 4$: dos puntos de partida distintos dan agrupamientos distintos.

¿Qué tan frecuente es llegar a la mejor solución?



En 86 de 100 corridas se llegó a la mejor solución; en las demás el algoritmo quedó atrapado en una peor.

Solución práctica

`nstart=25` repite el algoritmo 25 veces y se queda con la mejor corrida.

K-means en R: caso univariado

```r
set.seed(42)
kmedias = kmeans(scores_aire %>% select(PC1), centers=3)
scores_aire$Agrup_K = paste0("G", kmedias$cluster)

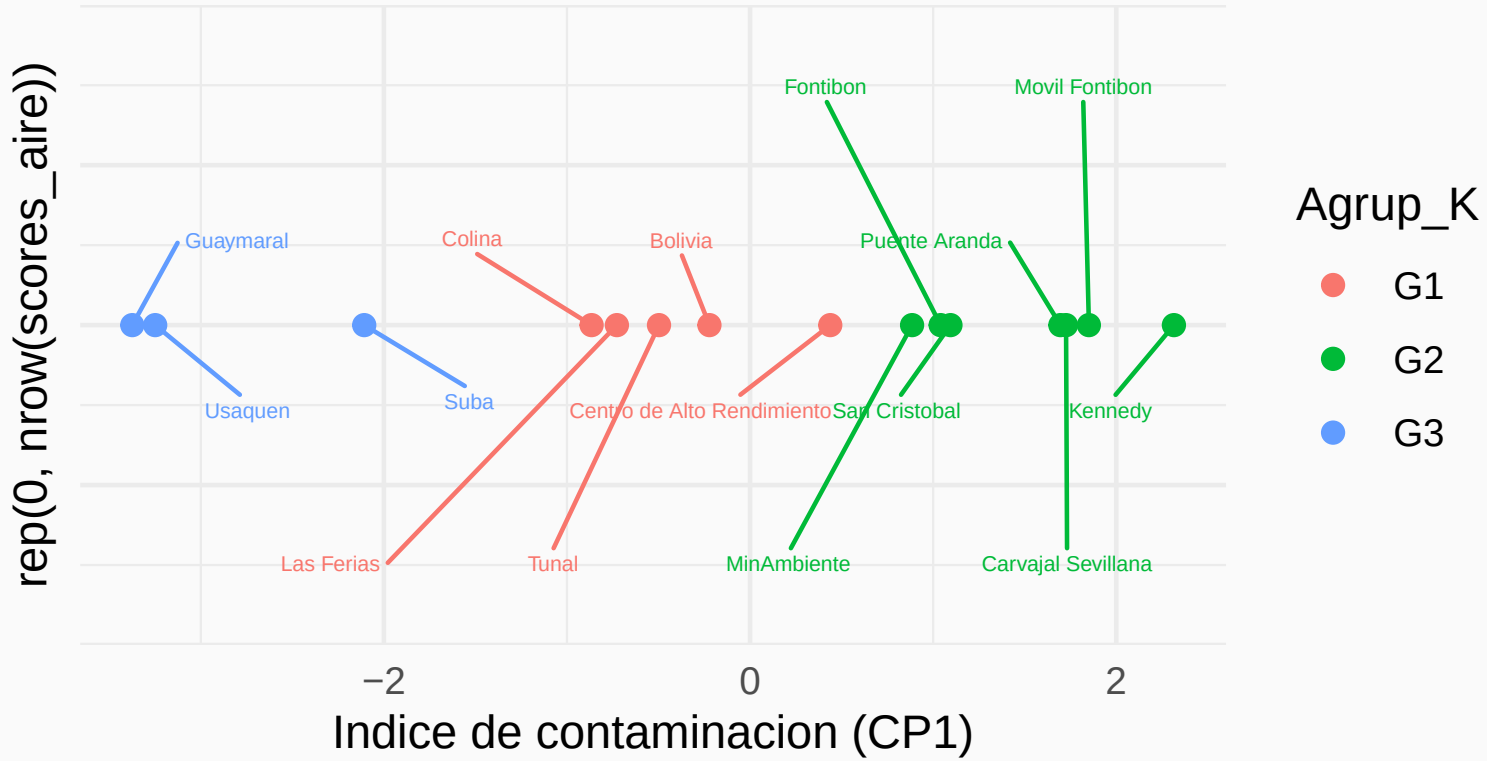
# Distancias cuadradas dentro de cada grupo
round(kmedias$withinss, 3)
```

```
## [1] 1.064 1.628 0.975
```

```r
cat("d^2 total K-means:", round(sum(kmedias$withinss), 3), "\n")
```

```
## d^2 total K-means: 3.667
```

```r
ggplot(scores_aire, aes(x=PC1, y=rep(0,nrow(scores_aire)),
                        color=Agrup_K, label=Estacion)) +
  geom_point(size=2.0) + theme_minimal() +
  geom_text_repel(size=1.8, box.padding=1.2, max.overlaps=Inf) +
  theme(axis.text.y=element_blank(), axis.ticks.y=element_blank()) +
  xlab("Indice de contaminacion (CP1)")
```



K-means en p dimensiones

El algoritmo generaliza directamente a $p > 1$ dimensiones:

- **Paso 1**: elegir K puntos aleatoriamente en $\mathbb{R}^p$
- **Paso 2**: iterar asignación y actualización usando la distancia euclidiana en $\mathbb{R}^p$

Mismo algoritmo, solo que con más ejes.

Importante

- No es necesario aplicar ACP antes de K-means. El ACP ayuda a **visualizar** los grupos, pero el clustering opera directamente sobre la tabla de datos estandarizada.
- **Sin embargo**: si las variables tienen distintas escalas, **estandarizar siempre** antes de calcular distancias.

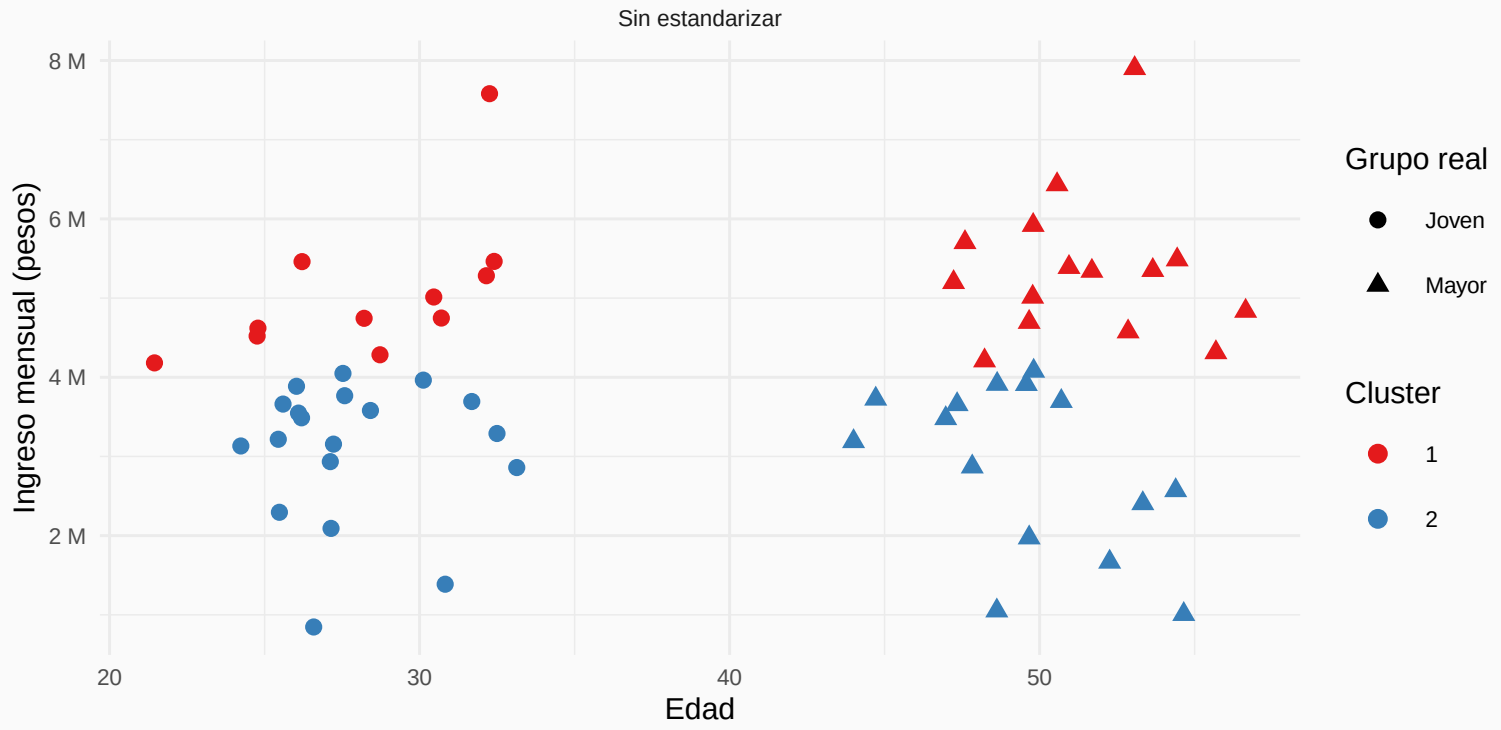
¿Por qué estandarizar? Un ejemplo simulado

Simulamos 60 personas con edad e ingreso mensual (en pesos).

- Hay **dos grupos reales**: jóvenes (alrededor de 28 años) y mayores (alrededor de 50)
- El ingreso varía igual en ambos grupos: **no** distingue los grupos

Pregunta
¿Logrará K-means recuperar los dos grupos reales?

Sin estandarizar vs. estandarizado



La moraleja de la estandarización

- **Sin estandarizar**: el ingreso (millones) "ahoga" a la edad (decenas). K-means agrupa casi solo por ingreso y mezcla jóvenes con mayores.
- **Estandarizado**: ambas variables pesan igual y K-means recupera los grupos reales.

Regla práctica

La variable con números más grandes "manda" en la distancia.

Estandarizar evita que la unidad de medida decida el resultado.

4. Selección del número de grupos K

El problema de elegir K

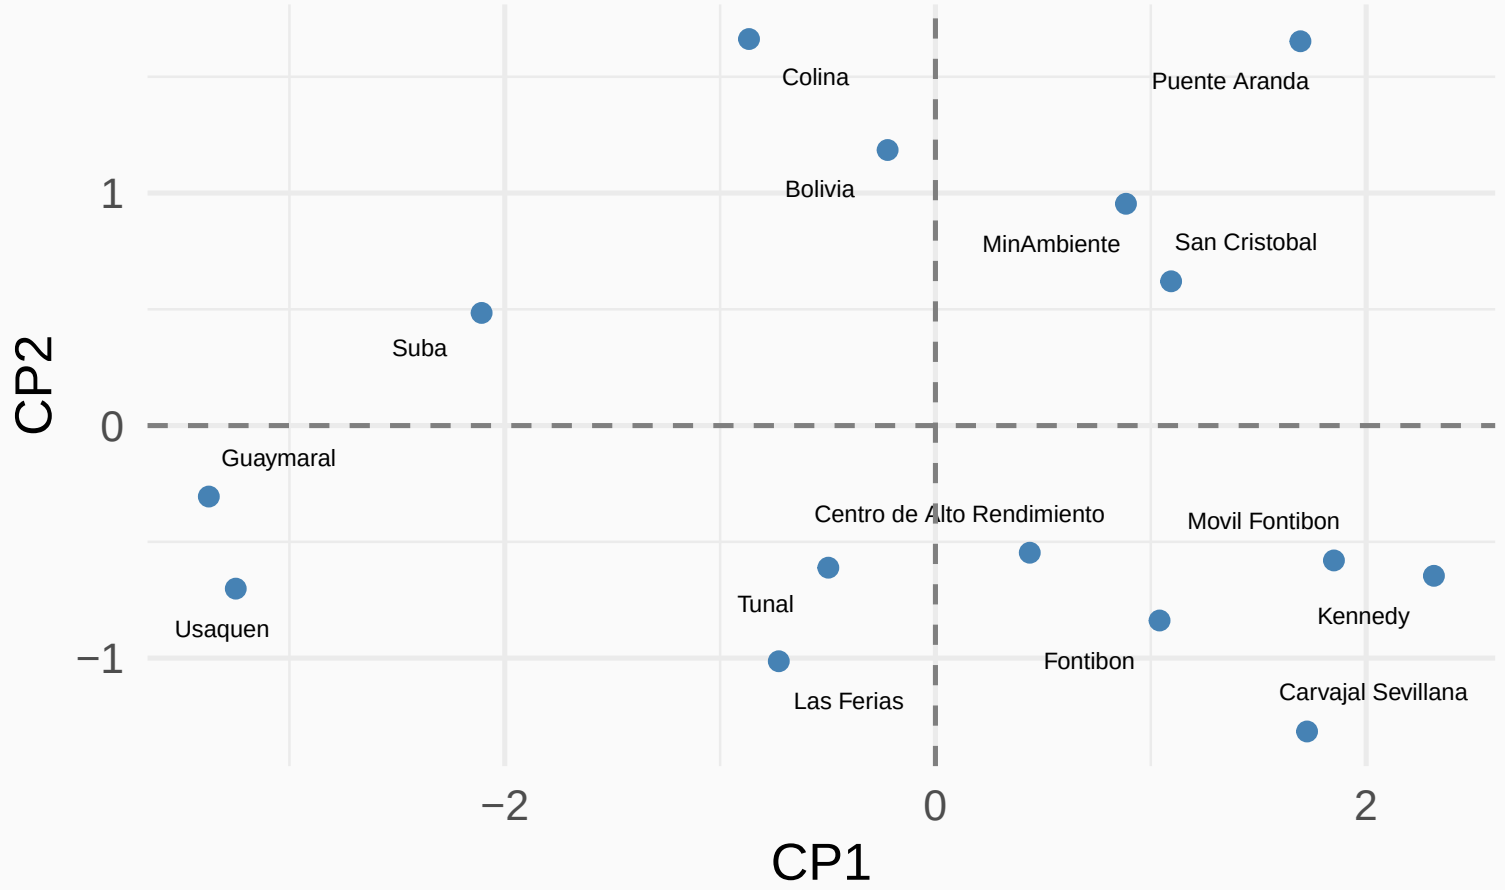
K-means requiere definir K **antes** de ejecutar el algoritmo.

Dos guías prácticas:

1. **Inspección visual** del primer plano factorial
2. **Método del codo** sobre d^2

Guía 1: inspección visual del primer plano factorial

Cuantos grupos hay en el plano factorial?



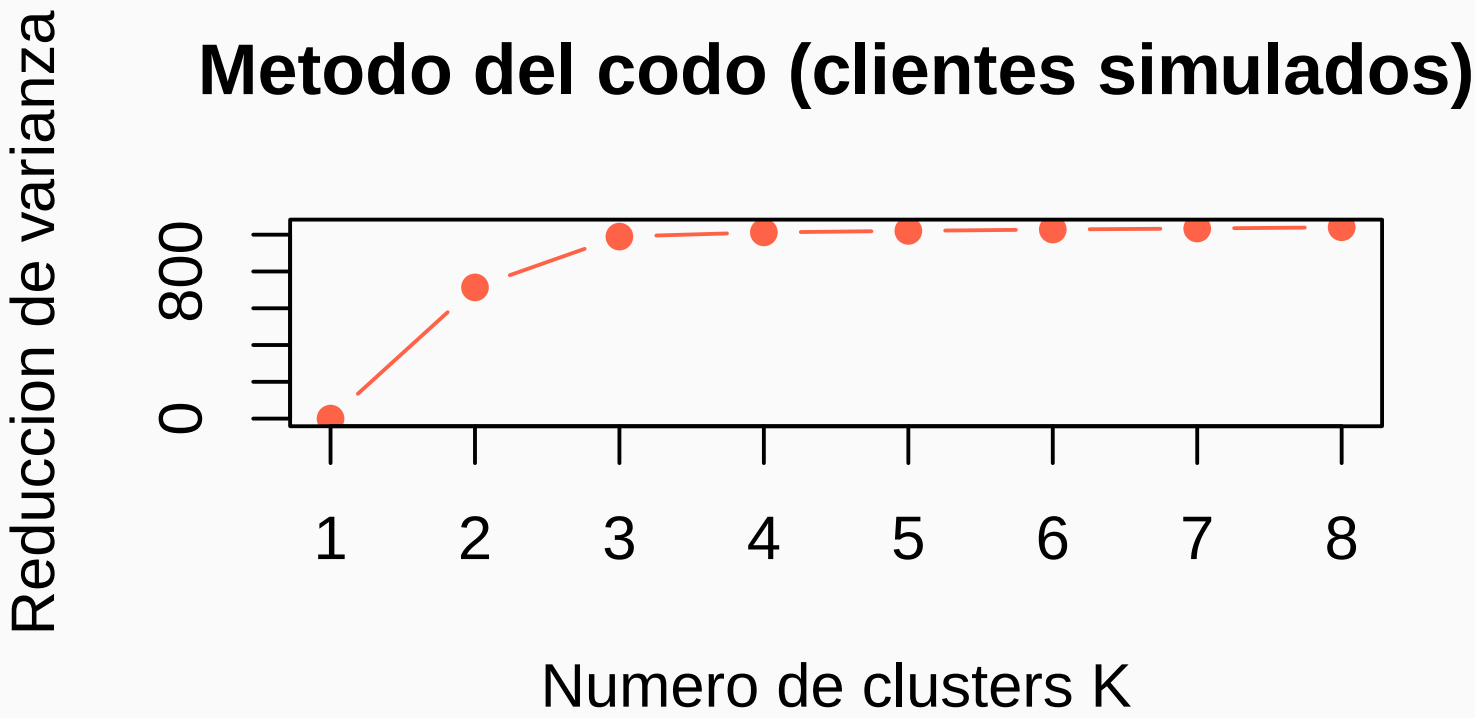
Guía 2: la intuición del codo

Más sedes, cada vez menos ganancia
Con más puntos de atención, los clientes quedan más cerca. Pero la **primera** sede mejora mucho; la décima, casi nada.

- A medida que K crece, d^2 **siempre** decrece
- Con $K = n$ cada punto es su propio grupo: inútil
- El **codo** es donde agregar un grupo más ya casi no mejora

El codo cuando conocemos la verdad (simulación)

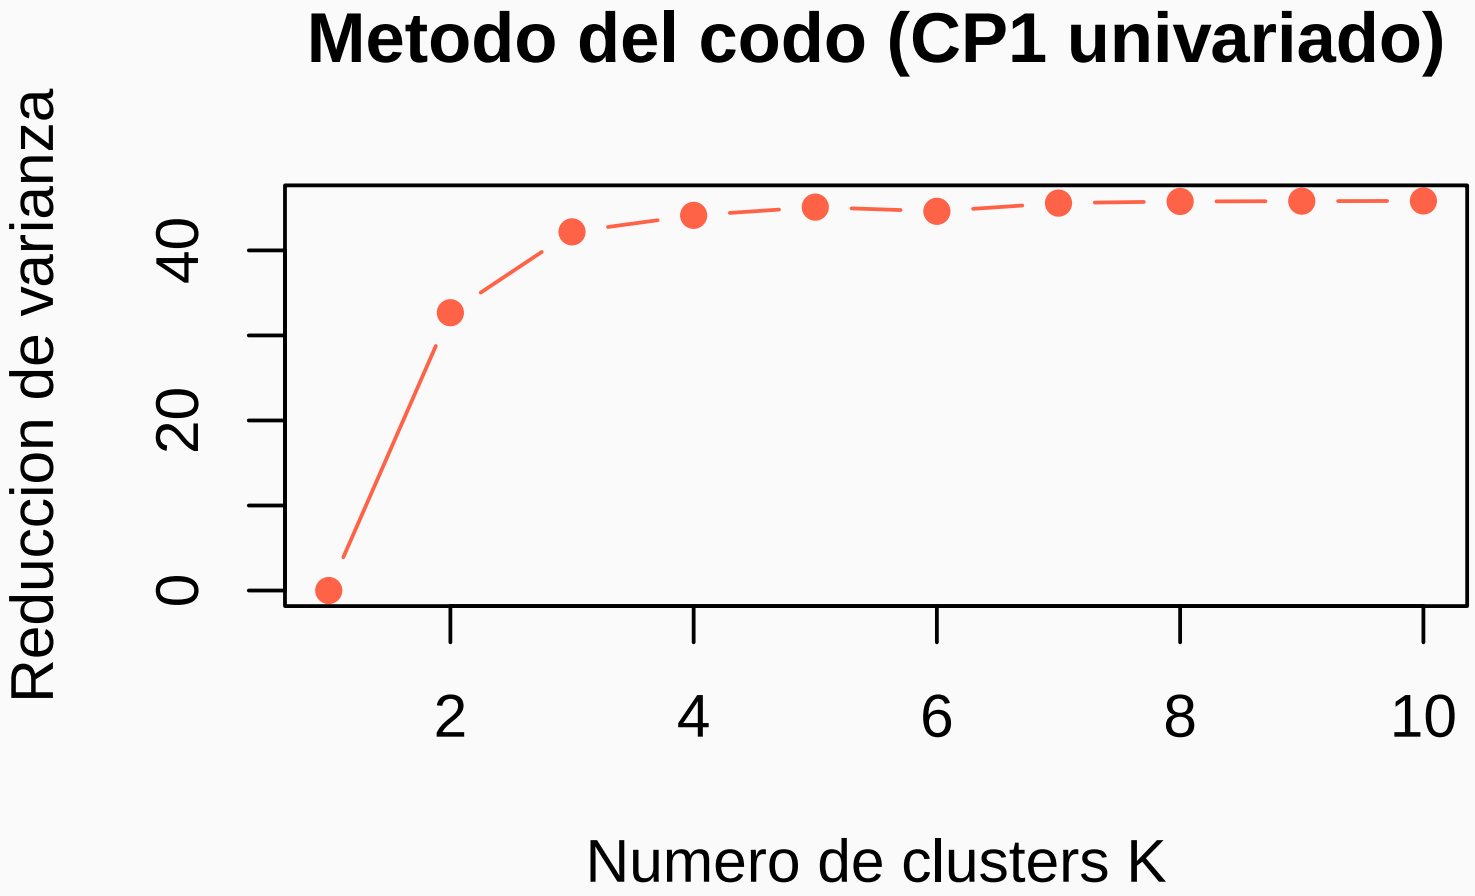
Los clientes simulados tienen exactamente 3 grupos. ¿Lo detecta el codo?



Guía 2: método del codo sobre d^2 (datos de aire)

Medimos cuánto baja d^2 al pasar de 1 a 10 grupos:

```
datos_univ = scores_aire %>% select(PC1)
dist_tot   = sum(dist(datos_univ)^2) / nrow(datos_univ)
reducc     = sapply(1:10, function(k) {
  dist_tot - sum(kmeans(datos_univ, centers=k,
                        nstart=10)$withinss)
})
```


Metodo del codo (CP1 univariado)
Reduccion de varianza
0
20
40
2
4
6
8
10
Numero de clusters K

Interpretando el método del codo

El gráfico muestra la **reducción de varianza intra-cluster** al agregar cada grupo adicional:

- $K = 1$: sin agrupamiento, reducción $= 0$
- $K = 2, 3$: grandes saltos en reducción: estos grupos son muy informativos
- $K = 4, 5, \ldots$: el incremento marginal decrece rápidamente
- **Codo en** $K = 3$: a partir de ahí, agregar más grupos aporta poco

Regla práctica

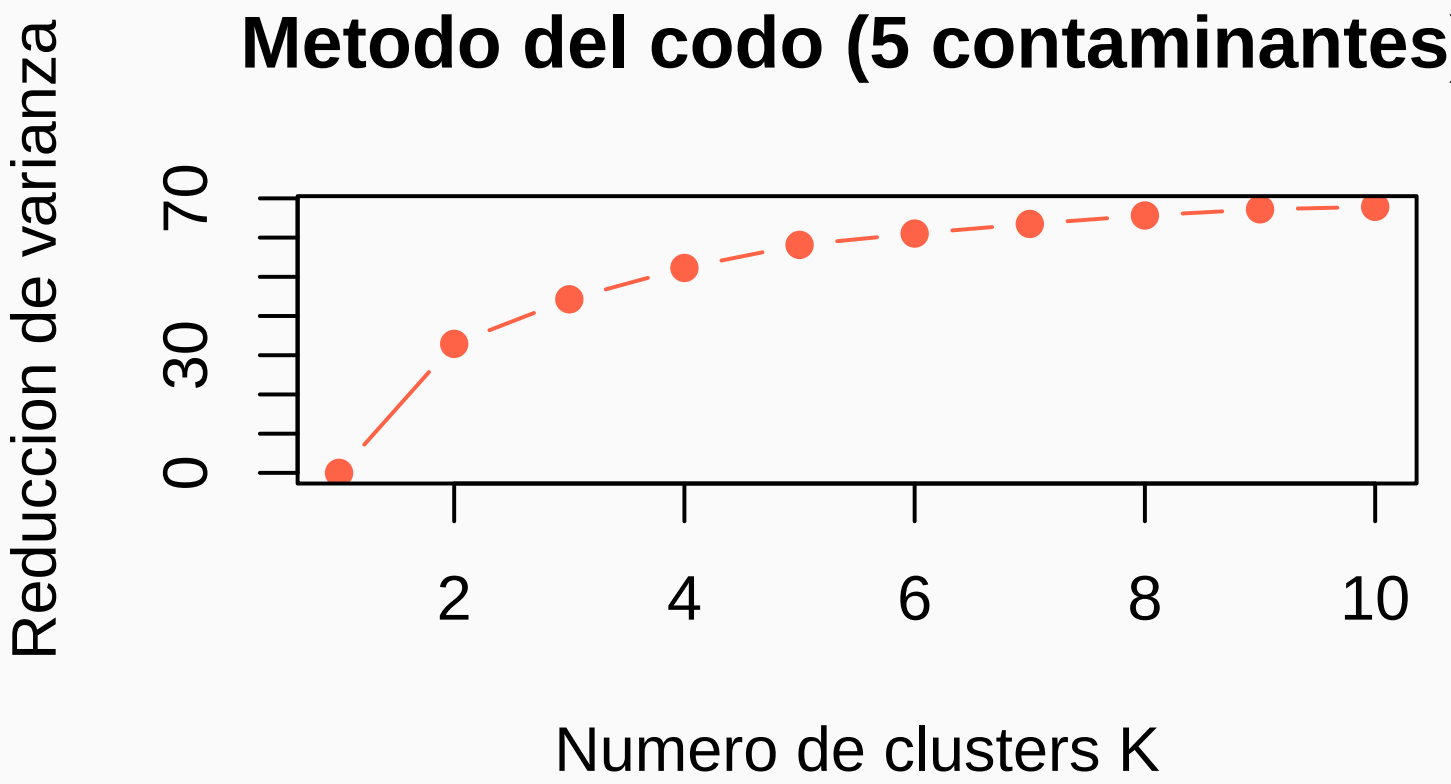
El método del codo es **heurístico**, no una prueba estadística. Se complementa con la inspección visual del plano factorial. Si los dos métodos coinciden en K, hay mayor confianza en la elección.

5. K-means sobre la tabla completa

Método del codo en $p = 5$ dimensiones

```
datos_esc  = scale(datos_vars)
dist_tot_p = sum(dist(datos_esc)^2) / nrow(datos_esc)
reducc_p   = sapply(1:10, function(k) {
  dist_tot_p - sum(kmeans(datos_esc, centers=k,
                          nstart=15)$withinss)
})
```

```r
plot(1:10, reducc_p, type="b", pch=16, col="tomato",
     xlab="Numero de clusters K",
     ylab="Reduccion de varianza",
     main="Metodo del codo (5 contaminantes)")
```



El codo sugiere $K = 4$ al trabajar con la tabla completa.

K-means con $K = 4$: verificando estabilidad

```
set.seed(123); km_4a = kmeans(datos_esc, centers=4, nstart=25)
set.seed(456); km_4b = kmeans(datos_esc, centers=4, nstart=25)
# Mismos grupos bajo distintas semillas: el resultado es estable
resultados = tibble(
  Estacion  = datos_aire$Estaciones,
  Cluster_A = paste0("G", km_4a$cluster),
  Cluster_B = paste0("G", km_4b$cluster)
) %>% arrange(Cluster_A)
```

```
resultados
```

```
## # A tibble: 15 x 3
##    Estacion                  Cluster_A Cluster_B
##    <chr>                     <chr>     <chr>
##  1 Carvajal Sevillana        G1        G2
##  2 Fontibon                  G1        G2
##  3 Kennedy                   G1        G2
##  4 Movil Fontibon            G1        G2
##  5 Guaymaral                 G2        G4
##  6 Suba                      G2        G4
##  7 Usaquen                   G2        G4
##  8 Bolivia                   G3        G3
##  9 Colina                    G3        G3
## 10 MinAmbiente               G3        G3
## 11 Puente Aranda             G3        G3
## 12 San Cristobal             G3        G3
## 13 Centro de Alto Rendimiento G4       G1
## 14 Las Ferias                G4        G1
## 15 Tunal                     G4        G1
```

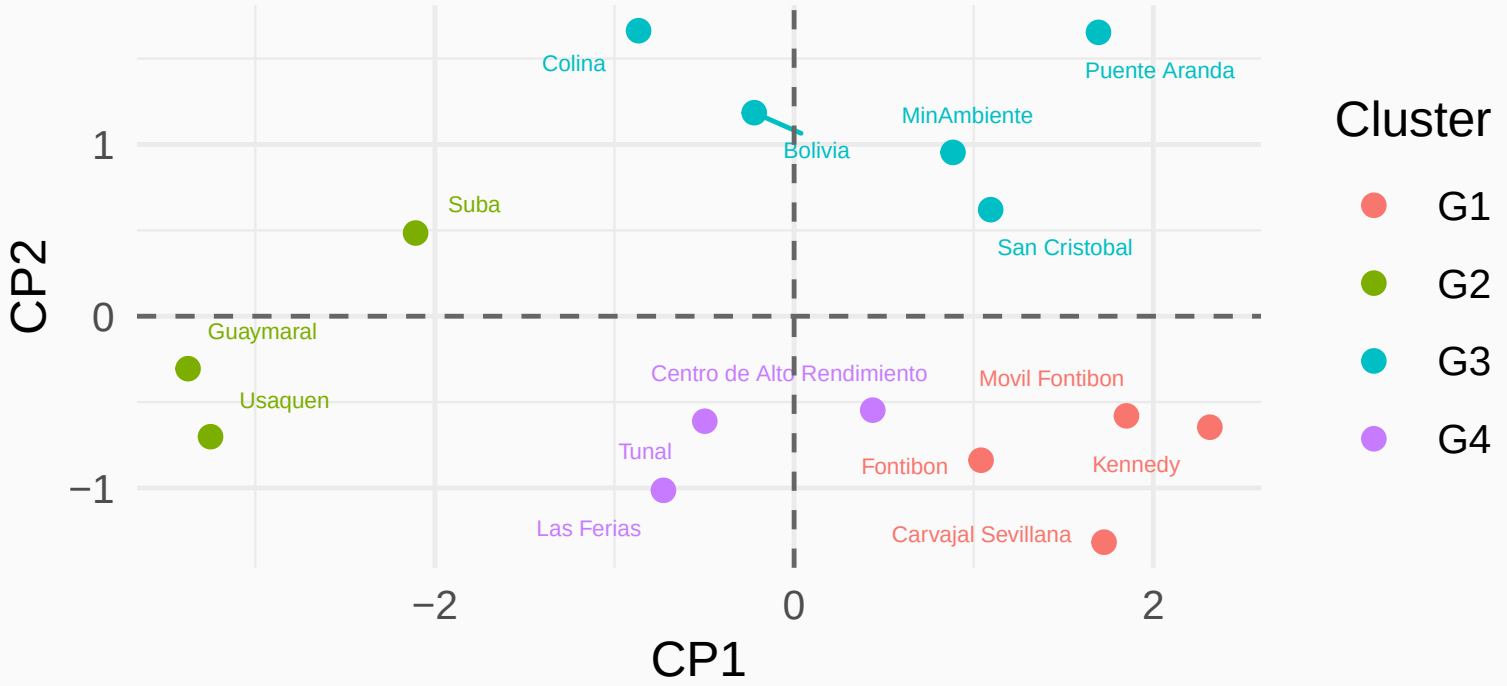
Ojo con las etiquetas

Los números (G1, G2, ...) son solo nombres y pueden cambiar entre corridas. Lo que importa es **quiénes quedan juntos**, no el número del grupo.

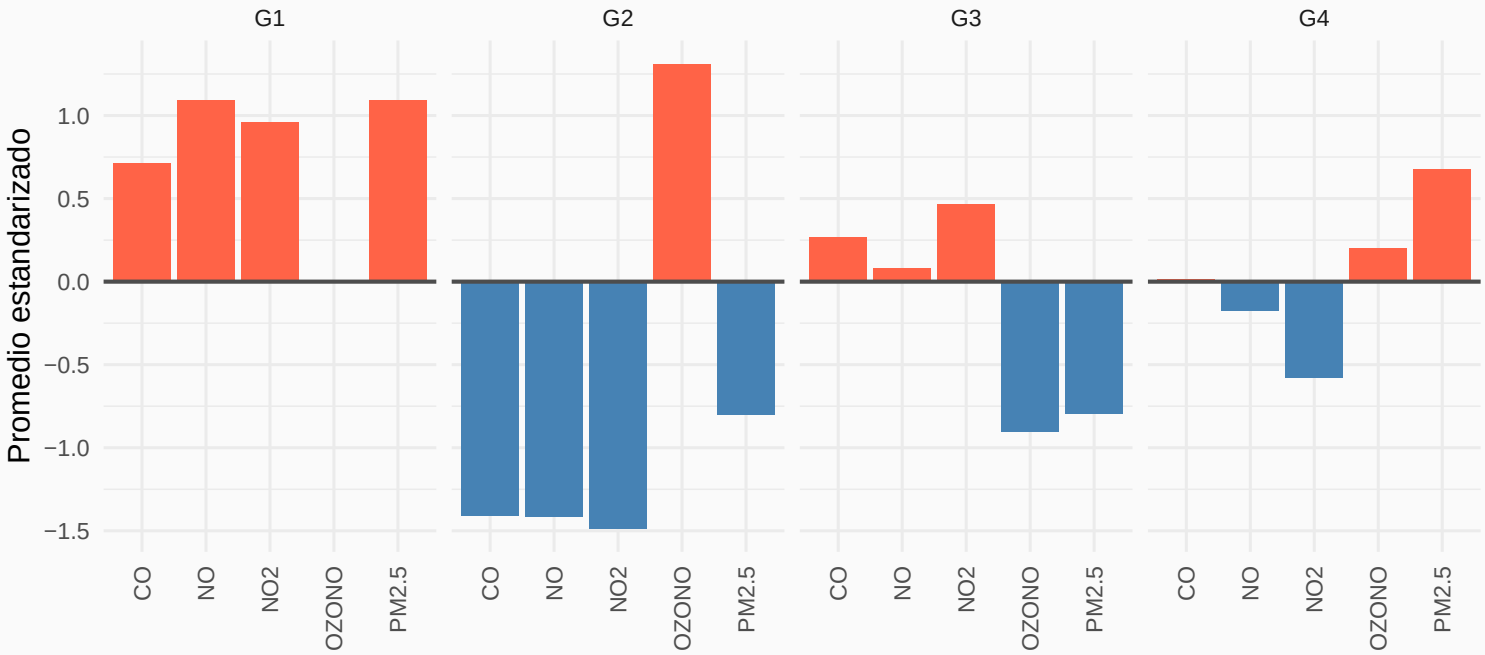
Visualización de K-means en el plano factorial

```
res_plot = resultados %>%
  left_join(scores_aire %>% select(PC1, PC2, Estacion),
            by="Estacion")
```

K−means K=4 visualizado en el plano factorial



¿Cómo es cada grupo? El perfil de los clusters



Barras hacia arriba = más contaminante que el promedio de Bogotá; hacia abajo = menos.

Ejercicio 7: pónganle nombre a cada grupo

Ejercicio 7 – Discusión en clase
Mirando el perfil de cada grupo:

- ¿Cuál es el grupo con más tráfico? ¿Y el de aire más limpio?
- ¿Qué nombre le pondría a cada grupo?
- ¿Qué medida recomendaría para el grupo con peor calidad del aire?

Un clustering solo sirve cuando **sabemos explicar** qué representa cada grupo.

6. Agrupamiento jerárquico

Motivación: la limitación de K-means

K-means tiene dos limitaciones importantes:

1. Requiere definir K **antes** de ejecutar
2. El resultado depende de la **inicialización aleatoria** (mínimo local, no global)

El **agrupamiento jerárquico aglomerativo** resuelve ambas: construye los grupos de forma progresiva, sin necesidad de especificar K a priori, y produce el mismo resultado en cada ejecución (sin aleatoriedad).

Analogía: carpetas y subcarpetas
Los archivos parecidos van juntos en una subcarpeta; las subcarpetas parecidas van juntas en una carpeta; y así hasta tener una sola carpeta con todo.

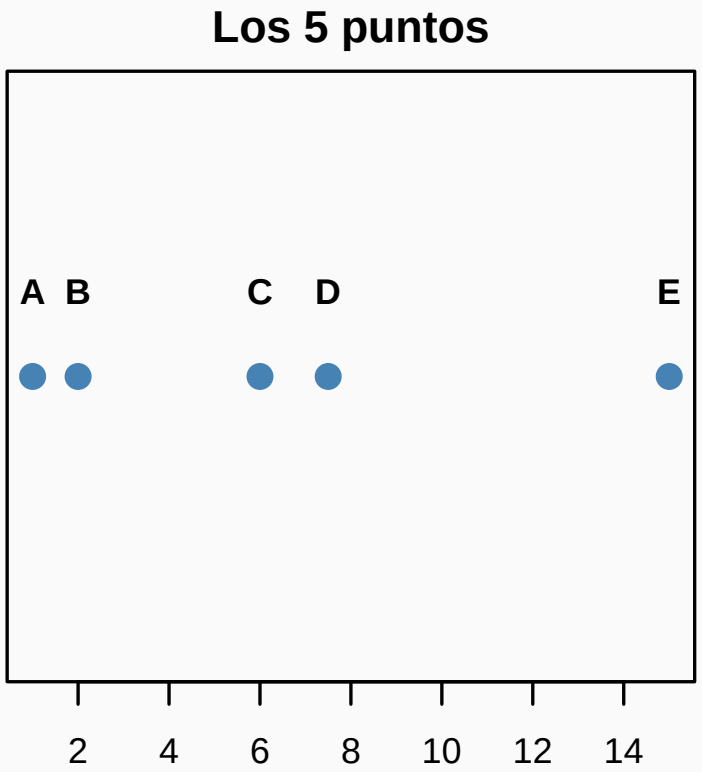
El algoritmo aglomerativo

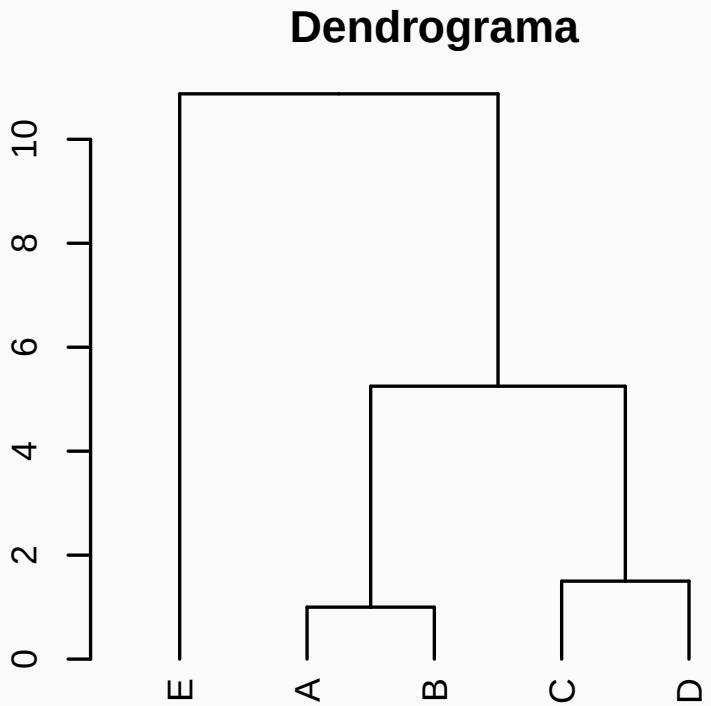
1. **Inicio**: cada observación es un grupo de tamaño 1
2. **Fusión**: unir los dos grupos **más cercanos**
3. **Repetir** hasta que quede un solo grupo ($n - 1$ fusiones)

El resultado es un **dendrograma**: el historial completo de fusiones.

La **altura** a la que se unen dos grupos indica la **distancia** entre ellos.

Un ejemplo pequeño: 5 puntos





Leyendo el ejemplo paso a paso

1. Se unen **A y B** (los más cercanos): altura 1.00
2. Se unen **C y D**: altura 1.50
3. Se unen **{A,B} y {C,D}**: altura 5.25
4. Se une **E**, el más alejado: altura 10.88

¿Cómo se mide la distancia entre {A,B} y {C,D}?
Aquí usamos el **promedio** de las 4 distancias entre un punto de cada grupo.

¿Cómo medir la distancia entre grupos?

La medida de distancia **entre dos clusters** (no entre dos puntos) define el criterio de enlace:

Enlace	**Distancia entre grupos**	**Característica**
Completo	Máx. entre pares de puntos	Clusters compactos
Promedio	Media entre todos los pares	Balance entre completo y simple
Simple	Mín. entre pares de puntos	Puede producir cadenas largas

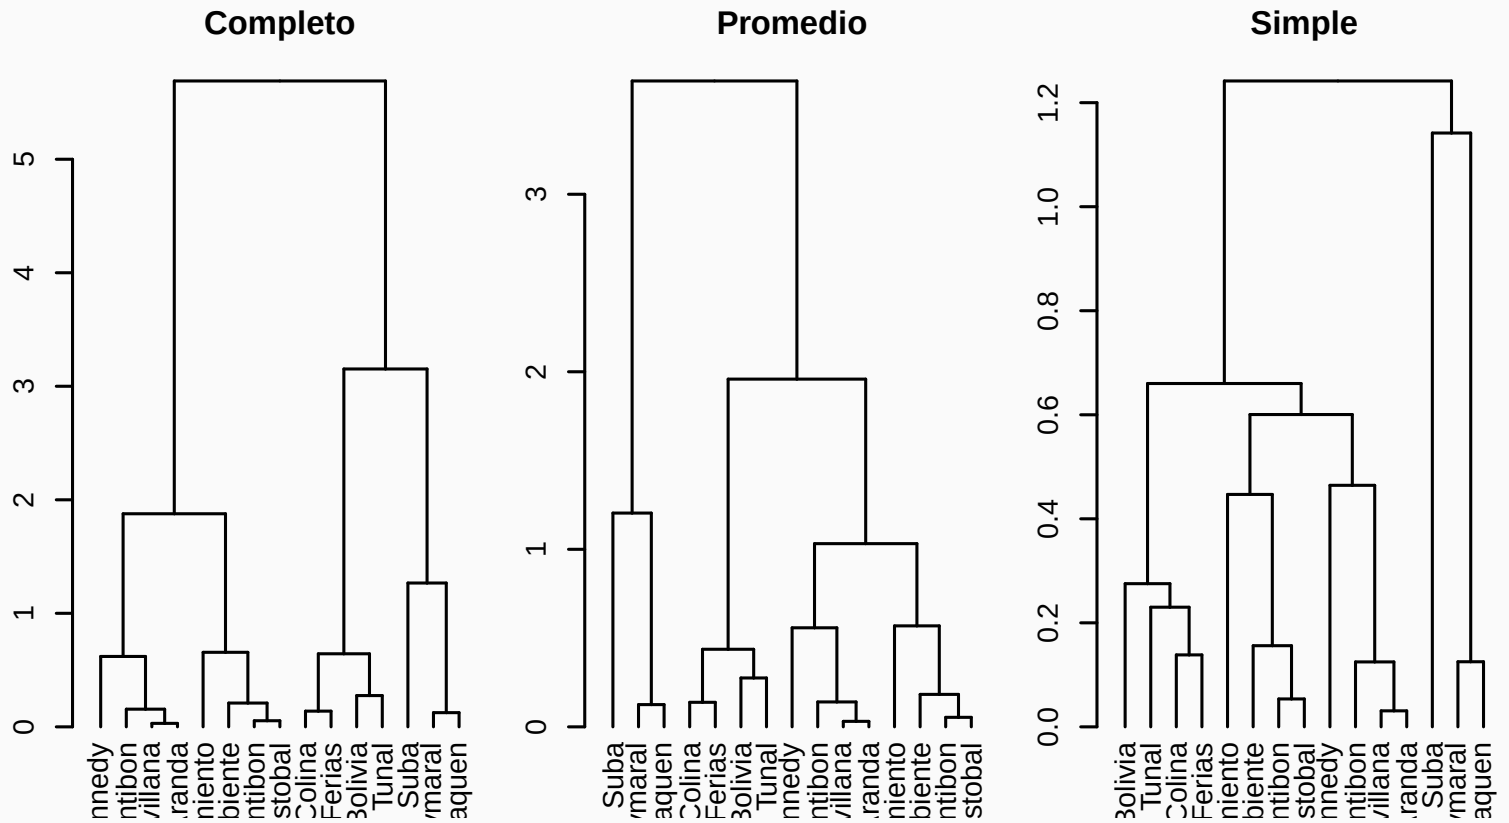
Recomendación

El enlace **promedio** suele ser el más robusto en la práctica. El enlace simple (también el completo) es sensible a observaciones atípicas y tiende a formar cadenas (“chaining effect”).

Dendrograma univariado: los tres criterios

```r
datos_jer_1d = data.frame(CP1=scores_aire$PC1)
rownames(datos_jer_1d) = scores_aire$Estacion

jer_comp = hclust(dist(datos_jer_1d), method="complete")
jer_prom = hclust(dist(datos_jer_1d), method="average")
jer_simp = hclust(dist(datos_jer_1d), method="single")
```



Mismo conjunto de estaciones, tres criterios de enlace: el árbol cambia de forma.

Leer el dendrograma: cómo cortar el árbol

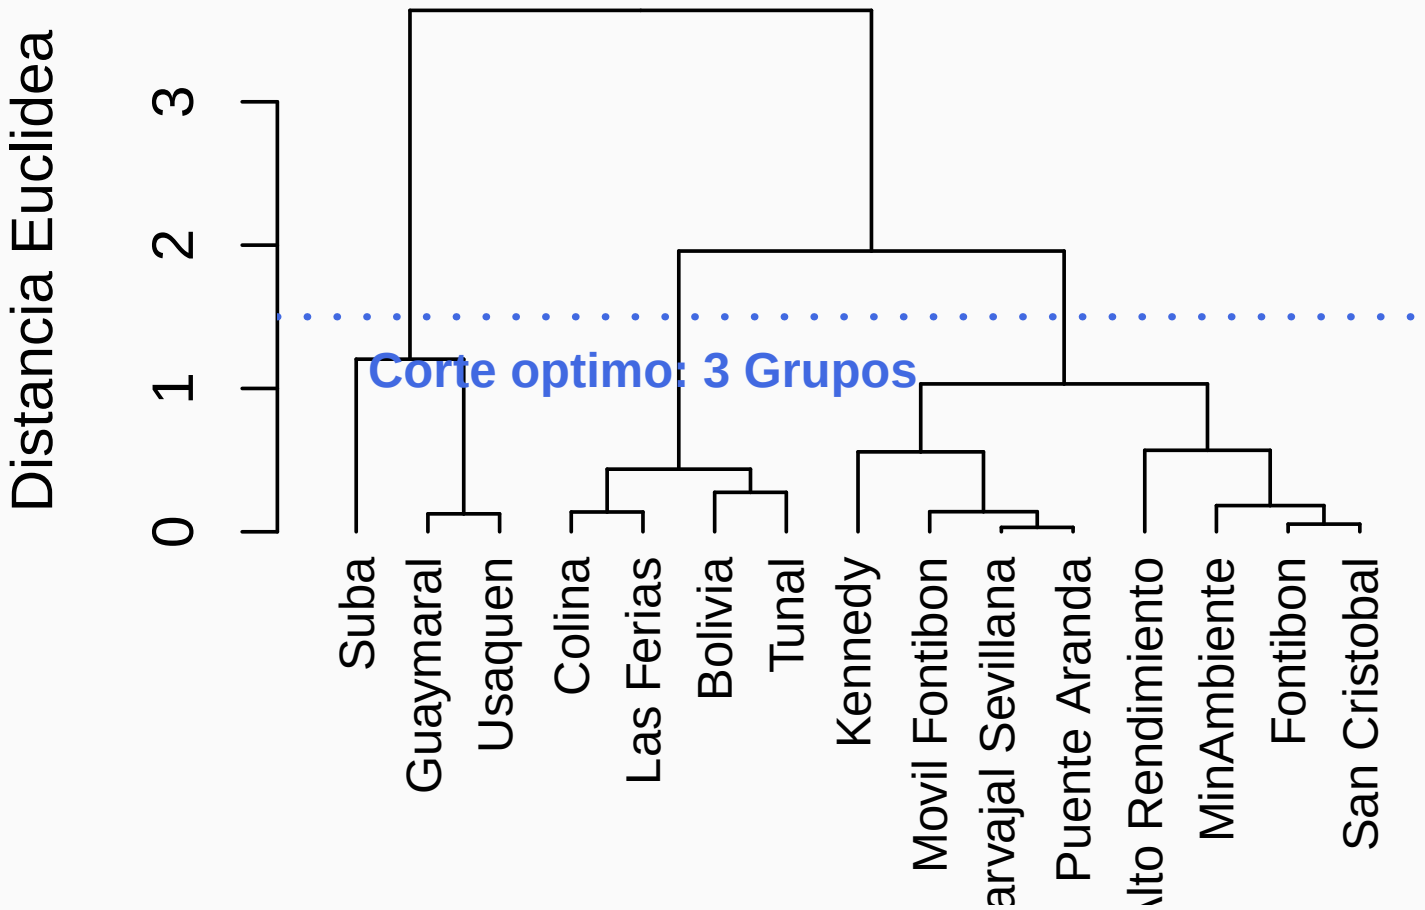
```r
# Ajustar margenes para que no se corte el texto
par(mar=c(5, 4, 4, 2))

plot(as.dendrogram(jer_prom),
     main="Dendrograma de Calidad del Aire - PC1",
     ylab="Distancia Euclidea",
     nodePar = list(lab.cex = 0.8, pch = NA))

# Linea de corte
abline(h=1.5, col="royalblue", lwd=2, lty=3)

# Texto
text(x=5, y=1.1, "Corte optimo: 3 Grupos", col="royalblue", font=2, cex=0.8)
```

Dendrograma de Calidad del Aire – PC1



El corte horizontal divide el árbol en ramas: cada rama es un grupo.

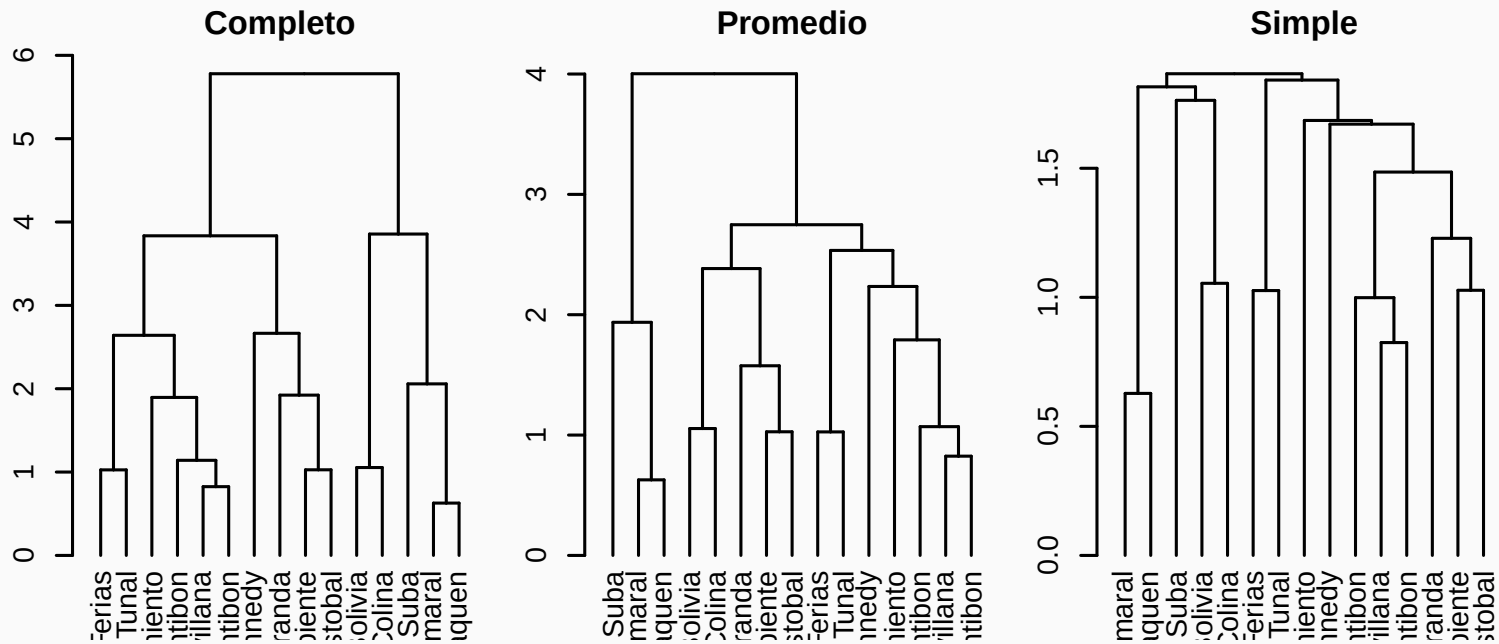
Cortar más alto da menos grupos; cortar más bajo da más grupos.

Agrupamiento jerárquico sobre la tabla completa

```
datos_jer_p = scale(datos_vars)
rownames(datos_jer_p) = datos_aire$Estaciones

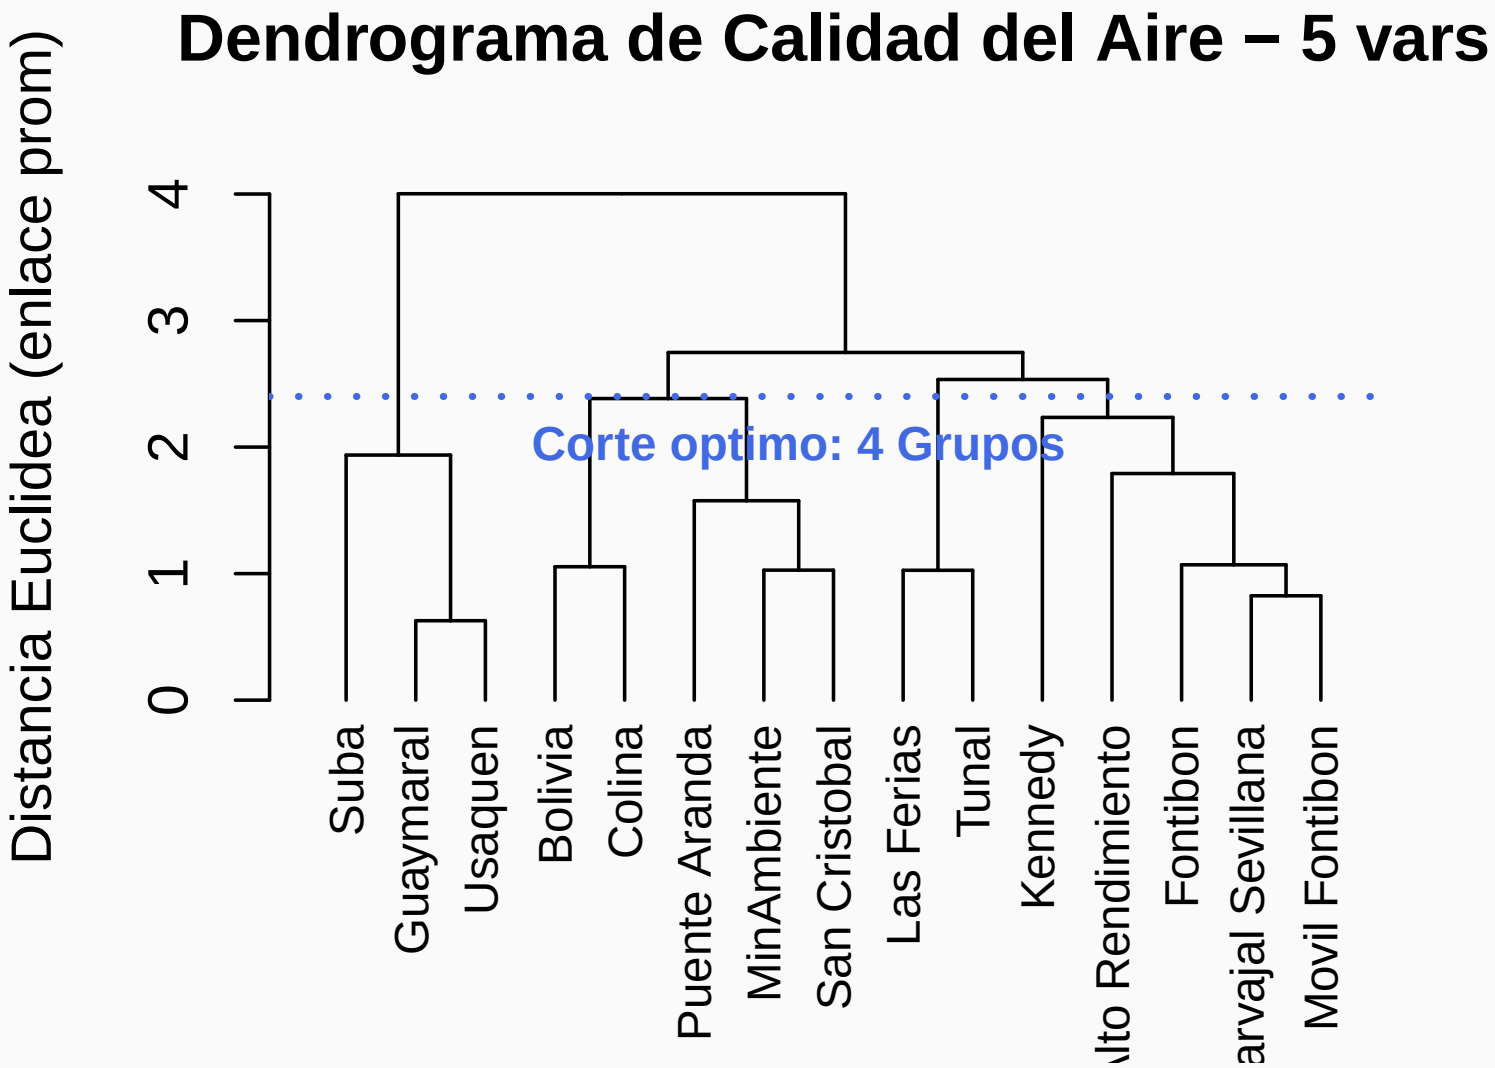
jer_comp_p = hclust(dist(datos_jer_p), method="complete")
jer_prom_p = hclust(dist(datos_jer_p), method="average")
jer_simp_p = hclust(dist(datos_jer_p), method="single")
```

```
par(mfrow=c(1,3), mar=c(2,2,2,1), cex=0.55)
plot(as.dendrogram(jer_comp_p), main="Completo")
plot(as.dendrogram(jer_prom_p), main="Promedio")
plot(as.dendrogram(jer_simp_p), main="Simple")
```



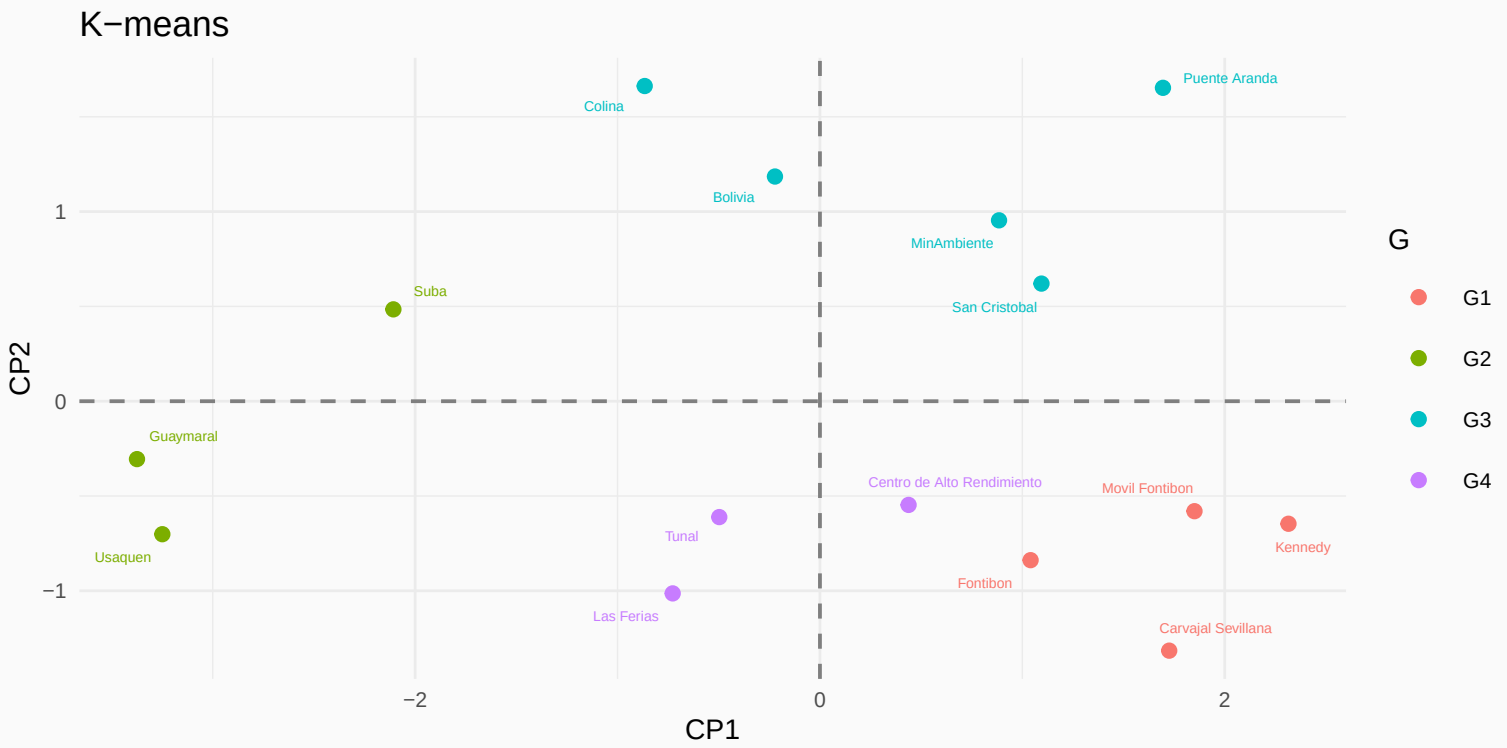

```
par(mfrow=c(1,1))
```

Corte del dendrograma en $K = 4$

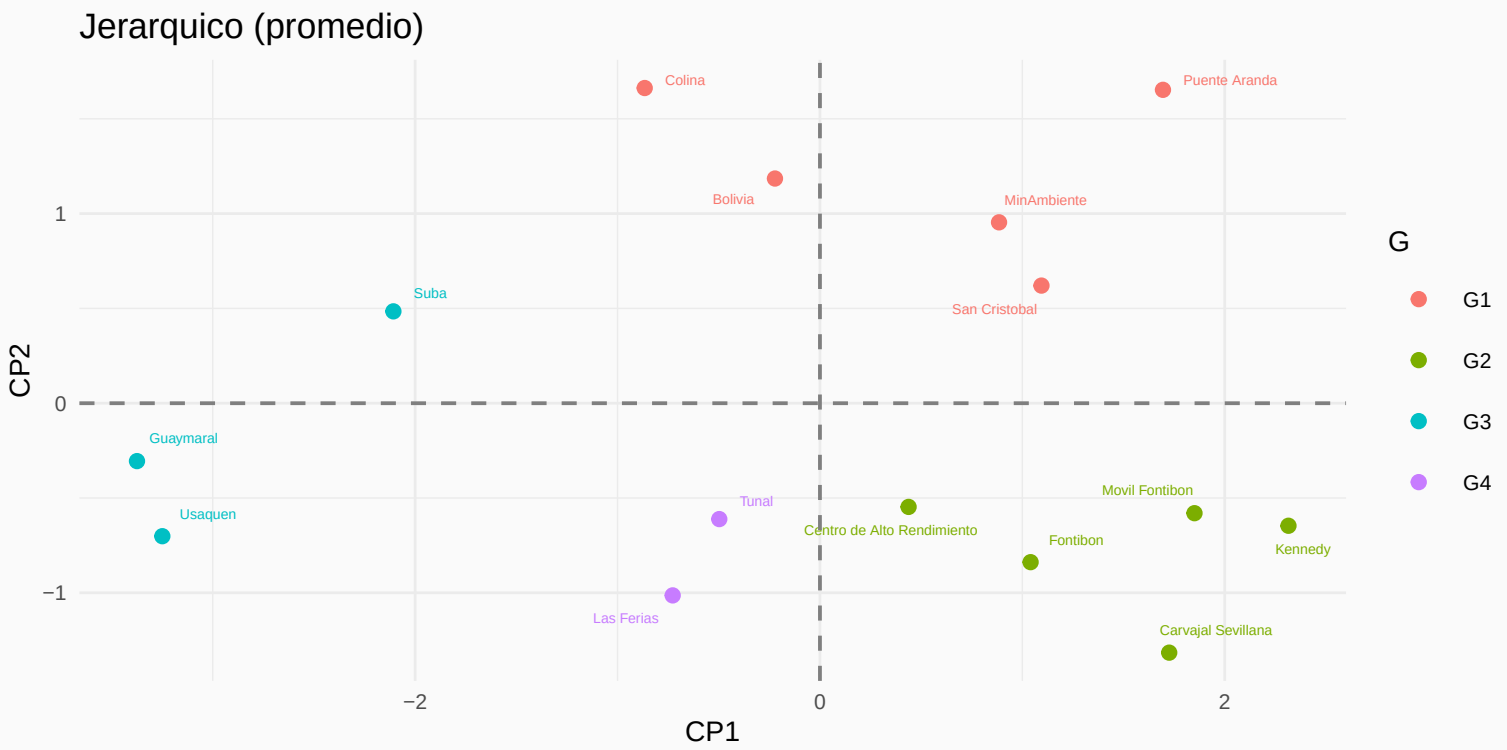


```r
grupos_jer = cutree(jer_prom_p, k=4)
resultados_jer = tibble(
  Estacion  = names(grupos_jer),
  Cluster_J = paste0("G", grupos_jer))
```

Comparación K-means vs. jerárquico



Comparación: agrupamiento jerárquico



¿Qué tan concordantes son los dos métodos?

```
tabla_conc = table(K_means = comp$Cluster_A,
                   Jerarquico = comp$Cluster_J)
print(tabla_conc)
```

```
##         Jerarquico
## K_means G1 G2 G3 G4
##      G1  0  4  0  0
##      G2  0  0  3  0
##      G3  5  0  0  0
##      G4  0  1  0  2
```

Los grupos son en general concordantes, con diferencias menores.

Las diferencias también informan
Revelan observaciones que están en la **frontera entre grupos**: la zona donde los dos métodos discrepan.

K-means vs. jerárquico: ¿cuál usar?

Situación	**K-means**	**Jerárquico**
Muchos datos	Más rápido	Más lento
K desconocido	Hay que probar	Se corta el árbol
Resultado repetible	Fijar semilla	Siempre igual
Explicar a terceros	Centros	Dendrograma

7. Agrupamientos duros vs. suaves: la visión completa

¿Por qué existen los métodos suaves?

Los métodos duros (K-means, jerárquico) asignan cada observación a **un solo grupo**. Pero en la práctica:

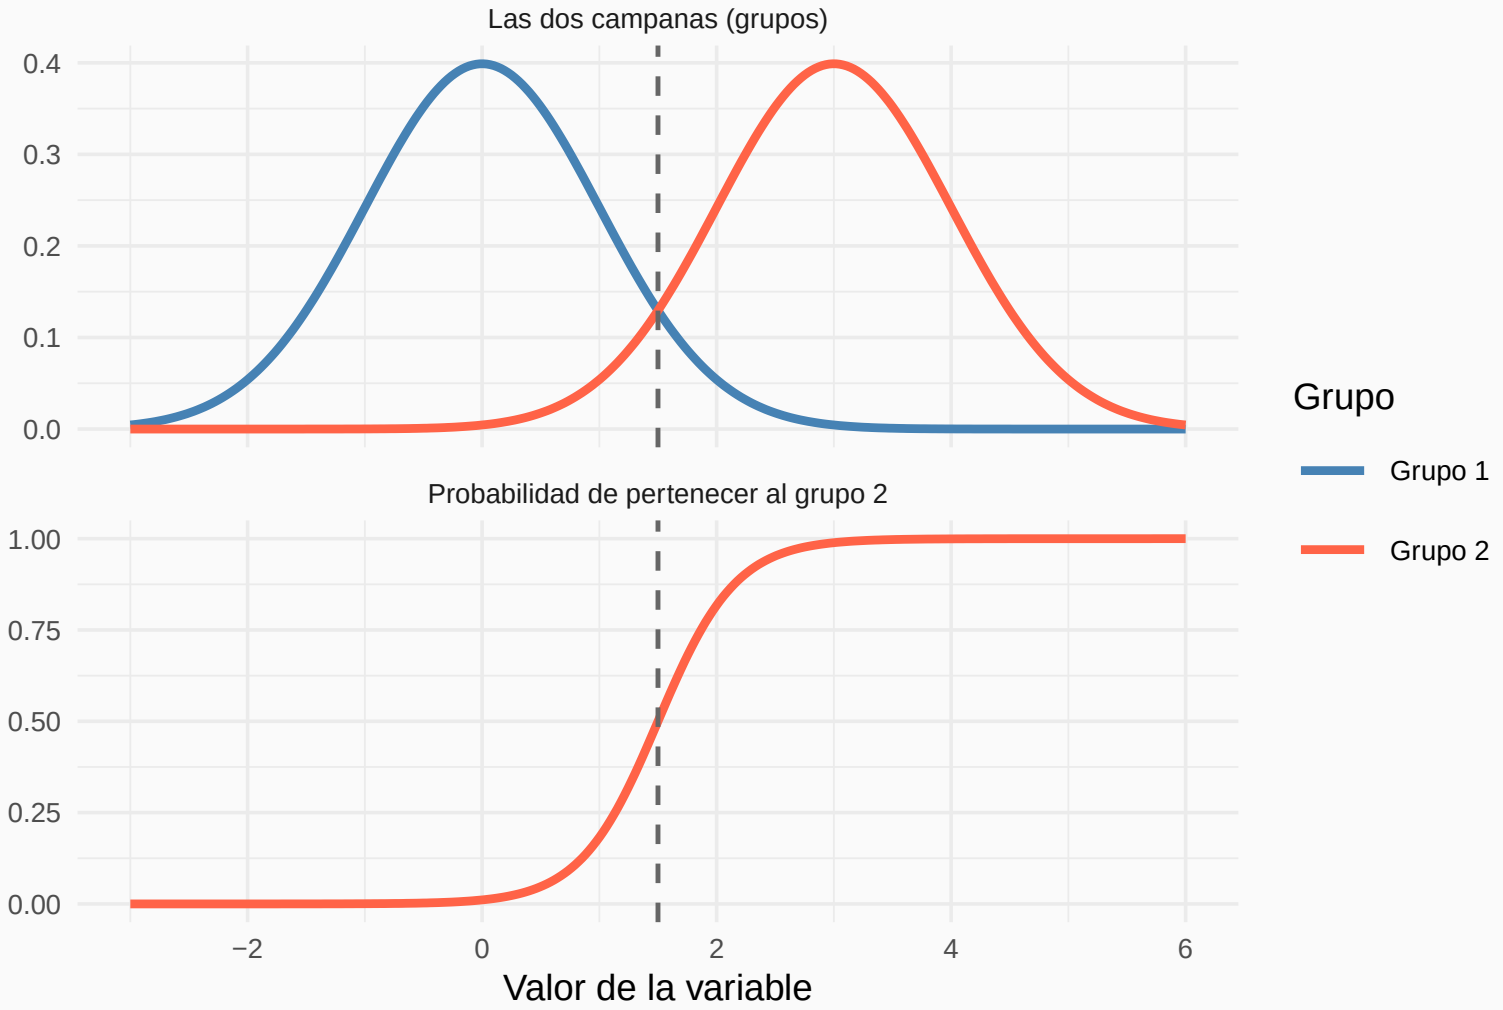
- Las estaciones en la **frontera** entre clusters podrían pertenecer razonablemente a más de uno
- Los grupos pueden **solaparse**: no hay una frontera nítida
- En algunos dominios, la **incertidumbre en la asignación** es información valiosa

Métodos suaves: probabilidades de pertenencia

Idea
En vez de una etiqueta, cada observación recibe un **porcentaje de pertenencia** a cada grupo. Por ejemplo: 70% grupo 2 y 30% grupo 3.

La notación formal está en el Anexo.

Simulación: pertenencia suave en una dimensión



Leyendo la simulación

- Un punto en $x = 0$: casi seguro del grupo 1 (99% grupo 1)
- Un punto en $x = 2$: 82% grupo 2, 18% grupo 1
- Un punto en la **frontera** ($x = 1.5$): 50% y 50%

Un método duro solo diría "grupo 1" o "grupo 2" y perdería esta información.

Métodos suaves: modelos de mezcla gaussiana (GMM)

El método suave más importante es el **Modelo de Mezcla Gaussiana** (GMM):

- Cada grupo es una **campana** (distribución normal multivariada)
- La población es una **mezcla de K campanas** superpuestas
- Para cada observación se calcula la probabilidad de pertenecer a cada campana

Conexión con la Sesión 3

El GMM es una extensión directa de la distribución normal multivariada: en lugar de **una** campana, son K campanas superpuestas. La distancia de Mahalanobis determina la probabilidad de pertenencia a cada grupo.

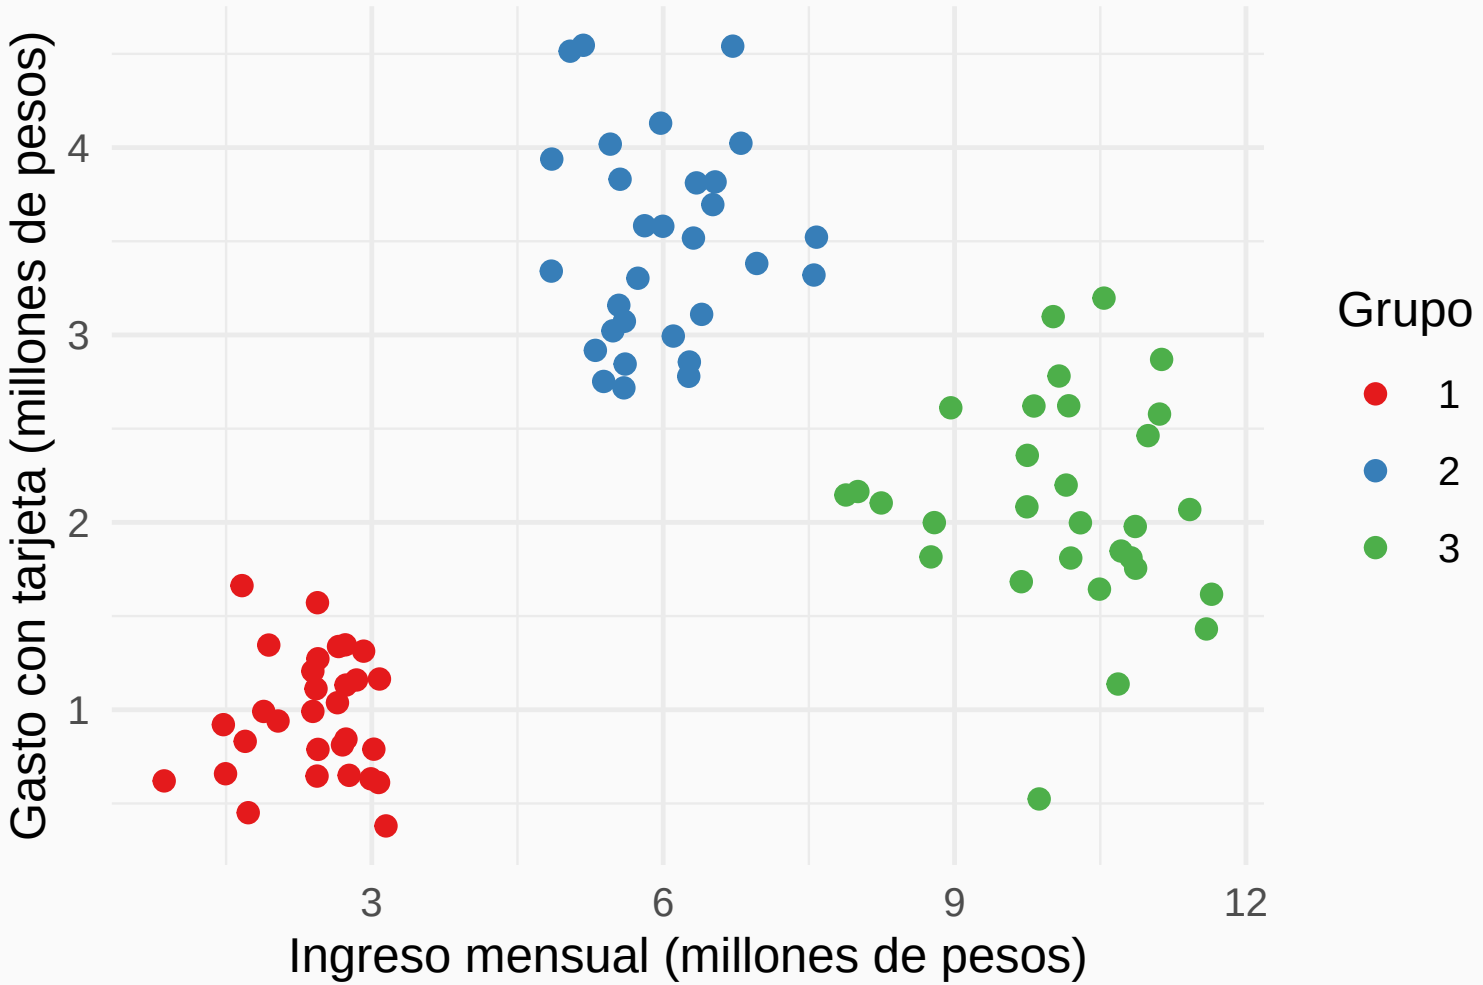
Comparación final: agrupamientos duros vs. suaves

Aspecto	**K-means**	**Jerárquico**	**GMM**
Tipo	Duro	Duro	Suave
K a priori	Sí	No	Sí
Aleatoriedad	Sí	No	Sí
Forma grupos	Esfera	Cualquiera	Elipsoide
Frontera	Rígida	Rígida	Probabilística
Costo comp.	Bajo	Medio-alto	Alto
Interpretable	Fácil	Fácil	Requiere probabilidades

En este curso trabajamos con K-means y jerárquico por su transparencia conceptual. Los GMM requieren métodos de estimación (algoritmo EM) que se estudian en cursos más avanzados.

8. Aplicaciones prácticas

Ejemplo aplicado: segmentación de clientes



K-means con $K = 3$ y `nstart=25` sobre los clientes simulados.

Del grupo a la decisión

Grupo	Ingreso	Gasto	Perfil	Estrategia
1	2.4	1.0	Ahorradores	Productos de ahorro
2	6.0	3.5	Consumidores activos	Programa de fidelidad
3	10.1	2.1	Ingreso alto	Productos premium

Ingreso y gasto: promedios en millones de pesos al mes. Cada grupo recibe una estrategia distinta: eso es segmentar.

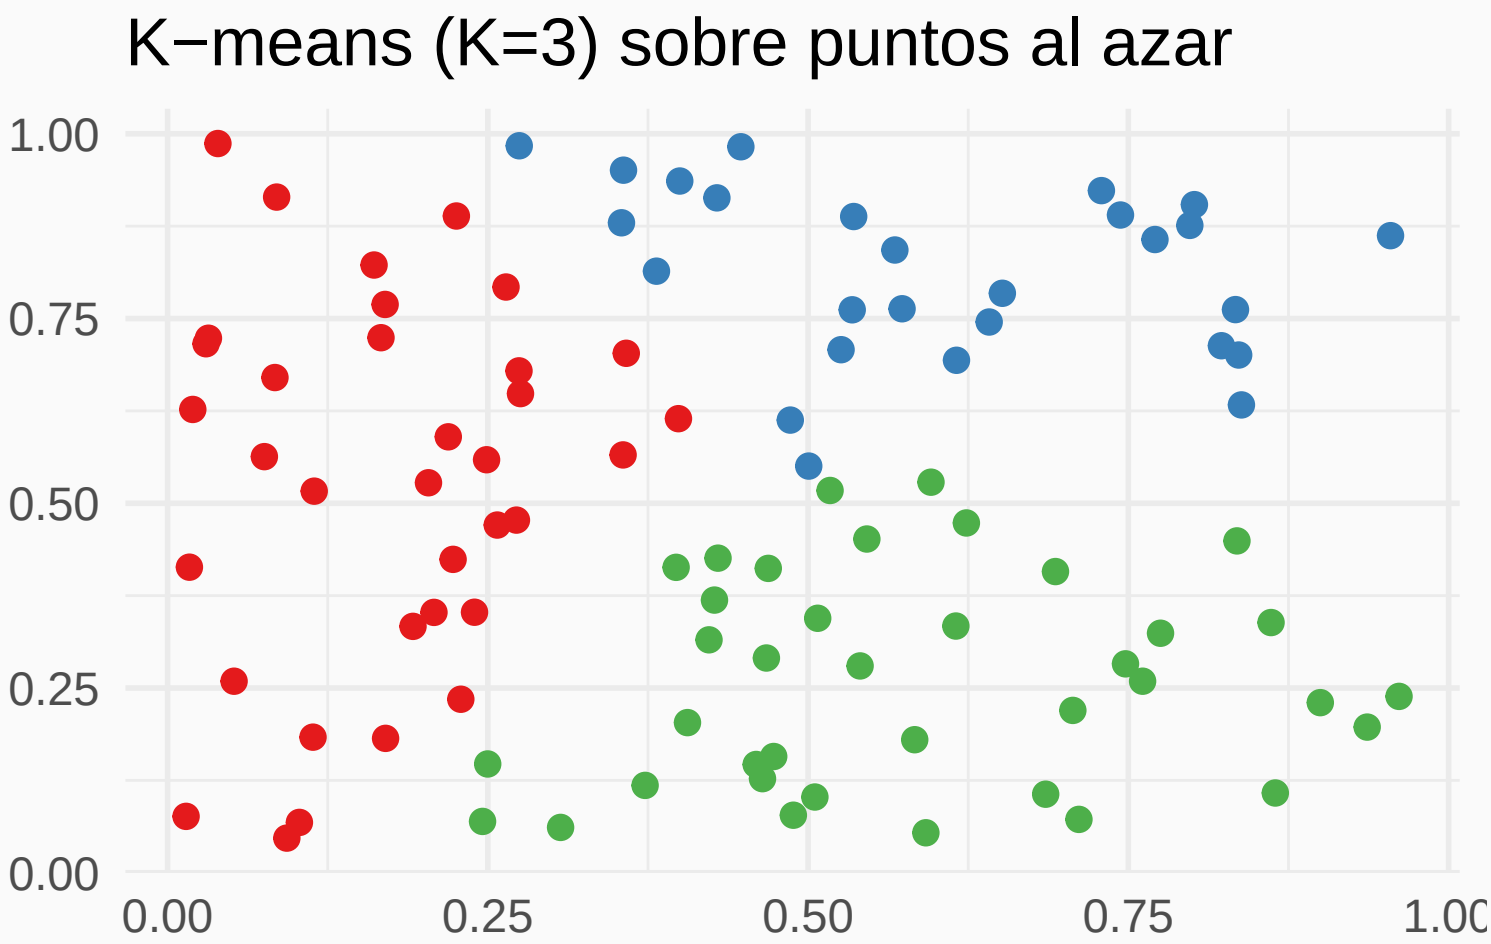
Aplicaciones en negocios y finanzas

Campo	¿Qué se agrupa?	¿Para qué sirve?
Marketing	Clientes por hábitos de compra	Campañas personalizadas
Banca y finanzas	Cuentas por comportamiento	Perfiles de riesgo y casos atípicos
Recursos humanos	Empleados por desempeño	Planes de retención y capacitación

Aplicaciones en sector público, salud y ambiente

Campo	¿Qué se agrupa?	¿Para qué sirve?
Salud pública	Municipios u hospitales por indicadores	Focalizar recursos
Política pública	Localidades por condiciones sociales	Priorizar inversión y subsidios
Educación	Estudiantes por desempeño y asistencia	Detectar quién necesita apoyo
Medio ambiente	Estaciones por perfil de contaminación	Decidir dónde actuar o medir

Cuidado: el algoritmo siempre devuelve grupos



Estos datos son ruido puro y K-means igual encontró “tres grupos”.

Buenas prácticas

- Un clustering **siempre** da una respuesta: hay que preguntarse si tiene sentido
- Los grupos dependen de las **variables**, la **escala** y el **valor de** K
- Validar con el **conocimiento del problema**: ¿podemos nombrar y explicar cada grupo?

9. Síntesis y puente

Receta práctica para hacer un clustering

1. **Estandarizar** las variables
2. **Elegir** K: codo + inspección visual (o cortar el dendrograma)
3. **Ejecutar** con `nstart` alto (K-means) y verificar la estabilidad
4. **Visualizar** los grupos en el plano factorial del ACP
5. **Interpretar**: perfil de cada grupo y validación con el conocimiento del problema

Conclusiones de la Sesión 5 (1/2)

- El clustering es **aprendizaje no supervisado**: no hay variable respuesta
- **Métodos duros**: asignación única por observación (K-means, jerárquico)
- **Métodos suaves**: probabilidades de pertenencia (GMM, fuzzy C-means)
- **K-means**: minimiza d^2 intra-cluster; rápido, sensible a la inicialización

Conclusiones de la Sesión 5 (2/2)

- **Jerárquico**: no requiere K a priori; el dendrograma permite distintos cortes
- El **codo en** d^2 y la **inspección visual del plano factorial** guían la selección de K
- Los resultados de clustering se visualizan mejor sobre el **primer plano factorial del ACP**
- El ACP y el clustering son **complementarios**, no sustitutos

El paso siguiente: regresión lineal (Sesión 6)

Las Sesiones 4 y 5 fueron **no supervisadas**: exploramos estructura sin una variable a predecir. La Sesión 6 introduce el cambio de paradigma:

De explorar a predecir
Regresión lineal: dado un conjunto de variables predictoras $X_1, X_2, \ldots, X_p$, modelamos y predecimos una variable respuesta cuantitativa Y:

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p + \varepsilon$$

Ahora sí hay una variable privilegiada (Y) y un objetivo claro de predicción.

Las diferencias fundamentales con lo que hemos visto

Concepto	**Sesiones 4–5**	**Sesión 6**
Objetivo	Descubrir estructura	Predecir / explicar Y
Variable resp.	No existe	Y cuantitativa
Evaluación	d^2, varianza	Error cuadrático medio
Supuesto clave	(ninguno fuerte)	Linealidad, normalidad de errores
Salida	Grupos / ejes	Ecuación de predicción $\hat{Y}$

Conexión con el ACP

En regresión con muchas variables correlacionadas, la **regresión en componentes principales** (PCR) usa los CPs como predictores, conectando directamente las Sesiones 4 y 6.

Conexión completa del arco del curso

Ses.	Herramienta	Supervisado	Variable Y
1–2	Estadística descriptiva	—	No
3	Normal multivariada	No	No
4	ACP	No	No
5	Clustering (K-means, jer.)	No	No
6	**Regresión lineal**	**Sí**	**Sí (Y cuant.)**

Bibliografía

Bibliografía

1. Hanif, M. et al. (2019). *Multivariate Techniques*. Cambridge Scholars Publishing.
2. Zelterman, D. (2015). *Applied Multivariate Statistics with R*. Springer.
3. Everitt, B. & Hothorn, T. (2011). *Applied Multivariate Analysis with R*. Springer.
4. James, G. et al. (2021). *An Introduction to Statistical Learning* (2a ed.). Springer.
5. RMCAB. Red de Monitoreo de Calidad del Aire de Bogotá. `http://201.245.192.252:81/`

Anexo

Correlación espacial de los clusters

Un resultado notable: los grupos obtenidos por clustering sobre datos de contaminación corresponden aproximadamente a **zonas geográficas** de Bogotá.

Resultado

Sin usar ninguna información de ubicación geográfica, los métodos de clustering recuperan una estructura espacial en los datos. Esto ocurre porque la contaminación del aire está correlacionada espacialmente: estaciones cercanas tienden a medir valores similares.

Esto ilustra el poder del clustering como herramienta exploratoria: puede revelar estructura latente en los datos que no fue medida directamente.

Anexo: la función objetivo de K-means

Para la partición $\{G_1, G_2, \ldots, G_K\}$ y una variable z:

$$d^2(\text{Agrupamiento}) = \sum_{k=1}^{K} \frac{1}{n_k} \sum_{i<j \in G_k} (z_i - z_j)^2 = \sum_{k=1}^{K} \sum_{i \in G_k} (z_i - \bar{z}_k)^2$$

- n_k: número de observaciones del grupo k; $\bar{z}_k$: su promedio (el centro)
- Las dos expresiones son equivalentes: la segunda es la suma de distancias **al cuadrado al centro**
- Con p variables, $(z_i - \bar{z}_k)^2$ se reemplaza por la distancia euclidiana al cuadrado entre $\mathbf{x}_i$ y el centro $\bar{\mathbf{x}}_k$

Anexo: modelo de mezcla gaussiana (formal)

$$f(\mathbf{x}) = \sum_{k=1}^{K} \pi_k \cdot \mathcal{N}_p(\mathbf{x} \mid \vec{\mu}_k, \Sigma_k)$$

- Cada componente k es una distribución normal $\mathcal{N}_p(\vec{\mu}_k, \Sigma_k)$
- π_k es la proporción del grupo k en la población
- Cada observación recibe un vector de pertenencia $\pi_i = (\pi_{i1}, \ldots, \pi_{iK})$ con $\sum_k \pi_{ik} = 1$
- Los parámetros se estiman con el algoritmo EM (cursos más avanzados)