

Análisis Estadístico de Datos

Sesiones 6 y 7: Regresión Lineal

Profesor: Nicolás López

2026-05-22

Puente desde las sesiones anteriores

El arco del curso hasta hoy

Sesion	Tema	Pregunta central	Tipo
1-2	E. descriptiva	¿Como describir variables?	Univariado
3	Normal multi.	¿Como modelar conjuntamente?	Multivariado
4	ACP	¿Como reducir dimensiones?	No supervisado
5	Clustering	¿Como detectar grupos?	No supervisado
6-7	Regresion lineal	¿Como predecir Y desde X ?	Supervisado

Cambio de paradigma

Las Sesiones 4 y 5 son **no supervisadas**: no hay variable respuesta. Las Sesiones 6 y 7 introducen el aprendizaje **supervisado**: tenemos una variable Y que queremos predecir o explicar a partir de variables X .

Aprendizaje supervisado vs. no supervisado

Característica	No supervisado	Supervisado
Variable respuesta Y	No existe	Si existe
Objetivo	Descubrir estructura	Predecir / explicar Y
Evaluacion	Subjetiva / interna	Objetiva (error de pred.)
Ejemplos	ACP, Clustering	Regresion, clasificacion
Etiquetas en datos	No se requieren	Necesarias para entrenar

1. Propósito de la regresión lineal

¿Qué es la regresión lineal?

Definición

La regresión lineal es una técnica de modelamiento estadístico que permite describir relaciones de tipo lineal entre una o varias variables independientes y una variable de respuesta. Al contar con n datos, asumimos que la respuesta del individuo i es una variable aleatoria Y_i cuya media μ_i depende de variables conocidas $x_{1,i}, \dots, x_{p,i}$.

Aclaración importante

La palabra “lineal” hace referencia a los **coeficientes**, no a las variables. El modelo $Y = \beta_0 + \beta_1 x^2 + \varepsilon$ es lineal en los parámetros aunque x aparezca al cuadrado.

Los cuatro usos del modelo de regresión

1. **Descripcion de datos:** cuantificar y resumir relaciones entre variables.
2. **Estimacion de parametros:** estimar efectos poblacionales con incertidumbre.
3. **Prediccion:** obtener valores esperados de Y para nuevas observaciones.
4. **Control:** determinar que valores de X llevan Y a un nivel deseado.

En estas sesiones

Estudiaremos los cuatro usos a traves de un ejemplo de rendimiento academico: ¿cuanto sube la nota de un estudiante por cada hora adicional de estudio?

Modelo determinístico vs. probabilístico

Si Y = nota del examen y x = horas de estudio:

Modelo determinístico:

$$y = \beta_0 + \beta_1 x$$

Pero dos estudiantes con las mismas horas de estudio no obtienen la *misma* nota. Necesitamos incorporar el error aleatorio:

Modelo probabilístico (Regresión Lineal Simple)

$$Y = \beta_0 + \beta_1 x + \varepsilon, \quad \varepsilon \sim (0, \sigma^2)$$

La respuesta esperada dado x :

$$E(Y \mid x) = \mu_{Y|x} = \beta_0 + \beta_1 x$$

La pendiente β_1 es el **cambio en la nota promedio** por cada hora adicional de estudio. Cuando σ^2 es grande, los datos se alejan de la recta.

Los supuestos del modelo

No.	Supuesto	Notacion
1	Relacion lineal entre Y y X	$E[Y X] = \beta_0 + \beta_1 X$
2	Normalidad del error	$\varepsilon \sim N(0, \sigma^2)$
3	Errores no autocorrelacionados	$\text{Cov}(\varepsilon_i, \varepsilon_j) = 0, i \neq j$
4	Homocedasticidad	$\text{Var}(\varepsilon_i) = \sigma^2$ (constante)

Cada supuesto sera verificado en la **etapa de validacion** mediante los residuales del modelo.

Las cuatro etapas del modelamiento estadístico

Etapa	Nombre	Descripcion
1	Identificacion	Herramientas graficas y numericas para detectar relaciones
2	Estimacion	Ajuste del modelo (minimos cuadrados ordinarios)
3	Validacion	Verificacion de supuestos con los residuales
4	Uso	Prediccion, inferencia, toma de decisiones

Flujo iterativo

El incumplimiento de **al menos un supuesto** en la etapa de validacion retorna al analista a la etapa de identificacion.

2. Los datos: rendimiento académico

Descripción del conjunto de datos

Datos simulados de $n = 60$ estudiantes que presentaron un examen. Para cada estudiante se midieron cuatro variables:

Variable	Descripcion	Rango
nota	Nota final en el examen	0.0 a 5.0
horas	Horas de estudio	0 a 12
sueno	Horas de sueno la noche anterior	3 a 10
capacidad	Conocimiento previo (pre-test)	0 a 10

Pregunta de la sesion

¿Podemos predecir la nota de un estudiante a partir de las horas que dedico a estudiar? ¿Cuanto sube la nota por cada hora adicional?


Generación de los datos

```
set.seed(42); n <- 60
capacidad <- round(pmin(10, pmax(0, rnorm(n, 5.5, 1.8))), 1)
horas <- round(pmax(0, pmin(12,
  2.5 + 0.55 * capacidad + rnorm(n, 0, 1.6))), 1)
sueno <- round(pmax(3, pmin(10,
  9.2 - 0.28 * horas + rnorm(n, 0, 0.9))), 1)
nota <- round(pmin(5.0, pmax(0.0,
  0.25 + 0.28 * horas + 0.38 * capacidad +
  0.07 * sueno + rnorm(n, 0, 0.38))), 1)
datos <- data.frame(nota, horas, sueno, capacidad)
head(datos, 5)
```

```
##   nota horas sueno capacidad
## 1  5.0   6.3   6.1         8.0
## 2  3.7   5.3   6.4         4.5
## 3  5.0   6.8   7.4         6.2
## 4  5.0   8.4   6.0         6.6
## 5  4.4   4.7   7.9         6.2
```


Exploración inicial

```
ggpairs(datos, progress = FALSE)
```




Variables de interés: horas de estudio y nota

```
ggpairs(datos %>% dplyr::select(horas, nota), progress = FALSE)
```



Etapla 1: Identificación

```
ggplot(datos, aes(x = horas, y = nota)) +  
  geom_point(alpha = 0.6, color = "steelblue", size = 1.8) +  
  labs(x = "Horas de estudio",  
       y = "Nota final (0-5)",  
       title = "Nota vs. horas de estudio") +  
  theme_minimal(base_size = 9)
```



La grafica confirma una **relacion lineal positiva**: a mas horas de estudio, mayor nota promedio.

Ejercicio 1 – Discusion en clase

- ¿La relacion parece estrictamente lineal o hay curvatura?
- ¿Todos los estudiantes con las mismas horas obtienen la misma nota?
¿Que otras variables podrian estar involucradas?
- ¿Estudiar mas horas *causa* mejor nota, o podria haber otros factores que expliquen ambas?

La limitación de la linealidad

Al usar regresión lineal imponemos una restricción importante:

Restricción del modelo lineal

Asumimos que la relación entre X e Y sigue una **recta**. Es decir, que **cada hora adicional de estudio produce el mismo aumento en la nota**, sin importar si se pasa de 1 a 2 horas o de 9 a 10. Esto puede no ocurrir en la realidad.

Ejemplo: el efecto de las primeras horas de estudio puede ser mayor que el de las últimas (rendimiento marginal decreciente). Si forzamos una recta sobre una relación curva, los residuales tendrán un **patrón sistemático** que delatará el problema.


¿Cómo detectarlo?

El gráfico de Residuales vs. Valores Ajustados en la etapa de validación. Si la relación real es curva, los residuales no serán ruido aleatorio.

3. Estimación por Mínimos Cuadrados (MCO)

Tres modelos candidatos

Para encontrar la recta que mejor ajusta los datos, necesitamos una medida de calidad. Consideremos tres candidatos:



La variabilidad alrededor de cada recta es distinta. ¿Como formalizarlo?

La suma de cuadrados como medida de calidad

Para cada modelo M_j :

$$SC(M_j) = \sum_i (y_i - \hat{y}_{i,M_j})^2$$


Es evidente que: $SC(M1) < SC(M2) < SC(M3)$

El modelo promedio (M2) como linea base

$M2$ no usa informacion de X : predice $\bar{Y}$ para todos. Representa el modelo mas simple posible: el **baseline**. Su SC equivale a la **variabilidad total** de Y : $SC(M2) = SC_T$.

La estimacion MCO consiste en encontrar (β_0, β_1) que minimicen $SC_E(\beta_0, \beta_1)$.

M1 vs. M2: la clave de R^2



Las líneas verticales son los **residuales**. Al pasar de M2 a M1 estos disminuyen: las horas de estudio explican parte de la variación en notas.

Descomposicion $SCT = SCM + SCE$

$$\underbrace{\sum_i (y_i - \bar{y})^2}_{SC_T} = \underbrace{\sum_i (\hat{y}_i - \bar{y})^2}_{SC_M} + \underbrace{\sum_i (y_i - \hat{y}_i)^2}_{SC_E}$$

- SC_T : variabilidad **total** de las notas respecto a su media (M2).
- SC_E : variabilidad **residual** que queda despues de ajustar M1.
- $SC_M = SC_T - SC_E$: variabilidad **explicada** por las horas de estudio.

MCO maximiza SC_M porque minimiza SC_E . Y maximizar SC_M es lo mismo que maximizar R^2 .

El coeficiente de determinación R^2

Definición de R^2

$$R^2 = \frac{SC_M}{SC_T} = 1 - \frac{SC_E}{SC_T} \in [0, 1]$$

R^2 es la **proporcion de la varianza en las notas** explicada por las horas de estudio.

- $R^2 \approx 1$: el modelo explica casi toda la variabilidad de las notas.
- $R^2 \approx 0$: el modelo no aporta sobre el simple promedio $\bar{Y}$.

```
cat("R^2:", round(summary(reg)$r.squared, 3))
```

```
## R^2: 0.604
```


Interpretacion

Las horas de estudio explican el **60.4%** de la variabilidad en las notas de los estudiantes.

Geometría de la optimización: la superficie de SCE

Para cada par (β_0, β_1) obtenemos un valor de SC_E . MCO minimiza esta superficie:

Superficie SCE(B0, B1)



La superficie tiene forma de **cuenco**: existe un mínimo global único en

Derivando $SC_E(\beta_0, \beta_1)$ e igualando a cero:

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{\sum_i y_i (x_i - \bar{x})}{\sum_i (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Conexion con la correlacion

$$\hat{\beta}_1 = r_{xy} \cdot \frac{s_y}{s_x}$$

Si $r_{xy} = 0$, entonces $\hat{\beta}_1 = 0$: las horas de estudio no aportan informacion sobre la nota y el mejor predictor es $\bar{Y}$ (M2).

La derivacion paso a paso se presenta en el **Anexo A**.

4. Bondad de ajuste e inferencia

R^2 ajustado: el problema del R^2 simple

Problema del R^2 simple

R^2 nunca decrece al agregar variables, aunque sean irrelevantes:

- Si la variable z no tiene efecto, MCO lleva $\beta_2 \rightarrow 0$.
- SC_M no disminuye: R^2 se mantiene igual o mejora artificialmente.

R^2 ajustado

$$R^2_{\text{adj}} = 1 - (1 - R^2) \frac{n - 1}{n - p - 1}$$

Penaliza la inclusion de variables adicionales. Es la metrica correcta para **comparar modelos** con distinto numero de predictores.

¿Por qué F si ya tenemos R^2 ?

R^2 mide *cuanto* explica el modelo, pero **no dice si esa cantidad es estadísticamente distinguible del azar.**

El problema de R^2 solo

Con n datos y p predictores, variables **completamente aleatorias** producen un $R^2 > 0$. ¿Como sabemos si el R^2 observado es grande **en relacion a lo esperado por azar?**

Mismo R^2 , conclusiones opuestas

$R^2 = 0.15$ con $n = 1000 \rightarrow F$ grande, modelo util.

$R^2 = 0.15$ con $n = 20 \rightarrow F$ pequeno, indistinguible del azar.

F incorpora el tamaño muestral; R^2 solo, no.

Hipotesis de la prueba F

$H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0$ (el modelo no aporta sobre M2)

$H_a : \text{al menos un } \beta_i \neq 0$


Estadístico F

$$F = \frac{SC_M/p}{SC_E/(n-p-1)} = \frac{SC_M/gl_M}{SC_E/gl_E}$$

F es la razón entre la **varianza explicada por variable** y la **varianza residual por grado de libertad**. Un F grande indica que el modelo explica mucho *en relacion* al ruido residual.

Simulación: ¿qué ocurre cuando no hay relación real?

Si las horas no predijesen la nota ($\beta_1 = 0$), los datos podrían verse así:




Cada panel son datos **completamente aleatorios**: horas y notas son independientes. Sin embargo, todos muestran $R^2 > 0$ y rectas con pendiente.

Lectura clave

El R^2 siempre es positivo incluso cuando no hay relacion. Bajo la hipotesis nula, esperamos valores F pequenos. Un F grande es evidencia de que la relacion es **real y no producto del azar**.

Distribución de F bajo H0: 10 000 simulaciones



El F observado (línea roja) es **muy atípico** bajo la hipótesis nula: la probabilidad de obtener un F tan grande por azar es menor a 0.001.

Distribución F simulada vs. teórica

La distribución simulada (azul) coincide perfectamente con la distribución $F_{1, n-2}$ teórica (naranja). El p-valor es la probabilidad de obtener un F tan grande o mayor bajo H_0 .

Prueba t individual vs. prueba F global

En regresion simple ambas son equivalentes ($F = t^2$). En regresion multiple tienen roles distintos:

Prueba	Hipotesis	Pregunta
t individual	$H_0 : \beta_j = 0$	¿Aporta X_j dado el resto?
F global	$H_0 : \beta_1 = \dots = \beta_p = 0$	¿Aporta el modelo completo?

Correlación no implica causalidad

Antes de continuar con la estimación, una advertencia fundamental:

El modelo describe asociaciones, no causas

Cuando ajustamos $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$, cuantificamos **como se mueve Y en promedio cuando X cambia en los datos**. Esto **no** implica que X cause Y .

Ejemplos clásicos:

- Las ventas de helado están correlacionadas con los ahogamientos (ambas suben en verano: el calor es la causa común, no los helados).
- El número de libros en una casa predice el rendimiento escolar, pero no por leer los libros sino porque refleja el nivel educativo del hogar (la causa real).
- En nuestros datos: ¿estudiar más *causa* mejores notas, o los estudiantes motivados hacen ambas cosas?

El modelo es correlacional, no causal

Lo que hace nuestro modelo

Describe **patrones en los datos**: en promedio, los estudiantes con mas horas de estudio obtienen mejor nota. Esto es util para predecir y describir, pero **no dice si obligar a un estudiante a estudiar mas lo hara subir la nota**.

La pregunta correcta al usar regresion

No: “¿Aumentar las horas de estudio *causara* mejor nota?”


Si: “¿Cuanto difiere la nota promedio entre estudiantes que estudiaron distinto numero de horas, en estos datos?”

En la Sesion 7 elaboraremos sobre variables de confusion, causalidad y como ir mas alla de las correlaciones.

5. Estimación en R

Ajustando el modelo: `lm()`

```
ggplot(datos, aes(x = horas, y = nota)) +  
  geom_point(alpha = 0.6, color = "steelblue", size = 1.5) +  
  geom_smooth(method = lm, se = FALSE, color = "red",  
              linewidth = 1) +  
  labs(x = "Horas de estudio", y = "Nota (0-5)") +  
  theme_minimal(base_size = 9)
```



```
reg <- lm(nota ~ horas, data = datos)  
summary(reg)
```


Leyendo el output: coeficientes

```
round(coef(summary(reg)), 4)
```

##	Estimate	Std. Error	t value	Pr(> t)
## (Intercept)	2.0413	0.2416	8.4494	0
## horas	0.3827	0.0407	9.4006	0

Interpretacion

- **Intercepto** $\hat{\beta}_0$: nota esperada de un estudiante con **cero** horas de estudio. Puede carecer de sentido si estudiar cero horas esta fuera del rango observable.
- **horas** $\hat{\beta}_1$: por cada hora adicional de estudio, la nota promedio **sube en** $\hat{\beta}_1$ **puntos**. El signo positivo confirma la relacion directa.

Leyendo el output: pruebas de hipótesis

```
round(coef(summary(reg))[, c("t value", "Pr(>|t|)"), 4)
```

```
##           t value Pr(>|t|)
## (Intercept)  8.4494      0
## horas       9.4006      0
```

- **Intercepto:** p-valor puede ser mayor a 0.05 dependiendo de los datos. Si es así, el intercepto no es estadísticamente distinto de cero.
- **horas:** $p\text{-valor} < 0.05 \Rightarrow$ se rechaza $H_0 : \beta_1 = 0$. Las horas de estudio **si** predicen significativamente la nota.

Leerendo el output: bondad de ajuste

```
s_reg <- summary(reg)
cat("R^2:           ", round(s_reg$r.squared, 4), "\n")

## R^2:           0.6037
cat("R^2 ajustado:  ", round(s_reg$adj.r.squared, 4), "\n")

## R^2 ajustado:  0.5969
cat("Error estandar:", round(s_reg$sigma, 4), "\n")

## Error estandar: 0.5856
cat("Estadistico F: ", round(s_reg$fstatistic[1], 4), "\n")

## Estadistico F:  88.3708
```

Error estandar residual

$$\hat{\sigma} = \sqrt{\frac{SC_E}{n - p - 1}}$$

Mide el tamaño típico del error de predicción, en las mismas unidades que Y (puntos de nota). Un $\hat{\sigma}$ de 0.5 significa que nuestras predicciones se equivocan en promedio en 0.5 puntos.

El ANOVA del modelo

```
anova(reg)
```

```
## Analysis of Variance Table
```

```
##
```

```
## Response: nota
```

```
##           Df Sum Sq Mean Sq F value    Pr(>F)
```

```
## horas      1 30.302 30.3019  88.371 2.914e-13 ***
```

```
## Residuals 58 19.888  0.3429
```

```
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Fuente	GL	SC	CM
Regresion (M)	p	SC_M	SC_M/p
Error (E)	$n - p - 1$	SC_E	$SC_E/(n - p - 1)$
Total	$n - 1$	SC_T	—

$F = CM_M/CM_E$. Con p-valor < 0.05 , las horas de estudio explican significativamente la variabilidad en las notas.

Intervalos de confianza para los coeficientes

```
confint(reg, level = 0.95)
```

```
##                2.5 %    97.5 %  
## (Intercept) 1.5577050 2.5248947  
## horas      0.3011929 0.4641649
```

IC vs. prueba de hipotesis

Si el IC para β_j no incluye 0 $\Leftrightarrow$ la prueba t rechaza H_0 al nivel $\alpha = 0.05$.

Los IC aportan **mas informacion**: indican el rango plausible del efecto, no solo si es significativo. Por ejemplo, el IC para $\hat{\beta}_1$ dice: “con 95% de confianza, cada hora adicional de estudio sube la nota entre $[a, b]$ puntos.”


6. Validación de supuestos

Etapa 3: Los residuales como herramienta de diagnóstico

$$e_i = y_i - \hat{y}_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 \cdot \text{horas}_i)$$

Si el modelo es correcto, los e_i se comportan como **ruido aleatorio**.
Cualquier patron sistematico es evidencia de violacion de supuestos.

```
par(mfrow = c(2, 2), mar = c(3.5, 3.5, 2, 1))
plot(reg)
```



```
par(mfrow = c(1, 1))
```


Interpretando: Residuales vs. Valores Ajustados

Este grafico evalua **linealidad** y **homocedasticidad**:

Lo que buscamos	Lo que indica un problema
Nube sin patron	Tendencia curvilinea → falta de linealidad
Dispersion homogenea	Patron de abanico → heterocedasticidad
Linea horizontal en cero	Estructura residual → variable omitida

En nuestros datos

¿El grafico muestra patron aleatorio o hay alguna tendencia?

Una curvatura sugeriria que el efecto de las horas no es constante (rendimiento marginal decreciente).

QQ-plot: concepto y ejemplo numérico



El grafico Q-Q compara cuantiles **observados** de los residuales con cuantiles **teóricos** de una $N(0, 1)$.

La logica en 5 pasos (ejemplo con $n = 5$)

1. Ordenar los residuales: $e_{(1)} < e_{(2)} < \dots < e_{(n)}$.
2. Calcular cuantiles teoricos: $q_i = \Phi^{-1}(i/(n+1))$.
3. Formar pares: $(q_i, e_{(i)})$.
4. Graficar. Si los puntos siguen la diagonal $\rightarrow$ normalidad.

i	$e_{(i)}$ obs.	$q_i = \Phi^{-1}(i/6)$	¿En la diag.?
1	-1.5	-0.97	Aprox.
2	-0.4	-0.43	Si
3	0.1	0.00	Si
4	0.6	0.43	Si
5	1.2	0.97	Aprox.

QQ-plot: residuales normales vs. con sesgo



Izquierda: puntos cerca de la diagonal $\rightarrow$ normalidad razonable. \

Derecha: puntos se curvan en la cola derecha $\rightarrow$ distribución con cola pesada (sesgo positivo).



Leverage y Cook: conceptos básicos

Concepto	¿Que mide?	Umbral tipico
Leverage h_{ii}	Que tan atipico es el valor de X	$> 2(p + 1)/n$
Cook D_i	Cuanto cambia $\hat{\beta}$ si eliminamos i	$> 4/n$

Distincion clave

Una observacion puede tener **alto leverage** (su X esta muy alejada de $\bar{X}$) sin ser influyente si sigue la tendencia del resto. Una observacion es **influyente** (Cook alto) cuando tiene alto leverage **y** un residual grande: “jala” la recta hacia ella.

Leverage y Cook: ejemplo visual



- **A:** el punto rojo ($X = 12$) esta lejos de $\bar{X}$ pero *sigue* la tendencia. La recta no cambia al incluirlo. Cook **bajo**.
- **B:** el punto rojo ($X = 12$) esta lejos de $\bar{X}$ y *ademas* tiene Y muy distinto a lo esperado. La recta se distorsiona. Cook **alto**.

Checklist de supuestos

Supuesto	Herramienta	Si falla...
Linealidad	Res. vs. Fitted	Transformar X o Y
Homocedasticidad	Scale-Location	SE robustos / WLS
Normalidad	Q-Q / Shapiro-Wilk	Transformacion / no parametrico
Sin autocorr.	Durbin-Watson	Modelos de series de tiempo

Regla de oro

Un R^2 alto no garantiza un modelo valido. El diagnostico de supuestos es **obligatorio** antes de usar el modelo para inferencia o prediccion.

7. Uso del modelo

Etapla 4: Predicción puntual

```
# Estudiante que estudio 7 horas
nueva_obs <- data.frame(horas = 7)
predict(reg, newdata = nueva_obs)

##          1
## 4.720052
shapiro.test(residuals(reg))

##
##  Shapiro-Wilk normality test
##
## data:  residuals(reg)
## W = 0.97315, p-value = 0.2076
```

IC vs. IP: el código

```
nueva_obs <- data.frame(horas = 7)

# Intervalo de CONFIANZA: para la nota MEDIA de estudiantes con 7h
predict(reg, newdata = nueva_obs,
        interval = "confidence", level = 0.95)

##          fit          lwr          upr
## 1 4.720052 4.532328 4.907777


# Intervalo de PREDICCIÓN: para UN estudiante específico con 7h
predict(reg, newdata = nueva_obs,
        interval = "prediction", level = 0.95)

##          fit          lwr          upr
## 1 4.720052 3.532964 5.90714
```

Intervalo	Interpreta
Confianza	Nota promedio de todos los estudiantes con 7h
Predicción	Nota de un estudiante específico que estudio 7h

El IP es siempre mas amplio: incorpora incertidumbre sobre la media y variabilidad individual.

IC vs. IP: el gráfico



Casi todos los puntos caen dentro del **IP** (rojo). La banda **IC** (azul) es mas estrecha porque estima la media, no individuos.

SESIÓN 7

Puente desde la Sesión 6

En la Sesión 6 completamos el ciclo con **una sola variable predictora**:

1. Identificamos la relación lineal entre horas de estudio y nota.
2. Estimamos por MCO: motivamos R^2 a través del modelo promedio (M2).
3. Justificamos la prueba F y la validamos mediante simulación.
4. Diagnosticamos supuestos: residuales, QQ-plot, Cook y leverage.
5. Usamos el modelo para predecir con IC e IP.
6. Introdujimos la distinción entre correlación y causalidad.

Objetivo de la Sesión 7


Extender a **múltiples predictores**, desarrollar el concepto de variable de confusión, elaborar sobre causalidad, y dominar el diagnóstico del modelo múltiple.

8. Regresión Lineal Múltiple

Motivación: ¿por qué más de una variable?

¿La nota depende solo de las horas de estudio, o también de cuánto durmío el estudiante la noche anterior?

```
ggpairs(datos %>% dplyr::select(nota, horas, sueno),  
        progress = FALSE)
```



Las horas de sueno también muestran relación con la nota. Ignorarlas podría dejarnos con un modelo sub-óptimo.

El modelo de regresión múltiple

Modelo general con p predictores

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i$$

En notación matricial: $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$

El estimador MCO generalizado:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

siempre que $(\mathbf{X}^\top \mathbf{X})^{-1}$ exista, lo cual requiere que las columnas de $\mathbf{X}$ sean **linealmente independientes**.

Supuesto 5: No multicolinealidad

Ningun predictor X_j puede ser combinacion lineal exacta de los demas. Si esto ocurre, $(\mathbf{X}^\top \mathbf{X})$ es singular y el sistema no tiene solucion unica.

Multicolinealidad perfecta vs. aproximada

La multicolinealidad **perfecta** hace el modelo irresoluble. La **aproximada** (alta correlación entre predictores) no impide la estimación pero **infla las varianzas** de $\hat{\beta}$, haciendo los coeficientes inestables y la inferencia poco confiable.

En nuestro ejemplo

Las horas de sueño tenderían a estar negativamente correlacionadas con las horas de estudio (quien estudia más, duerme menos). Si la correlación es muy alta, los efectos de ambas variables se confunden entre sí.

Estimación del modelo múltiple en R

```
mod <- lm(nota ~ horas + sueno, data = datos)
summary(mod)

##
## Call:
## lm(formula = nota ~ horas + sueno, data = datos)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.2077 -0.3896  0.0478  0.5215  1.0122
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  2.116659   0.938544   2.255   0.028 *
## horas        0.380124   0.051287   7.412 6.55e-10 ***
## sueno       -0.008128   0.097752  -0.083   0.934
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5907 on 57 degrees of freedom
## Multiple R-squared:  0.6038, Adjusted R-squared:  0.5899
## F-statistic: 43.43 on 2 and 57 DF,  p-value: 3.473e-12
```

Comparando simple vs. múltiple

```
data.frame(  
  Modelo = c("Simple (horas)",  
             "Multiple (horas + sueño)"),  
  R2      = round(c(summary(reg)$r.squared,  
                   summary(mod)$r.squared), 4),  
  R2_adj  = round(c(summary(reg)$adj.r.squared,  
                   summary(mod)$adj.r.squared), 4),  
  sigma   = round(c(summary(reg)$sigma,  
                   summary(mod)$sigma), 4)  
)
```

```
##               Modelo      R2 R2_adj  sigma  
## 1           Simple (horas) 0.6037 0.5969 0.5856  
## 2 Multiple (horas + sueño) 0.6038 0.5899 0.5907
```

La similitud en los estadísticos confirman que las horas de sueño **no aporta información real** sobre la nota, mas alla de las horas de estudio.

Comparando simple vs. múltiple con capacidad

```
mod_cap <- lm(nota ~ horas + capacidad, data = datos)

data.frame(
  Modelo = c("Simple (horas)",
             "Multiple (horas + capacidad)"),
  coef_horas = round(c(coef(reg)["horas"],
                       coef(mod_cap)["horas"]), 4),
  R2_adj      = round(c(summary(reg)$adj.r.squared,
                       summary(mod_cap)$adj.r.squared), 4)
)

##               Modelo coef_horas R2_adj
## 1             Simple (horas)    0.3827 0.5969
## 2 Multiple (horas + capacidad)    0.1741 0.8850
```

Al controlar por capacidad, el coeficiente de horas **cambia**: la confusión queda resuelta. Ahora estimamos el efecto de las horas de estudio **entre estudiantes con igual capacidad previa**.

En regresion multiple cada coeficiente mide el efecto de su variable **manteniendo las demas constantes**:

```
round(coef(summary(mod_cap)), 4)
```

##	Estimate	Std. Error	t value	Pr(> t)
## (Intercept)	1.5632	0.1349	11.5852	0
## horas	0.1741	0.0277	6.2769	0
## capacidad	0.3033	0.0251	12.0984	0


- $\hat{\beta}_{\text{horas}}$: efecto de una hora adicional de estudio, **dado el mismo nivel de capacidad previa**.
- $\hat{\beta}_{\text{capacidad}}$: efecto de un punto mas de capacidad previa, **dado el mismo numero de horas de estudio**.

¿Esto ya es causal?

Controlar por mas variables **reduce** la confusion pero no la elimina completamente si hay variables no medidas. Mas sobre esto a continuacion.

Visualización en 3D: el plano de regresión

Plano de regresion multiple



MCO minimiza la suma de distancias cuadradas verticales entre los **puntos observados** y el **plano ajustado**.

9. Evaluación del modelo múltiple

Prueba F y ANOVA

```
s_mod <- summary(mod_cap)
f_val <- s_mod$fstatistic
p_f    <- pf(f_val[1], f_val[2], f_val[3], lower.tail = FALSE)
cat("F =", round(f_val[1], 3),
    "| g11 =", f_val[2], "| g12 =", f_val[3],
    "| p-valor =", format(p_f, digits = 3, scientific = TRUE))

## F = 228.118 | g11 = 2 | g12 = 57 | p-valor = 6.29e-28
anova(mod_cap)

## Analysis of Variance Table
##
## Response: nota
##          Df  Sum Sq Mean Sq F value    Pr(>F)
## horas      1 30.3019  30.3019   309.86 < 2.2e-16 ***
## capacidad  1 14.3138  14.3138   146.37 < 2.2e-16 ***
## Residuals 57  5.5741   0.0978
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Inferencia individual y predicción

```
round(coef(summary(mod_cap)), 4)

##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   1.5632      0.1349 11.5852      0
## horas         0.1741      0.0277  6.2769      0
## capacidad     0.3033      0.0251 12.0984      0
nueva_obs_mult <- data.frame(horas = 7, capacidad = 6)
predict(mod_cap, newdata = nueva_obs_mult,
        interval = "prediction", level = 0.95)


##          fit          lwr          upr
## 1 4.602061 3.967578 5.236544
```

El modelo multiple produce intervalos mas estrechos que el simple porque la capacidad previa reduce la incertidumbre residual.

10. Validación del modelo múltiple

Diagnóstico del modelo múltiple

```
par(mfrow = c(2, 2), mar = c(3.5, 3.5, 2, 1))  
plot(mod_cap)
```



```
par(mfrow = c(1, 1))
```

Ejercicio 3 – Validación del modelo múltiple

Analice los cuatro gráficos de diagnóstico:

1. Residuales vs. Ajustados: ¿hay patrón sistemático?
2. Q-Q: ¿se aproximan los residuales a la normalidad?
3. Scale-Location: ¿varianza constante?
4. Leverage: ¿hay observaciones influyentes?

¿Mejorar el ajuste (R^2 mayor) garantiza mejor cumplimiento de supuestos?

11. Multicolinealidad

¿Qué es y por qué importa?

Definición

Existe multicolinealidad cuando dos o mas predictores estan **altamente correlacionados** entre si.

Consecuencia	Descripcion
Inestabilidad	Cambios pequenos en datos → grandes cambios en coef.
SE inflados	IC muy amplios; p-valores se inflan
Difícil interp.	No se puede aislar el efecto individual de cada variable
Pred. estable	El modelo puede predecir bien aunque los coef. sean malos

Detección 1: correlaciones entre predictores

```
round(cor(datos %>% dplyr::select(horas, sueno, capacidad)), 3)
```

```
##           horas  sueno capacidad
## horas      1.000 -0.599    0.621
## sueno     -0.599  1.000   -0.391
## capacidad  0.621 -0.391    1.000
```

Limitacion de la correlacion por pares

La correlacion de Pearson solo detecta relaciones **entre pares**. La multicolinealidad puede existir entre combinaciones de tres o mas variables aunque las correlaciones por pares sean moderadas. El VIF es una medida mas completa.

Detección 2: Factor de Inflación de Varianza (VIF)

VIF para el predictor X_j

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$


donde R_j^2 es el R^2 de la regresión de X_j sobre los demás predictores.

```
library(car)
mod_full <- lm(nota ~ horas + sueno + capacidad, data = datos)
vif(mod_full)
```

```
##      horas      sueno capacidad
## 2.154885 1.561470 1.630055
```

VIF	Interpretacion
= 1	Sin multicolinealidad
1-5	Moderada (generalmente aceptable)
5-10	Alta (preocupante)
> 10	Severa: accion requerida

Visualizando el VIF y soluciones



Si los VIF fueran altos: (1) eliminar variables redundantes, (2) combinar via ACP (conecta con Sesión 4), (3) regularización Ridge/LASSO (AAD).

12. Correlación, causalidad y el modelo de regresión

El modelo es correlacional, no causal

Lo que hace la regresion

Cuantifica la asociacion **promedio** entre X e Y en los datos. Controlar por mas variables (modelo multiple) reduce la confusion pero **no garantiza** inferencia causal.

si un estudiante que *normalmente* estudia 3 horas **decide** estudiar 7, ¿cuanto mejorara su nota?

- La regresion nos dice: en los datos, los estudiantes con 7h obtienen en promedio X puntos mas que los de 3h. Pero esos grupos pueden diferir en muchas otras cosas (capacidad, motivacion, dificultad del curso. . .).

El problema

Comparamos estudiantes **distintos** (7h vs. 3h), no el **mismo** estudiante en dos escenarios. Para responder la pregunta causal, necesitaríamos algo mas que regresion.

Correlación no implica causalidad: ejemplos

Ejemplo 1: libros en casa

Los hogares con mas libros tienen hijos con mejor rendimiento escolar.

¿Los libros causan el rendimiento? No directamente: ambos son consecuencia del nivel educativo de los padres (variable confusora). Regalar libros a hogares de bajo nivel educativo no produce el mismo efecto.

Correlación no implica causalidad: ejemplos

Ejemplo 2: hospitales y mortalidad

Los hospitales con mejor equipamiento tienen mayor tasa de mortalidad.

¿Mejor equipamiento causa muerte? No: los pacientes mas graves van a los mejores hospitales (sesgo de seleccion). Controlar por gravedad del paciente invierte la relacion.

La pregunta correcta para causalidad

“Si **intervenimos** y forzamos $X = x_0$, ¿que valor tomaria Y en promedio?”
(pregunta causal) vs. “Entre los que observamos con $X = x_0$, ¿que Y tienen en promedio?” (pregunta descriptiva).

¿Implica causalidad correlación?

Correlacion no implica causalidad

X e Y correlacionados no garantiza que X cause Y : puede haber causa comun (factor de confusión), o la causalidad puede ser inversa.

¿Causalidad implica correlacion (lineal)?

No necesariamente. Si X causa Y a traves de una relacion **no monotona** (e.g., $Y = (X - 5)^2$ con X simetrico alrededor de 5), la correlacion de Pearson puede ser ≈ 0 aunque X determine completamente Y .

Sin embargo, causalidad si implica **alguna forma de asociacion estadistica** (dependencia). Si dos variables son *independientes*, ninguna puede causar la otra. La independencia descarta causalidad; la dependencia la sugiere pero no la garantiza.

¿Cómo se encuentra la causalidad?

La causalidad no se puede establecer con regresión observacional sola. Se requieren estrategias adicionales:

Estrategia	Idea central
Experimento aleatorizado (RCT)	Asignar X al azar
Experimento natural	Aprovechar variación "cuasi-aleatoria" de X
Variables instrumentales	Usar Z que afecta X pero no Y directamente
Diferencias en diferencias	Comparar antes/después entre tratado y control
Grafos causales (DAGs)	Modelar la estructura causal explícitamente

Experimento aleatorizado

El **experimento aleatorizado** (RCT) garantiza inferencia causal sin supuestos adicionales: asignar aleatoriamente cuantas horas estudia cada estudiante (¡muy poco practico!) eliminaria todos los confounders.

13. Extensiones del modelo lineal

Selección de variables: AIC y BIC

Criterio de Información de Akaike (AIC)

$$AIC = n \ln\left(\frac{SC_E}{n}\right) + 2(p + 1)$$

Penaliza la complejidad. **Menor AIC = mejor modelo.**

BIC (criterio de Schwarz)

$$BIC = n \ln\left(\frac{SC_E}{n}\right) + (p + 1) \ln(n)$$

Penalización mas severa; prefiere modelos parsimoniosos con n grande.

```
AIC(reg, mod, mod_cap, mod_full)
```

```
##           df      AIC
## reg        3 110.01868
## mod        4 112.01140
## mod_cap    4  35.69970
## mod_full   5  37.65816
```

Transformaciones: tabla de interpretaciones

Modelo	Ecuacion	Interpretacion de $\hat{\beta}_1$
Lineal-lineal	$Y = \beta_0 + \beta_1 X$	$\Delta Y = \beta_1 \cdot \Delta X$
Log-lineal	$\log Y = \beta_0 + \beta_1 X$	$\% \Delta Y \approx 100 \beta_1 \cdot \Delta X$
Lineal-log	$Y = \beta_0 + \beta_1 \log X$	$\Delta Y = (\beta_1 / 100) \cdot \% \Delta X$
Log-log	$\log Y = \beta_0 + \beta_1 \log X$	$\% \Delta Y \approx \beta_1 \cdot \% \Delta X$

```
mod_log <- lm(log(nota + 0.01) ~ horas + capacidad,  
              data = datos)  
round(coef(mod_log), 5)
```

```
## (Intercept)      horas  capacidad  
##      0.62507      0.05448      0.08672
```

14. Síntesis y puente a métodos avanzados

Checklist del análisis de regresión

Supuesto	Herramienta	Accion si falla
Linealidad	Res. vs. Fitted	Transform. o vars. cuadraticas
Homocedasticidad	Scale-Loc. / Breusch-P.	SE robustos / WLS
Normalidad	Q-Q / Shapiro-Wilk	Transformacion / no parametrico
Sin autocorr.	Durbin-Watson	Modelos de series de tiempo
No multicolineal.	VIF	Eliminar / combinar / regularizar
Sin influencias	Cook / Leverage	Investigar y reportar

Cuando Y no es continua:

- Y binaria $\rightarrow$ Reg. logistica (AAD Ses. 5)
- Y de conteo $\rightarrow$ Poisson / NegBin
- Y categorica $\rightarrow$ Reg. multinomial

Relaciones no lineales:

- Splines / GAM (AAD Ses. 3)
- Kernel regression (AAD Ses. 4)
- Redes neuronales

Cuando hay muchos predictores o multicolinealidad:

- Ridge / LASSO: $\min SC_E + \lambda \|\beta\|^2$
- Regresión en Componentes Principales (PCR): usa los CPs de la Sesión 4 como predictores — conecta directamente ACP con regresión

Regresión lineal: el mapa completo

1. **Identificación:** relación lineal, gráfico de dispersión.
2. **Estimación:** MCO minimiza SC_E , maximiza R^2 respecto a M2.
3. **Bondad de ajuste:** R^2 , R^2_{adj} , $\hat{\sigma}$.
4. **Inferencia:** prueba t individual, prueba F global.
5. **Validación:** residuales, QQ-plot, Cook, leverage.
6. **Extensión:** regresión múltiple, VIF, transformaciones.
7. **Interpretación:** modelo correlacional; causalidad requiere más.

Mensaje final

La regresión lineal es una **herramienta de pensamiento**, no una receta.
Cada decisión requiere juicio estadístico sustantivo.

Bibliografía

1. Montgomery, D., Peck, E. A., & Vining, G. G. (2006). *Introducción al análisis de regresión lineal*. Limusa Wiley.
2. James, G. et al. (2021). *An Introduction to Statistical Learning* (2a ed.). Springer.
3. Pearl, J. & Mackenzie, D. (2018). *The Book of Why*. Basic Books. (Causalidad, confounders y grafos causales.)

Anexo A: Derivación MCO

Derivación MCO — Paso 1

Minimizamos:

$$SC_E(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Derivando e igualando a cero:

$$\frac{\partial SC_E}{\partial \beta_0} = -2 \sum (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\frac{\partial SC_E}{\partial \beta_1} = -2 \sum x_i (y_i - \beta_0 - \beta_1 x_i) = 0$$

Sistema de **ecuaciones normales**:

$$n\hat{\beta}_0 + \hat{\beta}_1 \sum x_i = \sum y_i \quad \hat{\beta}_0 \sum x_i + \hat{\beta}_1 \sum x_i^2 = \sum x_i y_i$$

De la primera ecuacion: $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$.

Sustituyendo en la segunda:

$$\hat{\beta}_1 = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}}$$

Conexion con covarianza y correlacion

S_{xy} es la covarianza muestral (sin dividir por $n - 1$). Ademàs

$\hat{\beta}_1 = r_{xy} \cdot s_y / s_x$: si $r_{xy} = 0$, entonces $\hat{\beta}_1 = 0$ y M2 es el mejor predictor posible.

Anexo B: Código diagnóstico completo

Verificación de supuestos: código de referencia

```
library(car); library(lmtest); library(sandwich)

# 1. Graficos diagnostico
par(mfrow = c(2, 2)); plot(mod_cap); par(mfrow = c(1, 1))

# 2. Normalidad formal
shapiro.test(residuals(mod_cap))

# 3. Heterocedasticidad (Breusch-Pagan)
bptest(mod_cap)

# 4. Autocorrelacion (Durbin-Watson)
dwtest(mod_cap)

# 5. VIF (multicolinealidad)
vif(mod_cap)

# 6. Puntos influyentes
influencePlot(mod_cap)    # paquete car

# 7. Errores robustos si hay heterocedasticidad
coeftest(mod_cap, vcov = vcovHC(mod_cap, type = "HC3"))
```