Análisis Estadístico de Datos

Sesiones 6 y 7: Regresión Lineal

Profesor: Nicolás López

Universidad del Rosario

Puente desde las sesiones anteriores

El arco del curso hasta hoy

Sesión	Tema	Pregunta central	Tipo
1–2	E. descriptiva	¿Cómo describir variables?	Univariado
3	Normal multi.	¿Cómo modelar conjuntamente?	Multivariado
4	ACP	¿Cómo reducir dimensiones?	No supervisado
5	Clustering	¿Cómo detectar grupos?	No supervisado
6–7	**Regresión lineal**	**¿Cómo predecir Y desde X?**	**Supervisado**

Cambio de paradigma

Las Sesiones 4 y 5 son **no supervisadas**: no hay variable respuesta.

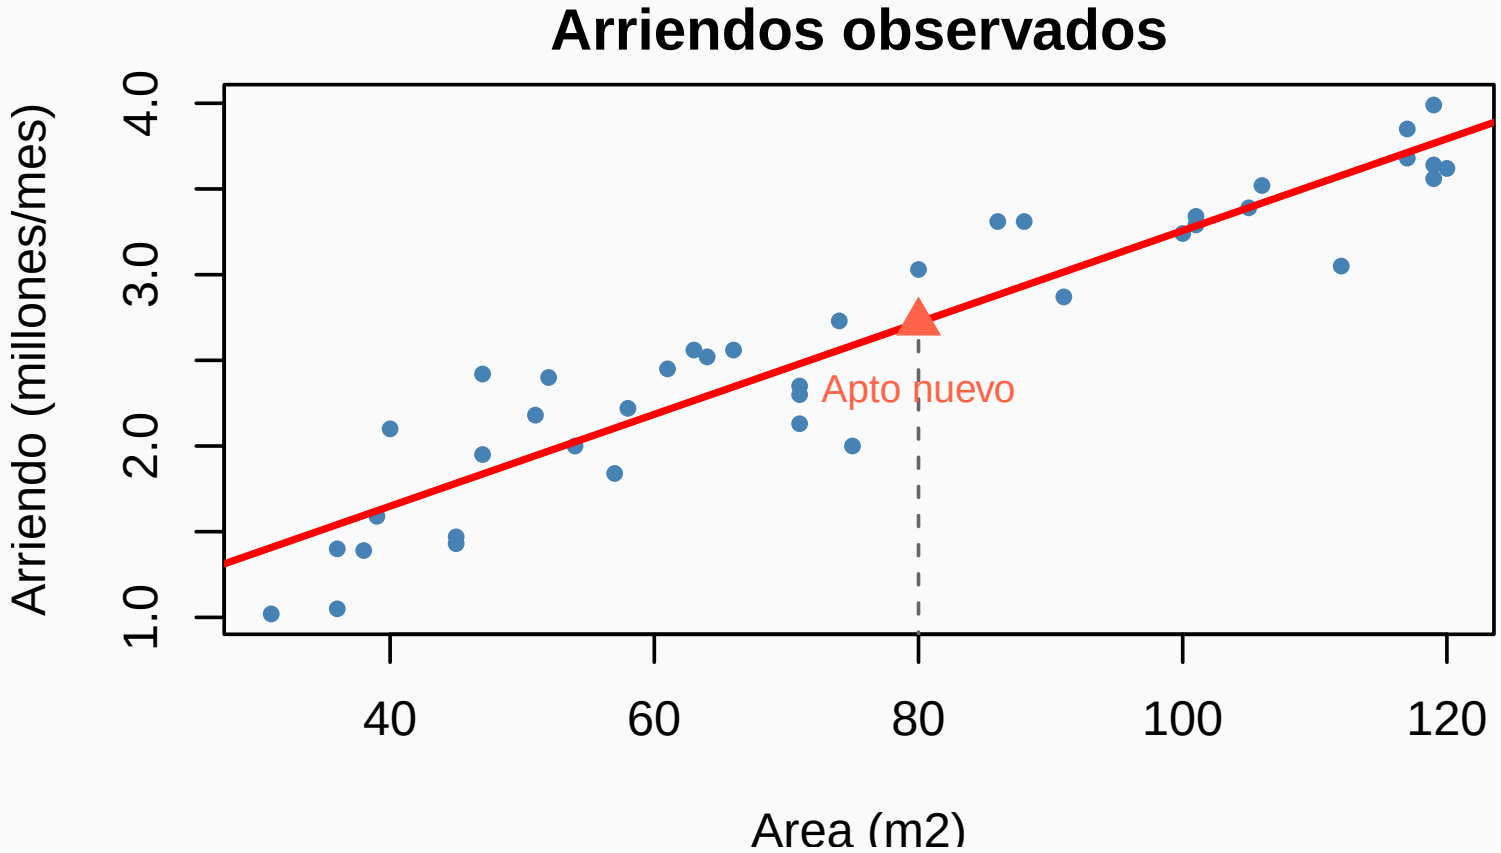
Las Sesiones 6 y 7 introducen el aprendizaje **supervisado**: tenemos una variable Y que queremos predecir o explicar a partir de variables X.

Aprendizaje supervisado vs. no supervisado

Característica	**No supervisado**	**Supervisado**
Variable respuesta Y	No existe	Sí existe
Objetivo	Descubrir estructura	Predecir / explicar Y
Evaluación	Subjetiva / interna	Objetiva (error de pred.)
Ejemplos	ACP, Clustering	Regresión, clasificación
Etiquetas en los datos	No se requieren	Necesarias para entrenar

Un ejemplo cotidiano: ¿cuánto cobrar de arriendo?

Tenemos el historial de 40 apartamentos (área y arriendo). Llega uno nuevo de 80 m^2.



El arriendo conocido "enseña" al modelo: eso es aprendizaje **supervisado**.

1. Propósito de la regresión lineal

¿Qué es la regresión lineal?

La idea en una frase
Una técnica para describir cómo cambia, **en promedio**, una variable respuesta Y cuando cambian una o varias variables explicativas X.

Ejemplos

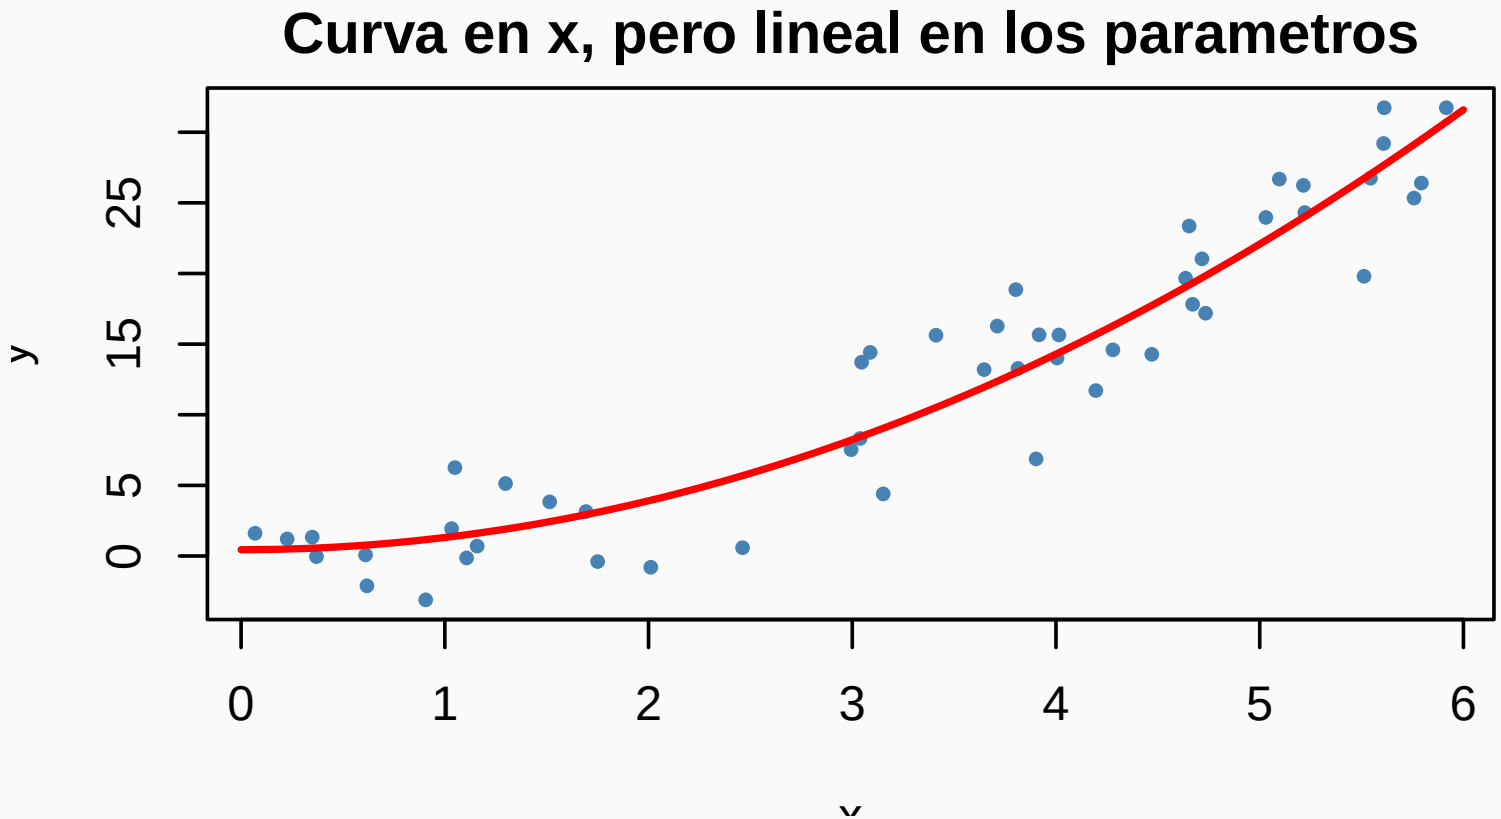
- ¿Cuánto sube el arriendo por cada m^2 adicional?
- ¿Cuánto sube la nota por cada hora de estudio?

La definición formal

Definición
Al contar con n datos, asumimos que la respuesta del individuo i es una variable aleatoria Y_i cuya media μ_i depende de variables conocidas $x_{1,i}, \ldots, x_{p,i}$.

Aclaración importante
Más adelante veremos qué significa realmente "lineal".

¿Qué significa “lineal”?



Aclaración importante

La palabra **"lineal"** hace referencia a los **coeficientes**, no a las variables.

El modelo $Y = \beta_0 + \beta_1 x^2 + \varepsilon$ es lineal en los parámetros aunque x aparezca al cuadrado.

Los cuatro usos del modelo de regresión

1. **Descripción**: resumir cómo se relacionan las variables.
   ¿Cómo cambia el arriendo con el área?
2. **Estimación**: medir efectos con su incertidumbre.
   ¿Entre qué valores está el aumento por m^2?
3. **Predicción**: anticipar Y para casos nuevos.
   ¿Cuánto cobrar por un apartamento de 80 m^2?
4. **Control**: elegir X para llevar Y a un nivel deseado.
   ¿Cuántas horas de estudio garantizan aprobar?

Aplicaciones prácticas de la regresión

Área	**Respuesta** Y	**Predictores** X
Inmobiliario	Arriendo o precio	Área, estrato, ubicación
Marketing	Ventas	Publicidad, precio
Salud	Presión arterial	Edad, peso, hábitos
Recursos humanos	Salario	Experiencia, formación
Logística	Tiempo de entrega	Distancia, tráfico
Educación	Nota del examen	Horas de estudio, pre-test

Nuestro hilo conductor: rendimiento académico

En estas sesiones
Estudiaremos los cuatro usos a través de un ejemplo de rendimiento académico:

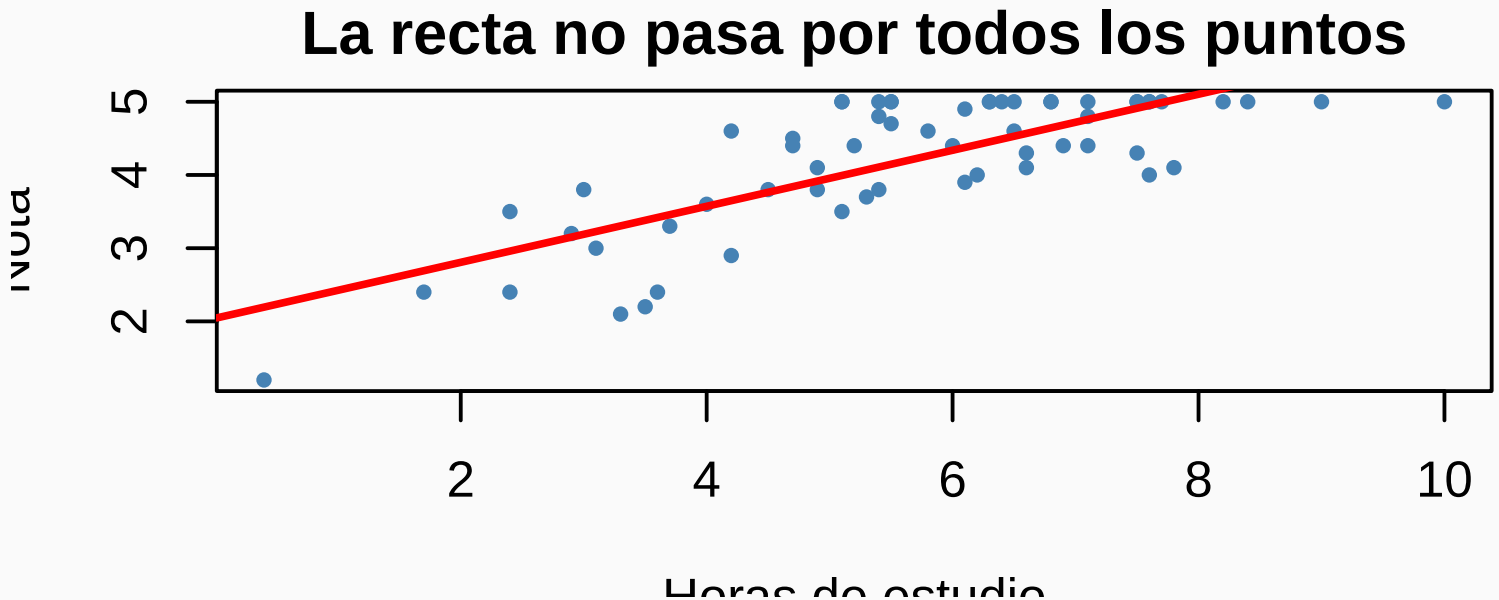
¿Cuánto sube la nota de un estudiante por cada hora adicional de estudio?

Modelo determinístico: un mundo sin azar

Si $Y =$ nota del examen y $x =$ horas de estudio:

$$y = \beta_0 + \beta_1 x$$

Este modelo dice que **todos** los estudiantes con las mismas horas obtienen **la misma** nota. ¿Es realista?



Modelo probabilístico: agregamos el error

Dos estudiantes con las mismas horas **no** obtienen la misma nota.
Necesitamos incorporar un error aleatorio:

Modelo probabilístico (Regresión Lineal Simple)

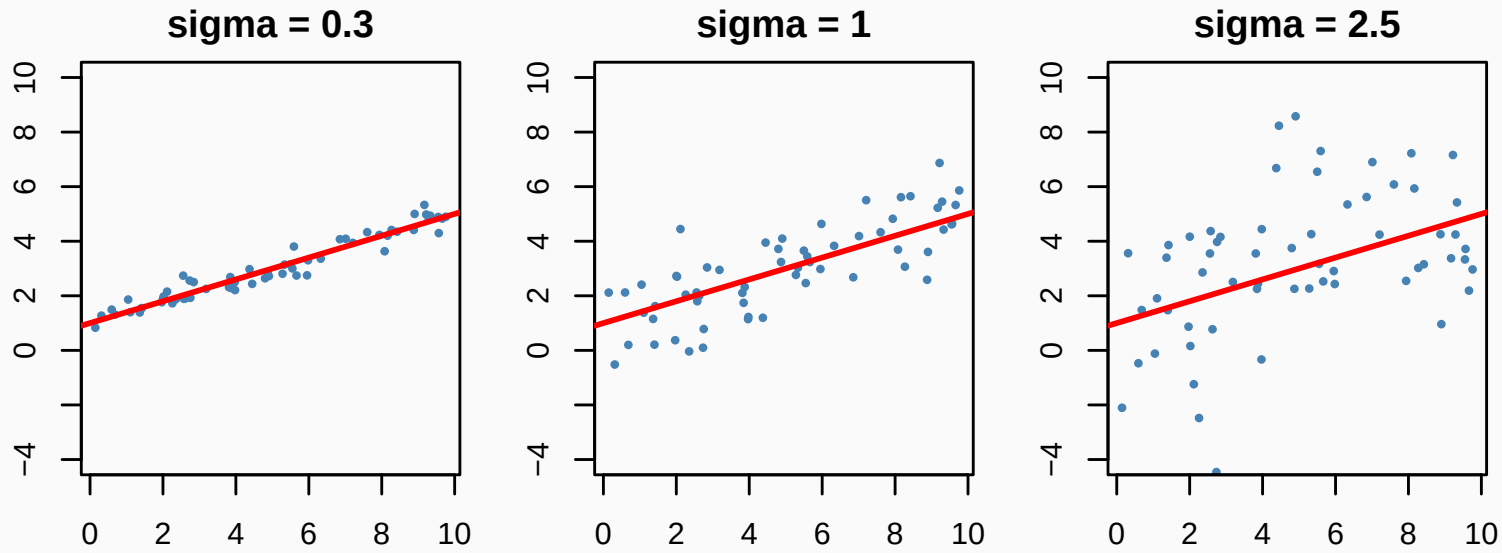
$$Y = \beta_0 + \beta_1 x + \varepsilon, \quad \varepsilon \sim (0, \sigma^2)$$

La respuesta esperada dado x:

$$E(Y \mid x) = \mu_{Y|x} = \beta_0 + \beta_1 x$$

¿Cómo se lee la pendiente? ¿Y el ruido?

Pendiente β_1
Cambio en la **nota promedio** por cada hora adicional de estudio.



Misma recta, distinto ruido σ: cuando σ^2 es grande, los datos se alejan de la recta.

Los supuestos del modelo

Supuesto	En palabras
1. Linealidad: $E[Y\|X] = \beta_0 + \beta_1 X$	El patrón promedio es una recta
2. Normalidad: $\varepsilon \sim N(0, \sigma^2)$	Los errores forman una campana
3. Sin autocorrelación: $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$	Un error no predice el siguiente
4. Homocedasticidad: $\text{Var}(\varepsilon_i) = \sigma^2$	Igual dispersión para todo x

Cada supuesto se verificará en la **etapa de validación** con los residuales.

Las cuatro etapas del modelamiento estadístico

Etapa	Nombre	Descripción
1	Identificación	Gráficos y números para detectar relaciones
2	Estimación	Ajuste del modelo (mínimos cuadrados ordinarios)
3	Validación	Verificación de supuestos con los residuales
4	Uso	Predicción, inferencia, toma de decisiones

Identificación $\rightarrow$ Estimación $\rightarrow$ Validación $\rightarrow$ Uso

Flujo iterativo

El incumplimiento de **al menos un supuesto** en la etapa de validación retorna al analista a la etapa de identificación.

2. Los datos: rendimiento académico

Descripción del conjunto de datos

Datos simulados de $n = 60$ estudiantes que presentaron un examen.

Variable	**Descripción**	**Rango**
`nota`	Nota final en el examen	0.0 a 5.0
`horas`	Horas de estudio	0 a 12
`sueno`	Horas de sueño la noche anterior	3 a 10
`capacidad`	Conocimiento previo (pre-test)	0 a 10

Pregunta de la sesión

Pregunta de la sesión

¿Podemos predecir la nota de un estudiante a partir de las horas que dedicó a estudiar?

¿Cuánto sube la nota por cada hora adicional?

Primeras filas de los datos

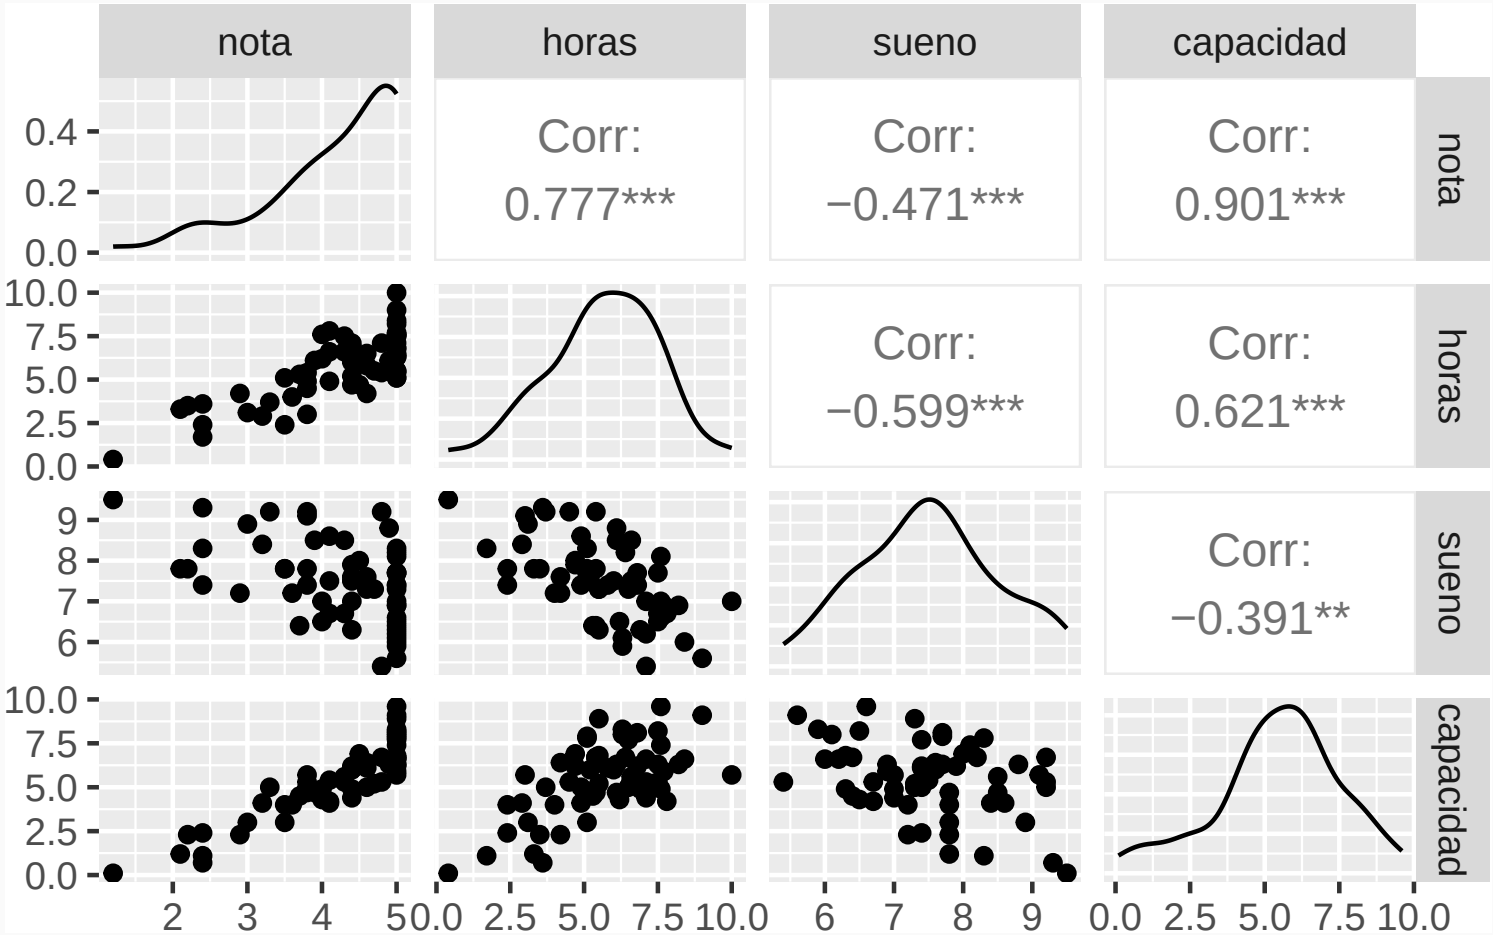
```
head(datos, 8)
```

```
##   nota horas sueno capacidad
## 1  5.0   6.3   6.1       8.0
## 2  3.7   5.3   6.4       4.5
## 3  5.0   6.8   7.4       6.2
## 4  5.0   8.4   6.0       6.6
## 5  4.4   4.7   7.9       6.2
## 6  4.3   7.5   6.7       5.3
## 7  5.0   7.5   6.5       8.2
## 8  4.8   7.1   5.4       5.3
```

El código con el que se simularon los datos está en el **Anexo E**.

Exploración inicial

```
ggpairs(datos, progress = FALSE)
```



Cómo leer esta matriz de gráficos

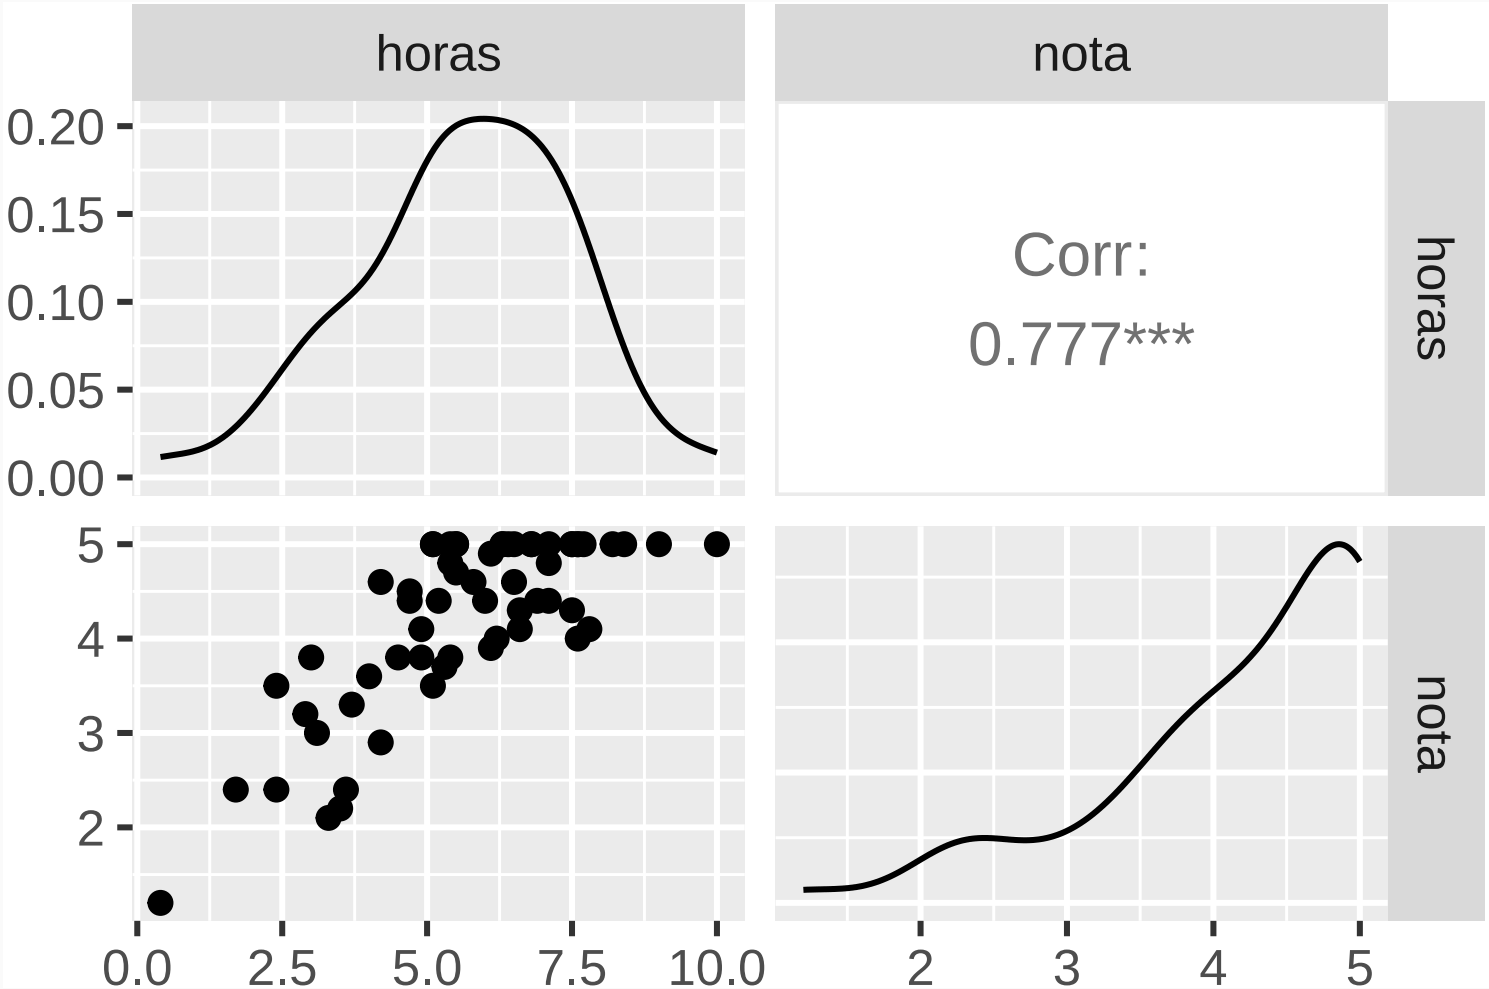
- **Diagonal**: la forma de cada variable (densidad).
- **Debajo de la diagonal**: diagramas de dispersión de cada par.
- **Encima de la diagonal**: la correlación de cada par.

Pistas en nuestros datos

`nota` se asocia fuerte y positivamente con `horas` y con `capacidad`.

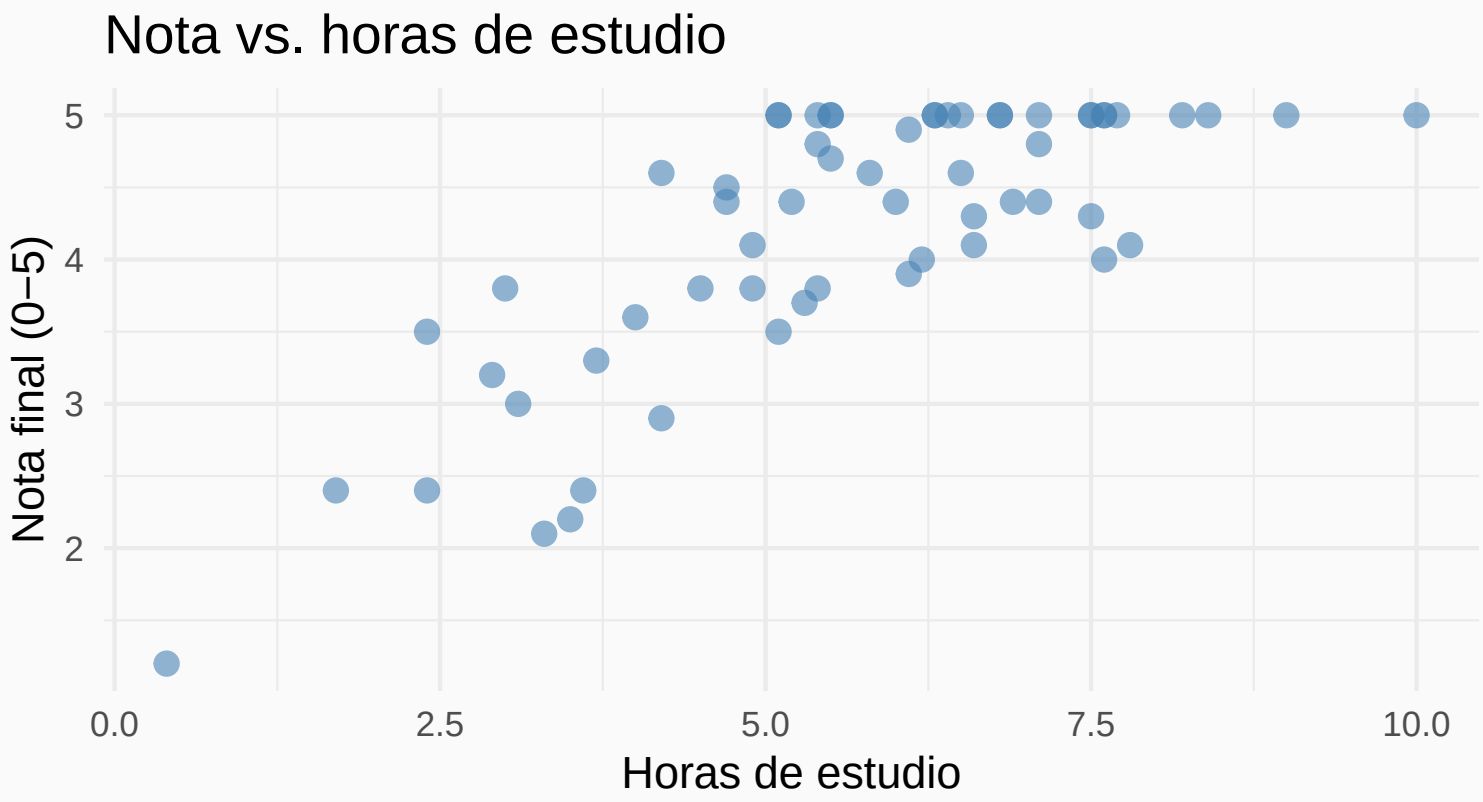
Variables de interés: horas de estudio y nota

```
ggpairs(datos %>% dplyr::select(horas, nota), progress = FALSE)
```



Etapa 1: Identificación

```r
ggplot(datos, aes(x = horas, y = nota)) +
  geom_point(alpha = 0.6, color = "steelblue", size = 1.8) +
  labs(x = "Horas de estudio",
       y = "Nota final (0-5)",
       title = "Nota vs. horas de estudio") +
  theme_minimal(base_size = 9)
```



La gráfica confirma una **relación lineal positiva**: a más horas de estudio, mayor nota promedio.

¿Qué tan cerca están los puntos de una recta? Esa es la pregunta que responderá el modelo.

Ejercicio 1: discusión en clase

Ejercicio 1 – Discusión en clase

- ¿La relación parece estrictamente lineal o hay curvatura?
- ¿Todos los estudiantes con las mismas horas obtienen la misma nota? ¿Qué otras variables podrían estar involucradas?
- ¿Estudiar más horas *causa* mejor nota, o podría haber otros factores que expliquen ambas?

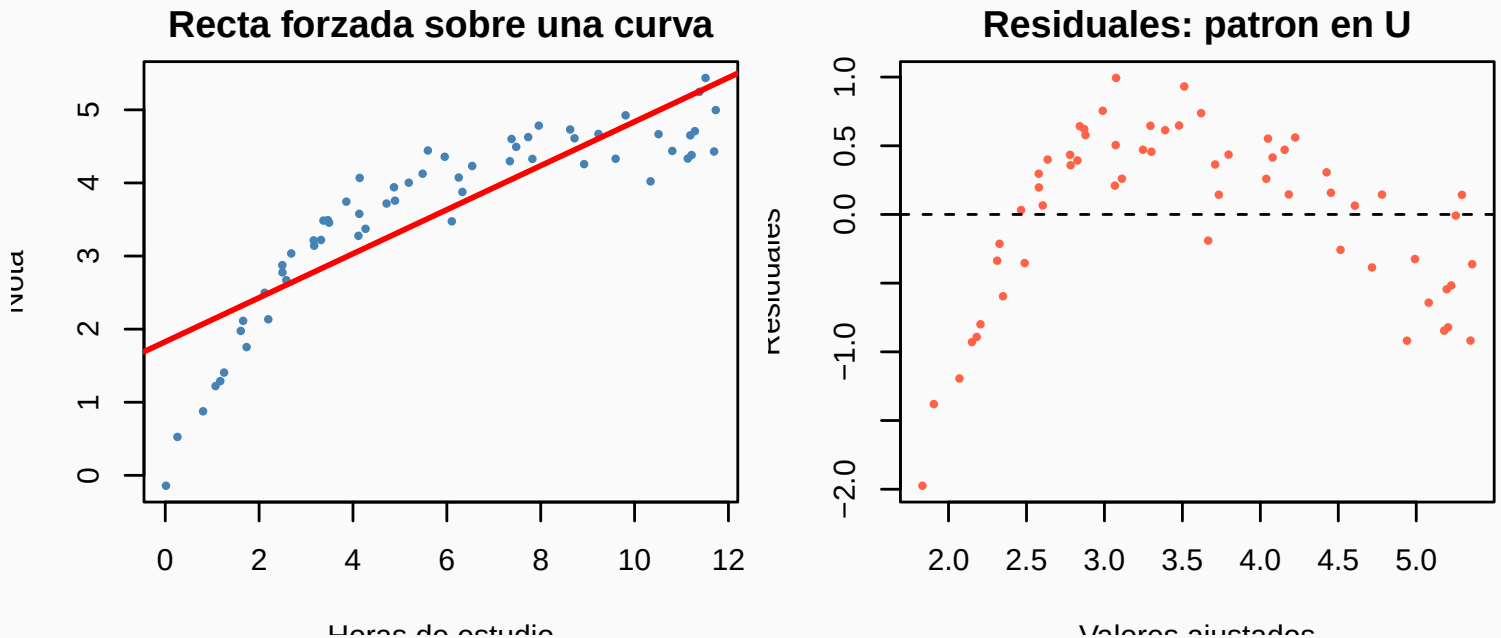
La limitación de la linealidad

Restricción del modelo lineal

Asumimos que la relación entre X e Y sigue una **recta**: cada hora adicional produce **el mismo aumento** en la nota, sin importar si se pasa de 1 a 2 horas o de 9 a 10.

Esto puede no ocurrir en la realidad.

Ejemplo: rendimiento marginal decreciente



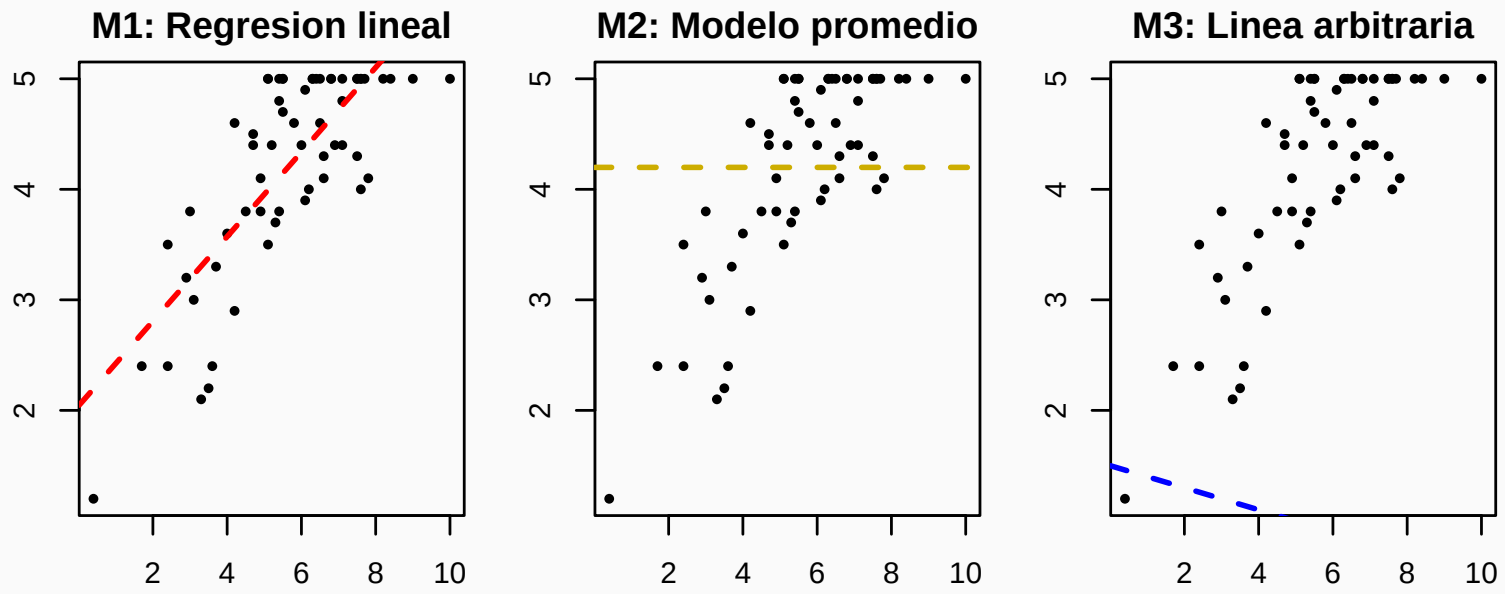
¿Cómo detectarlo?

Con el gráfico de Residuales vs. Valores Ajustados: si la relación real es curva, los residuales **no** serán ruido aleatorio.

3. Estimación por Mínimos Cuadrados (MCO)

Tres modelos candidatos

Para encontrar la recta que mejor ajusta necesitamos una medida de calidad. Consideremos tres candidatos:



La variabilidad alrededor de cada recta es distinta. ¿Cómo formalizarlo?

La suma de cuadrados como medida de calidad

Para cada modelo M_j sumamos los errores de predicción **al cuadrado**:

$$SC(M_j) = \sum_i \left(y_i - \hat{y}_{i,M_j}\right)^2$$

- Errores grandes pesan mucho más que errores pequeños.
- Elevar al cuadrado evita que errores positivos y negativos se cancelen.

¿Qué modelo comete menos error?

Modelo	SC
M1 (recta MCO)	19.9
M2 (promedio)	50.2
M3 (arbitraria)	706.5

Es evidente que $SC(M1) < SC(M2) < SC(M3)$.

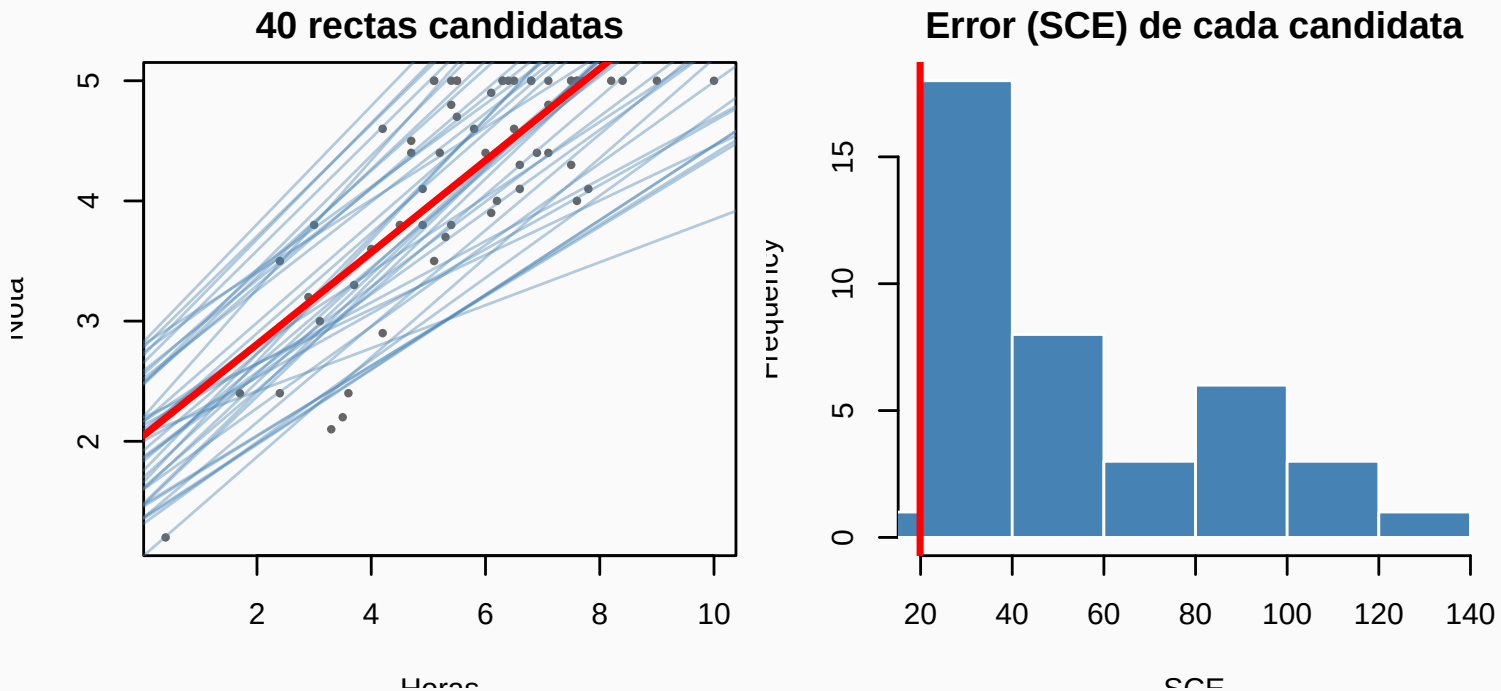
El modelo promedio como línea base

El modelo promedio (M2)
$M2$ no usa información de X: predice $\bar{Y}$ para todos. Es el modelo más simple posible: la **línea base**.

Su SC equivale a la **variabilidad total** de Y: $SC(M2) = SC_T$.

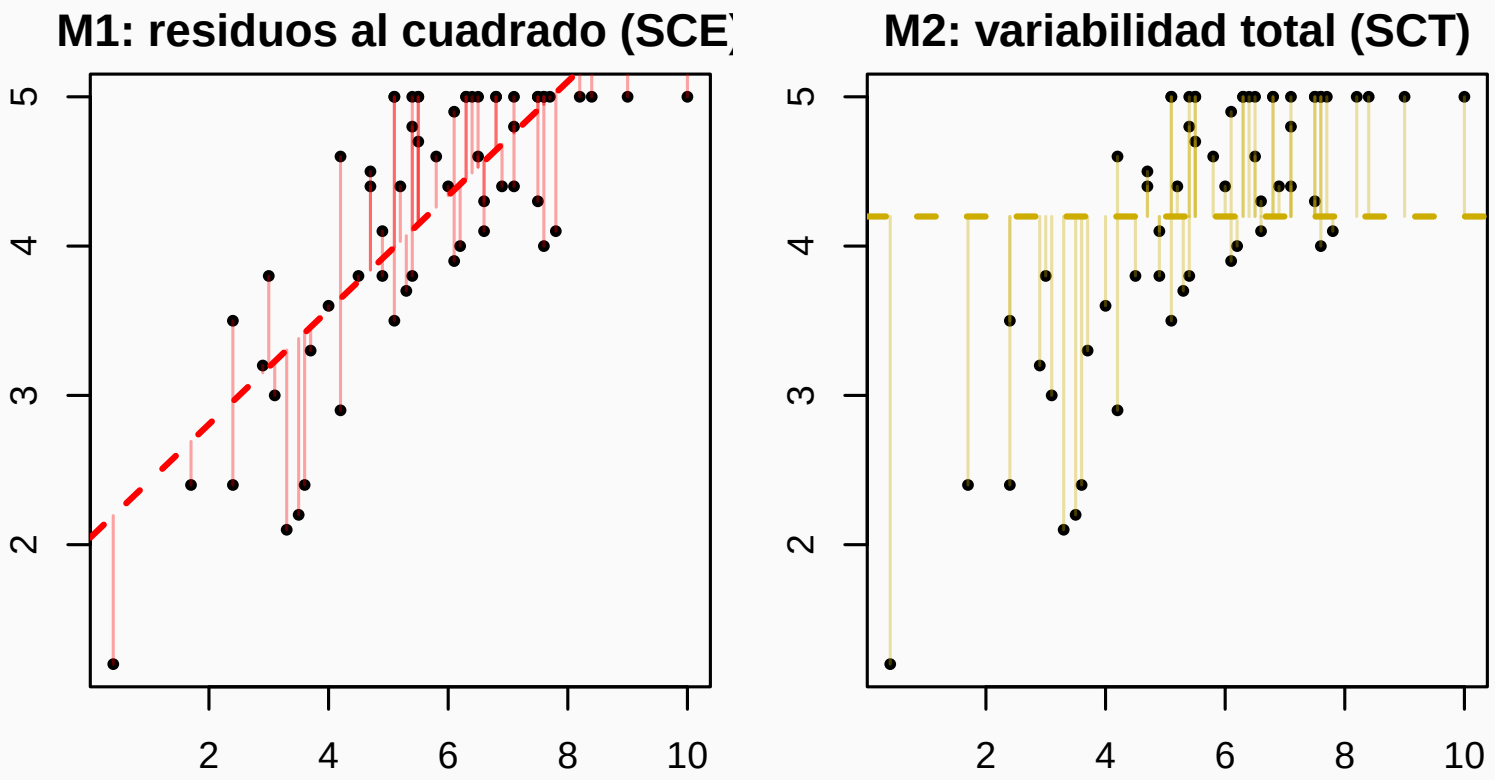
Analogía
Sin información, el mejor pronóstico de la nota de cualquier estudiante es la nota promedio del curso.

MCO: la mejor de todas las rectas



La estimación MCO encuentra (β_0, β_1) que **minimizan** SC_E: la recta roja.

M1 vs. M2: la clave de R^2



Las líneas verticales son los **residuales**. Al pasar de M2 a M1 disminuyen: las horas explican parte de la variación en las notas.

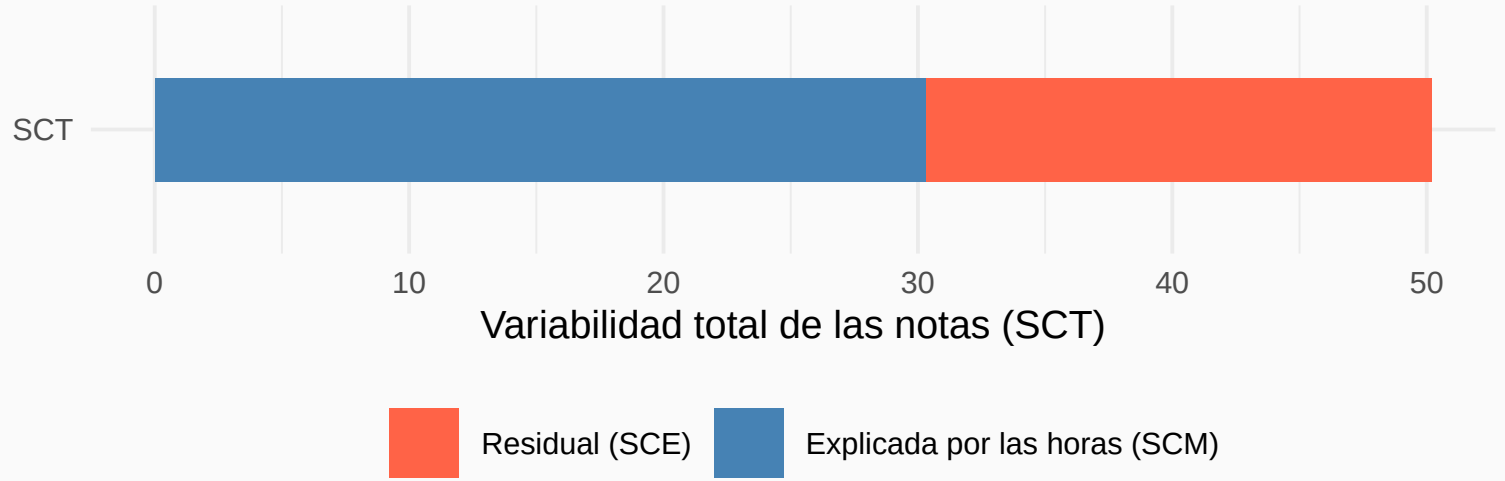
La descomposición de la variabilidad

Descomposición SCT = SCM + SCE

$$\underbrace{\sum_i (y_i - \bar{y})^2}_{SC_T} = \underbrace{\sum_i (\hat{y}_i - \bar{y})^2}_{SC_M} + \underbrace{\sum_i (y_i - \hat{y}_i)^2}_{SC_E}$$

- SC_T: variabilidad **total** de las notas (M2).
- SC_M: variabilidad **explicada** por las horas.
- SC_E: variabilidad **residual**, lo que queda sin explicar (M1).

La descomposición, en una imagen



MCO maximiza SC_M porque minimiza SC_E. Y maximizar SC_M es lo mismo que maximizar R^2.

El coeficiente de determinación R^2

Definición de R^2

$$R^2 = \frac{SC_M}{SC_T} = 1 - \frac{SC_E}{SC_T} \in [0, 1]$$

R^2 es la **proporción de la varianza en las notas** explicada por las horas.

- $R^2 \approx 1$: el modelo explica casi toda la variabilidad.
- $R^2 \approx 0$: el modelo no aporta sobre el simple promedio $\bar{Y}$.

R^2 en nuestros datos

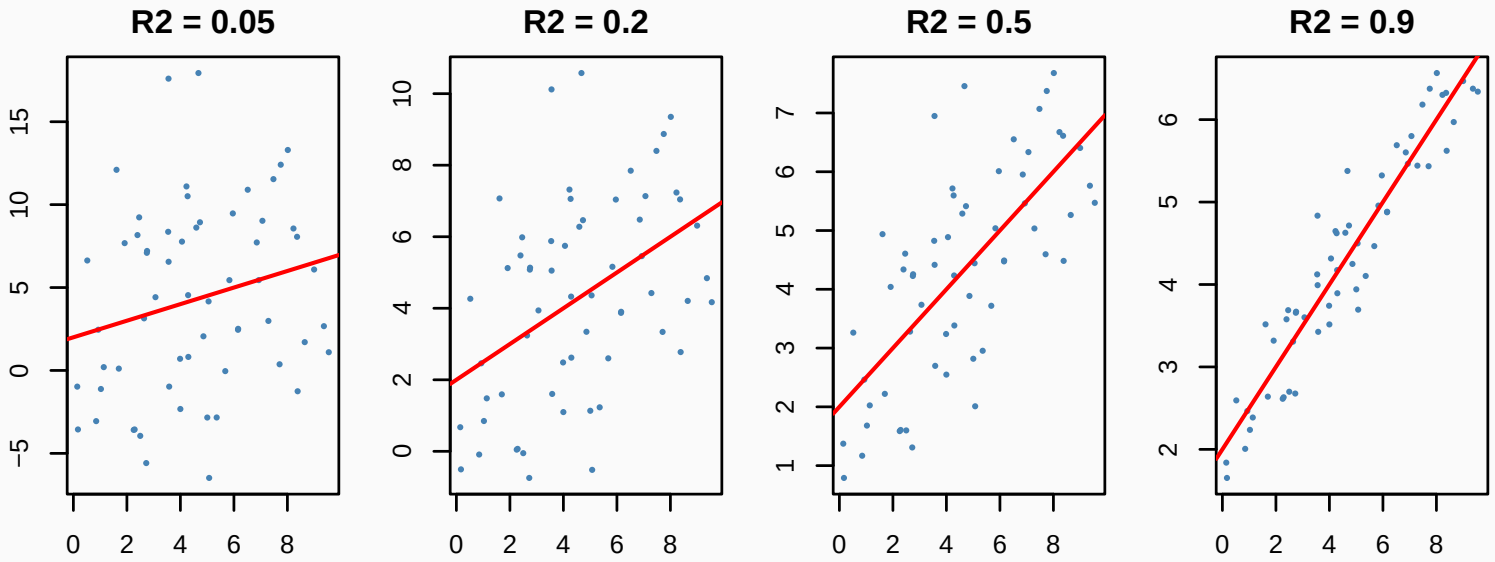
```r
cat("R^2:", round(summary(reg)$r.squared, 3))
```

```
## R^2: 0.604
```

Interpretación

Las horas de estudio explican el **60.4%** de la variabilidad en las notas de los estudiantes.

¿Cómo se ve un R^2 de 0.05, 0.2, 0.5 y 0.9?



Misma pendiente verdadera en los cuatro paneles: cambia solo el ruido.

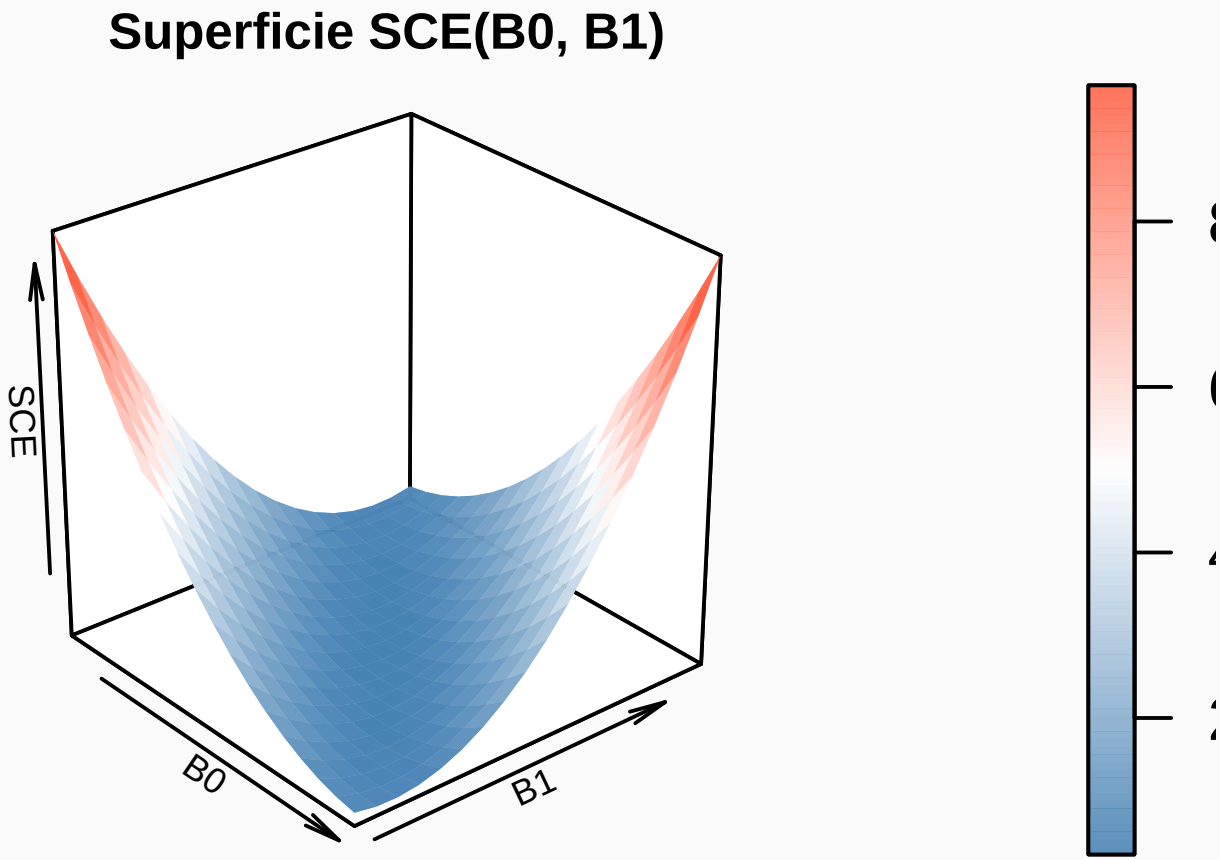
¿Qué es un R^2 "bueno"?

- **Depende del campo**: en ciencias sociales y comportamiento humano, $R^2 = 0.2$ puede ser valioso; en física o ingeniería se esperan valores cercanos a 1.
- Un R^2 alto **no** garantiza que el modelo sea válido.
- Un R^2 bajo **no** significa que el modelo sea inútil.

Recordar
R^2 mide cuánto explica el modelo, no si el modelo es correcto.

La superficie del error: buscando el fondo del cuenco

Para cada par (β_0, β_1) obtenemos un valor de SC_E. MCO busca el punto más bajo:



La superficie tiene forma de **cuenco**: hay un único mínimo, como una bola que rueda hasta el fondo.

Los estimadores MCO

La recta de mínimos cuadrados

$$\hat{\beta}_1 = r_{xy} \cdot \frac{s_y}{s_x} \qquad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

- r_{xy}: correlación entre X e Y.
- s_x, s_y: desviaciones estándar de X e Y.
- La recta siempre pasa por el punto $(\bar{x}, \bar{y})$.

La derivación paso a paso está en el **Anexo A**.

Conexión con la correlación

Si $r_{xy} = 0$
Entonces $\hat{\beta}_1 = 0$: las horas de estudio no aportan información sobre la nota y el mejor predictor es $\bar{Y}$ (M2).

Verificación con nuestros datos:

```
b1 <- cor(datos$horas, datos$nota) * sd(datos$nota) / sd(datos$horas)
b0 <- mean(datos$nota) - b1 * mean(datos$horas)
c(b0 = b0, b1 = b1)
```

```
##        b0        b1
## 2.0412998 0.3826789
```

```
coef(reg)
```

```
## (Intercept)       horas
##   2.0412998   0.3826789
```

4. Bondad de ajuste e inferencia

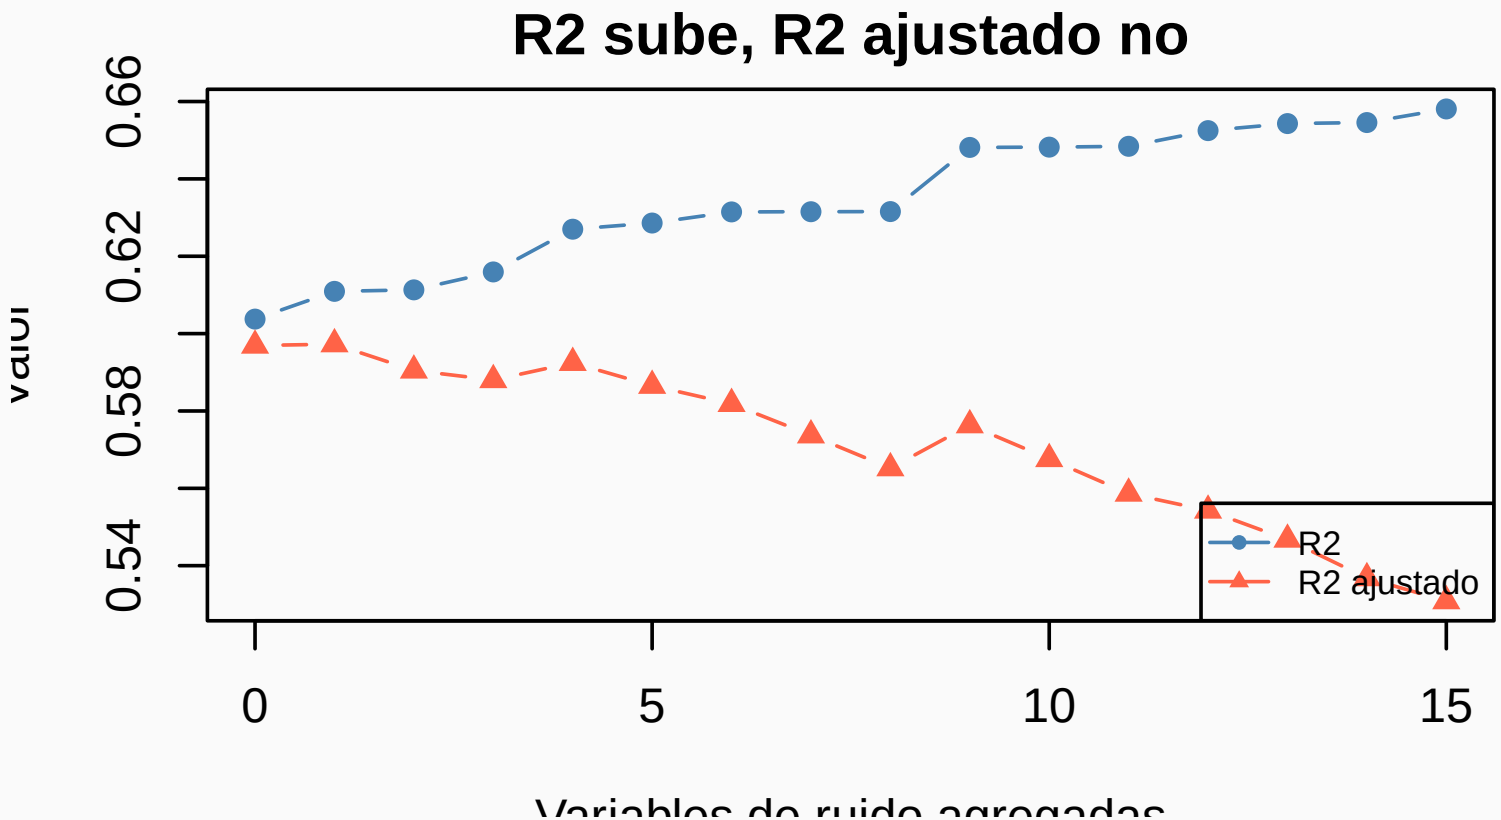
R^2 ajustado: el problema del R^2 simple

Problema del R^2 simple

R^2 **nunca decrece** al agregar variables, aunque sean irrelevantes.

- Si la variable z no tiene efecto, MCO lleva $\beta_z \to 0$.
- Pero SC_M no disminuye: R^2 se mantiene o mejora artificialmente.

Simulación: agregando variables de puro ruido



Cada punto agrega una variable generada al azar, sin relación con la nota.

R^2 ajustado: la solución

R^2 ajustado
Penaliza la inclusión de variables que no aportan.

Es la métrica correcta para **comparar modelos** con distinto número de predictores.

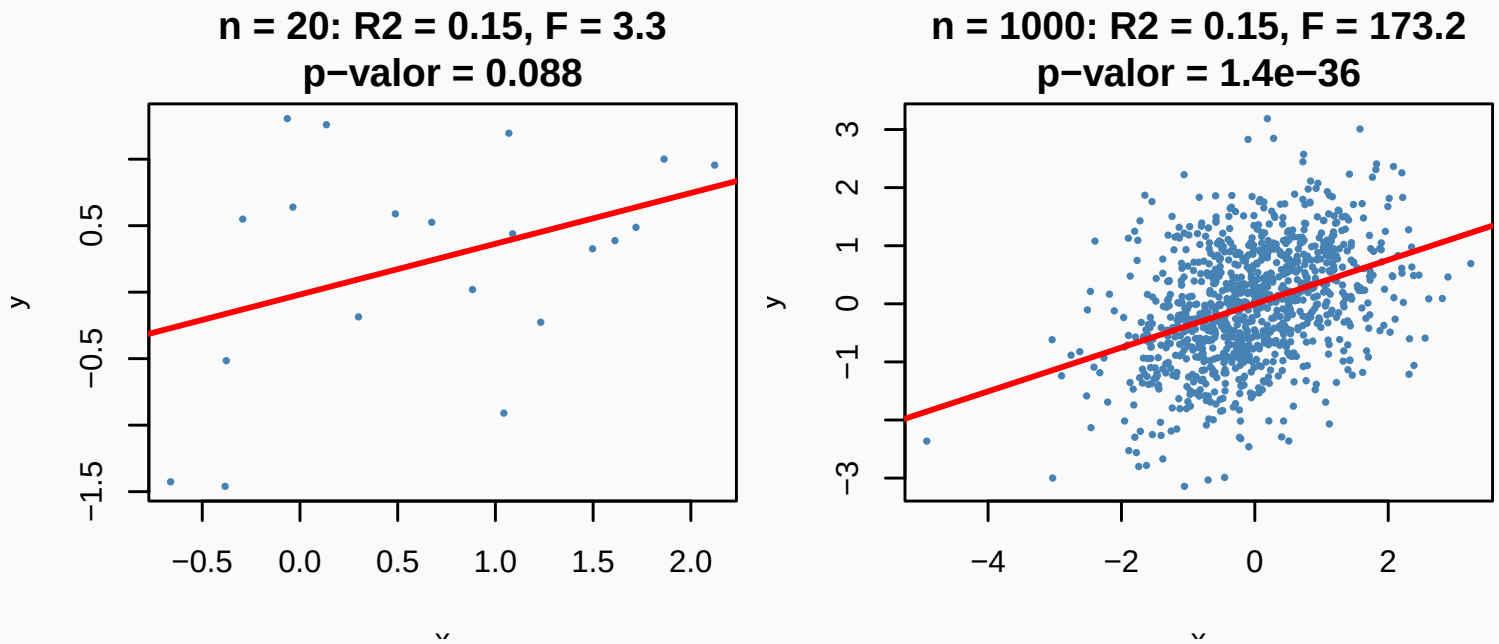
La fórmula está en el **Anexo C**.

¿Por qué F si ya tenemos R^2?

El problema de R^2 solo
R^2 mide *cuánto* explica el modelo, pero **no dice si esa cantidad es distinguible del azar**.

Con n datos y p predictores, variables **completamente aleatorias** producen un $R^2 > 0$. ¿Cómo saber si el R^2 observado es grande **en relación a lo esperado por azar**?

Mismo R^2, conclusiones opuestas



Mismo $R^2 \approx 0.15$

Con $n = 1000$: F grande, modelo útil. Con $n = 20$: F pequeño, indistinguible del azar. F incorpora el tamaño muestral; R^2 solo, no.

La prueba F: las hipótesis

Hipótesis de la prueba F

$H_0 : \beta_1 = \beta_2 = \cdots = \beta_p = 0$

(el modelo no aporta sobre M2)

H_a : al menos un $\beta_i \neq 0$

El estadístico F: señal contra ruido

Estadístico F

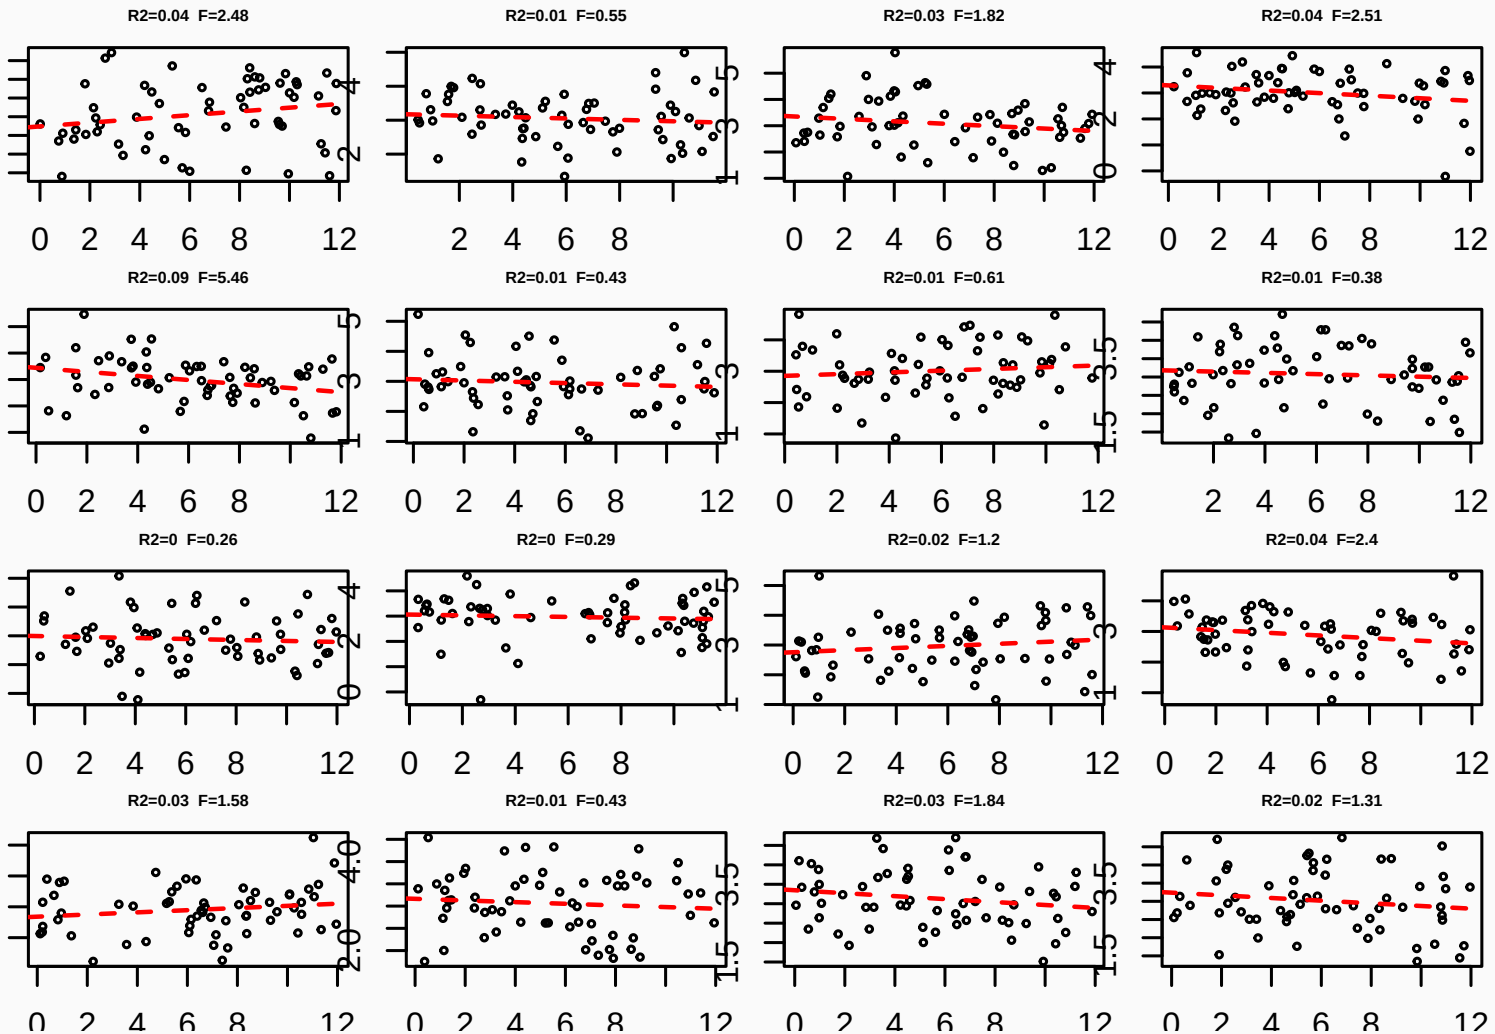
$$F = \frac{SC_M/p}{SC_E/(n-p-1)}$$

- **Numerador**: la "señal", lo que explica el modelo por variable.
- **Denominador**: el "ruido", lo que queda sin explicar.

Un F grande indica que el modelo explica mucho *en relación* al ruido residual.

Simulación: ¿qué ocurre cuando no hay relación real?

Si las horas no predijesen la nota ($\beta_1 = 0$), los datos podrían verse así:

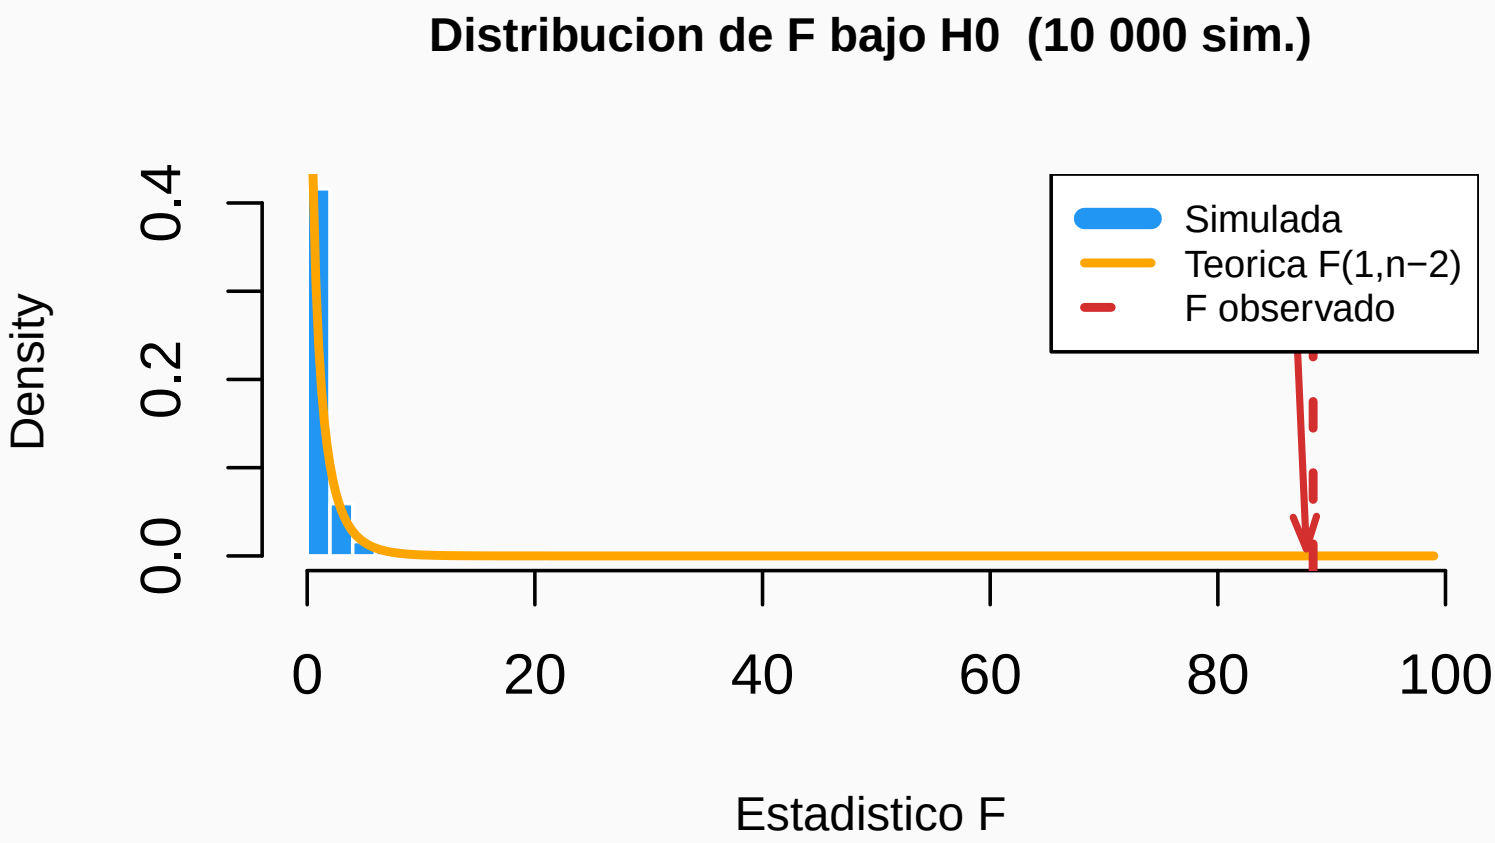


Cada panel son datos **completamente aleatorios**: horas y notas son independientes. Sin embargo, todos muestran $R^2 > 0$ y rectas con pendiente.

Lectura clave

El R^2 siempre es positivo, incluso cuando no hay relación. Bajo la hipótesis nula esperamos valores F pequeños.

Distribución de F bajo H0: 10 000 simulaciones



El F observado (línea roja) es **muy atípico** bajo la hipótesis nula: la probabilidad de obtener un F tan grande por azar es menor a 0.001.

Distribución F simulada vs. teórica
La distribución simulada (azul) coincide con la distribución $F_{1,\,n-2}$ teórica (naranja).

El p-valor en una frase

¿Qué es el p-valor?
La probabilidad de ver un resultado **tan extremo o más** si realmente **no hubiera relación** (H_0 cierta).

Analogía: la moneda
Si una moneda sale cara 10 veces seguidas, sospechamos que está cargada.

No es imposible con una moneda honesta (probabilidad ≈ 0.001), pero es **demasiado raro** para creerlo.

Prueba t individual vs. prueba F global

En regresión simple ambas son equivalentes ($F = t^2$). En regresión múltiple tienen roles distintos:

Prueba	**Hipótesis**	**Pregunta**
t individual	$H_0 : \beta_j = 0$	¿Aporta X_j dado el resto?
F global	$H_0 : \beta_1 = \cdots = \beta_p = 0$	¿Aporta el modelo completo?

Correlación no implica causalidad

Antes de continuar, una advertencia fundamental:

El modelo describe asociaciones, no causas
Cuando ajustamos $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$, cuantificamos **cómo se mueve Y en promedio cuando X cambia en los datos**. Esto **no** implica que X cause Y.

Ejemplos clásicos

- Las ventas de helado se correlacionan con los ahogamientos: ambas suben en verano (el calor es la causa común, no los helados).
- El número de libros en una casa predice el rendimiento escolar, pero no por leer los libros sino porque refleja el nivel educativo del hogar.
- En nuestros datos: ¿estudiar más *causa* mejores notas, o los estudiantes motivados hacen ambas cosas?

El modelo es correlacional, no causal

Lo que hace nuestro modelo
Describe **patrones en los datos**: en promedio, los estudiantes con más horas de estudio obtienen mejor nota. Sirve para predecir y describir, pero **no dice si obligar a un estudiante a estudiar más lo hará subir la nota**.

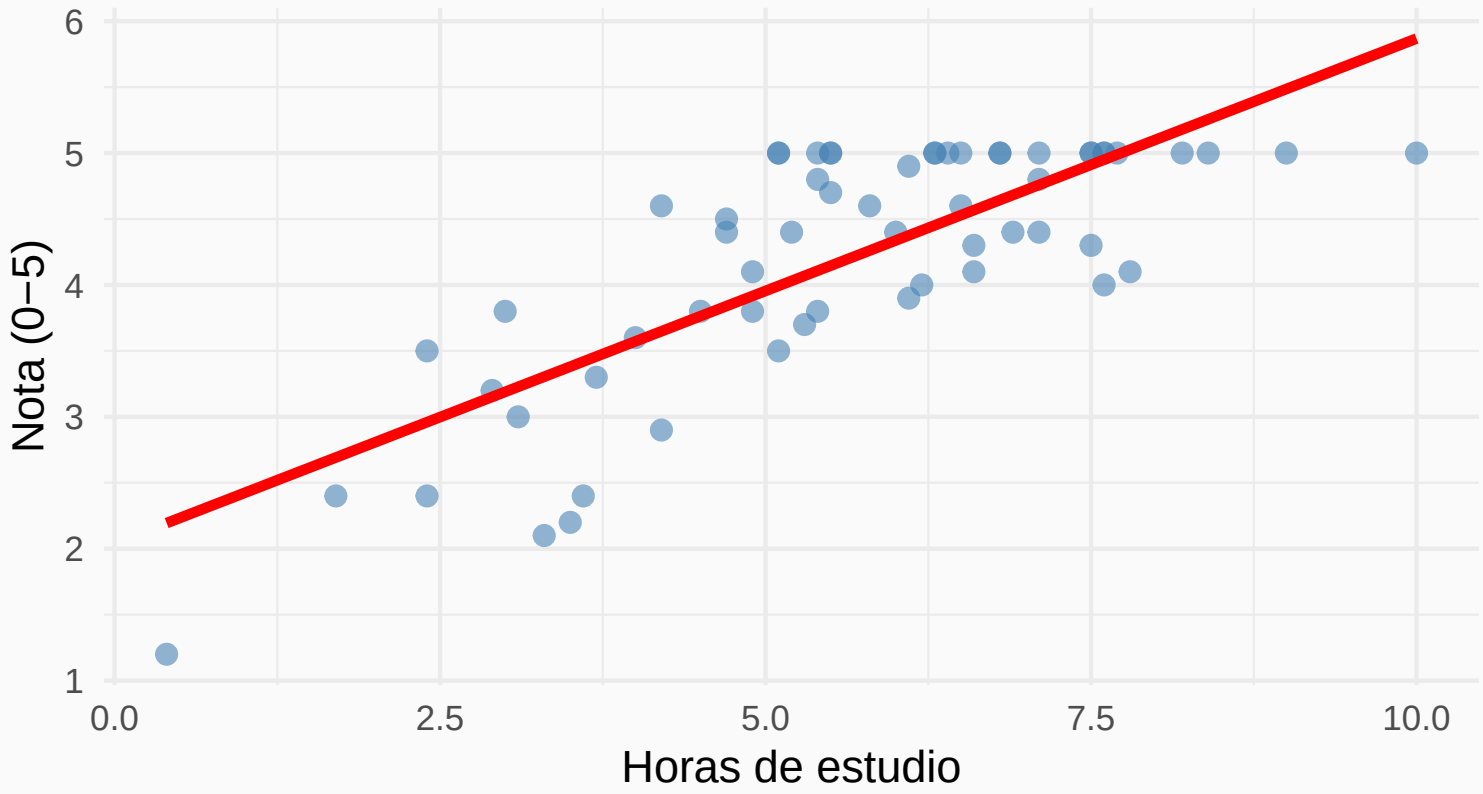
La pregunta correcta al usar regresión
No: "¿Aumentar las horas de estudio *causará* mejor nota?"
Sí: "¿Cuánto difiere la nota promedio entre estudiantes que estudiaron distinto número de horas, en estos datos?"

En la Sesión 7 elaboraremos sobre variables de confusión y causalidad.

5. Estimación en R

Ajustando el modelo: `lm()`

```r
ggplot(datos, aes(x = horas, y = nota)) +
  geom_point(alpha = 0.6, color = "steelblue", size = 1.5) +
  geom_smooth(method = lm, se = FALSE, color = "red",
              linewidth = 1) +
  labs(x = "Horas de estudio", y = "Nota (0-5)") +
  theme_minimal(base_size = 9)
```



El comando `lm()`

```r
reg <- lm(nota ~ horas, data = datos)
summary(reg)
```

```
##
## Call:
## lm(formula = nota ~ horas, data = datos)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.20414 -0.38060  0.04531  0.51326  1.00704
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  2.04130    0.24159   8.449 1.09e-11 ***
## horas        0.38268    0.04071   9.401 2.91e-13 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5856 on 58 degrees of freedom
## Multiple R-squared:  0.6037, Adjusted R-squared:  0.5969
## F-statistic: 88.37 on 1 and 58 DF,  p-value: 2.914e-13
```

Cómo leer el resultado de summary()

En el resultado	Qué responde
`Estimate`	¿Cuál es el efecto estimado?
`Std. Error`	¿Qué tan incierta es la estimación?
`t value`, `Pr(>|t|)`	¿El efecto es distinto de cero?
`Residual standard error`	¿Qué tan grande es el error típico?
`Multiple R-squared`	¿Cuánto explica el modelo?
`F-statistic`	¿El modelo en conjunto aporta?

Leyendo el resultado: coeficientes

```
round(coef(summary(reg)), 4)
```

```
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)   2.0413     0.2416  8.4494        0
## horas         0.3827     0.0407  9.4006        0
```

Interpretación del intercepto

Intercepto $\hat{\beta}_0 = 2.04$
Nota esperada de un estudiante con **cero** horas de estudio.

Puede carecer de sentido si estudiar cero horas está fuera del rango observable. En nuestros datos el mínimo es 0.4 horas.

Interpretación de la pendiente

Pendiente $\hat{\beta}_1 = 0.38$
Por cada hora adicional de estudio, la nota promedio **sube en 0.38 puntos**.

El signo positivo confirma la relación directa.

En la práctica
Diez horas más de estudio se asocian con unos 3.8 puntos más de nota promedio.

Leyendo el resultado: pruebas de hipótesis

```
round(coef(summary(reg))[, c("t value", "Pr(>|t|)")], 4)
```

```
##             t value Pr(>|t|)
## (Intercept)  8.4494        0
## horas        9.4006        0
```

- **horas**: p-valor $< 0.05 \Rightarrow$ se rechaza $H_0 : \beta_1 = 0$. Las horas **sí** predicen significativamente la nota.
- **Intercepto**: casi nunca es lo que nos interesa probar.

Leyendo el resultado: bondad de ajuste

```
s_reg <- summary(reg)
cat("R^2:           ", round(s_reg$r.squared,     4), "\n")
```

```
## R^2:            0.6037
```

```
cat("R^2 ajustado:  ", round(s_reg$adj.r.squared, 4), "\n")
```

```
## R^2 ajustado:   0.5969
```

```
cat("Error estandar:", round(s_reg$sigma,         4), "\n")
```

```
## Error estandar: 0.5856
```

```
cat("Estadistico F: ", round(s_reg$fstatistic[1], 4), "\n")
```

```
## Estadistico F:  88.3708
```

El error estándar residual

Error estándar residual

$$\hat{\sigma} = \sqrt{\frac{SC_E}{n-p-1}}$$

Mide el tamaño típico del error de predicción, en las **mismas unidades que** Y.

En nuestros datos

$\hat{\sigma} = 0.59$: nuestras predicciones se equivocan, en promedio, en unos 0.59 puntos de nota.

El ANOVA del modelo

```
anova(reg)
```

```
## Analysis of Variance Table
##
## Response: nota
##           Df Sum Sq Mean Sq F value    Pr(>F)
## horas      1 30.302 30.3019  88.371 2.914e-13 ***
## Residuals 58 19.888  0.3429
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

La tabla ANOVA: cómo se arma

Fuente	**GL**	**SC**	**CM**
Regresión (M)	p	SC_M	SC_M/p
Error (E)	$n-p-1$	SC_E	$SC_E/(n-p-1)$
Total	$n-1$	SC_T	—

$F = CM_M/CM_E$. Con p-valor < 0.05, las horas explican significativamente la variabilidad en las notas.

Intervalos de confianza para los coeficientes

```r
confint(reg, level = 0.95)
```

```
##                 2.5 %    97.5 %
## (Intercept) 1.5577050 2.5248947
## horas       0.3011929 0.4641649
```

Lectura

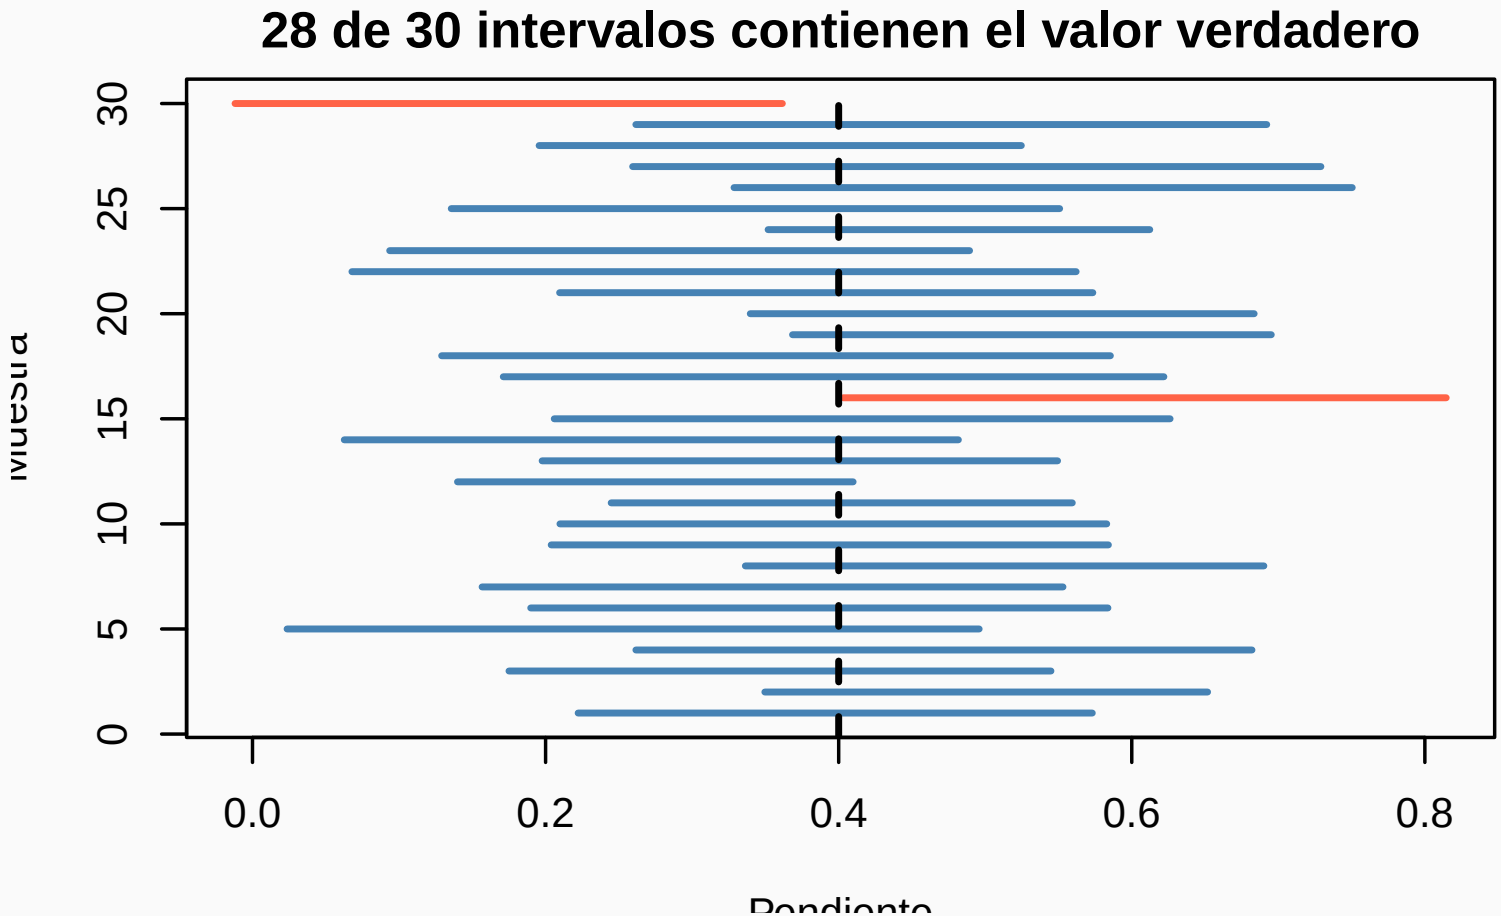
Con 95% de confianza, cada hora adicional de estudio sube la nota promedio entre 0.3 y 0.46 puntos.

IC vs. prueba de hipótesis

Dos caras de lo mismo
Si el IC para β_j no incluye 0 $\Leftrightarrow$ la prueba t rechaza H_0 al nivel $\alpha = 0.05$.

Los IC aportan **más información**: indican el rango plausible del efecto, no solo si es significativo.

¿Qué significa “95% de confianza”?



Repetimos el estudio 30 veces: aproximadamente 95% de los intervalos capturan la pendiente verdadera (línea punteada).

6. Validación de supuestos

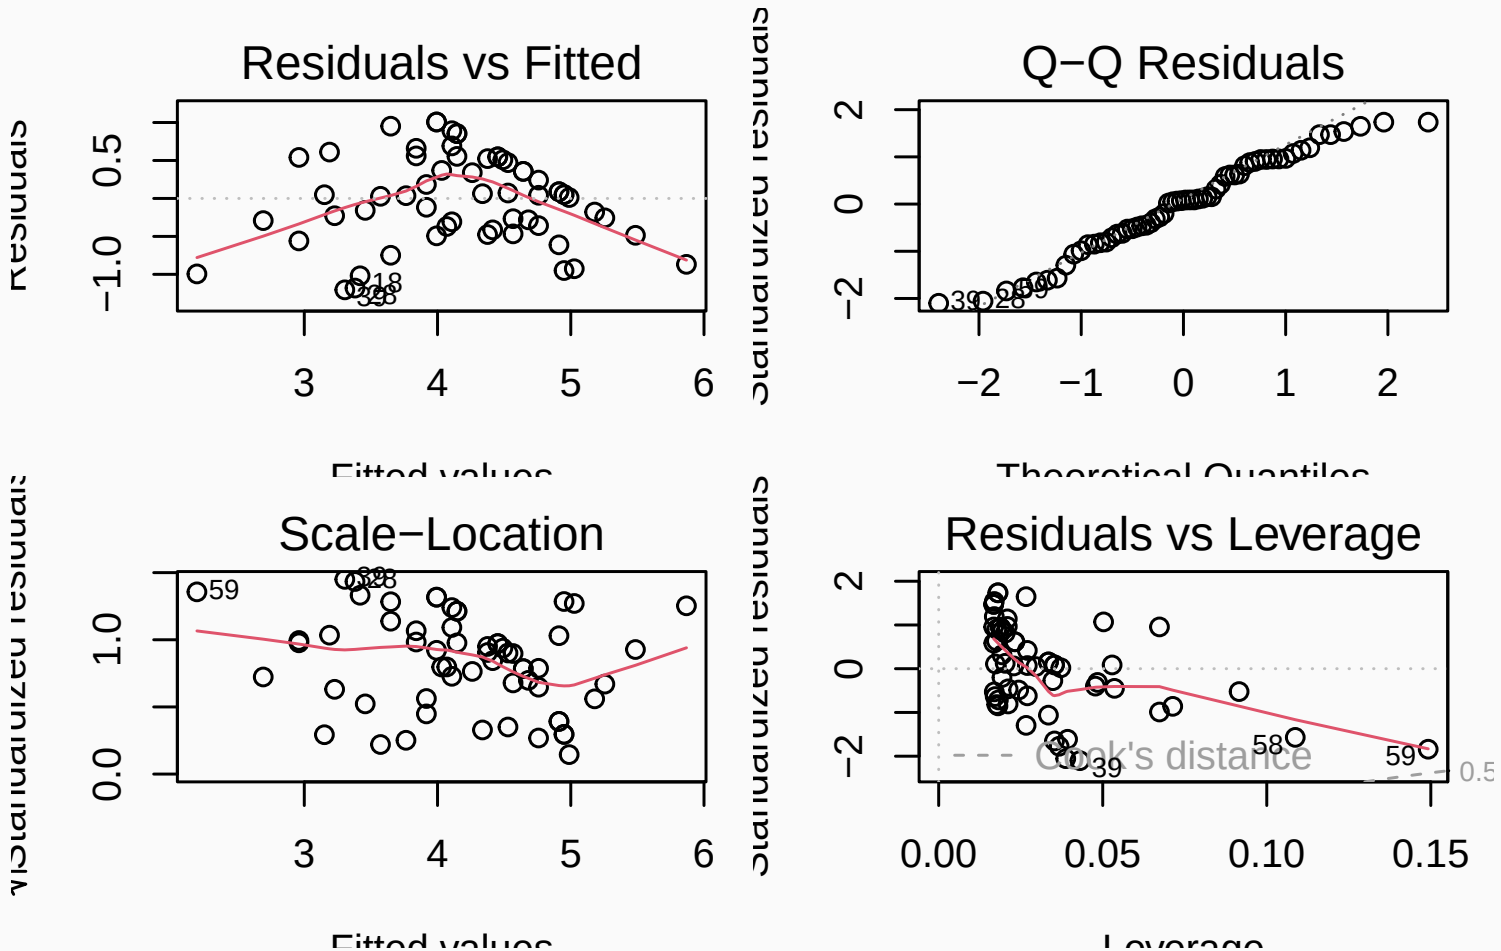
Etapa 3: Los residuales como herramienta de diagnóstico

$$e_i = y_i - \hat{y}_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 \cdot \text{horas}_i)$$

El residual es **lo que el modelo no pudo explicar** de cada estudiante.

Si el modelo es correcto, los e_i se comportan como **ruido aleatorio**.
Cualquier patrón sistemático es evidencia de violación de supuestos.

```
par(mfrow = c(2, 2), mar = c(3.5, 3.5, 2, 1))
plot(reg)
```



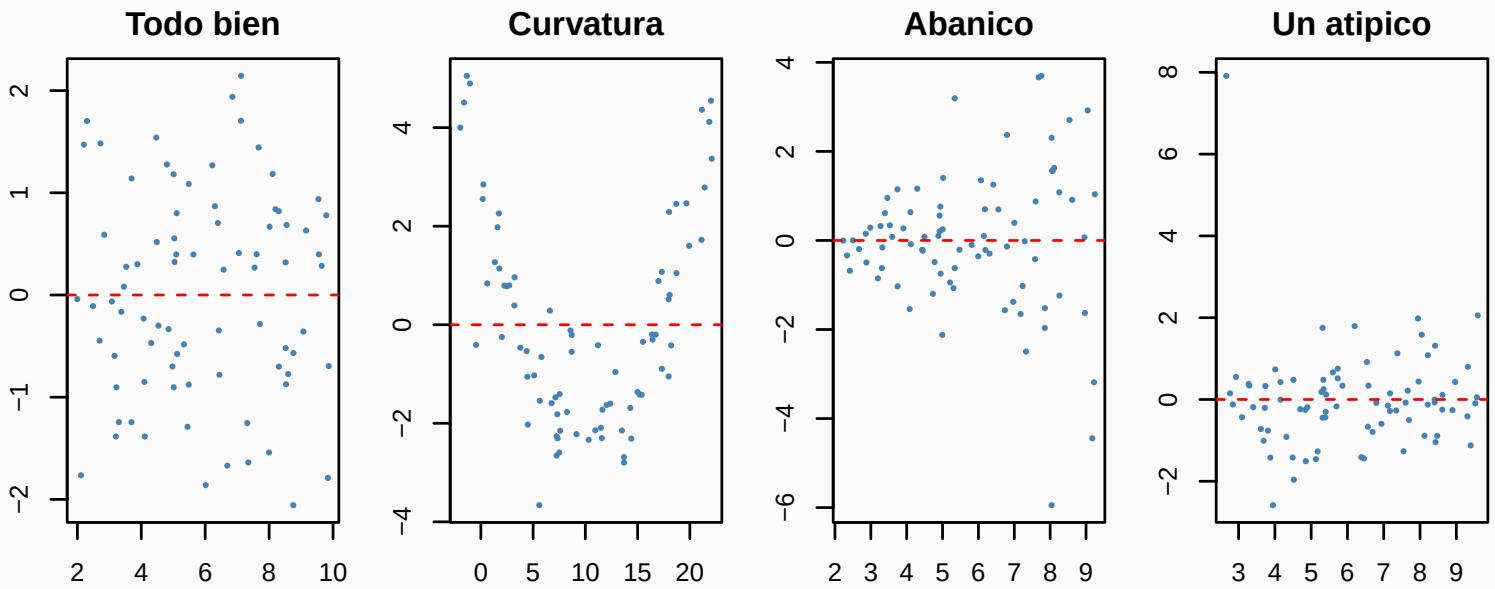

```
par(mfrow = c(1, 1))
```

Residuales vs. Valores Ajustados: qué buscar

Este gráfico evalúa **linealidad** y **homocedasticidad**:

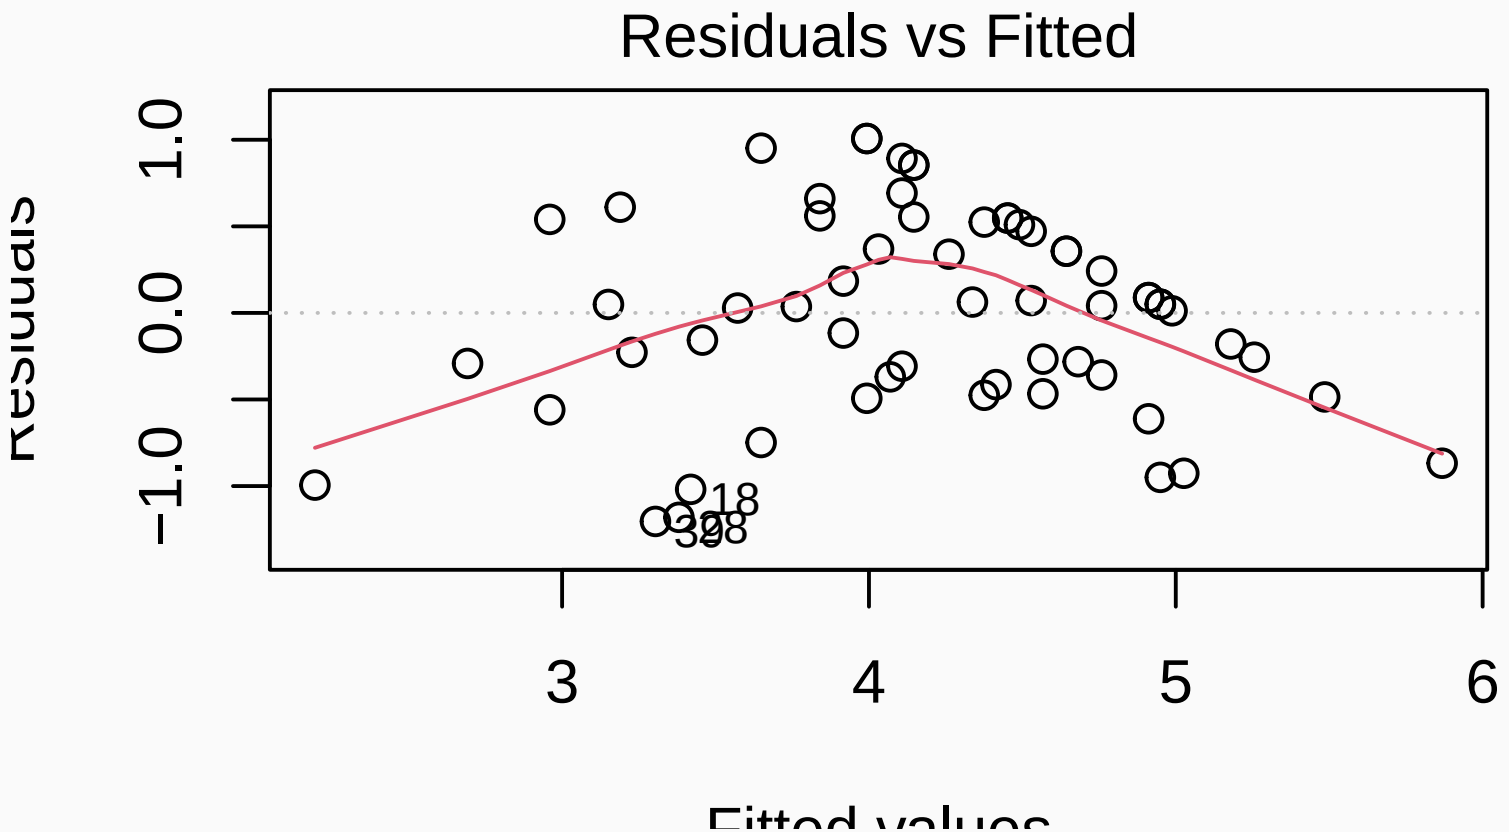
Lo que buscamos	**Lo que indica un problema**
Nube sin patrón	Tendencia curvilínea $\rightarrow$ falta de linealidad
Dispersión homogénea	Patrón de abanico $\rightarrow$ heterocedasticidad
Línea horizontal en cero	Estructura residual $\rightarrow$ variable omitida

Galería de patrones de residuales



Residuales vs. ajustados en cuatro situaciones: solo el primero es un modelo sano.

En nuestros datos



¿Patrón aleatorio o tendencia?
Una curvatura sugeriría que el efecto de las horas no es constante.

QQ-plot: la idea

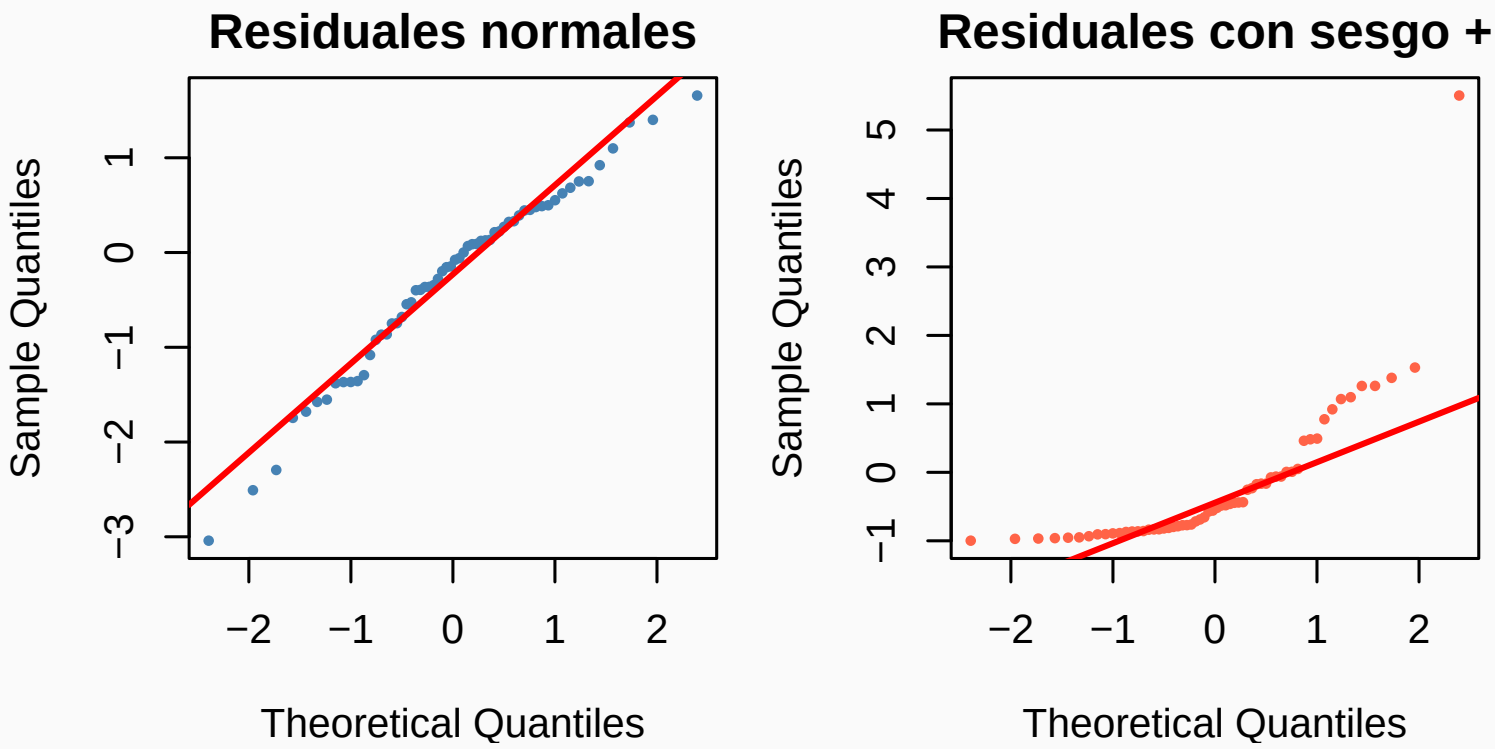
El gráfico Q-Q compara los residuales **observados** con los que tendríamos si los errores fueran **normales**.

La lógica en pocas palabras

1. Ordenamos los residuales de menor a mayor.
2. Calculamos qué valor ocuparía cada posición en una campana normal.
3. Graficamos un contra el otro.

Si los puntos siguen la diagonal $\rightarrow$ normalidad. El ejemplo numérico paso a paso está en el **Anexo D**.

QQ-plot: residuales normales vs. con sesgo



Izquierda: puntos cerca de la diagonal $\rightarrow$ normalidad razonable. \
Derecha: los puntos se curvan en la cola derecha $\rightarrow$ sesgo positivo.

Una prueba formal: Shapiro-Wilk

```
shapiro.test(residuals(reg))
```

```
##
##  Shapiro-Wilk normality test
##
## data:  residuals(reg)
## W = 0.97315, p-value = 0.2076
```

Lectura

H_0: los residuales provienen de una distribución normal. Un p-valor alto (por ejemplo > 0.05) **no rechaza** la normalidad.

Con muestras muy grandes la prueba rechaza desviaciones triviales: acompañe siempre con el QQ-plot.

Leverage y Cook: dos ideas distintas

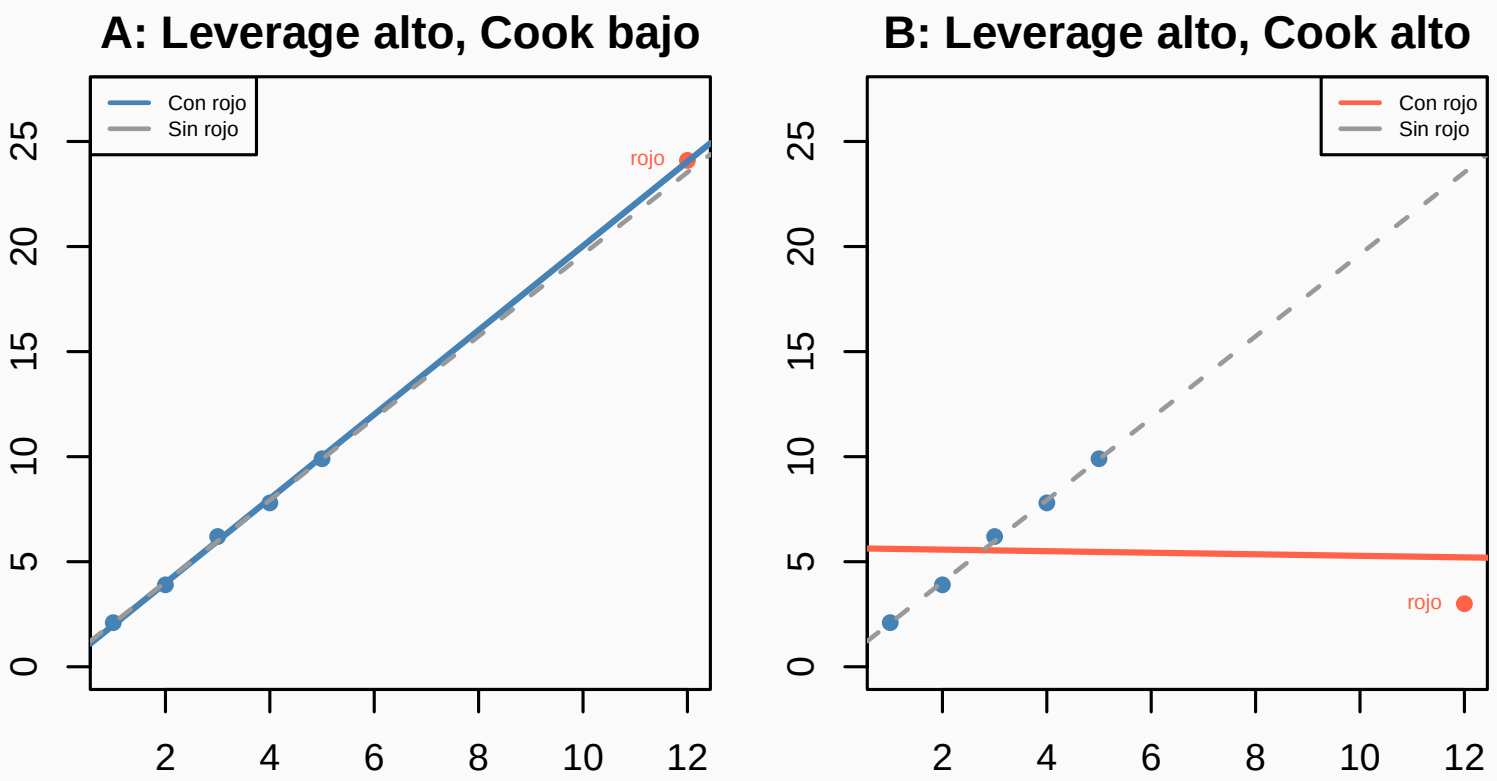
Concepto	**¿Qué mide?**	**Umbral típico**
Leverage h_{ii}	Qué tan atípico es el **valor de** X	$> 2(p+1)/n$
Cook D_i	Cuánto cambia $\hat{\beta}$ si eliminamos i	$> 4/n$

Una analogía: el balancín

Leverage (apalancamiento) = palanca
En un balancín, un niño sentado **lejos del centro** mueve mucho más el balancín que uno sentado cerca. Una observación con X extremo tiene mucha palanca sobre la recta.

Distinción clave
Tener palanca no es lo mismo que ser **influyente**: la observación influyente además tiene un **residual grande**.

Leverage y Cook: ejemplo visual



- **A**: el punto rojo ($X = 12$) está lejos de $\bar{X}$ pero *sigue* la tendencia. La recta no cambia al incluirlo. Cook **bajo**.
- **B**: el punto rojo ($X = 12$) está lejos de $\bar{X}$ *y además* tiene un Y muy distinto de lo esperado. La recta se distorsiona. Cook **alto**.

En la práctica

Un atípico influyente no se elimina sin más: se investiga (¿error de digitación? ¿caso especial?) y se reporta con y sin él.

Checklist de supuestos

Supuesto	**Herramienta**	**Si falla...**
Linealidad	Res. vs. Fitted	Transformar X o Y
Homocedasticidad	Scale-Location	SE robustos / WLS
Normalidad	Q-Q / Shapiro-Wilk	Transformar / no paramétrico
Sin autocorr.	Durbin-Watson	Series de tiempo

Regla de oro

Un R^2 alto no garantiza un modelo válido. El diagnóstico de supuestos es **obligatorio** antes de usar el modelo para inferencia o predicción.

7. Uso del modelo

Etapa 4: Predicción puntual

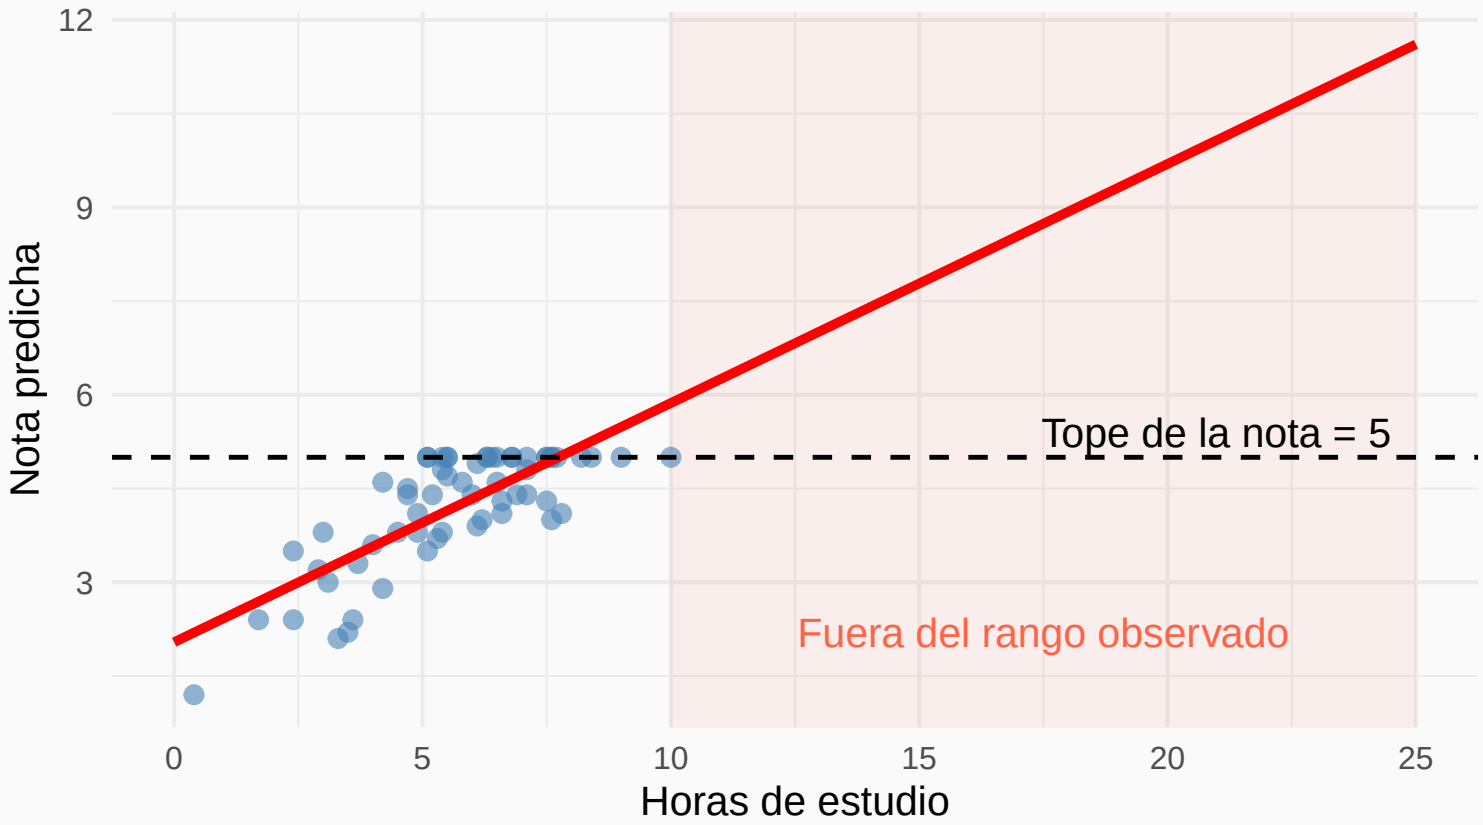
```r
# Estudiante que estudio 7 horas
nueva_obs <- data.frame(horas = 7)
predict(reg, newdata = nueva_obs)
```

```
##        1
## 4.720052
```

A mano

$$\hat{y} = 2.04 + 0.383 \times 7 = 4.72$$

Cuidado: no extrapolar



Con 20 horas el modelo predice una nota de 9.7: **imposible**.

Regla práctica de la predicción

No extrapolar

El modelo solo es confiable **dentro del rango de los datos** con los que se ajustó (aquí, entre 0.4 y 10 horas).

- Fuera de ese rango no sabemos si la relación sigue siendo una recta.
- Ejemplo: extrapolar las ventas a un nivel de publicidad nunca probado.

IC vs. IP: el código

```r
nueva_obs <- data.frame(horas = 7)

# Intervalo de CONFIANZA: para la nota MEDIA de estudiantes con 7h
predict(reg, newdata = nueva_obs,
        interval = "confidence", level = 0.95)
```

```
##        fit      lwr      upr
## 1 4.720052 4.532328 4.907777
```

```r
# Intervalo de PREDICCION: para UN estudiante especifico con 7h
predict(reg, newdata = nueva_obs,
        interval = "prediction", level = 0.95)
```

```
##        fit      lwr     upr
## 1 4.720052 3.532964 5.90714
```

IC vs. IP: ¿cuál usar?

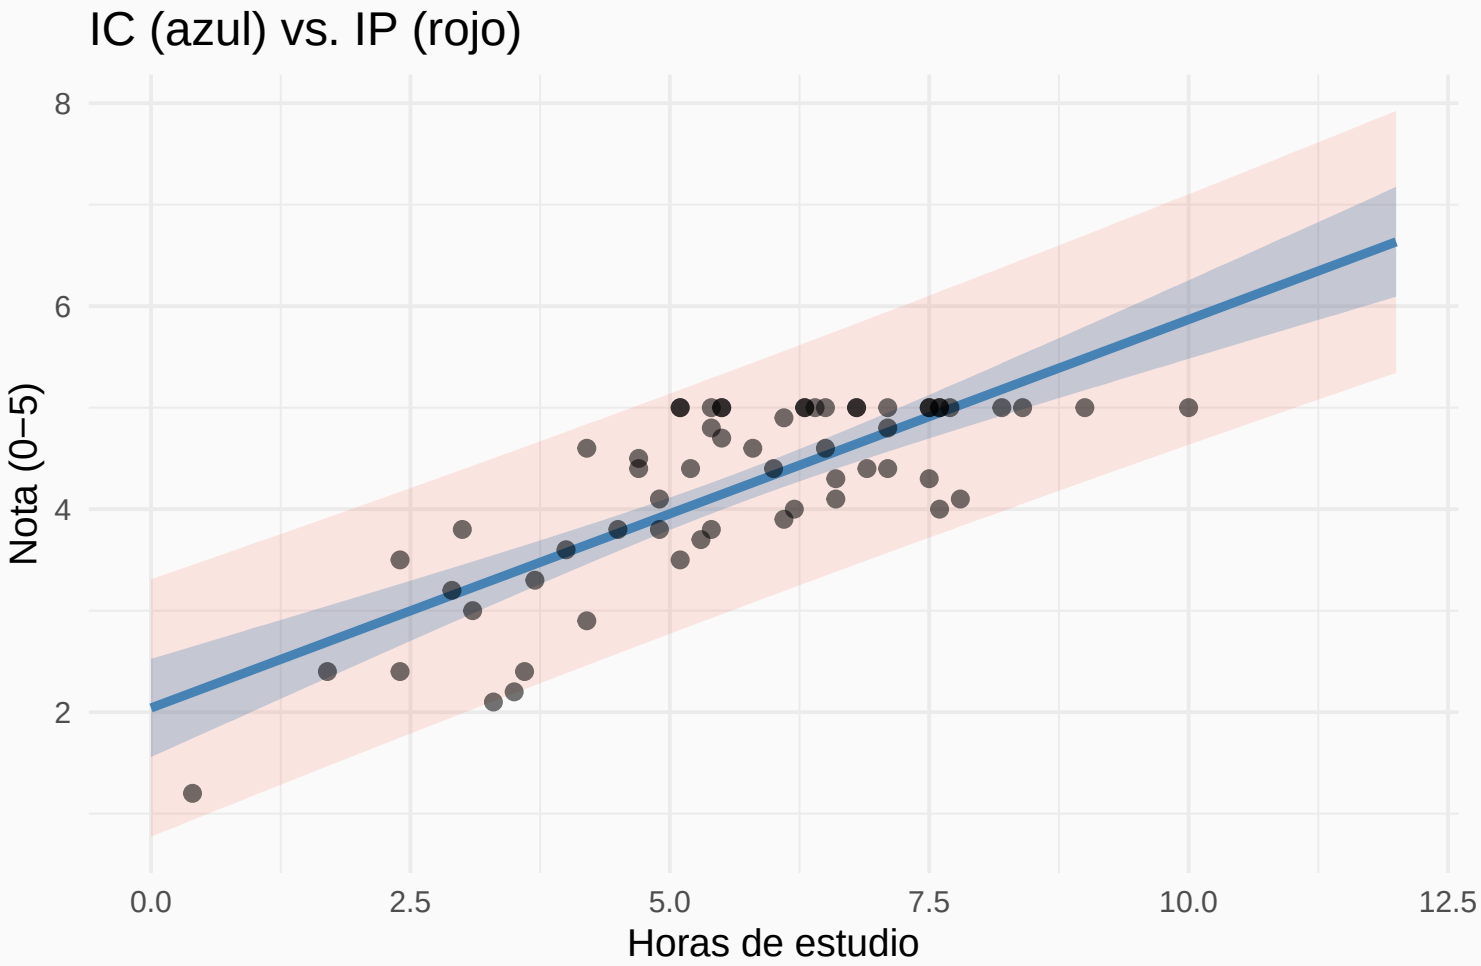
Intervalo	Interpreta
Confianza	Nota promedio de **todos** los estudiantes con 7h
Predicción	Nota de **un estudiante específico** que estudió 7h

Analogía

Predecir la estatura **promedio** de los hombres de 30 años es mucho más preciso que predecir la estatura de **un hombre específico** de 30 años.

El IP es siempre más amplio: incorpora incertidumbre sobre la media **y** variabilidad individual.

IC vs. IP: el gráfico



Casi todos los puntos caen dentro del **IP** (rojo). La banda **IC** (azul) es más estrecha porque estima la media, no individuos.

Una limitación del intervalo de predicción

Para un estudiante con 7 horas:

- Nota esperada: 4.72.
- IP al 95%: entre 3.53 y 5.91.

¡El límite superior supera 5.0!
El modelo lineal no conoce el tope de la nota. Los intervalos son una guía, no un hecho: hay que revisar si tienen sentido en el contexto.

¿Para qué sirve predecir? Aplicaciones

Decisión	Ejemplo
Planear inventarios	Predecir la demanda mensual de un producto
Fijar precios	Estimar el arriendo justo de un inmueble
Asignar presupuesto	Anticipar las ventas según la inversión publicitaria
Detectar anomalías	Marcar gastos muy alejados de lo esperado

En todos los casos, el **intervalo de predicción** cuantifica el riesgo de equivocarnos.

Ejercicio 2: predecir con cuidado

Ejercicio 2 – Predicción
Con el modelo `reg`:

1. Prediga la nota para 4 y para 10 horas de estudio, con su IP al 95%.
2. ¿Cuál de las dos predicciones es más precisa? ¿Por qué el intervalo se ensancha en los extremos?
3. ¿Qué pasa si predice para 20 horas?

Resumen de la Sesión 6

1. Identificamos la relación lineal entre horas de estudio y nota.
2. Estimamos por MCO: R^2 mide cuánto mejora la recta sobre el promedio.
3. Justificamos la prueba F con simulación.
4. Diagnosticamos supuestos: residuales, QQ-plot, Cook y leverage.
5. Predijimos con IC e IP, sin extrapolar.
6. Distinguimos correlación de causalidad.

SESIÓN 7

Puente desde la Sesión 6

Recapitulación — Sesión 6

En la Sesión 6 completamos el ciclo con **una sola variable predictora**:

1. Identificamos la relación lineal entre horas de estudio y nota.
2. Estimamos por MCO: motivamos R^2 a través del modelo promedio (M2).
3. Justificamos la prueba F y la validamos mediante simulación.
4. Diagnosticamos supuestos: residuales, QQ-plot, Cook y leverage.
5. Usamos el modelo para predecir con IC e IP.
6. Introdujimos la distinción entre correlación y causalidad.

Objetivo de la Sesión 7

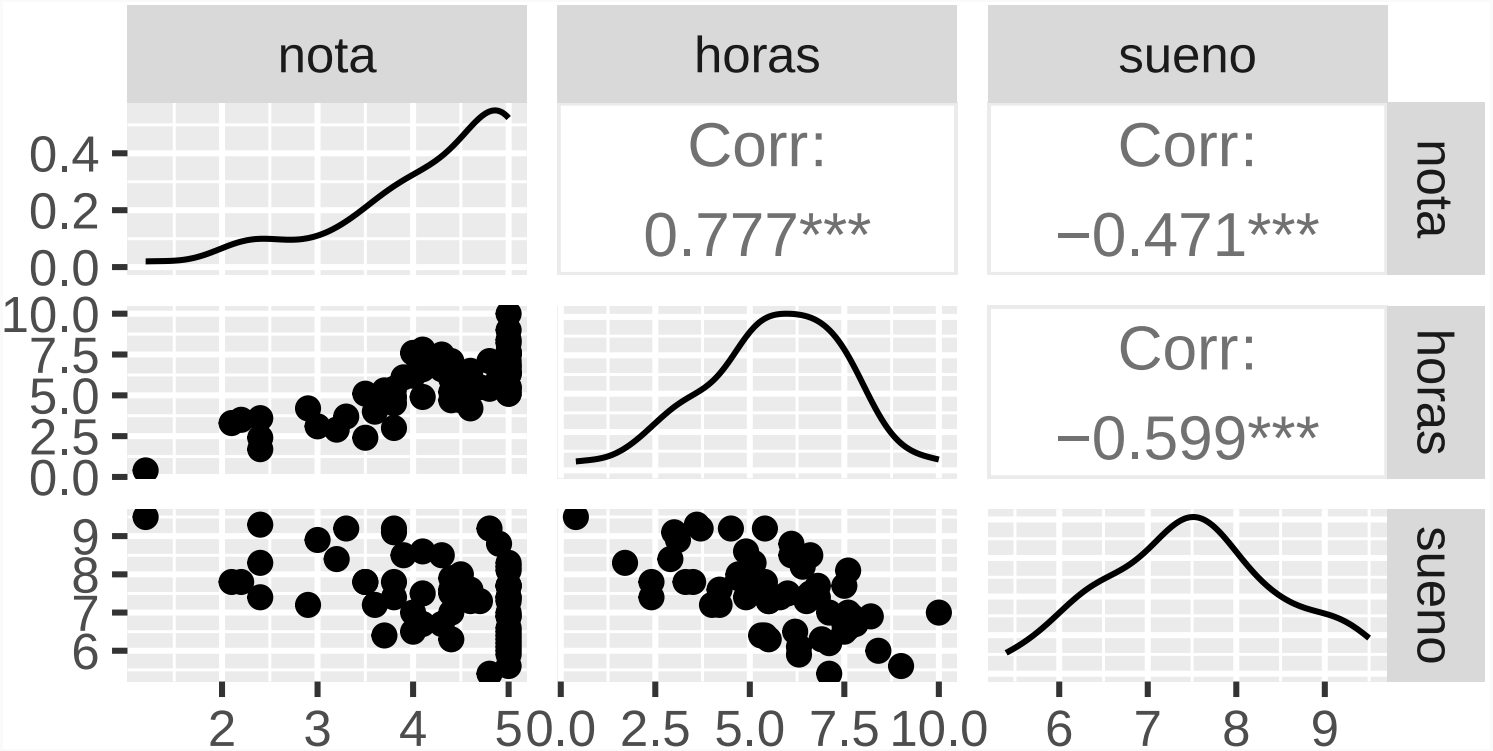
Extender a **múltiples predictores**, desarrollar el concepto de variable de confusión, elaborar sobre causalidad, y dominar el diagnóstico del modelo múltiple.

8. Regresión Lineal Múltiple

Motivación: ¿por qué más de una variable?

¿La nota depende solo de las horas de estudio, o también de cuánto durmió el estudiante la noche anterior?

```
ggpairs(datos %>% dplyr::select(nota, horas, sueno),
        progress = FALSE)
```



¿Qué ganamos con más variables?

- **Mejor predicción**: más información, menos error.
- **Comparaciones justas**: comparar estudiantes "en igualdad de condiciones".
- **Separar efectos**: distinguir qué parte se debe a cada variable.

Un ejemplo cotidiano

El arriendo no depende solo del área: también del estrato, la ubicación y la antigüedad. Una sola variable cuenta solo una parte de la historia.

El modelo de regresión múltiple

Modelo general con p predictores

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i$$

- Cada β_j es el efecto de x_j **manteniendo las demás constantes**.
- Se estima también por MCO: minimizar SC_E.

La forma matricial del modelo y del estimador está en el **Anexo C**.

Aplicaciones de la regresión múltiple

Contexto	**Pregunta**	**Predictores típicos**
Avalúo inmobiliario	¿Cuánto vale?	Área, estrato, antigüedad
Brecha salarial	¿Gana menos?	Experiencia, formación
Marketing	¿Qué canal vende?	Inversión por canal
Salud pública	¿Qué eleva el riesgo?	Edad, peso, hábitos

El quinto supuesto: no multicolinealidad

Supuesto 5: No multicolinealidad
Ningún predictor X_j puede ser una combinación lineal exacta de los demás.

Si esto ocurre, el modelo no tiene una solución única: no se pueden separar los efectos de las variables.

Multicolinealidad perfecta vs. aproximada

La **perfecta** hace el modelo irresoluble. La **aproximada** (alta correlación entre predictores) no impide estimar, pero **infla las varianzas** de $\hat{\beta}$: coeficientes inestables e inferencia poco confiable.

Multicolinealidad: nuestro caso

En nuestro ejemplo

Las horas de sueño tenderían a estar negativamente correlacionadas con las horas de estudio (quien estudia más, duerme menos). Si la correlación es muy alta, los efectos de ambas variables se confunden entre sí.

Estimación del modelo múltiple en R

```r
mod <- lm(nota ~ horas + sueno, data = datos)
summary(mod)
```

```
##
## Call:
## lm(formula = nota ~ horas + sueno, data = datos)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -1.2077 -0.3896  0.0478  0.5215  1.0122
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  2.116659   0.938544   2.255    0.028 *
## horas        0.380124   0.051287   7.412 6.55e-10 ***
## sueno       -0.008128   0.097752  -0.083    0.934
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5907 on 57 degrees of freedom
## Multiple R-squared:  0.6038, Adjusted R-squared:  0.5899
## F-statistic: 43.43 on 2 and 57 DF,  p-value: 3.473e-12
```

Comparando simple vs. múltiple

```
data.frame(
  Modelo = c("Simple (horas)",
             "Multiple (horas + sueno)"),
  R2     = round(c(summary(reg)$r.squared,
                   summary(mod)$r.squared), 4),
  R2_adj = round(c(summary(reg)$adj.r.squared,
                   summary(mod)$adj.r.squared), 4),
  sigma  = round(c(summary(reg)$sigma,
                   summary(mod)$sigma), 4)
)
```

```
##                     Modelo     R2 R2_adj  sigma
## 1           Simple (horas) 0.6037 0.5969 0.5856
## 2 Multiple (horas + sueno) 0.6038 0.5899 0.5907
```

Lectura

Los estadísticos casi no cambian: las horas de sueño **no aportan información real** sobre la nota, más allá de las horas de estudio.

Ahora con capacidad previa

```r
mod_cap <- lm(nota ~ horas + capacidad, data = datos)

data.frame(
  Modelo = c("Simple (horas)",
             "Multiple (horas + capacidad)"),
  coef_horas = round(c(coef(reg)["horas"],
                       coef(mod_cap)["horas"]), 4),
  R2_adj     = round(c(summary(reg)$adj.r.squared,
                       summary(mod_cap)$adj.r.squared), 4)
)
```

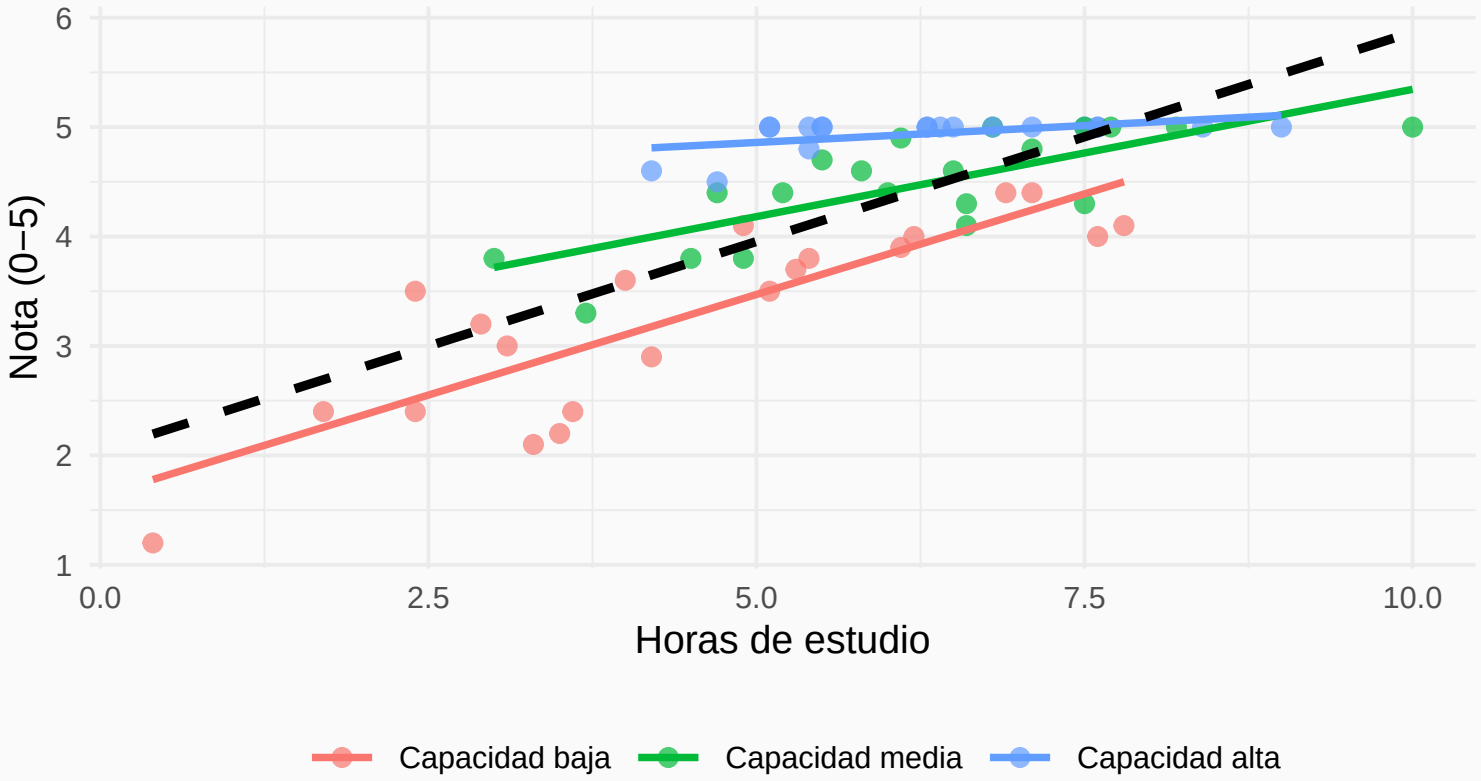
```
##                         Modelo coef_horas R2_adj
## 1                Simple (horas)     0.3827 0.5969
## 2 Multiple (horas + capacidad)     0.1741 0.8850
```

¡El coeficiente de las horas cambió!

Antes y después de controlar por capacidad
Coeficiente de `horas`: de **0.38** (modelo simple) a **0.17** (modelo múltiple).

¿Por qué?
Los estudiantes con más capacidad previa **estudian más y también sacan mejor nota**. El modelo simple le atribuía a las horas parte del mérito de la capacidad: eso es una **variable de confusión**.

Confusión en una imagen



Línea negra: pendiente global (empinada). Líneas de color: pendiente **dentro** de cada grupo de capacidad (más suave).

Interpretación: “manteniendo las demás constantes”

```
round(coef(summary(mod_cap)), 4)
```

```
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)   1.5632     0.1349 11.5852        0
## horas         0.1741     0.0277  6.2769        0
## capacidad     0.3033     0.0251 12.0984        0
```

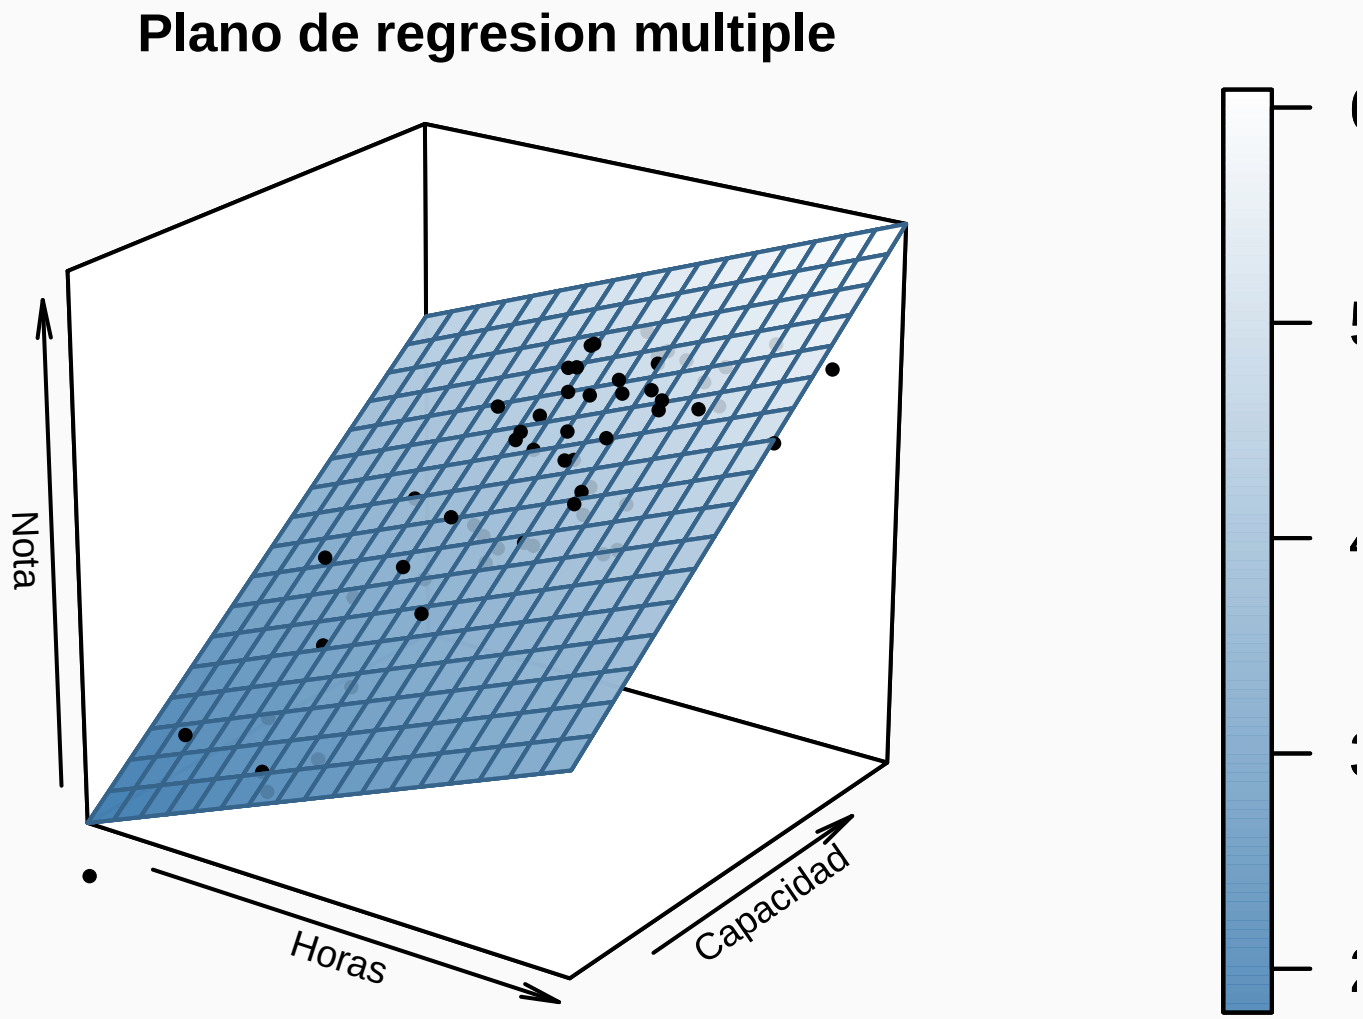
Qué dice cada coeficiente

- $\hat{\beta}_{\text{horas}} = 0.17$: efecto de una hora adicional de estudio, **dado el mismo nivel de capacidad previa**.
- $\hat{\beta}_{\text{capacidad}} = 0.3$: efecto de un punto más de capacidad previa, **dado el mismo número de horas de estudio**.

¿Esto ya es causal?

Controlar por más variables **reduce** la confusión pero no la elimina completamente si hay variables no medidas. Más sobre esto a continuación.

Visualización en 3D: el plano de regresión



Con dos predictores la recta se convierte en un **plano**. MCO minimiza la suma de distancias cuadradas verticales entre los puntos y el plano.

9. Evaluación del modelo múltiple

Prueba F global

```r
s_mod <- summary(mod_cap)
f_val <- s_mod$fstatistic
p_f   <- pf(f_val[1], f_val[2], f_val[3], lower.tail = FALSE)
cat("F =", round(f_val[1], 3),
    "| gl1 =", f_val[2], "| gl2 =", f_val[3],
    "| p-valor =", format(p_f, digits = 3, scientific = TRUE))
```

```
## F = 228.118 | gl1 = 2 | gl2 = 57 | p-valor = 6.29e-28
```

ANOVA del modelo múltiple

```
anova(mod_cap)
```

```
## Analysis of Variance Table
##
## Response: nota
##           Df  Sum Sq Mean Sq F value    Pr(>F)
## horas      1 30.3019 30.3019  309.86 < 2.2e-16 ***
## capacidad  1 14.3138 14.3138  146.37 < 2.2e-16 ***
## Residuals 57  5.5741  0.0978
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Inferencia individual (prueba t)

```
round(coef(summary(mod_cap)), 4)
```

```
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)   1.5632     0.1349 11.5852        0
## horas         0.1741     0.0277  6.2769        0
## capacidad     0.3033     0.0251 12.0984        0
```

Ambos predictores son significativos: cada uno aporta **dado el otro**.

Predicción con el modelo múltiple

```
nueva_obs_mult <- data.frame(horas = 7, capacidad = 6)
predict(mod_cap, newdata = nueva_obs_mult,
        interval = "prediction", level = 0.95)
```

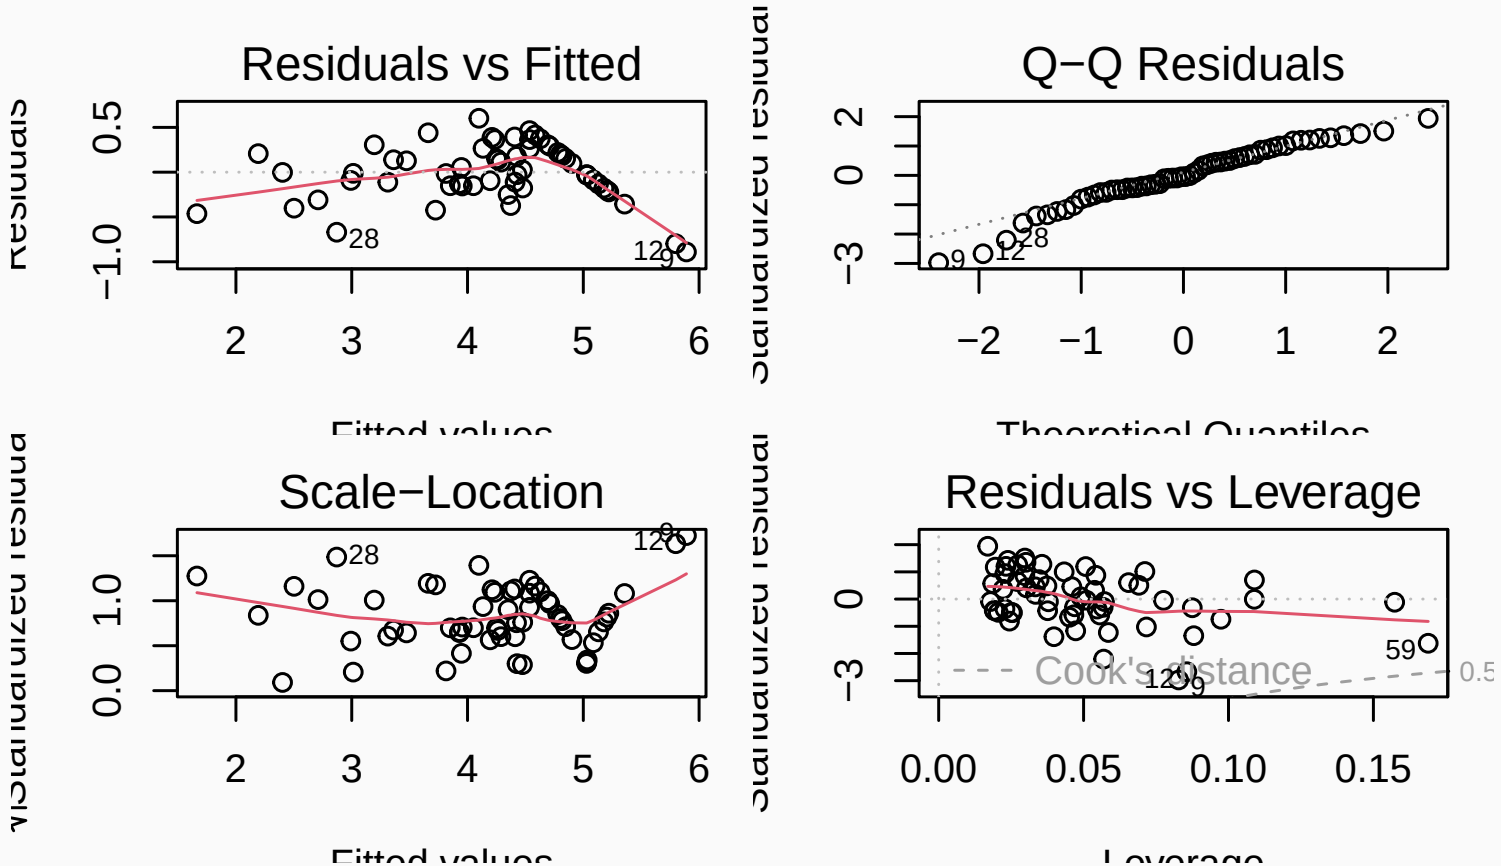
```
##        fit      lwr      upr
## 1 4.602061 3.967578 5.236544
```

El modelo múltiple produce intervalos más estrechos que el simple porque la capacidad previa reduce la incertidumbre residual.

10. Validación del modelo múltiple

Diagnóstico del modelo múltiple

```
par(mfrow = c(2, 2), mar = c(3.5, 3.5, 2, 1))
plot(mod_cap)
```




```
par(mfrow = c(1, 1))
```

Ejercicio 3: verificación de supuestos

Ejercicio 3 – Validación del modelo múltiple
Analice los cuatro gráficos de diagnóstico:

1. Residuales vs. Ajustados: ¿hay patrón sistemático?
2. Q-Q: ¿se aproximan los residuales a la normalidad?
3. Scale-Location: ¿varianza constante?
4. Leverage: ¿hay observaciones influyentes?

Pregunta para pensar

¿Mejorar el ajuste (R^2 mayor) garantiza un mejor cumplimiento de los supuestos?

11. Multicolinealidad

¿Qué es y por qué importa?

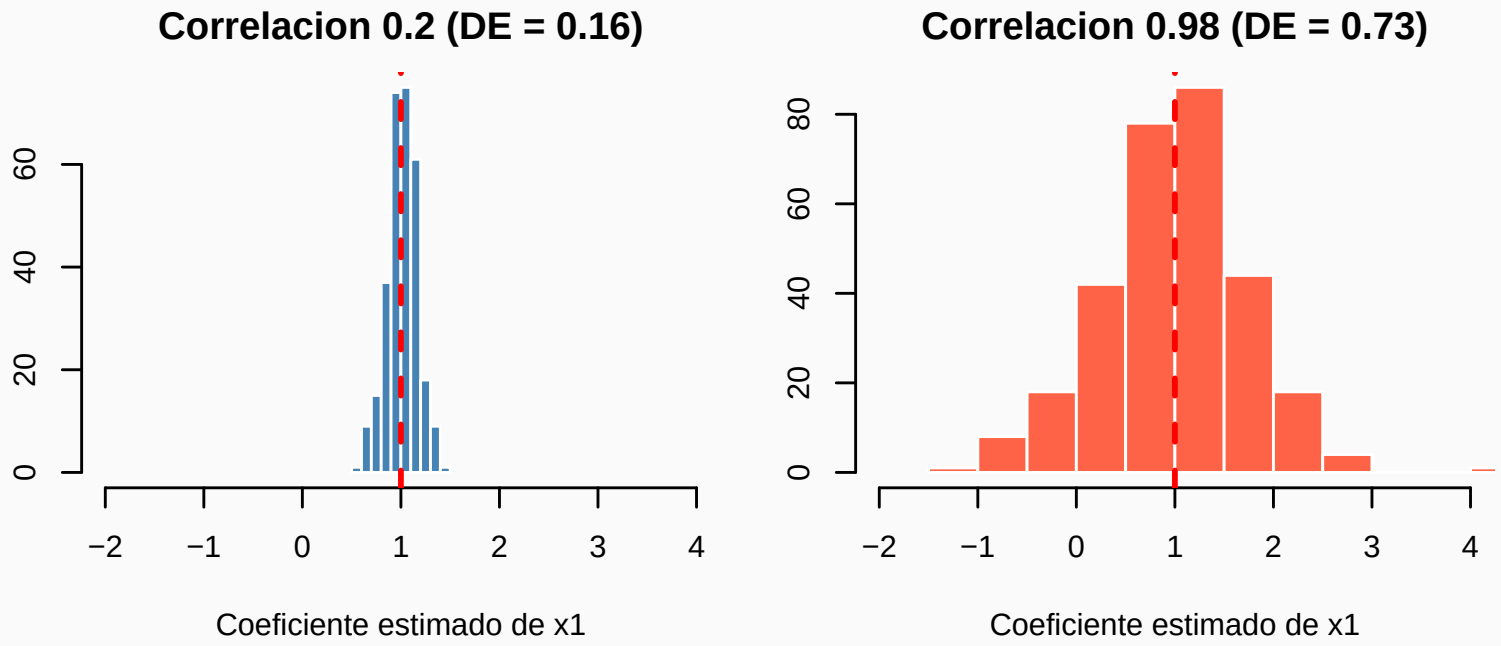
Definición
Existe multicolinealidad cuando dos o más predictores están **altamente correlacionados** entre sí.

Analogía
Dos personas que opinan exactamente lo mismo: si el grupo cambia de parecer, no podemos saber **a cuál de las dos** se debe el cambio.

Consecuencias de la multicolinealidad

Consecuencia	Descripción
Inestabilidad	Pequeños cambios en los datos $\rightarrow$ grandes cambios en coef.
SE inflados	IC muy amplios; p-valores se inflan
Difícil interp.	No se aísla el efecto de cada variable
Pred. estable	Puede predecir bien aunque los coef. sean malos

Simulación: predictores casi idénticos



El valor verdadero es 1 (línea roja). Con predictores casi idénticos, el coeficiente estimado salta de muestra en muestra: **inestabilidad**.

Detección 1: correlaciones entre predictores

```
round(cor(datos %>% dplyr::select(horas, sueno, capacidad)), 3)
```

```
##             horas  sueno capacidad
## horas       1.000 -0.599     0.621
## sueno      -0.599  1.000    -0.391
## capacidad   0.621 -0.391     1.000
```

Limitación de la correlación por pares

La correlación de Pearson solo detecta relaciones **entre pares**. La multicolinealidad puede existir entre combinaciones de tres o más variables aunque las correlaciones por pares sean moderadas.

Detección 2: Factor de Inflación de Varianza (VIF)

VIF para el predictor X_j

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

donde R_j^2 es el R^2 de la regresión de X_j sobre los demás predictores.

Idea: si los demás predictores ya "explican" a X_j, entonces X_j es redundante.

Cómo interpretar el VIF

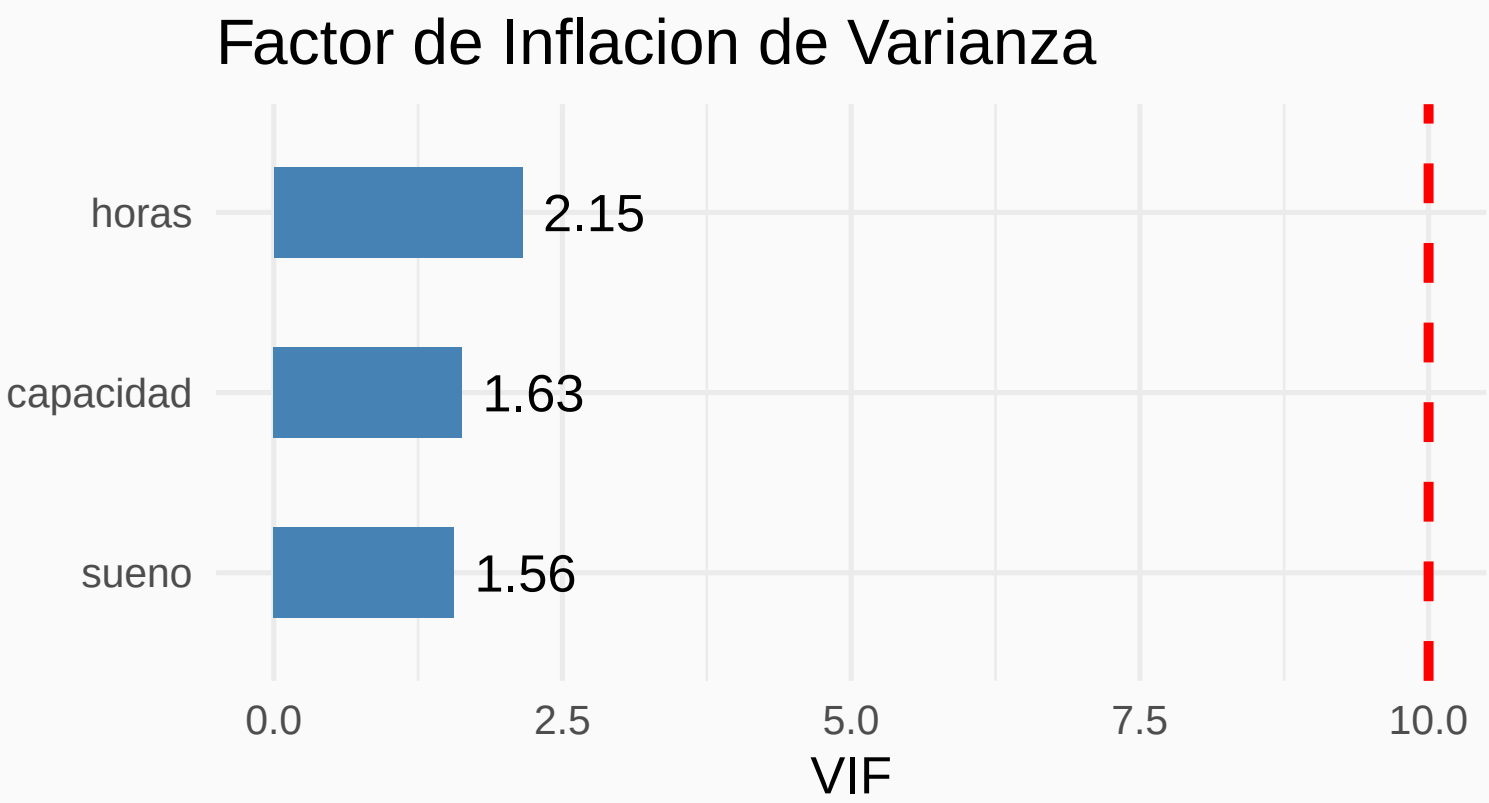
VIF	Interpretación
$= 1$	Sin multicolinealidad
1–5	Moderada (generalmente aceptable)
5–10	Alta (preocupante)
> 10	Severa: acción requerida

VIF en nuestros datos

```
library(car)
mod_full <- lm(nota ~ horas + sueno + capacidad, data = datos)
vif(mod_full)
```

```
##     horas     sueno capacidad
##  2.154885  1.561470  1.630055
```

Visualizando el VIF



Todos los VIF están muy por debajo de 10: no hay multicolinealidad preocupante.

¿Qué hacer si los VIF son altos?

1. **Eliminar** variables redundantes.
2. **Combinar** variables vía ACP (conecta con la Sesión 4).
3. **Regularizar** con Ridge/LASSO (se ve en AAD).

12. Correlación, causalidad y el modelo de regresión

El modelo es correlacional, no causal

Lo que hace la regresión
Cuantifica la asociación **promedio** entre X e Y en los datos. Controlar por más variables (modelo múltiple) reduce la confusión pero **no garantiza** inferencia causal.

Una pregunta causal

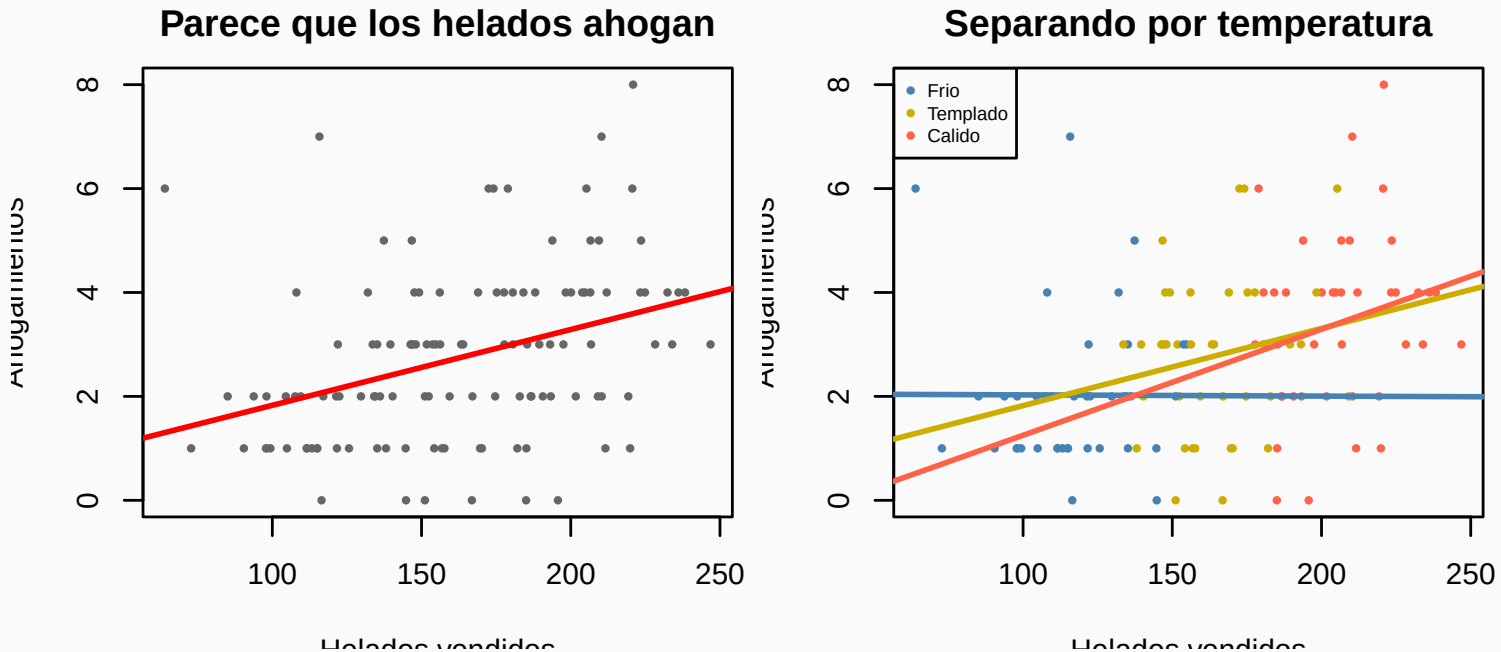
Si un estudiante que *normalmente* estudia 3 horas **decide** estudiar 7, ¿cuánto mejorará su nota?

La regresión nos dice: en los datos, los estudiantes con 7h obtienen en promedio cierta cantidad de puntos más que los de 3h. Pero esos grupos pueden diferir en muchas otras cosas (capacidad, motivación, dificultad del curso...).

El problema

Comparamos estudiantes **distintos** (7h vs. 3h), no el **mismo** estudiante en dos escenarios. Para responder la pregunta causal necesitaríamos algo más que regresión.

Simulación: helados y ahogamientos



Dentro de cada banda de temperatura la asociación se debilita; al controlar por la temperatura exacta (siguiente lámina) desaparece. El calor era la causa común.

Controlar por temperatura

```
##             Estimate Std. Error t value Pr(>|t|)
## sin_temp      0.0146     0.0035  4.2193   0.0000
## con_temp      0.0037     0.0103  0.3623   0.7178
```

Lectura

Sin controlar por temperatura, los helados parecen **significativos**. Al incluir la temperatura, su efecto se desvanece.

Correlación no implica causalidad: ejemplo 1

Ejemplo 1: libros en casa

Los hogares con más libros tienen hijos con mejor rendimiento escolar. ¿Los libros causan el rendimiento? No directamente: ambos son consecuencia del nivel educativo de los padres (variable confusora). Regalar libros a hogares de bajo nivel educativo no produce el mismo efecto.

Correlación no implica causalidad: ejemplo 2

Ejemplo 2: hospitales y mortalidad

Los hospitales con mejor equipamiento tienen mayor tasa de mortalidad. ¿Mejor equipamiento causa muerte? No: los pacientes más graves van a los mejores hospitales (sesgo de selección). Controlar por gravedad del paciente invierte la relación.

La pregunta correcta para causalidad

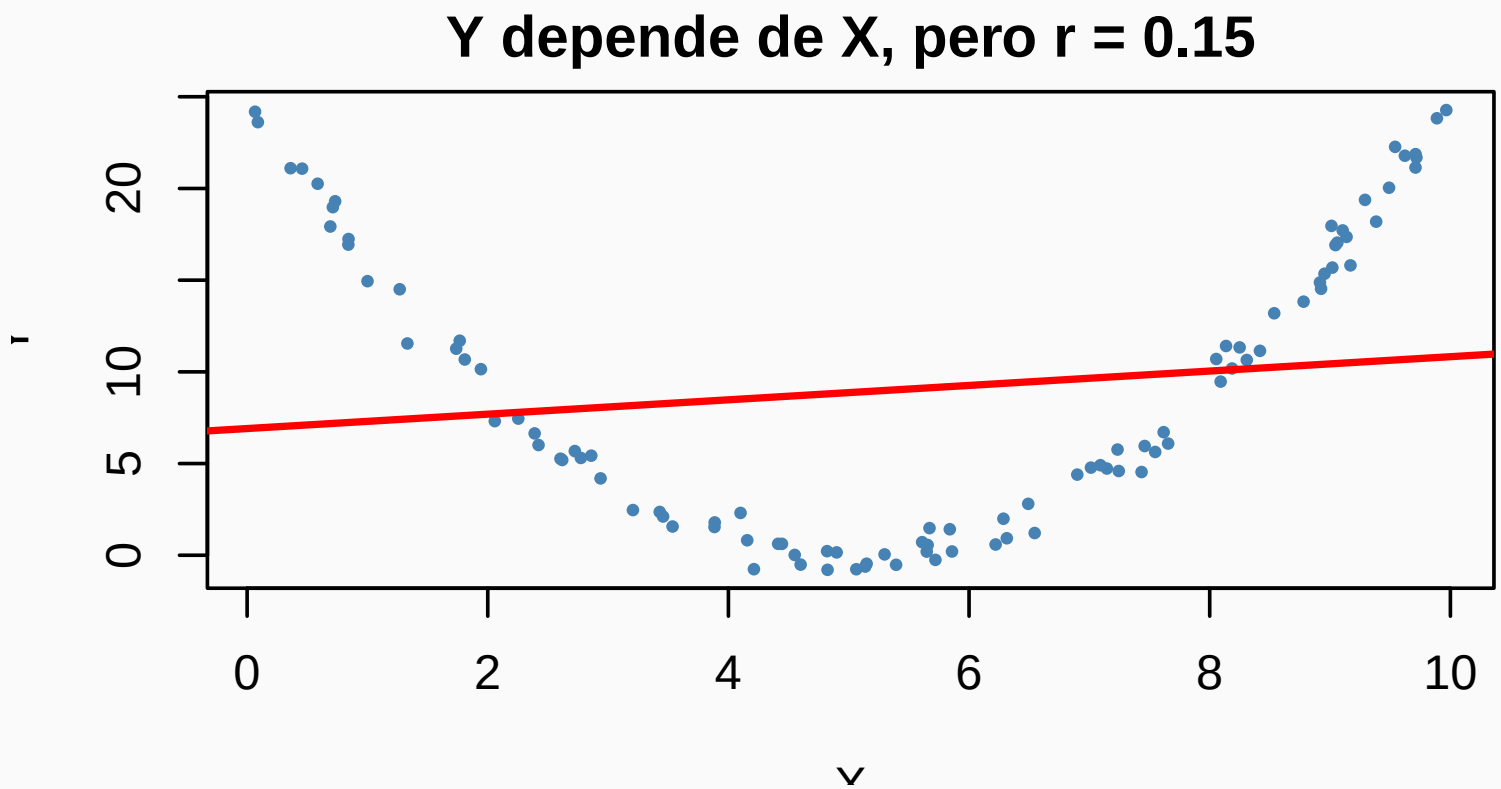
Dos preguntas distintas
Causal: "Si **intervenimos** y forzamos $X = x_0$, ¿qué valor tomaría Y en promedio?"

Descriptiva: "Entre los que observamos con $X = x_0$, ¿qué Y tienen en promedio?"

¿Implica causalidad correlación?

Correlación no implica causalidad
X e Y correlacionados no garantiza que X cause Y: puede haber una causa común (factor de confusión), o la causalidad puede ser inversa.

¿Y al revés? ¿La causalidad implica correlación (lineal)?



¿Causalidad implica correlación (lineal)?
No necesariamente. Si X causa Y a través de una relación **no monótona** (por ejemplo $Y = (X - 5)^2$), la correlación de Pearson puede ser ≈ 0 aunque X determine completamente a Y.

Lo que sí se cumple
La causalidad sí implica **alguna forma de dependencia**. Si dos variables son *independientes*, ninguna puede causar la otra. La independencia descarta causalidad; la dependencia la sugiere pero no la garantiza.

¿Cómo se encuentra la causalidad?

La causalidad no se puede establecer con regresión observacional sola. Se requieren estrategias adicionales:

Estrategia	**Idea central**
Experimento aleatorizado (RCT)	Asignar X al azar
Experimento natural	Variación "cuasi-aleatoria" de X
Variables instrumentales	Z afecta X pero no Y directamente
Diferencias en diferencias	Antes/después, tratado vs. control
Grafos causales (DAGs)	Modelar la estructura causal

Esas estrategias, con ejemplos

Estrategia	Ejemplo práctico
Experimento aleatorizado	Ensayos clínicos de una vacuna
Experimento natural	Becas asignadas por sorteo
Variables instrumentales	Distancia a la universidad como “empujón” a estudiar
Diferencias en diferencias	Ventas de comercios cerca y lejos de una nueva ciclorruta, antes y después
Grafos causales (DAGs)	Dibujar qué causa qué antes de decidir qué variables controlar

Experimento aleatorizado

El **experimento aleatorizado** (RCT) garantiza inferencia causal sin supuestos adicionales: asignar aleatoriamente cuántas horas estudia cada estudiante (¡muy poco práctico!) eliminaría todas las variables de confusión.

13. Extensiones del modelo lineal

Selección de variables: ¿con cuál modelo me quedo?

Criterio de Información de Akaike (AIC)
Equilibra **qué tan bien ajusta** el modelo con **qué tan complejo** es.

Menor AIC = mejor modelo.

BIC (criterio de Schwarz)
Penaliza más la complejidad; prefiere modelos parsimoniosos con n grande.

Las fórmulas están en el **Anexo C**.

AIC y BIC en nuestros modelos

```
data.frame(
  AIC = round(AIC(reg, mod, mod_cap, mod_full)$AIC, 1),
  BIC = round(BIC(reg, mod, mod_cap, mod_full)$BIC, 1),
  row.names = c("horas", "horas+sueno", "horas+capacidad", "las tres"))
```

```
##                    AIC   BIC
## horas            110.0 116.3
## horas+sueno      112.0 120.4
## horas+capacidad   35.7  44.1
## las tres          37.7  48.1
```

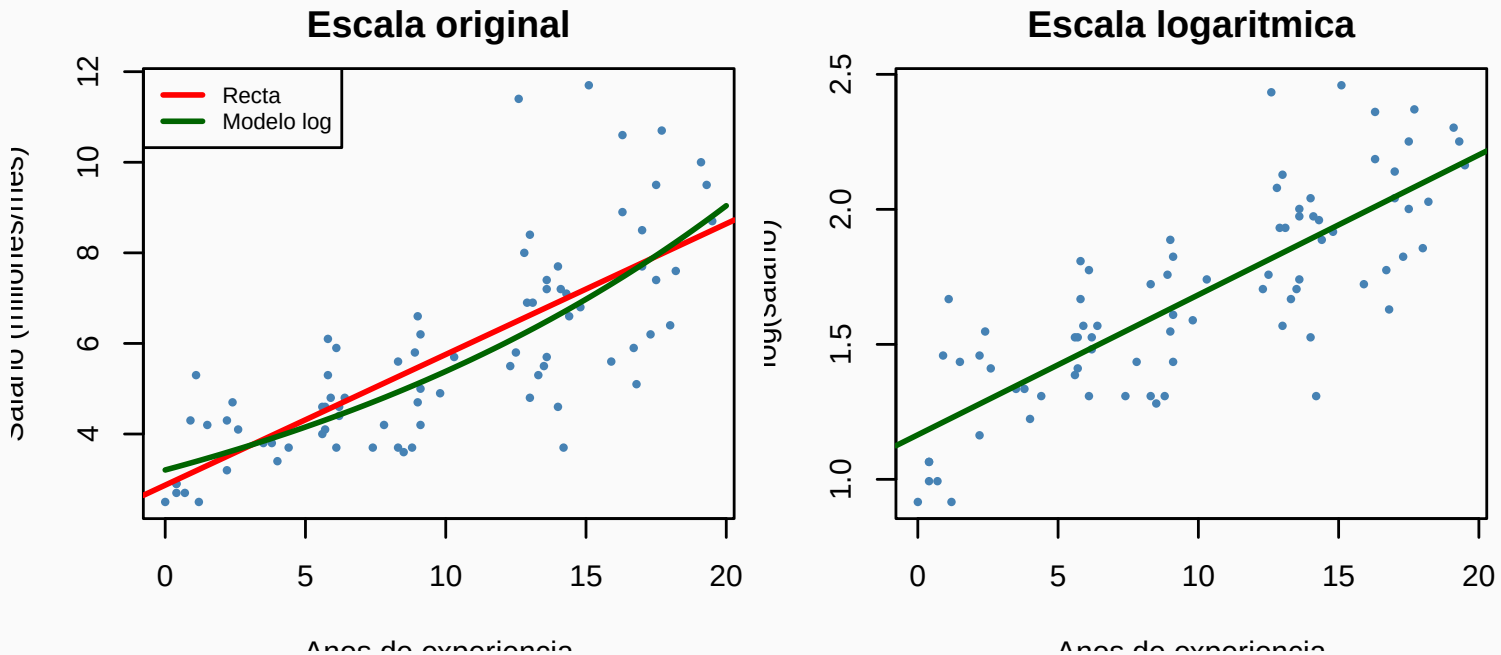
Lectura

Los modelos con capacidad tienen un AIC y un BIC mucho menores.

Agregar sueno **no** mejora el criterio.

Transformaciones: ¿recta o curva?

Un segundo ejemplo: salario mensual (millones de pesos) y años de experiencia.



El salario crece **proporcionalmente**, no en pasos fijos: en escala logarítmica la relación es una recta.

Transformaciones: tabla de interpretaciones

Modelo	**Ecuación**	**Interpretación de $\hat{\beta}_1$**
Lineal-lineal	$Y = \beta_0 + \beta_1 X$	$\Delta Y = \beta_1 \cdot \Delta X$
Log-lineal	$\log Y = \beta_0 + \beta_1 X$	$\%\Delta Y \approx 100\beta_1 \cdot \Delta X$
Lineal-log	$Y = \beta_0 + \beta_1 \log X$	$\Delta Y = (\beta_1/100) \cdot \%\Delta X$
Log-log	$\log Y = \beta_0 + \beta_1 \log X$	$\%\Delta Y \approx \beta_1 \cdot \%\Delta X$

Interpretando el modelo log-lineal

```
m_log <- lm(log(salario) ~ exper, data = salarios)
round(coef(m_log), 4)
```

```
## (Intercept)       exper
##      1.1650      0.0518
```

Lectura

Cada año adicional de experiencia se asocia con un aumento de aproximadamente **5.3%** en el salario.

Variables categóricas: el 0 y el 1

Muchas variables son categorías (programa, ciudad, ¿tiene posgrado?). Entran al modelo como **variables indicadoras**:

Persona	¿Posgrado?	Indicadora
Ana	Sí	1
Luis	No	0
Marta	Sí	1

$\hat{\beta}$ de la indicadora = diferencia promedio entre quienes la tienen y quienes no, **a igual experiencia**.

Modelo con una variable categórica

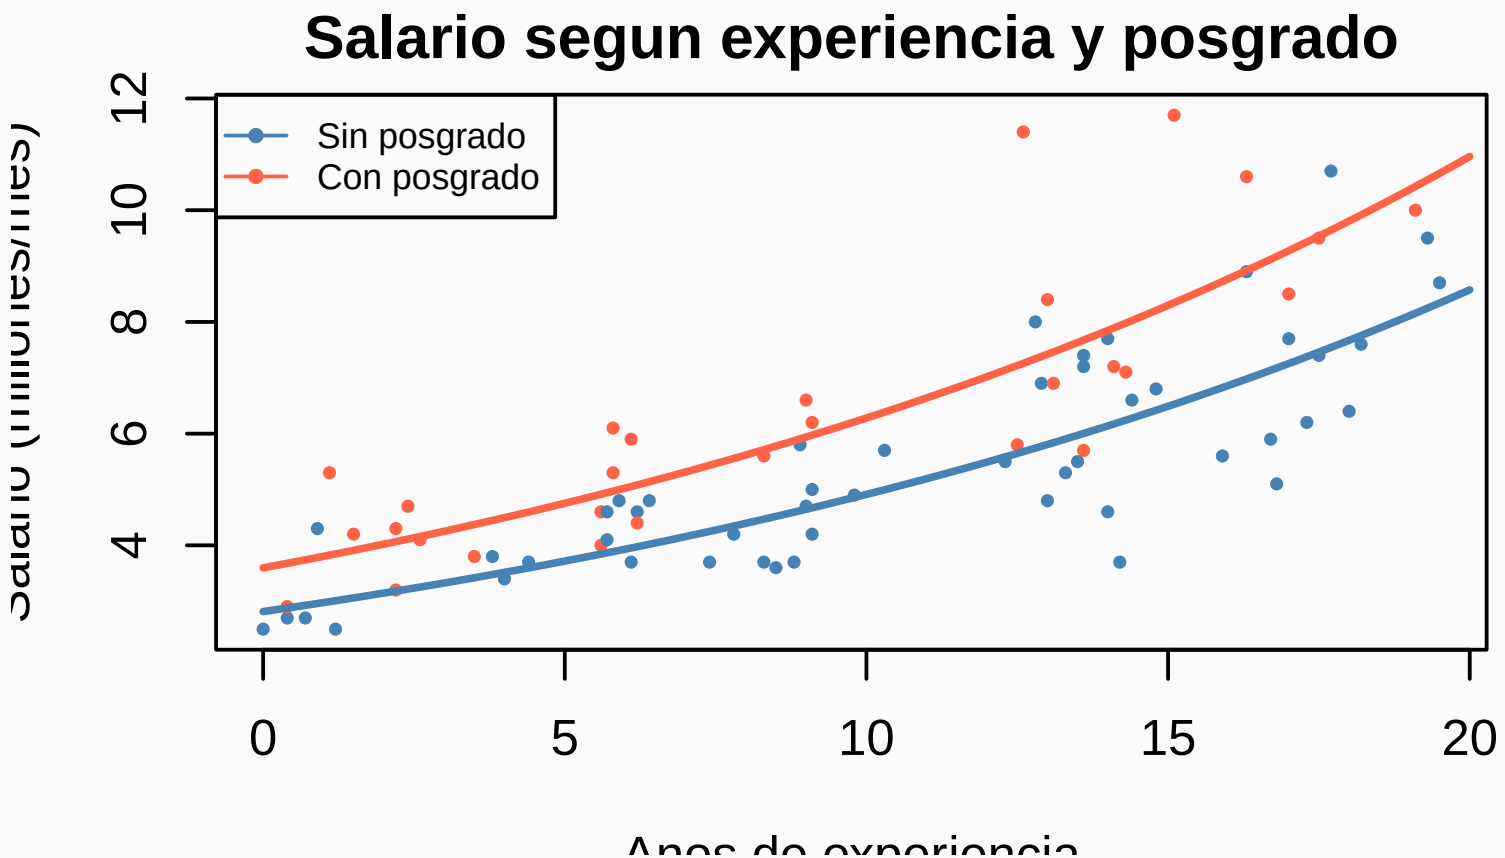
```
m_cat <- lm(log(salario) ~ exper + posgrado, data = salarios)
round(coef(summary(m_cat)), 4)
```

```
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)   1.0347     0.0484 21.3774        0
## exper         0.0557     0.0038 14.7519        0
## posgradoSi    0.2455     0.0443  5.5442        0
```

Lectura

A igual experiencia, tener posgrado se asocia con un salario **27.8%** mayor.

Dos grupos, dos curvas paralelas



14. Síntesis y puente a métodos avanzados

Checklist del análisis de regresión

Supuesto	Herramienta	Acción si falla
Linealidad	Res. vs. Fitted	Transformar o cuadráticos
Homocedasticidad	Scale-Loc. / Breusch-P.	SE robustos / WLS
Normalidad	Q-Q / Shapiro-Wilk	Transformar / no paramétrico
Sin autocorr.	Durbin-Watson	Series de tiempo
No multicolineal.	VIF	Eliminar / combinar / regularizar
Sin influencias	Cook / Leverage	Investigar y reportar

Regresión lineal como base de métodos avanzados

Cuando Y no es continua:

- Y binaria $\rightarrow$ Reg. logística (AAD Ses. 5)
- Y de conteo $\rightarrow$ Poisson / NegBin
- Y categórica $\rightarrow$ Reg. multinomial

Relaciones no lineales:

- Splines / GAM (AAD Ses. 3)
- Kernel regression (AAD Ses. 4)
- Redes neuronales

Muchos predictores o multicolinealidad

- **Ridge / LASSO**: penalizan los coeficientes grandes (fórmula en el Anexo C).
- **Regresión en Componentes Principales (PCR)**: usa los CPs de la Sesión 4 como predictores. Conecta directamente ACP con regresión.

Resumen del módulo: mapa completo

Regresión lineal: el mapa completo

1. **Identificación**: relación lineal, gráfico de dispersión.
2. **Estimación**: MCO minimiza SC_E, maximiza R^2 respecto a M2.
3. **Bondad de ajuste**: R^2, R^2_{adj}, $\hat{\sigma}$.
4. **Inferencia**: prueba t individual, prueba F global.
5. **Validación**: residuales, QQ-plot, Cook, leverage.
6. **Extensión**: regresión múltiple, VIF, transformaciones, categóricas.
7. **Interpretación**: modelo correlacional; causalidad requiere más.

¿Cómo reportar un modelo de regresión?

1. Describa los datos y la pregunta.
2. Reporte cada coeficiente **con su IC** y su interpretación en unidades reales.
3. Reporte R^2 ajustado y $\hat{\sigma}$.
4. Indique cómo verificó los supuestos.
5. Señale las **limitaciones**: rango de los datos, variables omitidas, causalidad.

Ejercicio 4: trabajo autónomo

Ejercicio 4 – Salarios
Con el conjunto `salarios`:

1. Ajuste `lm(log(salario) ~ exper + posgrado)` e interprete cada coeficiente.
2. Valide los supuestos con los gráficos de diagnóstico.
3. Prediga el salario de alguien con 10 años de experiencia, con y sin posgrado.

Mensaje final

Mensaje final

La regresión lineal es una **herramienta de pensamiento**, no una receta.

Cada decisión requiere juicio estadístico sustantivo.

Bibliografía

Bibliografía

1. Montgomery, D., Peck, E. A., & Vining, G. G. (2006). *Introducción al análisis de regresión lineal*. Limusa Wiley.
2. James, G. et al. (2021). *An Introduction to Statistical Learning* (2a ed.). Springer.
3. Pearl, J. & Mackenzie, D. (2018). *The Book of Why*. Basic Books. (Causalidad, variables de confusión y grafos causales.)

Anexo A: Derivación MCO

Derivación MCO — Paso 1

Minimizamos:

$$SC_E(\beta_0, \beta_1) = \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2$$

Derivando e igualando a cero:

$$\frac{\partial SC_E}{\partial \beta_0} = -2 \sum (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\frac{\partial SC_E}{\partial \beta_1} = -2 \sum x_i (y_i - \beta_0 - \beta_1 x_i) = 0$$

Sistema de **ecuaciones normales**:

$$n\hat{\beta}_0 + \hat{\beta}_1 \sum x_i = \sum y_i \qquad \hat{\beta}_0 \sum x_i + \hat{\beta}_1 \sum x_i^2 = \sum x_i y_i$$

Derivación MCO — Paso 2

De la primera ecuación: $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$.

Sustituyendo en la segunda:

$$\hat{\beta}_1 = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}} = \frac{\sum_i y_i (x_i - \bar{x})}{\sum_i (x_i - \bar{x})^2}$$

Conexión con covarianza y correlación
S_{xy} es la covarianza muestral (sin dividir por $n-1$). Además $\hat{\beta}_1 = r_{xy} \cdot s_y / s_x$: si $r_{xy} = 0$, entonces $\hat{\beta}_1 = 0$ y M2 es el mejor predictor posible.

Anexo B: Código diagnóstico completo

Verificación de supuestos: código de referencia

```r
library(car); library(lmtest); library(sandwich)

# 1. Graficos diagnostico
par(mfrow = c(2, 2)); plot(mod_cap); par(mfrow = c(1, 1))

# 2. Normalidad formal
shapiro.test(residuals(mod_cap))

# 3. Heterocedasticidad (Breusch-Pagan)
bptest(mod_cap)

# 4. Autocorrelacion (Durbin-Watson)
dwtest(mod_cap)

# 5. VIF (multicolinealidad)
vif(mod_cap)

# 6. Puntos influyentes
influencePlot(mod_cap)   # paquete car

# 7. Errores robustos si hay heterocedasticidad
coeftest(mod_cap, vcov = vcovHC(mod_cap, type = "HC3"))
```

Anexo C: Fórmulas complementarias

C1. El estadístico F

$$F = \frac{SC_M/p}{SC_E/(n-p-1)} = \frac{SC_M/gl_M}{SC_E/gl_E}$$

F es la razón entre la **varianza explicada por variable** y la **varianza residual por grado de libertad**. Bajo H_0 y con errores normales, $F \sim F_{p,\, n-p-1}$.

C2. R^2 ajustado

$$R^2_{\text{adj}} = 1 - (1 - R^2)\frac{n-1}{n-p-1}$$

Penaliza la inclusión de variables adicionales: solo sube si la nueva variable mejora el ajuste más de lo esperado por azar.

C3. Forma matricial

En notación matricial: $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$

El estimador MCO generalizado:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

siempre que $(\mathbf{X}^\top \mathbf{X})^{-1}$ exista, lo cual requiere que las columnas de $\mathbf{X}$ sean **linealmente independientes** (no multicolinealidad perfecta).

Criterio de Información de Akaike (AIC)

$$\text{AIC} = n \ln\left(\frac{SC_E}{n}\right) + 2(p+1)$$

BIC (criterio de Schwarz)

$$\text{BIC} = n \ln\left(\frac{SC_E}{n}\right) + (p+1)\ln(n)$$

C5. Regularización: Ridge y LASSO

Ridge: $\min\ SC_E + \lambda \sum_j \beta_j^2$ LASSO: $\min\ SC_E + \lambda \sum_j |\beta_j|$

El parámetro $\lambda \geq 0$ controla cuánto se encogen los coeficientes.

Anexo D: QQ-plot paso a paso

QQ-plot: ejemplo numérico con $n = 5$

La lógica en 4 pasos

1. Ordenar los residuales: $e_{(1)} < e_{(2)} < \cdots < e_{(n)}$.
2. Calcular cuantiles teóricos: $q_i = \Phi^{-1}(i/(n+1))$.
3. Formar pares: $(q_i,\ e_{(i)})$.
4. Graficar. Si los puntos siguen la diagonal $\rightarrow$ normalidad.

i	$e_{(i)}$ obs.	$q_i = \Phi^{-1}(i/6)$	¿En la diag.?
1	-1.5	-0.97	Aprox.
2	-0.4	-0.43	Sí
3	0.1	0.00	Sí
4	0.6	0.43	Sí
5	1.2	0.97	Aprox.

Anexo E: Código de generación de los datos

Simulación de los datos de rendimiento académico

```
set.seed(42); n <- 60
capacidad <- round(pmin(10, pmax(0, rnorm(n, 5.5, 1.8))), 1)
horas     <- round(pmax(0, pmin(12,
               2.5 + 0.55 * capacidad + rnorm(n, 0, 1.6))), 1)
sueno     <- round(pmax(3, pmin(10,
               9.2 - 0.28 * horas + rnorm(n, 0, 0.9))), 1)
nota      <- round(pmin(5.0, pmax(0.0,
               0.25 + 0.28 * horas + 0.38 * capacidad +
               0.07 * sueno + rnorm(n, 0, 0.38))), 1)
datos <- data.frame(nota, horas, sueno, capacidad)
head(datos, 5)
```